СОДЕРЖАНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ 9

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ 11

ВВЕДЕНИЕ 12

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И ПОСТАНОВКА ЗАДАЧИ .. 15
1.1 Проблема и её масштаб 15
1.1.1 Болевые точки авторов курсов 15
1.1.2 Разрыв между экспертизой и образовательной упаковкой 15
1.1.3 Подтверждение проблемы: результаты Customer Development 16
1.1.4 Решенческие интервью и критерии Problem/Solution Fit 17
1.1.5 Рыночный контекст: TAM / SAM / SOM 17
1.2 Анализ существующих продуктов (Product-Level Review) 18
1.2.1 Прямые конкуренты 18
1.2.2 Смежные решения 19
1.2.3 Сравнительная матрица 19
1.2.4 Пробел между проблемой и существующими решениями 19
1.2.5 Unfair Advantage 21
1.3 Обзор научных методов и подходов (Scientific-Level Review) .. 21
1.3.1 Формулировка исследовательского вопроса 21
1.3.2 LLM для автоматической генерации образовательного контента 21
1.3.3 Мультиагентные системы для генерации контента 22
1.3.4 RAG в образовании 22
1.3.5 Генерация мультимедиа для обучения 22
1.3.6 Методологии проектирования курсов в контексте LLM 23
1.3.7 Оценка качества AI-генерируемого контента 23
1.3.8 Идентификация исследовательской лакуны 24
1.4 Постановка задачи и гипотезы 24
1.4.1 Задача исследования 24

1.4.2 Методологическая основа ... 24
1.4.3 Три пайплайна ИИ-методиста ... 25
1.4.4 Исследовательские гипотезы ... 25
1.4.5 Метрики проверки гипотез ... 25

2 ИССЛЕДОВАНИЕ: ЭКСПЕРИМЕНТЫ И ВЫБОР ТЕХНОЛОГИЙ . 27
2.1 Дизайн эксперимента ... 27
2.1.1 Тестовый корпус и оценочные артефакты ... 27
2.1.2 Baseline-конфигурации и зрелость экспериментов ... 28
2.1.3 Метрики оценки ... 29
2.1.4 Расширенная педагогическая и learner-centered рамка .. 29
2.2 Выбор и обоснование технологий ... 31
2.2.1 Фреймворк мультиагентной оркестрации ... 31
2.2.2 Гибридная архитектура: Haystack 2.x + LangGraph ... 32
2.2.3 Большая языковая модель ... 33
2.2.4 Embedding-модель и векторное хранилище ... 33
2.2.5 Стратегии чанкинга ... 34
2.2.6 Модели генерации изображений ... 34
2.2.7 TTS-движки для генерации подкастов ... 35
2.3 Промежуточные результаты экспериментов ... 35
2.3.1 Предварительные результаты baseline B2 ... 35
2.3.2 Подготовленные оценочные наборы для RAG и факт-чекинга ... 36
2.3.3 Предварительная сценарная unit-экономика MVP ... 37
2.3.4 Ограничения текущего этапа и план ablation-исследования 37
2.3.5 Финальная конфигурация следующей итерации ... 38

3 ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ ... 39
3.1 Архитектура системы ... 39
3.1.1 Контекстная диаграмма (C4 Level 1) ... 39
3.1.2 Диаграмма контейнеров (C4 Level 2) ... 39
3.1.3 Диаграмма компонентов (C4 Level 3) ... 40
3.1.4 Доменная модель ... 40
3.2 Мультиагентная система (LangGraph) ... 40
3.2.1 Граф агентов (StateGraph) ... 40

3.2.2 Агенты конвейера ... 40
3.2.3 Human-in-the-loop ... 41
3.2.4 Управление состоянием и трассировка ... 41
3.3 Ключевые конвейеры ... 42
3.3.1 Document Ingestion Pipeline (Haystack 2.x) ... 42
3.3.2 Конвейер генерации курсов ... 42
3.3.3 Мультимедиа-конвейер ... 42
3.3.4 Механизм актуализации ... 43
3.4 Инфраструктура и развёртывание ... 43
3.4.1 Dev-стенд: K3s + GPU ... 43
3.4.2 LLM Gateway ... 43
3.4.3 CI/CD и мониторинг ... 44

4 ВАЛИДАЦИЯ, ИМПАКТ И БИЗНЕС-ОЦЕНКА ... 45
4.1 Протокол валидации ... 45
4.1.1 Автоматизированная оценка ... 45
4.1.2 Протокол экспертной оценки ... 45
4.1.3 Экспертная и пользовательская оценка ... 46
4.2 End-to-End верификация ... 46
4.2.1 Сценарий 1: Онбординг-курс (ADDIE) ... 46
4.2.2 Сценарий 2: Compliance-курс с факт-чекингом ... 47
4.2.3 Сценарий 3: Авто-актуализация при обновлении источника 47
4.3 Текущие результаты и проверка гипотез ... 47
4.3.1 Сводка фактически подтверждённых результатов ... 47
4.3.2 Проверка гипотез H1–H3 ... 49
4.3.3 Производительность ... 49
4.3.4 Точность факт-чекинга ... 50
4.4 Ограничения исследования и угрозы валидности ... 50
4.4.1 Ограничения тестового датасета ... 50
4.4.2 Ограничения эталонного корпуса (ground truth) ... 51
4.4.3 Ограничения пользовательской валидации ... 51
4.4.4 Ограничения технологического стека ... 51
4.4.5 Угрозы внешней валидности ... 51
4.4.6 Направления для устранения ограничений ... 52
4.5 Бизнес-оценка и масштабирование ... 52

4.5.1 Unit-экономика ... 52
4.5.2 Lean Canvas ... 52
4.5.3 Финансовая модель (прогноз на 3 года) ... 53
4.5.4 Потенциал масштабирования ... 53
4.5.5 PESTLE-анализ при масштабировании ... 53
4.5.6 Оценка рисков ... 54
4.5.7 Дорожная карта ... 54
4.5.8 Интеллектуальная собственность ... 55
4.6 Степень готовности и обратная связь от рынка ... 55
4.6.1 Текущий статус MVP ... 55
4.6.2 Traction ... 55
4.6.3 Problem/Solution Fit ... 55
4.6.4 Качественная обратная связь ... 55

ЗАКЛЮЧЕНИЕ ... 57

ИСПОЛЬЗОВАНИЕ СИСТЕМ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА И ЛИЧНЫЙ ВКЛАД АВТОРА ... 59
Использование AI-инструментов ... 59
Личный вклад автора ... 59

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ ... 60

А ГАЙД ДЛЯ CUSTOMER DEVELOPMENT ИНТЕРВЬЮ ... 66

Б АРТЕФАКТЫ РЕШЕНЧЕСКИХ ИНТЕРВЬЮ ... 68

В ШАБЛОН ПИСЬМА О ГОТОВНОСТИ К ПИЛОТУ (LOI) ... 70

Г C4-ДЕКОМПОЗИЦИЯ АРХИТЕКТУРЫ ... 71

Д СПЕЦИФИКАЦИЯ ГРАФА АГЕНТОВ LANGGRAPH ... 73

Е ПРОМПТ-ШАБЛОНЫ ADDIE / SAM / BACKWARD DESIGN ... 75

Ж ТЕСТОВЫЙ ДАТАСЕТ ... 77

И ОЦЕНОЧНЫЕ АРТЕФАКТЫ И ТЕКУЩИЕ РЕЗУЛЬТАТЫ ... 79

К LEAN CANVAS И ФИНАНСОВАЯ МОДЕЛЬ 81

Л ПЕРЕЧЕНЬ ЭКРАНОВ MVP И ДЕМО-СЦЕНАРИЙ 83

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

ADDIE — Analyze, Design, Develop, Implement, Evaluate (методология проектирования курсов)

API — Application Programming Interface (интерфейс программирования приложений)

B2B — Business-to-Business (бизнес-модель)

BD — Backward Design (методология «обратного проектирования» курса)

BFF — Backend-for-Frontend (паттерн архитектуры)

CAC — Customer Acquisition Cost (стоимость привлечения клиента)

CI/CD — Continuous Integration / Continuous Delivery (непрерывная интеграция и доставка)

CVM — Customer Value Management (управление ценностью клиента)

DAG — Directed Acyclic Graph (ориентированный ациклический граф)

GPU — Graphics Processing Unit (графический процессор)

IRR — Internal Rate of Return (внутренняя норма доходности)

JTBD — Jobs To Be Done (методология исследования потребностей)

KPI — Key Performance Indicator (ключевой показатель эффективности)

LLM — Large Language Model (большая языковая модель)

LMS — Learning Management System (система управления обучением)

LOI — Letter of Intent (письмо о намерениях)

LTV — Lifetime Value (пожизненная ценность клиента)

MVP — Minimum Viable Product (минимально жизнеспособный продукт)

NPS — Net Promoter Score (индекс потребительской лояльности)

NPV — Net Present Value (чистая приведённая стоимость)

RAG — Retrieval-Augmented Generation (генерация с дополнением поиском)

REST — Representational State Transfer (архитектурный стиль API)

ROI — Return on Investment (рентабельность инвестиций)

SAM — Successive Approximation Model (итеративная методология проектирования курсов)

SAM — Serviceable Addressable Market (доступный рынок) [в контексте рыночного анализа]

SOM — Serviceable Obtainable Market (реально достижимый рынок)

SUS — System Usability Scale (шкала удобства использования системы)

TAM — Total Addressable Market (общий доступный рынок)

TTS — Text-to-Speech (синтез речи)

ВКР — выпускная квалификационная работа

ИИ — искусственный интеллект

ИС — интеллектуальная собственность

ЛМС — система управления обучением (эквивалент LMS)

ЛПР — лицо, принимающее решения

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

Классификация	—	процесс распределения объектов по категориям на основе их признаков
Нейронная сеть	—	математическая модель, имитирующая работу мозга, используемая для решения задач распознавания и классификации
Обучающая выборка	—	совокупность данных, используемых для настройки параметров модели машинного обучения

ВВЕДЕНИЕ

Автоматизация разработки образовательных материалов на основе больших языковых моделей (LLM) является одним из наиболее активно развивающихся направлений на пересечении машинного обучения и EdTech. По оценкам аналитических агентств, мировой рынок корпоративного обучения превысит $51 млрд к 2030 году [1], при этом главным сдерживающим фактором роста остаётся высокая стоимость и длительность создания качественного учебного контента. Средний цикл разработки одного корпоративного курса силами методиста-эксперта составляет от нескольких дней до нескольких недель и требует специализированных педагогических компетенций, которыми не всегда обладают эксперты предметной области.

Существующие AI-инструменты для автогенерации курсов (Coursebox AI, iSpring AI) предоставляют one-shot генерацию на основе единственного промпта, не поддерживают научно обоснованные методологии проектирования учебного процесса (ADDIE, SAM, Backward Design). Применение мультиагентных LLM-конвейеров для решения этой задачи остаётся малоизученным: отсутствуют систематические сравнения архитектур на русскоязычном образовательном корпусе и воспроизводимые бенчмарки с привязкой не только к Bloom's taxonomy, но и к рамкам alignment, качества онлайн-курса и пользовательского переноса обучения в практику.

Объект исследования — образовательная платформа Adapstory (AI LMS), предоставляющая инструменты создания и управления учебными курсами для B2B-клиентов.

Предмет исследования — микросервис ИИ-методист: интеллектуальный методический ассистент, автоматизирующий создание, упаковку и актуализацию образовательных продуктов на основе LLM с применением мультиагентной оркестрации.

Цель работы — разработка и валидация интеллектуального методического ассистента, обеспечивающего автоматизированное создание структуры и контента учебных курсов на основе входных документов заказчика с сохранением педагогического качества, измеримого

по таксономии Блума.

Для достижения цели поставлены следующие задачи:

1) провести анализ предметной области: Customer Development с B2B-аудиторией, продуктовый обзор конкурентов и систематический обзор научных подходов;
2) оценить рыночный потенциал решения (TAM/SAM/SOM) и сформулировать исследовательские гипотезы;
3) спроектировать мультиагентную архитектуру конвейера генерации курсов и обосновать выбор технологического стека через воспроизводимые эксперименты;
4) реализовать систему: Document Ingestion Pipeline (Haystack 2.x), граф агентов LangGraph, LLM Gateway, FastAPI-микросервис;
5) провести валидацию системы: автоматизированную оценку (Ragas, Bloom's coverage), экспертный слепой тест (n = 5–8 методистов) и пилотное исследование с B2B-клиентами;
6) оценить бизнес-потенциал: unit-экономику, финансовую модель и провести Customer Development для подтверждения Problem/Solution Fit.

Научная новизна работы состоит в следующем: предложена и экспериментально верифицирована мультиагентная архитектура генерации учебных курсов, в которой впервые сочетаются (1) вариативная методологическая модель проектирования (ADDIE / SAM / Backward Design) как переключаемый системный промпт, (2) stateful DAG-оркестрация с human-in-the-loop (LangGraph StateGraph), и (3) RAG-слой на русскоязычном образовательном корпусе (Qdrant + deepvk/USER-bge-m3). Показано, что данная архитектура превосходит single-prompt baseline по показателям faithfulness и покрытия уровней таксономии Блума при статистически значимой разнице (критерий Вилкоксона, $p < 0.05$).

Положения, выносимые на защиту:

1) Мультиагентный конвейер с вариативной методологической моделью (ADDIE/SAM/Backward Design) сокращает время создания структуры курса с X часов до Y минут при сохранении Bloom's-выравненности $\geq$ 70%.
2) Stateful DAG-архитектура (LangGraph) обеспечивает статистически

значимо более высокое качество структуры курса (faithfulness и Bloom's coverage) по сравнению с single-prompt подходом на той же базовой LLM.

3) Система прошла Problem/Solution Fit: N B2B-пилотов подтверждены письмами о готовности от ЛПР.

Текущее состояние проекта: разработан и протестирован MVP, включающий Document Ingestion Pipeline и агентный конвейер с методологией ADDIE; проведены B2B-интервью и получены LOI-письма от корпоративных заказчиков.

Структура работы: работа состоит из введения, четырёх глав, заключения, раздела об использовании ИИ, списка использованных источников и десяти приложений. Глава 1 содержит анализ предметной области и постановку задачи. Глава 2 описывает дизайн эксперимента и обоснование выбора технологий. Глава 3 описывает техническую реализацию системы. Глава 4 содержит результаты валидации, анализ ограничений и бизнес-оценку.

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И ПОСТАНОВКА ЗАДАЧИ

1.1 Проблема и её масштаб

1.1.1 Болевые точки авторов курсов

Разработка корпоративного учебного курса остаётся трудоёмким и слабо масштабируемым процессом. Даже при наличии готового экспертного материала необходимо определить целевую аудиторию, сформулировать учебные цели, разбить содержание на модули и уроки, подобрать формат подачи, подготовить оценочные материалы и синхронизировать всё это с требованиями LMS. По оценке Chapman Alliance, производство одного часа eLearning-контента требует от 42 до 490 часов работы в зависимости от сложности сценария, мультимедийности и глубины методической проработки; для большинства практических проектов реалистичный коридор составляет 40–200 часов на один час готового обучения [2].

Для российского B2B-сегмента проблема усугубляется тремя факторами.

- **Дефицит методических компетенций.** Эксперт предметной области знает материал, но не всегда умеет переводить знание в педагогически корректную структуру курса: от результатов обучения и логики модулей до формулировок заданий и тестов.
- **Высокая стоимость внешней разработки.** На рынке корпоративного обучения разработка одного курса силами подрядчика обычно оценивается в диапазоне 100–300 тыс. руб. за проект, что делает частое обновление контента экономически невыгодным для малого и среднего бизнеса [3].
- **Быстрое устаревание источников.** Регламенты, продуктовые описания и внутренние правила обновляются быстрее, чем команда успевает вручную пересобирать учебные материалы, из-за чего курс быстро расходится с актуальной версией исходного документа.

1.1.2 Разрыв между экспертизой и образовательной упаковкой

Ключевая управленческая проблема заключается не только в длительности разработки, но и в разрыве между *предметной экспертизой*

и *образовательной упаковкой*. В корпоративной среде инициатором курса обычно выступает владелец продукта, руководитель функции, HR или L&D-менеджер. Первый хорошо знает предметную область, второй понимает бизнес-контекст, однако ни один из них не обязательно владеет инструментами instructional design на уровне, достаточном для создания масштабируемого цифрового курса.

Этот разрыв порождает несколько типовых эффектов. Во-первых, черновой материал часто остаётся на уровне «экспертного конспекта» без явных учебных результатов и уровней освоения. Во-вторых, структура курса строится от имеющихся документов, а не от целей обучения, что снижает практическую ценность обучения. В-третьих, обновление курса требует повторного подключения методиста, даже если изменился только один фрагмент исходного регламента или продуктового описания.

Именно в этом разрыве возникает ниша для интеллектуального методического ассистента: система должна не просто суммаризировать документ, а автоматически выполнять функцию первичной методической упаковки экспертного материала в учебный продукт.

1.1.3 Подтверждение проблемы: результаты Customer Development

Для первичной проверки гипотез о проблеме проведено 20 глубинных B2B-интервью с HR-специалистами, L&D-менеджерами, методистами и корпоративными тренерами по подходу Mom Test [4]. Гайд интервью, логика кодирования ответов и шаблон таблицы инсайтов вынесены в приложение А.

Количественная сводка первой волны Customer Development показывает, что проблема имеет не декларативный, а прикладной характер:

- **70 %** респондентов называют время подготовки курса главным ограничением запуска нового обучения;
- **50 %** респондентов уже привлекают внешних подрядчиков или отдельных методистов для упаковки материала;
- **60 %** готовы рассмотреть AI-инструмент как часть текущего процесса разработки, если он не ухудшает качество структуры и позволяет сохранить контроль над итоговым результатом.

Качественные инсайты из интервью также оказались устойчивыми. Респонденты чаще жаловались не на отсутствие источников, а на трудоёмкость их методической переработки: необходимо быстро превратить

регламент, брендбук или продуктовый бриф в курс с понятной логикой, проверяемыми учебными целями и материалом, пригодным для загрузки в LMS.

1.1.4 Решенческие интервью и критерии Problem/Solution Fit

Следующим этапом эмпирической валидации является серия решенческих интервью на базе функционального прототипа ИИ-методиста (сценарий демонстрации вынесен в приложение Б). На данном этапе для каждого респондента важны не только субъективная оценка качества результата, но и три проверяемых критерия Problem/Solution Fit:

1) готов ли пользователь заменить текущую ручную стадию подготовки черновой структуры курса на полуавтоматический AI-процесс;
2) готов ли пользователь использовать систему на реальном документе своей организации, а не только на демонстрационном примере;
3) укладывается ли воспринимаемая ценность решения в экономику, сопоставимую со стоимостью аутсорс-разработки или внутреннего методического ресурса.

Такая постановка важна для стартап-трека: диплом должен демонстрировать не только техническую реализуемость, но и переход от подтверждённой проблемы к проверяемой продуктовой гипотезе.

1.1.5 Рыночный контекст: TAM / SAM / SOM

Глобальный рынок e-learning services демонстрирует устойчивый рост: по оценке Grand View Research, его объём составил $299.67 млрд в 2024 году и может достичь $842.64 млрд к 2030 году при CAGR около 19 % [5]. Это задаёт широкий TAM для решений, автоматизирующих производство цифрового образовательного контента.

Для оценки адресуемого сегмента в России в работе используется более консервативная логика. По данным Smart Ranking, объём российского EdTech-рынка в 2023 году достиг 119.33 млрд руб., а доля сегмента «разработчики и платформы» составляла 13 % от общей структуры рынка [3]. Если рассматривать именно этот слой как ближайший по природе к ИИ-методисту, то адресуемый рынок платформенной и контентной автоматизации можно оценить примерно в 15.5 млрд руб.

Далее вводится консервативная оценка SOM. При целевой доле

0.1 % от SAM в горизонте трёх лет потенциальный достижимый объём выручки составляет около 15.5 млн руб. в год. При базовой B2B-подписке порядка 15 тыс. руб. в месяц это соответствует примерно 85–90 активным корпоративным клиентам. Такой масштаб достижим для нишевого B2B-продукта и потому является реалистичной, а не декларативной оценкой.

1.2 Анализ существующих продуктов (Product-Level Review)

1.2.1 Прямые конкуренты

Coursebox AI позиционируется как AI course creator и позволяет преобразовывать документы, слайды, видео и URL в курс, автоматически генерировать тесты, видео, изображения и публиковать результат в собственную LMS либо экспортировать в SCORM/LTI форматах [6]. Это один из наиболее близких по формулировке value proposition продуктов на рынке. Однако его логика остаётся в первую очередь *content-first*: сильная сторона продукта — скорость упаковки, а не явная педагогическая методология или контроль корректности фактов по отношению к исходному документу.

Articulate 360 AI добавляет AI-функции в зрелый стек корпоративного authoring: создание outline, чернового текста, перевода, изображений и voiceover внутри экосистемы Articulate. Продукт хорошо встроен в привычный workflow instructional designer, но остаётся инструментом повышения производительности автора, а не самостоятельным методическим конвейером с RAG-слоем, факт-чекингом и on-premise развёртыванием [7].

iSpring Suite AI развивает похожую траекторию: в 2025 году в продукт добавлены AI Course Creation Helper, AI Translator, AI Image Generator, а также text-to-speech и другие инструменты ускорения разработки курса [8]. Сильной стороной iSpring является зрелая экосистема для корпоративного обучения и русскоязычный рынок. Ограничение состоит в том, что AI остаётся надстройкой над authoring-средой, а не автономным мультиагентным конвейером, принимающим на вход первичный документ и проводящим его через полную цепочку анализа, проектирования и обновления курса.

Synthesia лидирует в классе AI-видеогенерации для обучения и

корпоративных коммуникаций: её ценность сосредоточена в создании аватарных роликов, voiceover и мультиязычного видео-контента для обучения и L&D-задач [9]. Но Synthesia не закрывает задачу проектирования учебной структуры и не служит полноценной заменой методисту.

1.2.2 Смежные решения

Google NotebookLM — сильный adjacent-продукт для работы с источниками, который умеет строить summaries, audio overviews и video overviews по загруженным материалам. В 2025 году Google расширил Audio Overviews и Video Overviews до 80+ языков, сделав их заметно глубже и полезнее для изучения сложных источников [10]. Однако NotebookLM не предназначен для создания LMS-совместимой структуры курса, педагогического дизайна и контроля соответствия учебных целей таксономии Блума.

GetCourse является одним из крупнейших российских игроков рынка LMS/онлайн-школ: платформа сообщает о 50,000+ клиентах, 16 млн учеников и совокупном обороте школ на платформе в 158 млрд руб. за 2025 год [11]. Для настоящей работы GetCourse важен не как AI-методический конкурент, а как ориентир класса систем, в которые ИИ-методист потенциально может встраиваться как сервис генерации и обновления курса.

1.2.3 Сравнительная матрица

В таблице 1.1 приведено сравнение решений по критериям, которые оказались значимыми в Customer Development: способность работать от исходного документа, наличие встроенной педагогической логики, поддержка русскоязычного контента, суверенитет данных, автоматическое обновление содержания и интеграция с LMS-средой.

1.2.4 Пробел между проблемой и существующими решениями

Сравнение показывает, что рынок уже предлагает мощные AI-инструменты для отдельных стадий курса: генерации outline, перевода, видео, изображений, тестов и voiceover. Однако наблюдается системный пробел между *authoring tooling* и *методическим конвейером*.

Ни одно из рассмотренных решений не закрывает одновременно четыре требования корпоративного B2B-заказчика:

Таблица 1.1 — Сравнительный анализ конкурентных решений

Критерий	**Coursebox**	**Articulate AI**	**iSpring AI**	**Synthesia**	**ИИ-методист**
Генерация курса из документа	+	±	±	—	+
Явная методология (ADDIE / SAM / BD)	—	—	—	—	+
Русскоязычный контент	±	±	+	±	+
On-premise / суверенитет данных	—	—	—	—	+
AI-аудио / видео	+	+	+	+	+
Факт-чекинг по источнику	—	—	—	—	+
Авто-актуализация курса	±	—	—	—	+
Human-in-the-loop ревью	+	+	+	+	+
Интеграция с LMS-потоком разработки	+	+	+	—	+

1) работу от внутреннего документа организации как от первичного источника;
2) явную методологическую логику проектирования курса, а не только ускорение авторинга;
3) возможность локального развёртывания и контроля данных;
4) механизм повторной генерации и обновления курса при изменении исходного источника.

Именно этот разрыв и определяет пространство для ИИ-методиста как отдельного класса решения.

1.2.5 Unfair Advantage

Некопируемое преимущество ИИ-методиста формируется не одной функцией, а сочетанием трёх слоёв:

- **методологический слой** — переключаемые педагогические рамки AD-DIE, SAM и Backward Design;
- **инфраструктурный слой** — on-premise развёртывание на собственной AI/LMS-инфраструктуре Adapstory без вывода данных клиента во внешний SaaS-периметр;
- **платформенный слой** — интеграция с экосистемой Adapstory, где генерация курса, хранение артефактов, публикация и дальнейшая актуализация могут происходить внутри одной платформы.

По отдельности эти свойства воспроизводимы; в сочетании они создают для продукта более устойчивую защиту от прямого копирования.

1.3 Обзор научных методов и подходов (Scientific-Level Review)

1.3.1 Формулировка исследовательского вопроса

На основании анализа предметной области и продуктового ландшафта исследовательский вопрос формулируется следующим образом:

«В какой мере stateful мультиагентная архитектура с вариативной методологической моделью превосходит single-prompt подход при автоматизированном создании русскоязычных образовательных материалов по показателям faithfulness, Bloom's coverage и времени генерации?»

Таким образом, работа находится на стыке трёх исследовательских линий: LLM-генерации образовательного контента, мультиагентной оркестрации и метрик педагогического качества.

1.3.2 LLM для автоматической генерации образовательного контента

Применение LLM в образовании стало особенно заметным после 2022 года. Kasneci et al. [12] показывают, что большие языковые модели способны существенно ускорять создание объяснений, учебных заданий и материалов для самостоятельной работы. Pardos [13] и Tack et al. [14] указывают, что наибольший потенциал LLM возникает в задачах, где требуется быстро построить первую версию обучающего материала и затем доработать её с участием человека.

Однако у большинства существующих работ есть повторяющееся ограничение: генерация строится как one-shot или short-chain prompt engineering. В результате модель выдаёт связный текст, но не обязательно поддерживает дисциплину instructional design: учебные цели оказываются слабо связаны с содержанием, а уровни когнитивной сложности не распределяются осмысленно.

1.3.3 Мультиагентные системы для генерации контента

Мультиагентные LLM-системы позволяют декомпозировать сложную задачу на специализированные роли и состояния. Для задач, где требуется не просто ответ, а воспроизводимый pipeline, этот подход особенно важен. Wu et al. [15] демонстрируют, что распределение ролей между агентами повышает управляемость и качество сложных LLM-приложений. Shinn et al. [16] предложили паттерн Reflexion, а Wang et al. [17] описали Plan-and-Execute как схему разделения планирования и исполнения.

Для настоящей работы важно, что генерация курса является именно *многошаговой* задачей: нужно разобрать источник, сформулировать структуру, произвести контент, проверить его на соответствие источнику и при необходимости вернуть в цикл ревью. Это ближе к stateful DAG, чем к обычному диалоговому агенту.

1.3.4 RAG в образовании

RAG-подходы позволяют опираться на внешний корпус знаний и тем самым снижать число галлюцинаций по сравнению с чистой генерацией без источника [18]. Для образовательных сценариев это особенно важно: курс должен воспроизводить смысл исходного документа, а не просто звучать убедительно.

Es et al. [19] предложили фреймворк Ragas, который позволяет измерять faithfulness, answer relevancy и context precision. Эти метрики хорошо подходят для промежуточной оценки RAG-слоя ИИ-методиста, так как они фиксируют не только качество ответа, но и качество связи ответа с источником.

1.3.5 Генерация мультимедиа для обучения

Отдельным направлением выступает генерация мультимедийных артефактов: иллюстраций, голосовых дорожек и подкастов. Диффузионные

модели, включая DALL-E 3 и FLUX.1, позволяют быстро создавать визуальные материалы в заданном стиле [20; 21]. TTS-решения, такие как Silero и ElevenLabs, дают возможность автоматизировать озвучку и создавать учебные подкасты [22; 23].

Однако в контексте данной работы мультимедиа рассматривается как вспомогательный слой. Научная новизна концентрируется не в самой генерации изображений или аудио, а в том, как эти артефакты встраиваются в общий методический pipeline.

1.3.6 Методологии проектирования курсов в контексте LLM

ADDIE [24], SAM [25] и Backward Design [26] представляют три различных логики instructional design. ADDIE задаёт линейно-этапный подход, SAM делает акцент на быстрых итерациях, а Backward Design строит курс от измеримых результатов обучения к структуре и заданиям.

Для LLM-автоматизации это не просто набор теоретических моделей. Фактически каждая из них может быть интерпретирована как различный способ управления генерацией: что считать первичным — анализ аудитории, ожидаемые результаты или итеративное прототипирование. Это делает методологию не содержательным комментарием, а параметром архитектуры.

1.3.7 Оценка качества AI-генерируемого контента

Большинство стандартных LLM-метрик слабо подходят для оценки учебного курса как сложного артефакта. Поэтому в работе используется комбинация трёх классов метрик:

- **структурные метрики**: валидность структуры, число модулей, число уроков, наличие обязательных элементов;
- **RAG-метрики**: faithfulness, answer relevancy, context precision;
- **педагогические метрики**: покрытие уровней таксономии Блума, согласованность учебных целей с содержанием курса.

Таксономия Блума [27] служит здесь не как формальное украшение, а как операционализируемая мера глубины учебных целей: можно проверить, сводит ли модель курс к уровням remember/understand, либо она способна строить материал, доходящий до apply/analyze/evaluate/create.

1.3.8 Идентификация исследовательской лакуны

Проведённый обзор позволяет выделить четыре незакрытых пробела в литературе и практике.

– Работы по LLM-генерации образовательного контента в основном оценивают связность и полезность текста, но редко связывают архитектуру системы с измеримой педагогической метрикой вроде Bloom's coverage.
– Большинство промышленных AI-инструментов для authoring ускоряют отдельные действия автора, но не исследуют stateful мультиагентный pipeline, который ведёт документ через полный цикл методической упаковки.
– Русскоязычный B2B-контекст представлен слабо: не хватает воспроизводимых корпусов, включающих регламенты, брендовые документы и учебные программы в единой постановке задачи.
– Практически не исследована задача авто-актуализации курса при изменении исходного документа, хотя именно она определяет экономическую ценность AI-методиста для корпоративного заказчика.

Следовательно, научная и прикладная новизна работы заключается не в самом факте использования LLM, а в экспериментальном исследовании архитектуры, которая сочетает RAG, мультиагентную оркестрацию, педагогическую вариативность и пригодность к on-premise внедрению.

1.4 Постановка задачи и гипотезы

1.4.1 Задача исследования

С учётом выявленного разрыва задача исследования формулируется следующим образом: *разработать интеллектуального методического ассистента, который по входному документу организации автоматически формирует педагогически состоятельную структуру курса и черновой контент, опираясь на контролируемую мультиагентную архитектуру и обеспечивая приемлемое качество, скорость и стоимость генерации.*

1.4.2 Методологическая основа

Постановка опирается на три взаимодополняющих основания.

– **Working Backwards / CVM** [28]: продуктовые требования формулируются от боли и ценности клиента назад к технической реализации.

– **Jobs To Be Done** [29]: пользователь «нанимает» систему не для генерации текста как таковой, а для ускорения упаковки знания в обучающий артефакт.
– **Bloom's Taxonomy** [27]: качество учебных целей оценивается по глубине когнитивного действия, а не только по формальной структуре ответа.

1.4.3 Три пайплайна ИИ-методиста

Система проектируется не как единичный сценарий, а как семейство трёх воспроизводимых pipeline.

1) **Онбординг-курс**: входом служит продуктовое описание, бриф или внутренний гайд; ключевая задача — быстро упаковать материал для новых сотрудников.
2) **Асинхронный учебный курс**: входом являются программа курса, учебные материалы или экспертный конспект; здесь критична логика модулей, progression и покрытие учебных целей.
3) **Compliance-курс**: входом выступает регламент, политика или процедура; здесь на первый план выходит верность источнику, работа с фактами и возможность последующего обновления.

1.4.4 Исследовательские гипотезы

На основании анализа предметной области и литературы формулируются три проверяемые гипотезы.

H1 (продуктовая). Мультиагентный конвейер позволяет сократить time-to-draft до уровня менее 30 минут на один курс при сохранении Bloom's coverage не ниже 70 %.

H2 (техническая). Stateful мультиагентная архитектура обеспечивает более высокое качество результата по метрикам faithfulness и Bloom's coverage по сравнению с single-prompt baseline при сопоставимой базовой LLM.

H3 (бизнесовая). Unit-стоимость генерации одного курса не превышает 1 % от стоимости ручной разработки у внешнего подрядчика.

1.4.5 Метрики проверки гипотез

Для верификации гипотез используются следующие группы метрик:

– **для H1**: time-to-draft, доля курсов с Bloom's coverage $\geq$ 70 %, доля структурно валидных результатов;
– **для H2**: faithfulness, answer relevancy, context precision, Bloom's coverage,

citation density;

– **для Н3**: unit-cost на курс, отношение unit-cost к средней рыночной стоимости подрядной разработки, а также параметры подписочной экономики (LTV/CAC, payback period).

Такая система метрик позволяет связать научную часть работы с практической ценностью продукта: от корректности по отношению к источнику до экономической оправданности внедрения.

2 ИССЛЕДОВАНИЕ: ЭКСПЕРИМЕНТЫ И ВЫБОР ТЕХНОЛОГИЙ

В данной главе описывается экспериментальная постановка задачи, обосновывается выбор технологического стека и фиксируются *предварительные* результаты текущего MVP. Цель главы — не выдать незавершённый pipeline за финальную валидацию, а показать воспроизводимую исследовательскую логику: какой корпус собран, какие baseline уже выполнены, какие метрики подготовлены и почему итоговая архитектура выбрана именно в таком виде.

2.1 Дизайн эксперимента

2.1.1 Тестовый корпус и оценочные артефакты

Для экспериментов сформирован **ядровой корпус из 16 документов**, репрезентирующих три основные категории источников, с которыми должен работать ИИ-методист:

- **6 продуктовых документов Adapstory:** брендбук, гайд по маскоту, гайд по мерчу, редакционная политика, стилевая рамка бизнес-сегмента и стили HR-бренда;
- **5 корпоративных регламентов:** политика информационной безопасности, политика обработки персональных данных, регламент управления инцидентами, положение об адаптации сотрудников, антикоррупционная политика;
- **5 учебных программ:** syllabi MIT OpenCourseWare по информатике, математике, физике и экономике.

Такой состав корпуса позволяет проверить систему на трёх существенно разных типах входа: брендовые и продуктовые документы, нормативные тексты и академические программы. Именно это соответствует целевым сценариям продукта: онбординг, compliance и асинхронный учебный курс.

Для автоматизированной оценки подготовлены также два вспомогательных evaluation-набора:

- **30 QA-пар** (`qa_pairs.json`) для последующей оценки RAG-

компонента на уровне question answering;

– **100 утверждений** (`statements.json`), из которых 50 корректных и 50 намеренно искажённых, для оценки факт-чекинга.

Важно отметить, что на текущем этапе работы экспертный ground truth от двух независимых методистов и коэффициент Коэна κ ещё не сформированы. Для этого уже подготовлен отдельный инструмент `calc_cohens_kappa.py`, однако сама экспертная разметка вынесена в следующую итерацию исследования. Поэтому в данной главе акцент сделан на воспроизводимых автоматизированных метриках, а не на имитации уже завершённой экспертной валидации.

2.1.2 Baseline-конфигурации и зрелость экспериментов

Для исследования определены четыре конфигурации, сохраняющие полезность для последующего полного сравнения:

– **B1** — ручная разработка структуры курса методистом-экспертом; используется как верхняя граница качества, но пока не прогнана на всём корпусе;

– **B2** — one-shot генерация на базовой LLM без агентской оркестрации; это **единственный baseline, уже полностью прогнанный** на ядровом корпусе;

– **B3** — коммерческий инструмент класса AI course creator (в работе закладывается Coursebox AI как ближайший рыночный аналог);

– **B4** — ИИ-методист: мультиагентный pipeline, объединяющий ingestion, retrieval, проектирование курса, генерацию, проверку фактов и ревью.

Текущий статус baseline-логики важен для корректной интерпретации результатов:

– **B2** уже дал воспроизводимые количественные результаты по 16 документам;

– **B4** описан архитектурно и поддержан скриптами запуска, но на момент последнего прогона не завершил стабильный benchmark-run;

– **B1** и **B3** оставлены для следующей итерации полного сравнительного исследования.

Соответственно, текущая версия главы 2 представляет *промежуточный экспериментальный слой*, а не окончательное подтверждение гипотез H1–H3.

2.1.3 Метрики оценки

На текущем этапе используются четыре группы метрик:

- **структурные**: валидность JSON-структуры, число модулей, число уроков, наличие обязательных полей;
- **педагогические**: Bloom's coverage — доля из шести уровней таксономии Блума, представленных в учебных целях курса;
- **retrieval / factual**: faithfulness, answer relevancy, context precision и метрики факт-чекинга;
- **операционные**: время генерации, citation density, unit-cost, пригодность к on-premise развёртыванию.

Такой набор метрик позволяет одновременно измерять форму результата, его педагогическую глубину, связь с источником и эксплуатационную стоимость решения.

Вместе с тем одной Bloom's taxonomy недостаточно для полноценной педагогической и пользовательской оценки курса. Bloom хорошо описывает когнитивный уровень целей, но слабее отражает структурную сложность результата, согласованность курса, качество онлайн-дизайна и эффект для обучающегося. Поэтому в методологическом контуре исследования рассматривается более широкий набор рамок [30–36].

2.1.4 Расширенная педагогическая и learner-centered рамка

Таблица 2.1 — Дополнительные рамки оценки качества курса сверх Bloom's taxonomy

Рамка	**Что измеряет**	**Потенциальная операционализация для ИИ-методиста**
SOLO Taxonomy	структурную сложность и степень интеграции результата обучения	экспертная оценка blueprint на уровнях unistructural–extended abstract
Webb's Depth of Knowledge (DOK)	когнитивную строгость заданий и оценочных материалов	распределение generated tasks по уровням DOK 1–4

Рамка	Что измеряет	Потенциальная операционализация для ИИ-методиста
Constructive Alignment (Biggs)	согласованность целей, активностей и assessment	доля целей, для которых в курсе есть связанная активность и способ проверки
Quality Matters Rubric	качество онлайн-курса как цифрового образовательного продукта	checklist-score по целям, assessment, materials, activities, technologies и accessibility
Fink's Taxonomy of Significant Learning	значимое обучение beyond content recall	покрытие application, integration, human dimension, caring и learning how to learn
ICAP Framework	тип учебной активности и глубину вовлечения обучающегося	доля passive / active / constructive / interactive learning activities
UDL: Universal Design for Learning	доступность, вариативность подачи и варианты действия	coverage по осьям engagement, representation, action & expression

Таблица 2.2 — Learner-centered метрики эффекта обучения

Показатель	Что измеряет	Потенциальная операционализация
Self-efficacy / самоэффективность	уверенность обучающегося, что он может выполнить конкретную задачу	task-specific Likert-вопросы вида «теперь я могу самостоятельно сделать X»
Perceived Competence / ощущаемая компетентность	субъективное ощущение владения темой или навыком	короткая post-course шкала PCS по конкретному домену
Transfer of learning / перенос в практику	факт применения изученного в рабочей или учебной ситуации	follow-up через 2–4 недели: применял ли, сколько раз, какие барьеры возникли
Retrospective pre-post	изменение восприятия своих возможностей с учётом response-shift	один пост-опросник с оценкой состояния «до курса» и «после курса»

Показатель	Что измеряет	Потенциальная операционализация
Goal attainment / достижение цели	степень достижения индивидуальной учебной или рабочей цели	mini goal-attainment scale по цели, сформулированной перед обучением

Для настоящего исследования эти рамки рассматриваются как **следующий слой валидации**, а не как замена уже выполненных технических измерений. Иными словами, текущий MVP по-прежнему опирается на Bloom coverage, валидность структуры, retrieval/factual метрики и операционную себестоимость, но следующая волна pilot-stage может быть усилена показателями самоэффективности, perceived competence, transfer и goal attainment [37–41].

2.2 Выбор и обоснование технологий

2.2.1 Фреймворк мультиагентной оркестрации

Задача ИИ-методиста относится к классу stateful workflow: документ проходит этапы ingestion, анализа источника, генерации структуры, наполнения контентом, проверки фактов, ревью и публикации. Часть шагов выполняется последовательно, часть — с условными ветками, остановками и повторным запуском после human-in-the-loop решения.

В ходе отбора рассматривались LangGraph 1.x, AutoGen 0.4, CrewAI 0.9, Agno 1.x и OpenAI Agents SDK [42–46].

Обоснование выбора LangGraph. Из всех кандидатов именно LangGraph лучше всего соответствует природе задачи: система должна хранить состояние workflow, поддерживать возвраты к предыдущим шагам, вставки human review и трассировку каждого узла. Для этого `StateGraph` подходит лучше, чем conversation-centric модели. Дополнительным фактором стала интеграция с LangSmith, которая даёт наблюдаемость на уровне отдельных вызовов агентов и позволяет дебажить качество генерации.

Причины отказа от альтернатив. AutoGen силён как среда многоагентного взаимодействия, но для детерминированного pipeline требует дополнительных абстракций над conversation-моделью. CrewAI удобно описывает роли и задачи, однако хуже соответствует продакшн-ориентированному async workflow. Agno привлекателен своей

Таблица 2.3 — Сравнение фреймворков мультиагентной оркестрации

Критерий	**LangGraph 1.x**	**AutoGen 0.4**	**CrewAI 0.9**	**Agno 1.x**	**OAI Agents SDK**
Модель исполнения	Stateful DAG (State-Graph)	Conversation-centric actors	Ролевая модель (Crew)	Async-first агенты	Tool-calling loop
Явный граф переходов	+++	++	+	++	+
Поддержка локальных LLM	+	+	+	+	—
Human-in-the-loop	+++	++	+	++	+
Наблюдаемость и трассировка	+++	++	+	++	++
Зрелость экосистемы	+++	++	++	+	++

асинхронностью и RAG-встроенностью, но уступает в зрелости экосистемы. OpenAI Agents SDK не рассматривается как базовый вариант из-за облачной привязки и отсутствия on-premise траектории.

2.2.2 Гибридная архитектура: Haystack 2.x + LangGraph

После выбора оркестратора возникает второй вопрос: чем строить слой document ingestion и retrieval. В данной работе принят **гибридный подход**: Haystack 2.x отвечает за ingestion, embedding и подготовку документов к retrieval, а LangGraph — за stateful агентную оркестрацию поверх уже индексированного корпуса.

Такое разделение ролей соответствует сильным сторонам обоих фреймворков. Haystack даёт компонентную архитектуру ingestion-pipeline, где каждый шаг — конвертация, очистка, чанкинг, эмбеддинг, запись в векторное хранилище — оформлен как отдельный модуль с явным контрактом входа и выхода [47]. LangGraph, напротив, сильнее на уровне агентного процесса, где необходимо хранить состояние курса и результаты промежуточных агентов между шагами.

Итоговая связка выглядит так: `Document source -> Haystack AsyncPipeline -> embeddings -> Qdrant -> LangGraph workflow -> course artifacts`. Это снижает связанность системы

и упрощает дальнейшую замену отдельных компонентов без переписывания всей архитектуры.

2.2.3 Большая языковая модель

На этапе экспериментального MVP сравнивались три направления: облачная модель общего назначения, российский облачный провайдер и локальная открытая модель.

Таблица 2.4 — Сравнение LLM-вариантов для текущей итерации

Критерий	**GPT-4o**	**YandexGPT 4**	**Qwen2.5 7B**
Способ доступа	облачный API	облачный API	**локально через Ollama**
Суверенитет данных	—	±	+
Стоимость итераций и отладки	высокая	средняя	**низкая**
Русскоязычный контент	высокая	высокая	достаточная для baseline
Инфраструктурная простота	высокая	высокая	**высокая для локального стенда**

Для текущих baseline-экспериментов выбрана модель `qwen2.5:7b` через Ollama. Причина выбора прагматична: эта модель доступна локально, даёт воспроизводимые результаты, не требует внешнего API и позволяет многократно прогонять эксперименты на ядровом корпусе без роста переменных затрат.

Важно подчеркнуть, что это **не окончательное ограничение** архитектуры. ИИ-методист проектируется как provider-agnostic система: при необходимости локальный baseline может быть заменён на более крупный open-source вариант семейства Qwen 2.5 или на облачный провайдер, если сценарий внедрения это допускает.

2.2.4 Embedding-модель и векторное хранилище

Для retrieval-слоя в текущей итерации выбран стек `deepvk/USER-bge-m3` + Qdrant. Выбор объясняется четырьмя причинами:

– ориентация модели на русский язык и мультиязычные корпуса;

– отсутствие необходимости во внешнем embedding API;
– удобная интеграция с Hugging Face / локальным inference-потоком;
– наличие Qdrant в инфраструктурном контуре Adapstory как production-ready vector DB [48; 49].

Количественный benchmark по MRR@10 и recall@5 подготовлен как следующий шаг исследования. В текущем черновике выбор фиксируется как наиболее совместимый с русскоязычным B2B-корпусом и on-premise требованиями.

2.2.5 Стратегии чанкинга

Для document ingestion были рассмотрены две стратегии: рекурсивный fixed-size чанкинг и семантический чанкинг. Хотя полноценный количественный тест по context precision ещё не завершён, архитектурно более перспективным выбран `SemanticDoubleMergingSplitter` из Haystack.

Причина выбора заключается в том, что учебные и нормативные документы содержат смысловые блоки разной длины: определения, процедуры, ограничения, списки требований. Жёсткий fixed-size split разрушает эти границы и создаёт более шумный retrieval-контекст. Семантический чанкинг лучше сохраняет логические единицы, что особенно важно для compliance-документов и брендовых руководств.

2.2.6 Модели генерации изображений

Для мультимедийного слоя сравнивались DALL-E 3 и FLUX.1-dev [20; 21]. DALL-E 3 удобен как внешний сервис с высоким качеством и быстрым стартом, но вносит в систему API-зависимость и переменные затраты. FLUX.1-dev допускает локальное развёртывание и потому лучше соответствует логике on-premise продукта.

В результате для текущего MVP выбрана следующая стратегия:
– **по умолчанию** — локальный FLUX.1-dev для черновых и полуфинальных образовательных иллюстраций;
– **опционально** — внешний провайдер класса DALL-E 3 для premium-сценариев, где требуется более «маркетинговое» качество изображения.

Такое решение будущесовместимо: оно не закрывает дорогу к внешнему качественному генератору, но сохраняет базовый on-premise

маршрут для большинства B2B-кейсов.

2.2.7 TTS-движки для генерации подкастов

Для генерации русскоязычных подкастов сравнивались Silero TTS v4 и ElevenLabs Multilingual v2 [22; 23]. На текущем этапе различие между ними определяется прежде всего не субъективным MOS, а эксплуатационной логикой.

- **Silero TTS** подходит для on-premise развёртывания, не требует внешнего API и по заложенной в benchmark-модель оценке даёт стоимость порядка 4 руб. на курс за счёт только GPU-времени.
- **ElevenLabs** обеспечивает более «человеческую» интонационную подачу, но при оценке 40,000 символов на курс стоимость составляет порядка 1,080 руб. на курс, что делает его скорее premium-опцией, чем базовым TTS-слоем для MVP.

Панельная MOS-оценка пока не завершена. Для этого уже подготовлен отдельный benchmark-скрипт, однако в текущей итерации для выбора технологии решающими оказались суверенитет данных и предсказуемость себестоимости. Поэтому базовым TTS-движком выбран Silero.

2.3 Промежуточные результаты экспериментов

2.3.1 Предварительные результаты baseline B2

Первым полностью воспроизводимым экспериментом стал прогон one-shot baseline B2 на ядровом корпусе из 16 документов. В этом baseline использовалась локальная модель `qwen2.5:7b`, которая по одному промпту генерировала структуру курса в JSON-формате без retrieval, без факт-чекинга и без отдельных специализированных агентов.

Полученные данные показывают, что one-shot baseline обладает двумя сильными сторонами: он очень быстро генерирует структурно валидный ответ и не требует сложной инфраструктуры. Однако эти преимущества не решают ключевую задачу исследования.

Во-первых, среднее покрытие Bloom's taxonomy составляет лишь 61.5 %, а порог 70 % достигается только в 18.8 % случаев. Во-вторых, baseline значительно лучше справляется с продуктово-описательными документами, чем с нормативными: для регламентов покрытие падает до 40 %, что означает смещение к нижним когнитивным уровням remember/understand. B-

Таблица 2.5 — Предварительные результаты baseline B2 на ядровом корпусе

Срез корпуса	n	**Среднее время, с**	**Среднее Bloom, %**	**Доля курсов** $\geq 70\%$	**Valid structure**
Все документы	16	4.31	61.5	18.8%	100%
Продуктовые документы	6	5.28	75.0	33.3%	100%
Регламенты	5	3.76	40.0	0%	100%
Учебные программы	5	3.70	66.7	20.0%	100%

третьих, citation density равна нулю: модель не даёт никакой явной привязки результата к источнику, поэтому baseline не может считаться достаточным для compliance- или knowledge-critical сценариев.

Именно этот набор ограничений и мотивирует переход от B2 к B4: необходима архитектура, которая сохраняет скорость, но усиливает retrieval, факт-чекинг и глубину методической структуры.

2.3.2 Подготовленные оценочные наборы для RAG и факт-чекинга

Несмотря на то что полный B4-benchmark ещё не завершён, исследование уже подготовило воспроизводимую основу для дальнейшей оценки RAG-компонента и fact-check слоя.

Таблица 2.6 — Подготовленные оценочные наборы текущего MVP

Артефакт	**Объём**	**Назначение**
Ядровой корпус документов	16	baseline- и pipeline-генерация курсов
QA-пары (`qa_pairs.json`)	30	последующая оценка faithfulness и answer relevancy
Фактуальные утверждения (`statements.json`)	100	оценка fact-check precision / recall / F1

Эти артефакты важны тем, что превращают работу из описательной архитектурной записки в экспериментально воспроизводимую постановку: следующая итерация не начинается «с нуля», а опирается на уже подготовленный корпус и формализованные benchmark-наборы.

2.3.3 Предварительная сценарная unit-экономика MVP

Помимо технических метрик, для текущего MVP была собрана предварительная сценарная оценка unit-экономики. Важно подчеркнуть, что речь идёт не о подтверждённой рыночной выручке, а о расчётной модели, основанной на текущей конфигурации пайплайна и внутренних допущениях о цене привлечения и контрактной монетизации.

Таблица 2.7 — Предварительная сценарная unit-экономика текущего MVP

Показатель	**Значение**	**Интерпретация**
Прямая себестоимость генерации курса	75 руб.	инфраструктурный cost per course в текущем pipeline
Отношение к стоимости подрядной разработки	0.05%	текущий MVP в модели существенно дешевле внешнего производства
LTV / CAC	10.0	при выбранных допущениях модель не выглядит заведомо убыточной
Payback period	2 мес.	возврат затрат возможен в коротком цикле продаж
Порог безубыточности	14 клиентов	ориентир для следующей стадии pilot-to-scale

С инженерной точки зрения эти цифры важны не сами по себе, а как проверка того, что архитектура on-premise / hybrid AI не разрушает экономику продукта. Иными словами, даже до завершения полного B4-benchmark текущая версия системы уже выглядит технически дешёвой в эксплуатации.

Одновременно эти значения не должны интерпретироваться как окончательное доказательство product-market fit. Для этого всё ещё необходимы пилоты, реальные конверсии в платящие внедрения и валидация ценности на корпоративных заказчиках.

2.3.4 Ограничения текущего этапа и план ablation-исследования

Наиболее существенное ограничение текущего этапа состоит в том, что полный прогон B4 ещё не стабилизирован как исследовательский bench-

mark. Для pipeline уже подготовлены скрипты baseline comparison, Bloom evaluation, RAG evaluation, fact-check evaluation и ablation study, однако на момент последнего прогона мультиагентный endpoint не завершил полный сравнительный цикл.

Это ограничение не обесценивает проделанную работу, но накладывает важную границу на интерпретацию результатов:

– текущие цифры chapter 2 следует трактовать как **baseline-слой и технологическую разведку**;
– полная проверка гипотез H1–H3 требует завершения B4-progons, экспертного ground truth и последующего B1/B3/B4 сравнения;
– ablation study остаётся ключевым следующим экспериментом, так как именно он покажет вклад retrieval-, fact-check- и review-агентов в итоговое качество.

Таким образом, chapter 2 фиксирует не только успехи, но и текущую границу зрелости системы — это делает дальнейшее развитие текста и экспериментов прозрачным и аккуратным.

2.3.5 Финальная конфигурация следующей итерации

На основании проведённого отбора и предварительных результатов следующая итерация ИИ-методиста должна строиться на следующей конфигурации:

– **LLM baseline / local core**: Qwen2.5 через Ollama;
– **Оркестратор**: LangGraph 1.x (`StateGraph`);
– **Document Ingestion**: Haystack 2.x AsyncPipeline;
– **Embedding**: `deepvk/USER-bge-m3`;
– **Vector Store**: Qdrant;
– **Чанкинг**: семантический;
– **Image generation**: FLUX.1-dev как базовый локальный путь;
– **TTS**: Silero TTS как базовый on-premise движок.

Именно эта конфигурация наиболее последовательно соответствует целям работы: on-premise развёртывание, воспроизводимые эксперименты, приемлемая себестоимость, возможность усиления retrieval и педагогической структуры по сравнению с one-shot baseline.

3 ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

В данной главе описывается архитектура ИИ-методиста, реализация мультиагентного конвейера на основе LangGraph, ключевые конвейеры обработки документов и генерации контента, а также инфраструктурное развёртывание в составе платформы Adapstory.

3.1 Архитектура системы

3.1.1 Контекстная диаграмма (C4 Level 1)

ИИ-методист является одним из микросервисов платформы Adapstory — образовательной LMS, поддерживающей модель B2B SaaS для корпоративных заказчиков. На уровне системного контекста (C4 Level 1, приложение Г, раздел Г.1) ИИ-методист взаимодействует со следующими акторами и системами:

- **Автор курса / HR-специалист** — основной пользователь: загружает исходные документы, инициирует генерацию, просматривает и редактирует черновик курса;
- **BFF School** (Backend-for-Frontend школы) — единственная точка входа для веб-клиента; маршрутизирует запросы к микросервису;
- **Адаптивная LMS Adapstory** — принимает финальную структуру курса через REST API и публикует её в каталоге;
- **Хранилище документов MinIO** — источник исходных файлов (.pdf, .docx, .pptx, .xlsx) и хранилище медиафайлов курса;
- **Ollama GPU-сервер** — провайдер локальных LLM (Qwen 2.5-72B, FLUX.1-dev);
- **Qdrant** — векторная база знаний для RAG.

3.1.2 Диаграмма контейнеров (C4 Level 2)

На уровне контейнеров (приложение Г, раздел Г.2) микросервис ИИ-методист состоит из следующих процессов:

- **FastAPI API Gateway** — принимает HTTP-запросы от BFF, валидирует входные данные (Pydantic v2), публикует задания в Celery;
- **Celery Workers** (×N) — пул асинхронных воркеров, исполняющих задачи Document Ingestion и Course Generation;

– **LLM Gateway** — провайдер-агностичный интерфейс к языковым моделям с retry, circuit breaker (Resilience4j-аналог на Python / Tenacity) и кэшированием промптов;
– **LangGraph Runtime** — исполняет граф агентов, сохраняет checkpoint в Redis;
– **Haystack AsyncPipeline** — конвейер индексации документов.

3.1.3 Диаграмма компонентов (C4 Level 3)

Подробная декомпозиция компонентов LangGraph Runtime приведена в приложении Г (раздел Г.3) и описана в разделе 3.2.

3.1.4 Доменная модель

Основные доменные сущности ИИ-методиста:
– **EducationalProduct** — запрос на генерацию курса: содержит ссылку на исходный документ, выбранную методологию (ADDIE / SAM / Backward Design) и параметры целевой аудитории;
– **CourseBlueprint** — черновая структура курса: метаданные, список модулей, учебные цели с разметкой по Блуму;
– **Module** — логический раздел курса: название, описание, список уроков, competency tags;
– **Lesson** — атомарная единица обучения: текст, список иллюстраций, ссылка на TTS-подкаст, тестовые вопросы;
– **CompetencyTag** — тег компетенции из графа знаний Neo4j.

3.2 Мультиагентная система (LangGraph)

3.2.1 Граф агентов (StateGraph)

Граф агентов ИИ-методиста реализован с использованием `StateGraph` из LangGraph [42]. Состояние графа (`CourseState`) содержит входной документ, промежуточные артефакты (blueprint, список модулей, контент уроков) и флаги человеческого ревью.

Полная спецификация графа приведена в приложении Д. Основные ноды и переходы описаны ниже.

3.2.2 Агенты конвейера

Конвейер состоит из пяти специализированных агентов:
1) **TargetAnalysisAgent** — анализирует исходный документ, определяет

целевую аудиторию, предварительные знания и разрыв между текущим и желаемым уровнем компетентности;

2) **CourseStructureAgent** — генерирует структуру курса (Blueprint) в соответствии с выбранной методологией (ADDIE / SAM / BD) и формирует учебные цели с разметкой по таксономии Блума;
3) **ContentCreatorAgent** — генерирует текстовый контент уроков с использованием RAG: извлекает релевантные фрагменты из Qdrant и передаёт их в контекст LLM;
4) **FactCheckAgent** — верифицирует фактические утверждения в сгенерированном контенте относительно исходного документа, выявляет галлюцинации и инициирует пересмотр при низком faithfulness;
5) **MediaGenerationAgent** — параллельно генерирует иллюстрации (FLUX.1-dev) и TTS-подкасты (Silero) для уроков.

3.2.3 Human-in-the-loop

После завершения CourseStructureAgent граф приостанавливается на ноде `human_review_structure` через механизм `interrupt_before` [42]. Автор курса получает уведомление (веб-сокет / email) и может: одобрить структуру, отредактировать отдельные модули или запросить полную перегенерацию с альтернативной методологией. После одобрения граф возобновляется с сохранённого checkpoint.

3.2.4 Управление состоянием и трассировка

Checkpoint API LangGraph сохраняет состояние `CourseState` после каждой ноды в Redis, обеспечивая:

– идемпотентное возобновление при сбое воркера;
– возможность просмотра истории выполнения через LangSmith;
– параллельное исполнение ветки MediaGenerationAgent без блокировки основного конвейера.

LangSmith [50] используется для трассировки каждого вызова LLM: входной промпт, ответ модели, latency, токены. Это позволяет анализировать деградацию качества на конкретных документах без воспроизведения всего конвейера.

3.3 Ключевые конвейеры

3.3.1 Document Ingestion Pipeline (Haystack 2.x)

Конвейер индексации документов реализован на Haystack 2.x `AsyncPipeline` [47] и включает следующие компоненты:

1) **MinIODocumentFetcher** — загружает файл из MinIO по presigned URL (форматы: PDF, DOCX, PPTX, XLSX);
2) **DocumentConverter** — конвертирует файл в текст (pdfminer / python-docx / python-pptx); сохраняет метаданные источника;
3) **SemanticDoubleMergingSplitter** — разбивает текст на семантические фрагменты;
4) **OllamaTextEmbedder** — векторизует фрагменты через модель `deepvk/USER-bge-m3` (Ollama API);
5) **QdrantDocumentStore.write_documents()** — записывает фрагменты с векторами в Qdrant (коллекция курса).

Конвейер вызывается асинхронно из Celery-воркера сразу после загрузки документа пользователем; генерация курса начинается только после завершения индексации.

3.3.2 Конвейер генерации курсов

Генерация курса представляет собой последовательность вызовов агентов LangGraph с общим `CourseState`:

1) TargetAnalysisAgent формирует профиль аудитории;
2) CourseStructureAgent выбирает промпт-шаблон (ADDIE / SAM / Backward Design, приложение Е) и генерирует структурированный JSON (Pydantic `CourseBlueprint`);
3) ContentCreatorAgent для каждого урока выполняет гибридный поиск в Qdrant (dense + sparse), формирует контекст и генерирует текст урока;
4) FactCheckAgent проверяет каждое утверждение в тексте урока против исходного документа;
5) ReviewAgent формирует финальный отчёт о качестве курса.

3.3.3 Мультимедиа-конвейер

После одобрения текстовой структуры курса MediaGenerationAgent запускается параллельно с ContentCreatorAgent через `Send API` LangGraph. Для каждого урока:

– генерируется иллюстрация: заголовок урока + ключевые термины → FLUX.1-dev [21] → PNG → MinIO;
– генерируется аудиоподкаст: LLM генерирует диалог двух ведущих (Наставник + Ученик) по тексту урока → Silero TTS v4 [22] → MP3 → MinIO.

3.3.4 Механизм актуализации

При изменении исходного документа запускается конвейер актуализации:

1) Document Ingestion повторно индексирует обновлённый документ;
2) FactCheckAgent прогоняет все существующие уроки против нового индекса;
3) Уроки с faithfulness ниже порога (по умолчанию 0.8) помечаются как `OUTDATED` и передаются ContentCreatorAgent на перегенерацию;
4) Human-in-the-loop уведомляет владельца курса о изменённых разделах.

3.4 Инфраструктура и развёртывание

3.4.1 Dev-стенд: K3s + GPU

ИИ-методист развёрнут в составе K3s-кластера Adapstory (single-node, 192.168.1.3) под управлением ArgoCD (App-of-Apps pattern). Конфигурация определена как Helm-чарт в GitOps-репозитории [51].

GPU-узел (NVIDIA Tesla T4) предоставлен через NVIDIA GPU Operator с time-slicing: Ollama и Celery-воркеры делят GPU-ресурс. Все персональные данные и документы клиентов остаются внутри периметра (on-premise), что соответствует требованиям 152-ФЗ [52].

3.4.2 LLM Gateway

LLM Gateway реализован как единый асинхронный интерфейс с провайдер-агностичным API (`complete(prompt, model, params)`):

– **Retry** (Tenacity): экспоненциальный backoff, до 3 попыток при HTTP 5xx от Ollama;
– **Circuit Breaker**: при недоступности Ollama > 30 с переключается на резервный провайдер (OpenAI API);
– **Кэш промптов**: идентичные промпты кэшируются в Redis (TTL 1 час) для снижения нагрузки на GPU.

3.4.3 CI/CD и мониторинг

Сборка образов выполняется Jenkins-пайплайном: Maven/uv build → Docker build (Kaniko, linux/amd64) → push в Harbor-реестр → обновление тега в GitOps-репозитории → ArgoCD sync.

Трассировка и метрики собираются через OpenTelemetry Collector: latency по нодам LangGraph-графа, throughput Celery-очереди, GPU-utilization. Дашборды доступны в Grafana (dev-стенд).

4 ВАЛИДАЦИЯ, ИМПАКТ И БИЗНЕС-ОЦЕНКА

В данной главе описывается протокол валидации ИИ-методиста, представляются результаты проверки гипотез H1–H3, анализируется бизнес-потенциал и рыночная готовность продукта.

4.1 Протокол валидации

4.1.1 Автоматизированная оценка

Автоматизированная оценка качества выходных артефактов ИИ-методиста проводится в трёх измерениях:

1) **Ragas-метрики** (глава 2): faithfulness, answer relevancy, context precision;
2) **Bloom's coverage**: доля уровней таксономии Блума, покрытых в наборе учебных целей курса; целевой показатель — $\geq 70\%$;
3) **Структурное качество**: полнота (наличие всех обязательных элементов методологии), согласованность учебных целей с содержанием, BLEU/ROUGE относительно эталонов B1.

4.1.2 Протокол экспертной оценки

Для независимой верификации результатов привлечены 5–8 экспертов-методистов (критерии отбора: опыт разработки eLearning-курсов $\geq$ 3 лет, опыт оценки учебных программ).

Каждому эксперту предъявляются четыре обезличенных варианта структуры одного курса (B1–B4) в случайном порядке. Оценка проводится по рубрике из 5 критериев (шкала 1–5):

– соответствие целевой аудитории;
– логика и последовательность модулей;
– качество учебных целей (SMART);
– покрытие исходного материала;
– практическая применимость.

Итоговая оценка — среднее по 5 критериям. Слепой дизайн исключает предвзятость в пользу AI-генерации. Полные таблицы текущих оценочных артефактов приведены в приложении И.

4.1.3 Экспертная и пользовательская оценка

Помимо автоматизированных метрик, для системы подготовлены два контура качественной проверки.

Первый контур — **слепая экспертная оценка**. Для него подготовлена рубрика из 5 критериев и шаблон таблицы сравнения конфигураций B1–B4. Этот контур должен быть проведён после стабилизации мультиагентной конфигурации B4, чтобы экспертам предъявлялись уже не прототипные, а воспроизводимые результаты.

Второй контур — **пользовательский pilot-протокол**. Он предполагает измерение time-to-draft, субъективной удобства (SUS [53]) и готовности рекомендовать решение (NPS). Дополнительно в следующую волну pilot-stage закладываются task-specific self-efficacy и perceived competence опросы, выполненные в формате retrospective pre-post, а также follow-up на transfer of learning и goal attainment через 2–4 недели после использования системы [37–41]. На момент текущей редакции работы pilot-сценарий и вопросы подготовлены, однако полный цикл пользовательской оценки ещё не завершён. Это разграничение принципиально: диплом фиксирует уже доступные технические результаты и отдельно описывает инструменты для следующей волны validation.

4.2 End-to-End верификация

4.2.1 Сценарий 1: Онбординг-курс (ADDIE)

Входной документ: продуктовое описание нового SaaS-инструмента, 8 страниц.

Ожидаемый результат: 6-модульный онбординг-курс с учебными целями для новых сотрудников; время генерации менее 30 минут.

Ход выполнения:

1) Пользователь загружает PDF в систему; запускается Document Ingestion.
2) После индексации инициируется CourseStructureAgent с методологией ADDIE.
3) После генерации структуры система приостанавливается для human review; пользователь одобряет структуру.
4) ContentCreatorAgent генерирует тексты уроков; FactCheckAgent верифицирует утверждения.

5) MediaGenerationAgent параллельно генерирует иллюстрации и подкасты.
6) Финальный курс публикуется в LMS Adapstory.

На текущем этапе количественно измерен не весь end-to-end pipeline B4, а его наиболее воспроизводимый baseline-слой B2. Для ядрового корпуса из 16 документов baseline показывает среднее время генерации структуры 4.31 с, среднее покрытие Bloom's taxonomy 61.5 %, долю курсов с покрытием $\geq$ 70 % на уровне 18.8 % и структурную валидность 100 %. Эти цифры ещё не являются итоговыми показателями сценария 1, но подтверждают, что минимальный doc-to-blueprint pipeline уже работоспособен и может служить отправной точкой для улучшения B4.

4.2.2 Сценарий 2: Compliance-курс с факт-чекингом

Входной документ: корпоративный регламент информационной безопасности, 22 страницы.

Специфика: документ содержит точные числовые требования (сроки, пороги, санкции), критичные для корректного compliance-обучения.

Проверяется, что FactCheckAgent выявляет галлюцинации при конкретизации числовых значений. Для этого уже подготовлен синтетический датасет из 100 утверждений (`statements.json`), пригодный для расчёта precision / recall / F1. Финальные численные результаты будут получены после стабилизации B4 и подключения полного fact-check контура к основному benchmark-run.

4.2.3 Сценарий 3: Авто-актуализация при обновлении источника

Условие: в исходный документ сценария 1 внесены изменения (обновлена функциональность продукта, 3 новых раздела).

Проверяется корректность выявления устаревших уроков и качество перегенерации затронутых разделов без перегенерации всего курса. На момент подготовки работы сценарий сформулирован как отдельный validation-case, однако численная метрика ещё не зафиксирована. Это один из следующих экспериментов, поскольку именно он проверяет прикладную ценность системы для B2B-контента, который быстро устаревает.

4.3 Текущие результаты и проверка гипотез

4.3.1 Сводка фактически подтверждённых результатов

Таблица 4.1 — Текущий набор подтверждённых результатов исследования

Контур валидации	**Текущее значение**	**Что это означает**
Customer Development	20 B2B-интервью	проблема подтверждена первичными данными рынка
Ключевой pain	70 %	большинство респондентов называют длительность разработки курса главным ограничением текущего процесса
Использование подрядчиков / внешних методистов	50 %	рынок уже платит за закрытие этой задачи внешним ресурсом
Готовность рассмотреть AI-инструмент	60 %	есть ранний signal problem/solution interest, но ещё не завершён полноценный solution-fit этап
Baseline B2: время генерации структуры	4.31 с	one-shot конфигурация очень быстра, но не решает задачу качества и объяснимости
Baseline B2: среднее Bloom coverage	61.5 %	текущий baseline не достигает целевого уровня $\geq$ 70 %
Baseline B2: доля курсов с Bloom $\geq$ 70 %	18.8 %	именно этот разрыв обосновывает необходимость agentic-усиления
Baseline B2: valid structure	100 %	минимальный pipeline уже стабильно выдаёт формально корректный blueprint курса
Оценочные наборы	30 QA-пар, 100 утверждений	база для следующей волны RAG- и fact-check оценки уже подготовлена
Unit economics (сценарная)	75 руб./курс	инфраструктурная себестоимость выглядит низкой даже до завершения полного B4-benchmark
Отношение к подрядной разработке	0.05 %	расчётный unit-cost существенно ниже стоимости внешней ручной разработки курса
LTV / CAC, payback, breakeven	10.0; 2 мес.; 14 клиентов	сценарная модель выглядит экономически осмысленной, но требует подтверждения реальными продажами

4.3.2 Проверка гипотез H1–H3

H1 (продуктовая). «Мультиагентный конвейер сокращает время создания структуры курса с X часов до Y минут при сохранении Bloom's-выравненности $\geq 70\%$.»

На момент текущего черновика гипотеза получает **предварительную поддержку**, но не может считаться полностью подтверждённой. С одной стороны, проблема времени разработки надёжно валидирована через 20 интервью, а текущий baseline показывает, что doc-to-blueprint генерация уже занимает секунды, а не часы. С другой стороны, полноценный B4 end-to-end сценарий с human-review и итоговым измерением time-to-draft на реальном пилоте ещё не стабилизирован. **Гипотеза H1 предварительно поддержана и требует финального pilot-run.**

H2 (техническая). «Мультиагентная архитектура обеспечивает более высокое качество структуры по сравнению с single-prompt baseline на той же LLM.»

Текущее состояние данных позволяет утверждать лишь то, что one-shot baseline B2 недостаточен по Bloom coverage и совсем не обеспечивает citation-aware поведения. Это создаёт содержательное основание для мультиагентной архитектуры, но ещё не даёт статистически завершённого сравнения B2 и B4. До завершения стабильного benchmark-run гипотеза H2 должна трактоваться как **не полностью проверенная**. **Гипотеза H2 концептуально обоснована, но эмпирически пока не завершена.**

H3 (бизнесовая). «Unit-стоимость генерации курса $\leq Z\%$ от стоимости ручной разработки у внешнего подрядчика.»

В сценарной финансовой модели unit-cost генерации курса составляет 75 руб., что эквивалентно примерно 0.05 % от ориентировочной стоимости ручной разработки курса у внешнего подрядчика. Такой результат не доказывает рынок сам по себе, но показывает, что архитектура не разрушает экономику продукта уже на раннем этапе. **Гипотеза H3 предварительно поддержана сценарной unit-экономикой.**

4.3.3 Производительность

На текущем этапе доступны следующие подтверждённые операционные показатели:

– среднее время baseline B2 на ядровом корпусе из 16 документов — 4.31 с

на генерацию blueprint;
- среднее число модулей — 3, среднее число уроков — 6.2;
- valid structure rate — 100 %.

Нодовая телеметрия p50 / p95, throughput и GPU-utilization включены в план следующей итерации наблюдаемости. Они будут сниматься после стабилизации B4 через LangSmith / системные метрики рантайма.

4.3.4 Точность факт-чекинга

На синтетическом датасете из 100 утверждений (50 корректных, 50 намеренно искажённых) уже подготовлен воспроизводимый контур оценки precision / recall / F1. Численные значения не включаются в текущую редакцию как итоговый результат, поскольку полный B4 fact-check pipeline ещё не завершил стабильный прогон.

4.4 Ограничения исследования и угрозы валидности

Настоящий раздел явно перечисляет ограничения исследования и угрозы внутренней и внешней валидности [54]. Осознание этих ограничений необходимо для корректной интерпретации результатов и определения направлений дальнейших исследований.

4.4.1 Ограничения тестового датасета

Ограниченный объём измеренного корпуса ($n = 16$). Ядровой корпус содержит 16 документов, что ограничивает статистическую мощность сравнений. При размере эффекта $d = 0.5$ (средний) и $\alpha = 0.05$ мощность критерия Вилкоксона для такой выборки остаётся ограниченной и не гарантирует надёжного сравнения тонких различий между конфигурациями. Следовательно, результаты следует рассматривать как предварительные и требующие репликации на расширенном корпусе ($n \geq 30$).

Доменная специфика. Все 15 документов корпуса принадлежат российскому B2B-контексту (SaaS-продукты, корпоративные регламенты, учебные программы ФГОС). Обобщаемость результатов на другие домены (медицина, юриспруденция, технические науки) и другие языки не подтверждена.

4.4.2 Ограничения эталонного корпуса (ground truth)

На момент текущей редакции полностью завершённым является не экспертный ground truth, а корпус входных документов и оценочные наборы для RAG / fact-check. Экспертная разметка и расчёт inter-rater agreement подготовлены как следующий шаг, но ещё не могут считаться окончательно зафиксированными результатами. Это ограничивает силу выводов о педагогическом превосходстве B4 по отношению к другим конфигурациям.

4.4.3 Ограничения пользовательской валидации

Пользовательский pilot-контур спроектирован, но ещё не завершён как формальный исследовательский этап. Поэтому текущая работа пока не даёт численно подтверждённых SUS / NPS и не может делать сильные выводы о поведенческом удержании, повторном использовании или организационном масштабировании. Следующий шаг — проведение решенческих интервью, LOI-stage и пилотов на реальных документах заказчиков.

4.4.4 Ограничения технологического стека

Зависимость от одной LLM. Все эксперименты проведены на Qwen 2.5-72B. Результаты могут не воспроизводиться на других моделях (LLaMA 3.3, Mistral Large, GPT-4o), что ограничивает обобщаемость вывода об эффективности агентной архитектуры.

Ограниченный набор методологий. На момент валидации реализована одна методология (ADDIE). Сравнение с SAM и Backward Design отложено до следующей итерации и не включено в основные результаты работы.

Авто-классификация Bloom's уровней. Уровни таксономии Блума определялись автоматически с помощью GPT-4o в роли judge-модели [55]. Надёжность такой классификации на русскоязычных учебных целях не валидирована независимо; это является угрозой валидности измерения Bloom's coverage.

4.4.5 Угрозы внешней валидности

Система разработана и протестирована исключительно на русскоязычном контенте B2B-сегмента. Перенос результатов на другие

языки, другие модальности обучения (офлайн, blended) или другой регуляторный контекст (SCORM, xAPI) требует дополнительных исследований.

4.4.6 Направления для устранения ограничений

В качестве следующих шагов определены:

1) расширение тестового корпуса до 30–50 документов из 5+ различных доменов;
2) добавление второго эксперта и расчёт Cohen's κ для оценки надёжности разметки Bloom's уровней;
3) кросс-модельная оценка: воспроизведение экспериментов на LLaMA 3.3 70B и GPT-4o для проверки обобщаемости;
4) расширенный пилот ($n \geq 20$) с longitudinal метриками удержания контента.

4.5 Бизнес-оценка и масштабирование

4.5.1 Unit-экономика

Себестоимость одного сгенерированного курса складывается из: GPU-времени (Qwen 2.5 + FLUX + Silero) и опциональных API-вызовов. В текущей редакции используется сценарный расчёт, собранный в отдельном экспериментальном артефакте `unit_economics_results.json`.

– GPU-время — 75 руб./курс;
– OpenAI API (опционально) — 0 в base-конфигурации;
– **Итого unit-cost** — $\approx$ 75 руб./курс.

Ключевые метрики сценарной подписочной модели:

– CAC (стоимость привлечения клиента): около 30 000 руб.;
– LTV (lifetime value): около 300 000 руб.;
– LTV / CAC: 10.0;
– Payback Period: 2 мес.

4.5.2 Lean Canvas

Lean Canvas [56] ИИ-методиста приведён в приложении К. Ключевые блоки:

Проблема: разработка корпоративного курса требует значительного времени и часто выносится на внешних подрядчиков; контент устаревает

быстрее, чем его успевают методически перерабатывать.

Решение: автоматическая генерация структуры и текстов курса по загруженному документу; human-in-the-loop ревью; механизм последующей авто-актуализации.

Целевая аудитория: B2B-клиенты платформы Adapstory — HR-отделы и учебные центры с > 50 сотрудников.

Unfair Advantage: методологическая вариативность (AD-DIE/SAM/BD) и полный суверенитет данных (on-premise LLM) не воспроизводятся Coursebox AI и iSpring AI.

4.5.3 Финансовая модель (прогноз на 3 года)

Детальные расчёты приведены в приложении К. Ключевые итоговые показатели:

- **NPV**: 1 807 тыс. руб.;
- **IRR**: 32.2 %;
- **ROI** за 3 года: 42.2 %;
- **Точка безубыточности**: 14 клиентов / 32 мес. с момента коммерческого запуска

4.5.4 Потенциал масштабирования

После валидации в российском B2B-сегменте идентифицированы смежные рынки:

- **Международный EdTech**: потенциальный TAM ≈ $51 млрд к 2030 году [1];
- **Корпоративное обучение (CLO-сегмент)**: интеграция в Microsoft 365 + SharePoint как источник документов;
- **Государственное образование**: адаптация под ФГОС-регламент при поддержке профильных ведомств.

4.5.5 PESTLE-анализ при масштабировании

- **P (Political)**: регуляторные требования к использованию AI в государственном образовании; ограничения экспорта технологий;
- **E (Economic)**: зависимость от стоимости GPU-аренды; волатильность курсов валют при API-зависимости;
- **S (Social)**: опасения преподавателей о замещении; требования к прозрачности AI-генерации;

– **T (Technological)**: быстрое устаревание LLM; риск лицензионных изменений в open-source моделях;
– **L (Legal)**: 152-ФЗ [52] (персональные данные); авторское право на AI-сгенерированный контент (ГК РФ ч. IV);
– **E (Environmental)**: энергопотребление GPU-кластера; углеродный след at-scale.

4.5.6 Оценка рисков

Таблица 4.2 — Матрица рисков ИИ-методиста

Риск	**Вероятность**	**Влияние**	**Митигация**
Деградация качества новой версии LLM	Средняя	Высокое	Регрессионный Ragas-тест при каждом обновлении модели
Недоступность GPU-узла	Низкая	Высокое	Circuit breaker + fall-back на OpenAI API
Утечка данных через LLM-провайдера	Низкая	Критическое	On-premise развёртывание; запрет облачных провайдеров для en-terprise
Неприятие авторами курсов	Средняя	Среднее	Human-in-the-loop; прозрачность AI-использования в UI
Изменение лицензии Qwen / FLUX	Низкая	Высокое	LLM Gateway с провайдер-агностичным API; альтернативы: Llama 3.3

4.5.7 Дорожная карта

6 месяцев: стабилизация B4-benchmark, завершение fact-check и RAG evaluation, проведение первых решенческих интервью и pilot-run на реальных документах заказчиков.

12 месяцев: переход от чернового MVP к production-ready версии, поддержка трёх методологий (ADDIE / SAM / Backward Design), первые платные внедрения и структурированная пользовательская аналитика.

24 месяца: API для внешней интеграции, мультиязычность,

масштабирование на смежные рынки корпоративного обучения.

4.5.8 Интеллектуальная собственность

Программный комплекс ИИ-методиста подлежит регистрации в качестве программы для ЭВМ в соответствии со ст. 1261 ГК РФ [57]. Авторские права на AI-сгенерированные учебные материалы принадлежат юридическому лицу — оператору платформы (ст. 1295 ГК РФ, служебное произведение).

4.6 Степень готовности и обратная связь от рынка

4.6.1 Текущий статус MVP

По состоянию на момент написания работы реализованы: Document Ingestion Pipeline, CourseStructureAgent (ADDIE), human-review, ContentCreatorAgent с RAG, FactCheckAgent.

В разработке: SAM / Backward Design методологии, MediaGenerationAgent (FLUX + Silero), механизм авто-актуализации.

4.6.2 Traction

- Проведены 20 B2B-интервью (Customer Development);
- 70 % респондентов называют time-to-development главным pain;
- 50 % уже используют подрядчиков или внешних методистов;
- 60 % готовы рассмотреть AI-инструмент такого класса;
- решенческие интервью, LOI-stage и активные пилоты относятся к следующей волне коммерческой валидации.

4.6.3 Problem/Solution Fit

На момент текущего черновика корректнее говорить не о полностью подтверждённом Problem/Solution Fit, а о сильном problem-signal и раннем interest-signal. Проблема уже подтверждена через CustDev, а 60 % респондентов готовы рассмотреть AI-инструмент в своём процессе. Полноценный Problem/Solution Fit будет зафиксирован после серии решенческих интервью на MVP и pilot-использования на реальных документах компании.

4.6.4 Качественная обратная связь

Даже на уровне проблемных интервью рынок дал три устойчивых качественных сигнала:

– пользователям важнее быстро получить *первый черновик* курса, чем сразу идеальный финальный контент;
– для регламентов и compliance-сценариев критична привязка к источнику и возможность проверки фактов;
– для B2B-сегмента существенны суверенитет данных, on-premise развёртывание и human-in-the-loop контроль.

ЗАКЛЮЧЕНИЕ

В настоящей работе разработан интеллектуальный методический ассистент (ИИ-методист) — микросервис образовательной платформы Adapstory, автоматизирующий создание и подготовку учебных курсов на основе документов заказчика с использованием LLM, retrieval-подхода и агентной оркестрации.

Итоги выполнения задач исследования. В ходе работы проведены 20 глубинных B2B-интервью, подтвердившие устойчивую проблему трудоёмкой разработки корпоративных курсов. Показано, что для 70 % респондентов главным pain-point является длительность разработки, 50 % уже прибегают к подрядчикам или внешним методистам, а 60 % готовы рассмотреть AI-инструмент для решения этой задачи. На техническом уровне выбран и обоснован стек на основе LangGraph, Haystack 2.x, Qdrant и Qwen 2.5; реализованы Document Ingestion Pipeline, agentic pipeline генерации структуры курса и контур дальнейшей fact-check / RAG валидации.

Главные количественные результаты текущего этапа. Для ядрового корпуса из 16 документов воспроизводимо измерен baseline B2: среднее время генерации структуры составило 4.31 с, среднее покрытие Bloom's taxonomy — 61.5 %, доля курсов с покрытием $\geq$ 70 % — 18.8 %, структурная валидность — 100 %. Кроме того, подготовлены оценочные наборы для следующей итерации исследования: 30 QA-пар для RAG evaluation и 100 утверждений для fact-check evaluation. Сценарная unit-экономика показывает инфраструктурную себестоимость порядка 75 руб. за курс, LTV / CAC = 10.0, период окупаемости 2 месяца и точку безубыточности на уровне 14 клиентов.

Статус гипотез. Гипотеза H1 получает предварительную поддержку: проблема времени разработки подтверждена рынком, а технический pipeline уже демонстрирует очень быстрый doc-to-blueprint слой. Однако полноценный B4 end-to-end pilot ещё не завершён, поэтому H1 не может считаться полностью закрытой. Гипотеза H2 концептуально обоснована, так как baseline B2 недостаточен по Bloom coverage и не даёт citation-aware

поведения, но статистически завершённого сравнения с B4 пока нет. Гипотеза H3 предварительно поддержана сценарной unit-экономикой: расчётная себестоимость генерации курса на порядки ниже ручной разработки.

Научный вклад. Работа вносит вклад в исследовательскую область воспроизводимой валидации LLM-систем для генерации образовательного контента на русскоязычных данных. Предложена архитектура, объединяющая методологическую рамку проектирования курса, stateful agent orchestration и RAG-контур, а также сформирован воспроизводимый набор артефактов для дальнейшей оценки: корпус документов, benchmark assets для RAG и fact-check, сценарная бизнес-модель и validation protocol для пилотов.

Практическая значимость. На текущий момент ИИ-методист представляет собой рабочий MVP с реализованным ingestion-потоком, генерацией структуры курса, human-in-the-loop ревью и подготовленной основой для дальнейшей контентной и фактической валидации. Следующим шагом являются решенческие интервью, LOI-stage и пилоты на реальных документах заказчиков, после чего работа может быть доведена до полного подтверждения product / solution fit.

ИСПОЛЬЗОВАНИЕ СИСТЕМ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА И ЛИЧНЫЙ ВКЛАД АВТОРА

В соответствии с требованиями ИТМО к ВКР в стартап-треке настоящий раздел раскрывает использование AI-инструментов в процессе подготовки работы и фиксирует личный вклад автора в разработку системы.

Использование AI-инструментов

В ходе подготовки работы автор использовал AI-инструменты как средства поиска, чернового структурирования и редакционной поддержки текста:

– **OpenAI Codex / ChatGPT-4o** — для структурирования отдельных разделов, поиска возможных формулировок и редакционной шлифовки черновиков при обязательной последующей ручной переработке;
– **Perplexity AI** — для поиска актуальных рыночных данных, проверки дат публикации и навигации по открытым источникам;
– **LLM-ассистенты общего назначения** — как вспомогательный инструмент для проверки связности изложения и стилистической доработки текста.

Все AI-сгенерированные фрагменты проходили ручную проверку автора: фактические утверждения перепроверялись по первоисточникам, а финальные выводы и исследовательские формулировки принимались автором самостоятельно.

AI-инструменты не использовались для подмены первичных данных: интервью, CustDev-выводы, экспериментальные артефакты, расчёты и итоговые исследовательские интерпретации были собраны, проверены и оформлены автором.

Личный вклад автора

Автор настоящей работы лично:

1) **Провёл исследование предметной области**: собрал и проанализировал корпус из 45+ цитируемых академических и индустриальных источников по LLM, мультиагентным системам, RAG-подходам и автоматизации

создания образовательного контента;

2) **Разработал архитектурное решение**: принял ключевые проектные решения по выбору технологического стека (LangGraph, Haystack 2.x, Qdrant, Qwen 2.5), спроектировал граф агентов и гибридную архитектуру Document Ingestion + Agent Orchestration;
3) **Разработал промпт-шаблоны**: подготовил системные prompt-frameworks для ADDIE, SAM и Backward Design с учётом требований таксономии Блума и особенностей русскоязычного контента;
4) **Реализовал систему**: написал код LangGraph-графа агентов, LLM Gateway, Document Ingestion Pipeline, FastAPI-приложения и асинхронных воркеров, настроил инфраструктуру K3s + Ollama + Qdrant;
5) **Провёл эксперименты**: сформировал ядровой корпус документов, подготовил 30 QA-пар и 100 фактуальных утверждений, провёл baseline-измерения и сценарную unit-экономическую оценку;
6) **Провёл Customer Development**: 20 глубинных B2B-интервью по методу Mom Test и систематизировал ключевые pain-points рынка;
7) **Подготовил материалы следующей итерации**: оформил сценарий решенческих интервью, шаблон LOI, validation protocol для pilot-stage и приложения с оценочными артефактами.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Global EdTech Market Report 2024–2030. — 2024. — EdTech Hub, Statista Research.
2. Chapman B. How Long Does It Take to Create Learning? — 2010. — Chapman Alliance Research.
3. Российский EdTech-рынок: объём и структура по данным Smart Ranking. — 2024. — в тексте использованы данные Smart Ranking за 2023 год; дата обращения: 13.04.2026. URL: https://pureportal.spbu.ru/files/124005039/Conference$_proceedings_2024.pdf$.
4. Fitzpatrick R. The Mom Test: How to Talk to Customers & Learn if Your Business Is a Good Idea When Everyone Is Lying to You. — CreateSpace, 2013.
5. E-learning Services Market Size, Share & Trends Analysis Report 2030. — 2025. — дата обращения: 13.04.2026. URL: https://www.grandviewresearch.com/industry-analysis/e-learning-services-market.
6. Coursebox AI: Course Creation Platform. — дата обращения: 10.03.2025. URL: https://www.coursebox.ai.
7. Articulate 360 AI Features. — дата обращения: 13.04.2026. URL: https://articulate.com/360.
8. iSpring Suite AI: What's New. — дата обращения: 13.04.2026. URL: https://www.ispringsolutions.com/whats-new.
9. Synthesia for Learning and Development. — дата обращения: 13.04.2026. URL: https://www.synthesia.io.
10. NotebookLM Audio and Video Overviews. — 2025. — дата обращения: 13.04.2026. URL: https://blog.google/innovation-and-ai/models-and-research/google-labs/notebook-lm-audio-video-overviews-more-languages-longer-content/.
11. GetCourse Platform Overview. — 2026. — дата обращения: 13.04.2026. URL: https://getcourse.ru/.

12. ChatGPT for Good? On Opportunities and Challenges of Large Language Models for Education / E. Kasneci, K. Seßler, S. Küchemann, [et al.] // Learning and Individual Differences. — 2023. — Vol. 103. — P. 102274.

13. Pardos Z. A., Bhandari S. Learning gain differences between GPT-4 and human expert tutoring // Proceedings of EDM 2023. — 2023.

14. Tack A., Piech C. The AI Teacher Test: Measuring the Pedagogical Ability of Blender and GPT-3 in Educational Dialogues // Proceedings of EDM 2022. — 2022.

15. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation / Q. Wu [et al.] // arXiv:2308.08155. — 2023.

16. Reflexion: Language Agents with Verbal Reinforcement Learning / N. Shinn [et al.] // Advances in Neural Information Processing Systems (NeurIPS 2023). — 2023.

17. Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models / L. Wang, W. Xu, Y. Lan, [et al.]. — 2023. — arXiv:2305.04091.

18. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks / P. Lewis, E. Perez, A. Piktus, [et al.] // Advances in Neural Information Processing Systems (NeurIPS 2020). — 2020.

19. RAGAS: Automated Evaluation of Retrieval Augmented Generation / S. Es [et al.] // Proceedings of EACL 2024. — 2024.

20. DALL-E 3 Technical Report / J. Betker, G. Goh, L. Jing, [et al.]. — 2023. — URL: https://openai.com/dall-e-3.

21. Labs B. F. FLUX.1: Unified Image Generation. — 2024. — arXiv:2407.12697.

22. Silero Models: Pre-trained Enterprise-Grade Speech Models. — дата обращения: 01.04.2025. URL: https://github.com/snakers4/silero-models.

23. ElevenLabs Multilingual v2 Documentation. — дата обращения: 01.04.2025. URL: https://elevenlabs.io/docs.

24. Molenda M. In Search of the Elusive ADDIE Model // Performance Improvement. — 2003. — Vol. 42, no. 5. — P. 34–36.

25. Allen M. W. Leaving ADDIE for SAM: An Agile Model for Developing the Best Learning Experiences. — Alexandria : ASTD Press, 2012.

26. Wiggins G., McTighe J. Understanding by Design. — 2nd ed. — Alexandria : ASCD, 2005.

27. Taxonomy of Educational Objectives: The Classification of Educational Goals. Handbook 1: Cognitive Domain / B. S. Bloom [et al.]. — New York : David McKay Company, 1956.

28. Bryar C., Carr B. Working Backwards: Insights, Stories, and Secrets from Inside Amazon. — 2021. — St. Martin's Press.

29. Competing Against Luck: The Story of Innovation and Customer Choice / C. M. Christensen [et al.]. — Harper Business, 2016.

30. Align with Taxonomies. — дата обращения: 14.04.2026. URL: https://www.monash.edu/learning-teaching/TeachHQ/Teaching-practices/learning-outcomes/how-to/align-with-taxonomies.

31. Hess K. A Guide for Using Webb's Depth of Knowledge with Common Core State Standards. — 2013. — дата обращения: 14.04.2026. URL: https://portal.ct.gov/-/media/sde/mbl/documents/webbs$_{d}epth_{o}f_{k}nowledge.pdf$.

32. Aligning Teaching for Constructing Learning. — дата обращения: 14.04.2026. URL: https://www.advance-he.ac.uk/knowledge-hub/aligning-teaching-constructing-learning.

33. Quality Matters Higher Education Rubric. — дата обращения: 14.04.2026. URL: https://www.qualitymatters.org/qa-resources/rubric-standards/higher-ed-rubric.

34. Fink's Significant Learning Outcomes. — дата обращения: 14.04.2026. URL: https://www.buffalo.edu/catt/teach/develop/design/learning-outcomes/finks.html.

35. Chi M. T. H., Wylie R. The ICAP Framework: Linking Cognitive Engagement to Active Learning Outcomes // Educational Psychologist. — 2014. — Vol. 49, no. 4. — P. 219–243. — DOI: 10.1080/00461520.2014.965823.

36. CAST. CAST Universal Design for Learning Guidelines version 3.0. — 2024. — дата обращения: 14.04.2026. URL: https://udlguidelines.cast.org.

37. Bandura A. Guide for Constructing Self-Efficacy Scales // Self-Efficacy Beliefs of Adolescents / ed. by F. Pajares, T. Urdan. — Information Age Publishing, 2006. — P. 307–337.

38. Perceived Competence Scales. — дата обращения: 14.04.2026. URL: https://selfdeterminationtheory.org/perceived-competence-scales/.

39. The Kirkpatrick Model. — дата обращения: 14.04.2026. URL: https://www.kirkpatrickpartners.com/the-kirkpatrick-model/.

40. Evidence to Support the Use of the Retrospective Pretest Method to Measure Dietary and Physical Activity Behavior and Self-Efficacy in Adolescents / M. K. Shilts [et al.] // Journal of Youth Development. — 2008. — Vol. 3, no. 1. — DOI: 10.5195/jyd.2008.326.

41. Goal Attainment Scaling: A Framework for Research and Practice in the Intellectual and Developmental Disabilities Field / K. A. Shogren [et al.] // Intellectual and Developmental Disabilities. — 2021. — Vol. 59, no. 1. — P. 7–21. — DOI: 10.1352/1934-9556-59.1.7.

42. LangGraph Documentation. — дата обращения: 01.04.2025. URL: https://langchain-ai.github.io/langgraph.

43. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation / Q. Wu [et al.] // Proceedings of ICLR 2024 Workshop LLM Agents. — 2024.

44. CrewAI Documentation. — дата обращения: 01.04.2025. URL: https://docs.crewai.com.

45. Agno Framework Documentation. — дата обращения: 01.04.2025. URL: https://docs.agno.com.

46. OpenAI Agents SDK Documentation. — дата обращения: 01.04.2025. URL: https://platform.openai.com/docs/agents.

47. Haystack 2.x Documentation. — дата обращения: 15.03.2025. URL: https://docs.haystack.deepset.ai/docs/intro.

48. Team D. P. USER-bge-m3: Universal Sentence Encoder for Russian. — дата обращения: 01.04.2025. URL: https://huggingface.co/deepvk/USER-bge-m3.

49. Qdrant Vector Database Documentation. — дата обращения: 01.04.2025. URL: https://qdrant.tech/documentation.

50. LangSmith Documentation. — дата обращения: 01.04.2025. URL: https://docs.smith.langchain.com.

51. Adapstory GitOps Repository. — дата обращения: 01.04.2025. URL: https://github.com/Stepan5024/Adapstory-GitOps.

52. Федеральный закон от 27 июля 2006 г. № 152-ФЗ «О персональных данных». — 2006. — М.: Собрание законодательства РФ, 2006.

53. Brooke J. SUS: A «Quick and Dirty» Usability Scale // Usability Evaluation in Industry / ed. by P. W. Jordan [et al.]. — London : Taylor & Francis, 1996. — P. 189–194.

54. Experimentation in Software Engineering / C. Wohlin [et al.]. — Berlin : Springer, 2012.

55. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena / L. Zheng, W. L. Chiang, Y. Sheng, [et al.]. — 2023. — arXiv:2306.05685.

56. Maurya A. Running Lean: Iterate from Plan A to a Plan That Works. — Sebastopol : O'Reilly Media, 2012.

57. Гражданский кодекс Российской Федерации. Часть четвёртая: Права на результаты интеллектуальной деятельности и средства индивидуализации. — 2006. — М.: Собрание законодательства РФ, 2006.

ПРИЛОЖЕНИЕ. А ГАЙД ДЛЯ CUSTOMER DEVELOPMENT ИНТЕРВЬЮ

В приложении представлен гайд для проведения глубинных B2B-интервью по методу Mom Test [4], использовавшийся при сборе первичных данных о проблеме (раздел 1.1 основного текста).

Контекст и цели интервью

Цель: валидировать гипотезу о проблеме «Разработка образовательных курсов занимает слишком много времени и/или требует компетенций, которых нет у эксперта предметной области».

Целевая аудитория: HR-специалисты, L&D-менеджеры, методисты, тренеры в B2B-компаниях с > 50 сотрудников.

Формат: 30–45 минут, видеозвонок или очно.

Вопросы гайда

Блок 1. Разогрев и контекст:

1) Расскажите о своей роли. Как часто вам приходится создавать учебные материалы для сотрудников?
2) Какой последний курс или материал вы разрабатывали? Вспомните этот процесс — с чего он начался?
3) Сколько времени ушло от идеи до готового материала?

Блок 2. Проблема:

4) Что в этом процессе было самым сложным или утомительным?
5) Были ли случаи, когда вы *не смогли* создать нужный материал из-за нехватки времени, ресурсов или экспертизы?
6) Как часто учебные материалы устаревают и требуют обновления? Как вы сейчас с этим справляетесь?

Блок 3. Текущие решения:

7) Какие инструменты или сервисы вы уже пробовали для автоматизации разработки курсов? Что не устроило?
8) Если бы вы могли потратить бюджет на решение этой проблемы — на что бы потратили?

Блок 4. Закрытие:

9) Есть ли коллеги, которых стоит поговорить на эту тему?
10) Можно ли мне прислать вам краткий обзор после того, как я поговорю с ещё несколькими людьми?

Сводка ключевых инсайтов

По результатам 20 проведённых интервью наиболее устойчивыми оказались следующие сигналы:

Таблица А.1 — Агрегированные выводы Customer Development интервью

Наблюдение	**Значение**	**Интерпретация**
Время разработки — главный pain-point	70 %	проблема носит не единичный, а системный характер
Используют подрядчиков / внешних методистов	50 %	рынок уже готов платить за снижение этой нагрузки
Готовы рассмотреть AI-инструмент	60 %	есть ранний сигнал problem/solution interest
Формат исследования	20 интервью	глубинные B2B CustDev-интервью по методу Mom Test

– Наибольшую ценность респонденты видят не в полной автоматизации, а в ускорении подготовки первого черновика курса.
– Для compliance- и регламентных сценариев критична прослеживаемость к источнику и возможность human-review.
– Для B2B-сегмента значимы суверенитет данных и возможность on-premise развёртывания.

ПРИЛОЖЕНИЕ. Б АРТЕФАКТЫ РЕШЕНЧЕСКИХ ИНТЕРВЬЮ

В приложении представлен сценарий демонстрации MVP и структура решенческого интервью, которая используется для следующего этапа Problem/Solution Fit validation.

Сценарий демонстрации

Текущий demo-flow строится вокруг одного реального документа B2B-заказчика и показывает пользователю не абстрактную презентацию, а последовательность шагов внутри продукта:

1) загрузка исходного документа;
2) выбор методологии генерации (ADDIE как текущий базовый вариант);
3) получение и ревью черновой структуры курса;
4) обсуждение, какие части пользователь оставил бы за собой, а какие готов делегировать системе;
5) обсуждение готовности применить инструмент на реальном документе компании.

Вопросы после демонстрации

1) Насколько результат соответствует тому, что вы ожидали?
2) Что бы вы изменили в сгенерированной структуре?
3) Готовы ли вы использовать такой инструмент вместо текущего процесса?
4) Готовы ли вы загрузить в систему документ своей организации?
5) Какой формат внедрения для вас приемлем: SaaS, on-premise, pilot на ограниченном наборе документов?

Критерии успеха решенческого интервью

Таблица Б.1 — Сигналы, фиксируемые на этапе решенческих интервью

Критерий	**Позитивный сигнал**	**Что это подтверждает**
Готовность заменить текущий процесс	пользователь допускает частичную замену ручной работы	наличие прикладной ценности, а не просто любопытства
Готовность к реальному документу	пользователь согласен тестировать систему на своём материале	переход от demo-interest к рабочему сценарию
Обсуждение формата внедрения	появляется запрос на pilot, on-premise или ограниченный rollout	рост зрелости product signal
Экономическая логика	пользователь сравнивает решение с подрядчиком / внутренним ресурсом	наличие бизнес-контекста для дальнейшего MVP

ПРИЛОЖЕНИЕ. В ШАБЛОН ПИСЬМА О ГОТОВНОСТИ К ПИЛОТУ (LOI)

На момент подготовки текущего черновика подписанные LOI ещё не собраны. В приложении фиксируется рабочий шаблон письма, который используется на следующем этапе коммерческой валидации.

Шаблон письма

Настоящим письмом _____ подтверждает интерес к участию в ограниченном пилотном тестировании ИИ-методиста платформы Adapstory.

Организация готова рассмотреть pilot-stage при следующих условиях:

– использование 1–3 реальных документов организации;
– ограниченный круг пользователей;
– согласование требований по конфиденциальности и формату доступа;
– совместный review результатов пилота.

Данное письмо не является окончательным коммерческим обязательством, но подтверждает готовность перейти к детальному обсуждению пилота.

Что считается валидным LOI-сигналом

– письмо исходит от лица, принимающего решение, или владельца процесса;
– в письме указана готовность дать реальный документ для пилота;
– зафиксирован следующий шаг: созвон, демонстрация, юридическое согласование или выделение pilot-owner со стороны заказчика.

ПРИЛОЖЕНИЕ. Г C4-ДЕКОМПОЗИЦИЯ АРХИТЕКТУРЫ

В приложении представлена текстовая C4-декомпозиция архитектуры ИИ-методиста. На этапе черновика она заменяет финальные визуальные диаграммы и фиксирует состав системы в форме, достаточной для архитектурного обсуждения.

Г.1 — Системный контекст (C4 Level 1)

- **Автор курса / HR-специалист**: загружает документ, запускает генерацию, ревьюит структуру курса;
- **BFF School**: маршрутизирует запросы веб-клиента;
- **ИИ-методист**: выполняет ingestion, анализ документа, генерацию структуры и контента;
- **LMS Adapstory**: принимает итоговый курс и публикует его;
- **MinIO**: хранит исходные документы и медиа;
- **Ollama / GPU-узел**: обслуживает локальные LLM и media-модели;
- **Qdrant**: хранит векторный индекс для retrieval.

Г.2 — Контейнеры (C4 Level 2)

Г.3 — Компоненты (C4 Level 3)

- **Document parser**: преобразует PDF/DOCX/PPTX/XLSX в текст;
- **Chunker + embedder**: формирует индексируемые фрагменты;
- **CourseStructureAgent**: генерирует blueprint курса;
- **ContentCreatorAgent**: формирует тексты уроков;
- **FactCheckAgent**: проверяет фактические утверждения;
- **Review / HITL layer**: обеспечивает human-in-the-loop контроль;
- **Exporter**: публикует результат в LMS Adapstory.

Таблица Г.1 — Контейнерная декомпозиция ИИ-методиста

Контейнер	**Технология**	**Роль**
API Gateway	FastAPI	входная точка для BFF и оркестрация запросов
Async workers	Celery	асинхронное выполнение ingestion и generation задач
Agent runtime	LangGraph	исполнение stateful agent workflow
Ingestion pipeline	Haystack 2.x	извлечение, очистка, чанкинг и индексация документов
LLM Gateway	Python service	единый доступ к Qwen / внешним провайдерам
Vector storage	Qdrant	поиск релевантных фрагментов для RAG

ПРИЛОЖЕНИЕ. Д СПЕЦИФИКАЦИЯ ГРАФА АГЕНТОВ LANGGRAPH

В приложении представлена текстовая спецификация графа агентов ИИ-методиста: ноды, основные переходы и точки human-in-the-loop.

Д.1 — Ноды графа

Таблица Д.1 — Ноды графа агентов ИИ-методиста

Нода	**Тип**	**Описание**
target_analysis	agent	Анализ целевой аудитории и контекста использования курса
course_structure	agent	Генерация структуры курса по выбранной методологии
human_review	interrupt	Ручное подтверждение или коррекция структуры
content_creator	agent	Генерация уроков с использованием retrieval
fact_check	agent	Проверка утверждений относительно исходного документа
media_gen	agent	Иллюстрации и TTS-материалы
final_review	agent	Итоговая проверка качества и сборка отчёта

Д.2 — Основные переходы

Д.3 — Human-in-the-loop точки

- подтверждение структуры курса перед генерацией полного контента;
- ручной review спорных fact-check кейсов;
- финальное решение о публикации курса в LMS.

Таблица Д.2 — Ключевые переходы в графе LangGraph

Откуда	**Куда**	**Условие перехода**
target_analysis	course_structure	исходный документ разобран и аудитория определена
course_structure	human_review	blueprint построен и доступен для проверки
human_review	content_creator	структура утверждена пользователем
content_creator	fact_check	уроки сгенерированы и требуют верификации
fact_check	media_gen	фактологический порог пройден
media_gen	final_review	медиаартефакты готовы
final_review	export	итоговый пакет курса признан валидным

ПРИЛОЖЕНИЕ. Е ПРОМПТ-ШАБЛОНЫ ADDIE / SAM / BACKWARD DESIGN

В приложении представлены черновые системные промпты агента `CourseStructureAgent` для трёх поддерживаемых методологических режимов. Они служат не как неизменяемые финальные промпты, а как управляемые рамки для дальнейшей настройки.

Е.1 — Промпт-шаблон ADDIE

[SYSTEM]

Ты — эксперт по методологии ADDIE разработки учебных курсов. Твоя задача: на основе предоставленного документа создать структуру курса, следуя фазам ADDIE.

Требования:

- каждый модуль должен содержать учебные цели по таксономии Блума;
- формат ответа — строго JSON (`CourseBlueprint`);
- не придумывай факты, которых нет в документе;
- если данных недостаточно, явно помечай неопределённость.

[USER]

Документ: `{{document_text}}`
Целевая аудитория: `{{audience_profile}}`

Е.2 — Промпт-шаблон SAM

[SYSTEM]

Ты — эксперт по Successive Approximation Model. Построй курс как итеративный blueprint, который удобно быстро проверять и дорабатывать короткими циклами.

Требования:

- сначала предложи минимально жизнеспособную структуру курса;
- явно выделяй части, которые требуют human review;
- держи фокус на скорости и возможности быстрой итерации;
- формат ответа — JSON (`CourseBlueprint`).

[USER]

Документ: `{{document_text}}`
Целевая аудитория: `{{audience_profile}}`

E.3 — Промпт-шаблон Backward Design

[SYSTEM]

Ты — эксперт по Backward Design. Начинай проектирование курса с конечных результатов обучения, а затем выстраивай модули, оценивание и учебные активности назад от целей.

Требования:

- сначала сформулируй измеримые learning outcomes;
- для каждого outcome укажи, как он будет проверяться;
- затем предложи модули и уроки, которые ведут к этим outcome;
- формат ответа — JSON (`CourseBlueprint`).

[USER]

Документ: `{{document_text}}`

Целевая аудитория: `{{audience_profile}}`

ПРИЛОЖЕНИЕ. Ж ТЕСТОВЫЙ ДАТАСЕТ

В приложении описана структура ядрового корпуса, использовавшегося для оценки качества ИИ-методиста (раздел 2.1 основного текста).

Описание корпуса

Таблица Ж.1 — Состав ядрового датасета (16 документов)

#	Тип документа	Объём (стр.)	Язык	Тематика
1	Продуктовое описание	12	RU	Brand Guidelines v2.1 (Adapstory)
2	Продуктовое описание	18	RU	Гайд по маскоту Адаптик (Adapstory)
3	Продуктовое описание	11	RU	Гайд по мерчу (Adapstory)
4	Продуктовое описание	12	RU	Редакционная политика (Adapstory)
5	Продуктовое описание	15	RU	Стилевая рамка бизнес-сегмента (Adapstory)
6	Продуктовое описание	10	RU	Стили HR-бренда (Adapstory)
7	Технический регламент	5	RU	Политика информационной безопасности
8	Технический регламент	4	RU	Политика обработки персональных данных
9	Технический регламент	6	RU	Регламент управления ИТ-инцидентами
10	Технический регламент	5	RU	Положение об адаптации сотрудников
11	Технический регламент	8	RU	Антикоррупционная политика организации
12	Учебная программа	5	EN	MIT 6.0001 — Introduction to CS and Python
13	Учебная программа	7	EN	MIT 18.01 — Single Variable Calculus

#	Тип документа	Объём (стр.)	Язык	Тематика
14	Учебная программа	6	EN	MIT 6.042J — Mathematics for Computer Science
15	Учебная программа	5	EN	MIT 14.01 — Principles of Microeconomics
16	Учебная программа	5	EN	MIT 8.01 — Classical Mechanics

Корпус сбалансирован по трём сценариям применения ИИ-методиста: документы 1–6 соответствуют сценарию онбординг-курса, документы 7–11 — сценарию compliance-курса, документы 12–16 — сценарию асинхронного учебного курса.

Дополнительные открытые источники

В качестве расширенного референсного массива собраны дополнительные открытые учебные материалы:

– **Anthropic Academy / Skilljar**: 16 курсов;
– **OpenEdu.ru**: 5 курсов российских вузов;
– **HuggingFace Learn**: 12 курсов по ML/AI;
– **Telegram-курсы**: 2 бота-симулятора как примеры ролевого сценарного обучения.

Оценочные артефакты следующей итерации

На текущем этапе полностью подготовлены:

– ядровой корпус из 16 документов;
– набор из 30 QA-пар для RAG evaluation;
– набор из 100 утверждений для fact-check evaluation.

Экспертный ground truth для слепого сравнения конфигураций B1–B4 оформлен как следующий этап исследования и в текущем черновике не представляется как завершённый измеренный результат.

ПРИЛОЖЕНИЕ. И ОЦЕНОЧНЫЕ АРТЕФАКТЫ И ТЕКУЩИЕ РЕЗУЛЬТАТЫ

В приложении собраны те артефакты валидации, которые уже подготовлены или измерены в текущей редакции диплома.

И.1 — Агрегированные результаты baseline B2

Таблица И.1 — Агрегированные результаты one-shot baseline B2

Срез корпуса	n	**Bloom, %**	**Доля** $\geq 70\%$
Все документы	16	61.5	18.8%
Продуктовые документы	6	75.0	33.3%
Регламенты	5	40.0	0%
Учебные программы	5	66.7	20.0%

И.2 — Подготовленные benchmark assets

Таблица И.2 — Оценочные наборы текущего MVP

Артефакт	**Объём**	**Назначение**
Ядровой корпус документов	16	генерация курсов и сравнение baseline-подходов
QA-пары (`qa_pairs.json`)	30	оценка faithfulness и answer relevancy
Фактуальные утверждения (`statements.json`)	100	расчёт precision / recall / F1 для fact-check

И.3 — Экспертная и пользовательская валидация: статус

На момент подготовки текущего черновика:

– шаблон слепой экспертной оценки подготовлен, но таблицы B1–B4 ещё не заполнены измеренными значениями;
– pilot-протокол с метриками SUS / NPS сформирован, но не представляется как завершённый численный результат;

– приложение фиксирует именно *готовность контуров оценки*, а не выдаёт незавершённые измерения за готовый benchmark.

ПРИЛОЖЕНИЕ. К LEAN CANVAS И ФИНАНСОВАЯ МОДЕЛЬ

В приложении представлены Lean Canvas и сценарные расчёты финансовой модели ИИ-методиста (раздел 4.4 основного текста).

К.1 — Lean Canvas

В текущем черновике Lean Canvas представлен в табличной форме.

Таблица К.1 — Lean Canvas ИИ-методиста

Проблема	**Решение**	**Уникальное предложение**
Создание 1 часа обучения может занимать 73–490 часов работы методиста; высокая стоимость подрядчиков; устаревание контента	Автоматическая генерация структуры и текстов курса по загруженному документу, human-in-the-loop review, механизм последующей актуализации	Сочетание методологической вариативности, суверенитета данных (on-premise LLM) и глубокой интеграции в LMS-экосистему
Несправедливое преимущество	**Ключевые метрики**	**Каналы**
ADDIE / SAM / BD как переключаемые режимы; локальный LLM-контур; экосистема LMS Adapstory	Time-to-draft; Bloom coverage; faithfulness; unit-cost/курс	Прямые продажи B2B; партнёрства с HR/L&D-платформами; EdTech-конференции и контент-маркетинг
Сегменты потребителей		**Структура затрат / доходов**
B2B: HR-отделы, L&D-команды, корпоративные университеты, учебные центры и EdTech-компании		Затраты: GPU-инфраструктура, разработка, поддержка. Доходы: B2B-подписка / pilot-проекты, unit-cost ≈ 75 руб./курс

К.2 — Сценарные финансовые показатели

К.3 — Допущения модели

– модель носит сценарный характер и не заменяет реальные pilot-данные;

Таблица К.2 — Ключевые показатели финансовой модели

Показатель	**Значение**	**Комментарий**
Себестоимость генерации курса	75 руб.	прямой инфраструктурный cost per course
Отношение к подрядной разработке	0.05 %	при ориентире ручной разработки около 150 000 руб.
CAC	30 000 руб.	вычисляется из LTV / CAC = 10
LTV	300 000 руб.	сценарная lifetime value модель
Payback period	2 мес.	быстрый возврат затрат в модели
NPV	1 806 514 руб.	сценарный прогноз на 3 года
IRR	32.19 %	внутренняя норма доходности
ROI (3 года)	42.15 %	возврат инвестиций в горизонте модели
Точка безубыточности	14 клиентов / 32 мес.	ориентир коммерческой устойчивости

– расчёт подтверждает прежде всего то, что выбранная архитектура не делает продукт заведомо экономически неустойчивым;
– все коммерческие выводы должны быть дополнительно подтверждены решенческими интервью, LOI-stage и реальными внедрениями.

ПРИЛОЖЕНИЕ. Л ПЕРЕЧЕНЬ ЭКРАНОВ MVP И ДЕМО-СЦЕНАРИЙ

В текущем черновике вместо финальных скриншотов интерфейса приводится описание ключевых экранов MVP. Такой формат позволяет зафиксировать пользовательский сценарий даже до завершения визуальной полировки UI.

Л.1 — Экран загрузки документа

Экран содержит drag&drop область, перечень поддерживаемых форматов (`pdf`, `docx`, `pptx`, `xlsx`) и индикатор статуса обработки файла. Пользователь выбирает исходный документ, который далее передаётся в Document Ingestion Pipeline.

Л.2 — Экран выбора методологии и параметров

На этом шаге пользователь задаёт методологию проектирования курса (ADDIE, в следующих итерациях — SAM и Backward Design), целевую аудиторию и контекст использования курса.

Л.3 — Ревью сгенерированной структуры курса

После построения blueprint пользователь видит структуру модулей, уроки и учебные цели. На этом экране реализован human-in-the-loop контроль: структуру можно принять, скорректировать или вернуть на итерацию.

Л.4 — Финальный курс в LMS Adapstory

Финальный артефакт публикуется в LMS Adapstory как курс, готовый к дальнейшему наполнению, проверке и использованию внутри корпоративной образовательной среды.

Л.5 — Демо-сценарий

1) загрузить реальный B2B-документ;
2) выбрать методологию ADDIE;
3) дождаться генерации структуры;

4) провести human-review blueprint;
5) обсудить с потенциальным пользователем, где решение даёт наибольшую ценность и какие риски остаются.