

СОДЕРЖАНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ	9
ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	11
ВВЕДЕНИЕ	12
1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И ПОСТАНОВКА ЗАДАЧИ ..	16
1.1 Проблема и её масштаб	16
1.1.1 Болевые точки авторов курсов	16
1.1.2 Разрыв между экспертизой и образовательной упаковкой	17
1.1.3 Подтверждение проблемы: результаты исследования клиентов	17
1.1.4 Решенческие интервью и критерии решения	18
1.1.5 Рыночный контекст: TAM / SAM / SOM	18
1.2 Анализ существующих продуктов	19
1.2.1 Прямые конкуренты	19
1.2.2 Смежные решения	20
1.2.3 Сравнительная матрица	20
1.2.4 Пробел между проблемой и существующими решениями	21
1.2.5 Тяжелокопируемые конкурентные преимущества	23
1.3 Обзор научных методов и подходов	26
1.3.1 Формулировка исследовательского вопроса	26
1.3.2 LLM для поддержки проектирования образовательных материалов	26
1.3.3 Мультиагентные системы для поддержки проектирования курса	27
1.3.4 RAG в образовании	27
1.3.5 Генерация мультимедиа для обучения	28
1.3.6 Методологии проектирования курсов в контексте LLM	28
1.3.7 Оценка качества результатов, подготовленных с участием ИИ	28
1.3.8 Идентификация исследовательской лакуны	28

1.4	Постановка задачи и гипотезы	29
1.4.1	Задача исследования	29
1.4.2	Методологическая основа	29
1.4.3	Три конвейера ИИ-методиста	30
1.4.4	Исследовательские гипотезы	30
1.4.5	Метрики проверки гипотез	30
2	ИССЛЕДОВАНИЕ: ЭКСПЕРИМЕНТЫ И ВЫБОР ТЕХНОЛОГИЙ .	32
2.1	Дизайн эксперимента	32
2.1.1	Тестовый корпус и оценочные артефакты	32
2.1.2	Конфигурации эксперимента и расшифровка B1–B4....	33
2.1.3	Метрики оценки	34
2.1.4	Расширенная педагогическая и пользовательская рамка	34
2.2	Выбор и обоснование технологий	35
2.2.1	Фреймворк мультиагентной оркестрации.....	35
2.2.2	Выбранная архитектура	37
2.2.3	Большая языковая модель.....	38
2.2.4	Поиск, векторные представления и граф знаний.....	39
2.2.5	Стратегии разбиения документов на фрагменты.....	40
2.2.6	Перспективное развитие генерации изображений	40
2.2.7	Перспективное развитие генерации подкастов.....	41
2.3	Проверенные результаты экспериментов	41
2.3.1	Результаты одношаговой LLM-конфигурации (B2).....	41
2.3.2	Сравнение LLM-конфигурации (B2) и ИИ-методиста (B4)	44
2.3.3	Оценочные наборы для RAG и проверки фактов	45
2.3.4	Сценарная экономика единицы продукта MVP	46
2.3.5	Ограничения этапа и план исследования	46
2.3.6	Финальная MVP-конфигурация	47
3	ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ	49
3.1	Архитектура системы	49
3.1.1	Контекстная диаграмма (C4 Level 1)	49
3.1.2	Диаграмма контейнеров (C4 Level 2).....	49
3.1.3	Доменная модель	50

3.2	Мультиагентная система (LangGraph).....	51
3.2.1	Граф агентов.....	51
3.2.2	Ноды конвейера	51
3.2.3	Управление состоянием и участие человека в контуре ..	53
3.3	Ключевые конвейеры.....	53
3.3.1	Обработка источника и поиск	53
3.3.2	Подготовка черновика курса	54
3.3.3	Метка качества, прослеживаемость и валидация ВКР ..	54
3.3.4	Компоненты плана развития.....	56
3.4	Инфраструктура и развёртывание	56
3.4.1	Стенд для тестирования и промышленной эксплуатации	56
3.4.2	Наблюдаемость и проверяемость	56
4	ВАЛИДАЦИЯ, ИМПАКТ И БИЗНЕС-ОЦЕНКА	57
4.1	Протокол валидации.....	57
4.1.1	Автоматизированная оценка.....	57
4.1.2	Критерии контроля качества	57
4.1.3	Лабораторная апробация MVP	58
4.2	Сквозная верификация	58
4.2.1	Сценарий 1: Онбординг-курс (ADDIE)	58
4.2.2	Сценарий 2: Нормативный курс с проверкой фактов....	59
4.2.3	Сценарий 3: Автоактуализация	59
4.3	Текущие результаты и проверка гипотез.....	59
4.3.1	Сводка фактически подтверждённых результатов	59
4.3.2	Проверка гипотез Н1–Н3	60
4.3.3	Производительность.....	61
4.3.4	Точность проверки фактов.....	61
4.4	Ограничения исследования и угрозы валидности	62
4.4.1	Ограничения тестового набора данных	62
4.4.2	Ограничения эталонного корпуса.....	63
4.4.3	Ограничения пользовательской валидации	63
4.4.4	Ограничения технологического стека	63
4.4.5	Угрозы внешней валидности	64
4.4.6	Направления для устранения ограничений	64
4.5	Бизнес-оценка и масштабирование	64

4.5.1	Экономика единицы продукта.....	64
4.5.2	Lean Canvas	65
4.5.3	Финансовая модель (прогноз на 3 года)	65
4.5.4	Потенциал масштабирования	66
4.5.5	PESTLE-анализ при масштабировании	67
4.5.6	Оценка рисков	67
4.5.7	Дорожная карта	67
4.5.8	Интеллектуальная собственность	69
4.6	Степень готовности и обратная связь от рынка	69
4.6.1	Текущий статус MVP	69
4.6.2	Рыночные сигналы	69
4.6.3	Соответствие решения проблеме	69
4.6.4	Качественная обратная связь	69
ЗАКЛЮЧЕНИЕ		73
Использование ИИ и личный вклад автора		76
Использование ИИ-инструментов		76
Личный вклад автора		76
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ		77
А РУКОВОДСТВО ДЛЯ ИНТЕРВЬЮ С КЛИЕНТАМИ		83
Б АРТЕФАКТЫ ДЕМОНСТРАЦИИ MVP		85
В ПРОТОКОЛ ВНУТРЕННЕЙ И ОТКРЫТОЙ АПРОБАЦИИ		87
Г С4-ДЕКОМПОЗИЦИЯ АРХИТЕКТУРЫ		88
Д СПЕЦИФИКАЦИЯ ГРАФА АГЕНТОВ LANGGRAPH		90
Е ШАБЛОНЫ ЗАПРОСОВ ADDIE / SAM / BACKWARD DESIGN		93
Ж ТЕСТОВЫЙ КОРПУС ДОКУМЕНТОВ		95
И ОЦЕНОЧНЫЕ АРТЕФАКТЫ И ТЕКУЩИЕ РЕЗУЛЬТАТЫ.....		97

К	LEAN CANVAS И ФИНАНСОВАЯ МОДЕЛЬ	102
Л	МАТРИЦА ВОСПРОИЗВОДИМОСТИ MVP	105

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

ADDIE	— Analyze, Design, Develop, Implement, Evaluate (методология проектирования курсов)
API	— Application Programming Interface (интерфейс программирования приложений)
B2B	— Business-to-Business (бизнес-модель)
BD	— Backward Design (методология «обратного проектирования» курса)
BFF	— серверный слой для веб-клиента (Backend-for-Frontend)
CAC	— Customer Acquisition Cost (стоимость привлечения клиента)
CI/CD	— Continuous Integration / Continuous Delivery (непрерывная интеграция и доставка)
CVM	— Customer Value Management (управление ценностью клиента)
DAG	— Directed Acyclic Graph (ориентированный ациклический граф)
GPU	— Graphics Processing Unit (графический процессор)
IRR	— Internal Rate of Return (внутренняя норма доходности)
JTBD	— Jobs To Be Done (методология исследования потребностей)
KPI	— Key Performance Indicator (ключевой показатель эффективности)
LLM	— Large Language Model (большая языковая модель)
LMS	— Learning Management System (система управления обучением)
LTV	— Lifetime Value (пожизненная ценность клиента)

MVP	— Minimum Viable Product (минимально жизнеспособный продукт)
NPS	— Net Promoter Score (индекс потребительской лояльности)
NPV	— Net Present Value (чистая приведённая стоимость)
RAG	— Retrieval-Augmented Generation (генерация с дополнением поиском)
REST	— Representational State Transfer (архитектурный стиль API)
ROI	— Return on Investment (рентабельность инвестиций)
SAM	— Successive Approximation Model (итеративная методология проектирования курсов)
SAM	— Serviceable Addressable Market (доступный рынок) [в контексте рыночного анализа]
SOM	— Serviceable Obtainable Market (реально достижимый рынок)
SUS	— System Usability Scale (шкала удобства использования системы)
TAM	— Total Addressable Market (общий доступный рынок)
TTS	— Text-to-Speech (синтез речи)
ВКР	— выпускная квалификационная работа
ИИ	— искусственный интеллект
ИС	— интеллектуальная собственность
ЛМС	— система управления обучением (эквивалент LMS)
ЛПР	— лицо, принимающее решения

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

Классификация	— процесс распределения объектов по категориям на основе их признаков
Нейронная сеть	— математическая модель, имитирующая работу мозга, используемая для решения задач распознавания и классификации
Обучающая выборка	— совокупность данных, используемых для настройки параметров модели машинного обучения

ВВЕДЕНИЕ

Большие языковые модели (LLM) всё активнее применяются для автоматизации рутинных операций при проектировании образовательных материалов. Мировой рынок корпоративного обучения, по оценкам аналитических агентств, превысит \$51 млрд к 2030 году [1]. Главный сдерживающий фактор роста — высокая стоимость и длительность создания качественного учебного контента. Средний цикл разработки одного корпоративного курса силами методиста-эксперта составляет от нескольких дней до нескольких недель и требует педагогических компетенций, которыми не всегда обладают эксперты предметной области.

Существующие ИИ-инструменты для ускоренной подготовки курсов (Coursebox AI, iSpring AI) сильны как средства разработки курса: они помогают получить структуру, тестовые задания, визуальные материалы, перевод или SCORM/LMS-экспорт, однако в открытых продуктовых материалах для них не заявлена воспроизводимая цепочка артефактов: привязка к источнику, происхождение блоков, проверка фактов, знак качества и парное сравнение с одношаговой базовой конфигурацией. Мультиагентные LLM-конвейеры для решения этой задачи остаются малоизученными: отсутствуют систематические сравнения архитектур на воспроизводимом российском корпусе документов и внешнем зарубежном сравнительном контуре, а также воспроизводимые контрольные наборы с привязкой не только к таксономии Блума, но и к согласованности курса, качеству онлайн-курса и переносу обучения в практику.

Объект исследования — образовательная платформа Adap-story (AI LMS), предоставляющая инструменты создания и управления учебными курсами для B2B-клиентов.

Предмет исследования — микросервис ИИ-методист: интеллектуальный проактивный методический ассистент, поддерживающий методиста, эксперта и разработчика курса при создании, упаковке и актуализации образовательных продуктов на основе LLM с применением мультиагентной оркестрации.

Цель работы — разработать MVP интеллектуального методического

ассистента платформы Adapstory и воспроизводимый контур его технической и продуктовой валидации, показывающий, насколько мультиагентная обработка внутренних и открытых учебных документов способна снизить рутинную нагрузку при подготовке структуры и черновых материалов курса при сохранении за человеком методического решения и контроля качества.

Для достижения цели поставлены следующие задачи:

- 1) провести анализ предметной области: исследование клиентов с B2B-аудиторией, продуктовый обзор конкурентов и систематический обзор научных подходов;
- 2) оценить рыночный потенциал решения (TAM/SAM/SOM) и сформулировать исследовательские гипотезы;
- 3) спроектировать мультиагентную архитектуру конвейера поддержки проектирования курсов и обосновать выбор технологического стека через воспроизводимые эксперименты;
- 4) реализовать систему: FastAPI-микросервис AI Course Generator, граф агентов LangGraph, интеграцию с Dify/RAG-контуром, графом знаний и сохранением состояния в PostgreSQL;
- 5) провести валидацию системы: автоматизированную оценку времени генерации, покрытия уровней таксономии Блума, привязки к источнику, проверки фактов и экономики единицы продукта на внутреннем и открытом корпусе;
- 6) оценить бизнес-потенциал: экономику единицы продукта, финансовую модель и провести исследование клиентов для подтверждения соответствия решения выявленной проблеме.

Научная новизна работы состоит в следующем: предложена и инженерно реализована воспроизводимая схема проверки мультиагентного ИИ-методиста для проектирования учебных курсов, сочетающая (1) исполняемую методологическую модель проектирования курса в первой реализации ADDIE, (2) графовую оркестрацию LangGraph с двумя точками участия человека, (3) RAG/KG-контур с опорой на источник, таблицу свидетельств, проверку фактов, знак качества и запись происхождения результата каждого запуска. Уникальность решения не сводится к применению LLM: в отличие от Coursebox AI, iSpring AI, NotebookLM и одношаговой LLM-конфигурации (B2), система проектирует

курс как проверяемый методический конвейер, где каждый блок результата связан с исходным документом, проходит автоматический контроль качества и сохраняется как воспроизводимый доказательный артефакт для последующей проверки человеком. Тяжелокопируемые конкурентные преимущества решения раскрыты через таблицу 1.2: сравнение построено не по лозунгам, а по проверяемым механизмам доверия, проверки и повторяемости результата.

Положения, выносимые на защиту:

- 1) Одношаговая LLM-конфигурация (B2) на измеренном корпусе из 19 документов генерирует структуру курса в среднем за 4.37 с, но достигает только 61.4 % среднего покрытия уровней таксономии Блума и не создаёт ссылок на источник; это обосновывает переход к мультиагентной архитектуре.
- 2) Мультиагентная шестиузловая архитектура LangGraph (source_analyzer -> course_structure -> content_creator -> fact_check -> review -> verifier) вводит таблицу свидетельств, проверку фактов, знак качества, прослеживаемость результата и две точки проверки человеком, необходимые для корпоративного курса с опорой на источник. В парном прогоне на том же корпусе ИИ-методист (B4) повысил среднее покрытие Блума до 83.3 % и дал привязку к источнику 100 % при знаке качества PASS в 19 из 19 запусков.
- 3) Исследование клиентов подтвердило наличие проблемы: проведены 20 B2B-интервью, 70 % респондентов называют длительность разработки главным ограничением, 50 % используют подрядчиков или внешних методистов, 60 % готовы рассмотреть ИИ-инструмент такого класса.

Текущее состояние проекта: разработан MVP, включающий контур обработки источников, агентный конвейер поддержки проектирования курса с методологией ADDIE, слой источниковой привязки и прослеживаемости результата, знак качества и ручная проверка. Проведены проблемные B2B-интервью, парный прогон одношаговой LLM (B2) и ИИ-методиста (B4) на 19 документах, детерминированная проверка RAG-показателей и фактологическая проверка, а также сценарная оценка экономики единицы продукта. Партнёрские материалы и закрытые внешние документы

в валидации работы не используются. Важно зафиксировать границу доказательств: $n = 19$ является лабораторной проверкой MVP и инженерной готовности текущего MVP, но этого недостаточно для сильного вывода о превосходстве над аналогами. Следующий контрольный этап — сравнительная проверка на открытых курсах $n \geq 30$ с исходными JSON/CSV-артефактами, базовой ручной оценкой по шкале и отдельной фиксацией ограничений.

Работа состоит из введения, четырёх глав, заключения, раздела об использовании ИИ, списка использованных источников и десяти приложений. Глава 1 содержит анализ предметной области и постановку задачи. Глава 2 описывает дизайн эксперимента и обоснование выбора технологий. Глава 3 посвящена технической реализации системы. Глава 4 содержит результаты валидации, анализ ограничений и бизнес-оценку.

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И ПОСТАНОВКА ЗАДАЧИ

1.1 Проблема и её масштаб

1.1.1 Болевые точки авторов курсов

Разработка корпоративного учебного курса остаётся трудоёмким и слабо масштабируемым процессом. Даже при наличии готового экспертного материала необходимо определить целевую аудиторию, сформулировать учебные цели, разбить содержание на модули и уроки, подобрать формат подачи, подготовить оценочные материалы и синхронизировать всё это с требованиями LMS. По оценке Charman Alliance, производство одного часа eLearning-контента требует от 42 до 490 часов работы в зависимости от сложности сценария, мультимедийности и глубины методической проработки; для большинства практических проектов реалистичный коридор составляет 40–200 часов на один час готового обучения [2].

Для российского B2B-сегмента проблема усугубляется дополнительно.

- **Дефицит методических компетенций.** Эксперт предметной области знает материал, но не всегда умеет переводить знание в педагогически корректную структуру курса. Другой проблемой становится нехватка или перегрузка специалистов в области методики преподавания. У компаний зачастую нет финансовой возможности иметь собственный методический отдел.
- **Высокая стоимость внешней разработки.** На рынке корпоративного обучения разработка одного курса силами подрядчика обычно оценивается в диапазоне 100–300 тыс. руб. за проект, что делает частое обновление контента экономически невыгодным для малого и среднего бизнеса [3].
- **Быстрое устаревание источников.** Регламенты, продуктовые описания и внутренние правила обновляются быстрее, чем команда успевает вручную пересобрать учебные материалы, из-за чего курс быстро расходится с актуальной версией исходного документа.

1.1.2 Разрыв между экспертизой и образовательной упаковкой

В корпоративной среде инициатором курса обычно выступает владелец продукта, руководитель функции, HR или L&D-менеджер. Первый хорошо знает предметную область, второй понимает бизнес-контекст, однако ни один из них не обязательно владеет инструментами педагогическим дизайном на уровне, достаточном для создания масштабируемого цифрового курса.

На практике это проявляется так: черновой материал остаётся на уровне «экспертного конспекта» без явных учебных результатов и уровней освоения. Структура курса строится от имеющихся документов, а не от целей обучения, что снижает практическую ценность. Сопровождение же требует подключения методиста, зачастую не входящего в команду.

1.1.3 Подтверждение проблемы: результаты исследования клиентов

Для первичной проверки гипотез о проблеме проведено 20 глубинных B2B-интервью с HR-специалистами, L&D-менеджерами, методистами и корпоративными тренерами по подходу Mom Test [4]. Руководство интервью, логика кодирования ответов и шаблон таблицы выводов вынесены в приложение А.

Количественные результаты:

- **70 %** респондентов называют время подготовки курса главным ограничением запуска нового обучения;
- **50 %** респондентов уже привлекают внешних подрядчиков или отдельных методистов для упаковки материала;
- **60 %** готовы рассмотреть ИИ-инструмент как часть текущего процесса разработки, если он не ухудшает качество структуры и позволяет сохранить контроль над итоговым результатом.

Распределение ответов респондентов представлено на рисунке 1.1.

Качественный вывод: обучающиеся находятся в профиците информации и дефиците времени. Отсюда запрос — быстро превратить регламент, брендбук или продуктовый бриф в обучение с понятной логикой, проверяемыми учебными целями и практическим результатом.



Рисунок 1.1 — Результаты исследования клиентов (n=20 B2B-интервью)

1.1.4 Решенческие интервью и критерии соответствия решения проблеме

Серия решенческих интервью проведена на базе функционального прототипа ИИ-методиста (сценарий демонстрации — приложение Б). Проверяемые критерии соответствия решения проблеме:

- 1) готов ли руководитель L&D-отдела встроить систему в текущую ручную стадию подготовки черновой структуры курса как инструмент ускорения и снятия рутины;
- 2) готов ли методист использовать систему на реальном документе своей организации;
- 3) экономически эффективно ли решение по отношению к стоимости аутсорс-разработки или внутреннего методического ресурса.

1.1.5 Рыночный контекст: TAM / SAM / SOM

Глобальный рынок онлайн-обучения растёт: по оценке Grand View Research, его объём составил \$299.67 млрд в 2024 году и может достичь \$842.64 млрд к 2030 году при CAGR около 19 % [5]. Это задаёт широкий TAM для решений, ускоряющих подготовку цифровых образовательных материалов.

Для оценки сегмента в России в работе используется более консервативная логика. По данным Smart Ranking, объём российского EdTech-рынка в 2023 году достиг 119.33 млрд руб., а доля сегмента «разработчики и платформы» составляла 13 % от общей структуры рынка [3]. Актуальные обзоры СберОбразования за 2025 год также фиксируют рост внимания к ИИ-инструментам, персонализации и автоматизации

образовательных процессов [6; 7]. Этот слой ближе всего по природе к ИИ-методисту; рынок инструментов поддержки разработки курсов оценивается примерно в 15.5 млрд руб.

При целевой доле 0.1 % от SAM в горизонте трёх лет SOM составляет около 15.5 млн руб. в год. При базовой B2B-подписке порядка 15 тыс. руб. в месяц это соответствует примерно 85–90 активным корпоративным клиентам. Такой масштаб достижим для нишевого B2B-продукта.

Структура рыночной оценки показана на рисунке 1.2.




Рисунок 1.2 — Оценка рынка: TAM / SAM / SOM

1.2 Анализ существующих продуктов

1.2.1 Прямые конкуренты

Coursebox AI позиционируется как конструктор курсов на основе ИИ и позволяет преобразовывать документы, слайды, видео и URL в курс, автоматически генерировать тесты, видео, изображения и публиковать результат в собственную LMS либо экспортировать в SCORM/LTI форматах [8]. Это один из наиболее близких по ценностному предложению продукт на рынке. Однако его логика остаётся в первую очередь ориентированной на быструю упаковку содержимого: сильная сторона продукта — скорость, а не явная педагогическая методология или контроль корректности фактов по отношению к исходному документу.

Articulate 360 AI добавляет ИИ-функции в зрелую среду корпоративного контента: создание структуры курса, чернового текста, перевода, изображений и озвучки внутри экосистемы Articulate. Продукт хорошо встроен в привычный рабочий процесс методиста, но остаётся инструментом повышения производительности разработчика курса, а не самостоятельным методическим конвейером с RAG-слоем, проверкой

фактов и локальным развёртыванием [9].

iSpring Suite AI развивает похожую траекторию: в 2025 году в продукт добавлены AI Course Creation Helper, AI Translator, AI Image Generator, а также функции синтеза речи и другие инструменты ускорения разработки курса [10]. Сильной стороной iSpring является зрелая экосистема для корпоративного обучения и русскоязычный рынок. Ограничение состоит в том, что ИИ остаётся надстройкой над средой разработки контента, а не автономным мультиагентным конвейером, принимающим на вход первичный документ и проводящим его через полную цепочку анализа, проектирования и обновления курса.

Synthesia лидирует в классе ИИ-видеогенерации для обучения и корпоративных коммуникаций: её ценность сосредоточена в создании аватарных роликов, озвучки и мультиязычного видео-контента для обучения и L&D-задач [11]. Но Synthesia не закрывает задачу проектирования учебной структуры.

1.2.2 Смежные решения

Google NotebookLM — сильный смежный продукт для работы с источниками, который умеет строить краткие выжимки, аудиообзоры и видеообзоры по загруженным материалам. В 2025 году Google расширил генерацию аудио и видео обзоров до 80+ языков, сделав их заметно реалистичнее и полезнее для изучения сложных источников [12]. Однако NotebookLM не предназначен для создания LMS-совместимой структуры курса, педагогического дизайна и контроля соответствия учебных целей.

GetCourse является одним из крупнейших российских игроков рынка LMS/онлайн-школ: платформа сообщает о 50,000+ клиентах, 16 млн учеников и совокупном обороте школ на платформе в 158 млрд руб. за 2025 год [13]. Для настоящей работы GetCourse важен как ориентир класса систем, в которые ИИ-методист потенциально может встраиваться как сервис генерации и обновления курса.

1.2.3 Сравнительная матрица

В таблице 1.1 приведено сравнение решений по критериям, которые оказались значимыми в исследовании клиентов: способность работать от исходного документа, наличие встроенной педагогической логики,

поддержка русскоязычного контента, суверенитет данных, автоматическое обновление содержания и интеграция с LMS-средой.

Таблица 1.1 — Сравнительный анализ конкурентных решений

Критерий	Coursebox	Articulate AI	iSpring AI	Synthesia	ИИ-методист
Генерация курса из документа	+	±	±	—	+
Явная методология (ADDIE / SAM / BD)	—	—	—	—	+
Русскоязычный контент	±	±	+	±	+
On-premise / суверенитет данных	—	—	—	—	+
ИИ-аудио / видео	+	+	+	+	+
Проверка фактов по источнику	—	—	—	—	+
Авто-актуализация курса	±	—	—	—	+
Ревью с участием человека	+	+	+	+	+
Интеграция с LMS-потокотом разработки	+	+	+	—	+

Визуализация сравнения в форме радарной диаграммы приведена на рисунке 1.3.

1.2.4 Пробел между проблемой и существующими решениями

Рынок предлагает и стартапы, и зрелые продукты для ускорения создания обучения. Однако сохраняется разрыв между генерацией учебных материалов и адаптацией к контексту каждого обучающегося.

Ни одно из рассмотренных решений не закрывает одновременно четыре требования корпоративного B2B-заказчика:

- 1) работу от внутреннего документа организации как от первичного источника;
- 2) поддерживать методическую логику проектирования курса для достижения целей обучения;
- 3) возможность локального развёртывания и контроля данных;
- 4) механизм повторной генерации и обновления курса при изменении




Рисунок 1.3 — Радарная диаграмма сравнения решений

исходного источника.

Позиционирование решений на карте приведено на рисунке 1.4.




Рисунок 1.4 — Карта позиционирования конкурентных решений

1.2.5 Тяжелокопируемые конкурентные преимущества

Уникальность предлагаемого решения состоит не в том, что оно использует LLM для генерации текста, а в соединении методического проектирования, источниковой доказательности и воспроизводимой проверки в одном производственном контуре. В отличие от одношаговых запросов, инструментов ускоренной разработки курсов и исследовательских блокнотов с опорой на источник, ИИ-методист не ограничивается созданием черновика: он сохраняет доказательный контекст, строит структуру курса до генерации уроков, вводит точки проверки человеком, рассчитывает знак качества и позволяет повторить парную проверку на том же корпусе.

Ключевое возражение к новизне решения состоит в том, что современный ChatGPT уже умеет работать с файлами, искать в вебе и в режиме глубокого исследования (deep research) формировать отчёты с источниками [14]. Это действительно снижает ценность простых

одношаговых запросов как самостоятельной разработки. Поэтому в настоящей работе уникальность защищается не самим фактом использования LLM, а тем, что ИИ-методист превращает генерацию курса в контролируемый производственный процесс: источник становится первым объектом системы, происхождение результата сохраняется на уровне блоков, знак качества рассчитывается машинно, а публикация проходит через контрольные точки с участием человека.

В таблице 1.2 сравниваются не маркетинговые заявления, а свойства, которые можно проверить в артефактах MVP. Для ChatGPT учитывается текущий класс возможностей OpenAI: поиск и глубокое исследование дают ссылки на источники, но сам по себе запрос не создаёт постоянную цепочку подготовки курса и не гарантирует доменный контроль качества [14; 15]. Для NotebookLM признаётся сильная работа с цитатами и опорой на источники, однако продукт остаётся исследовательским блокнотом, а не конвейером подготовки корпоративного курса [16]. Для Coursebox и iSpring фиксируются сильные функции разработки курса из открытых материалов [8; 10]; отсутствие отметки означает только то, что в открытом описании продукта не заявлен такой же проверяемый механизм.

Таблица 1.2 — Защита уникальности ИИ-методиста через сравнение механизмов доверия

Критерий	ChatGPT + запрос / B2	Coursebox / iSpring	NotebookLM	ИИ-методист B4
Привязка к источнику	Зависит от режима и дисциплины запроса; B2 в эксперименте имеет 0% привязки к источнику.	Генерируют курс или структуру из материалов, но карта источников на уровне артефактов не заявлена.	Ответы опираются на выбранные источники и цитаты.	100% B4-запусков имеют ссылки и связь блока с источником.
Происхождение результата	История чата не является воспроизводимым журналом курса.	В открытом описании не заявлено происхождение каждого фрагмента курса.	Сохраняет источники и заметки блокнота, но не цепочку подготовки курса.	Сохраняются JSON-файлы со статусом, результатом и происхождением, происхождение блоков и исходные доказательства запусков.
Методический конвейер	Методология остаётся текстом в запросе и легко теряется при повторе.	Сильный слой разработки курса: план, тестовые задания, визуальные материалы, перевод, LMS/SCORM.	Сильный исследовательский и учебный помощник, но не LMS-конструктор курса.	ADDIE реализован как граф: анализ источника, структура, контент, проверка фактов, педагогическая проверка, верификатор.
Проверка фактов и знак качества	OpenAI рекомендует проверять важные данные; встроенного доменного знака качества для курса нет.	В открытых материалах не заявлен воспроизводимый знак качества по источнику.	Цитаты помогают проверять ответ, но не дают педагогический контроль качества.	19 из 19 B4-запусков получили знак качества PASS; F1 проверки фактов = 0.720.
Контрольные точки с участием человека	Возможны вручную, но не являются частью исполняемого процесса.	Редактирование автором есть, но контрольная точка как состояние конвейера не заявлена.	Совместное редактирование заметок, без процесса согласования в LMS.	Две обязательные точки проверки человеком до публикации и после верификации.
Воспроизводимая цепочка артефактов	Нельзя честно повторить парное сравнение без внешней дисциплины логирования.	Продуктовые материалы описывают ускорение разработки курса, а не экспериментальную цепочку.	Есть артефакты блокнота, но нет цикла парной оценки B2/B4.	Парный B2/B4 на 19 документах, контроль готовности, исходные доказательства и приложения Ж-К.

Из сравнения следует, что преимущество ИИ-методиста защищается не доступом к LLM, а воспроизводимым контуром доверия. ChatGPT может быть сильным генератором черновика и исследовательским помощником, но ИИ-методист делает проверяемым весь жизненный цикл учебного артефакта. В системе явно заданы источник, методическая рамка, цепочка происхождения результата, автоматическая проверка фактов, знак качества, контрольные точки с участием человека и парная цепочка B2/B4. Именно эта совокупность даёт долгосрочно развиваемое преимущество: каждый новый агент, модель или методология могут подключаться к тем же контрактам доверия, а качество версии проверяется не впечатлением от ответа, а повторяемым набором артефактов. При этом парный B2/B4 на 19 документах доказывает не рыночное превосходство над аналогами, а работоспособность механизма доверия в пределах лабораторной проверки MVP. Для сильного сравнительного утверждения требуется отдельная сравнительная проверка

на открытых курсах $n \geq 30$ с теми же исходными артефактами и явно описанной базовой методикой.

Тяжелокопируемое преимущество формируется на основе четырёх элементов:

- **методологического подхода** — вариативные педагогические рамки ADDIE, SAM и Backward Design становятся параметрами агентного конвейера, а не внешним текстовым комментарием;
- **подхода доказательности от источника** — каждый результат связан с источником через ссылки, происхождение блоков, проверку фактов и знак качества, что снижает риск неподтверждённой генерации;
- **инфраструктурного подхода** — быстрый старт в формате самостоятельного запуска с возможностью перехода к локальному развёртыванию на собственной ИИ/LMS-инфраструктуре без вывода данных клиента в облако Adapstory;
- **платформного подхода** — масштабируемой работы человека с ИИ для автоматизации актуализации, проверки фактов, сопровождения и других рутинных операций на базе общей истории запусков и машиночитаемых доказательных артефактов.

1.3 Обзор научных методов и подходов

1.3.1 Формулировка исследовательского вопроса

Исследовательский вопрос:

«В какой мере мультиагентная архитектура с сохраняемым состоянием и вариативной методологической моделью превосходит одношаговый подход при поддержке методического проектирования корпоративных и учебных материалов по показателям точности, покрытия уровней таксономии Блума и времени подготовки первого черновика?»

Работа находится на стыке трёх линий: применения LLM в проектировании образовательных материалов, мультиагентной оркестрации и метрик педагогического качества.

1.3.2 LLM для поддержки проектирования образовательных материалов

Применение LLM в образовании стало особенно заметным после 2022 года. Kasneci et al. [17] показывают, что большие языковые модели

способны существенно ускорять создание объяснений, учебных заданий и материалов для самостоятельной работы. Pardos [18] и Tack et al. [19] указывают, что наибольший потенциал LLM возникает в задачах, где требуется быстро построить первую версию обучающего материала и затем доработать её с участием человека.

Однако у большинства существующих работ есть повторяющееся ограничение: генерация строится как одношаговый сценарий или короткая цепочка запросов. В результате модель выдаёт связный текст, но не обязательно поддерживает дисциплину педагогического проектирования: учебные цели оказываются слабо связаны с содержанием, а уровни когнитивной сложности не распределяются осмысленно.

1.3.3 Мультиагентные системы для поддержки проектирования курса

Мультиагентные LLM-системы декомпозируют сложную задачу на специализированные роли и состояния. Wu et al. [20] показали, что распределение ролей между агентами повышает управляемость и качество LLM-приложений. Shinn et al. [21] предложили паттерн Reflexion, а Wang et al. [22] описали Plan-and-Execute как схему разделения планирования и исполнения.

Проектирование курса — *многошаговая* задача: разобрать источник, сформулировать структуру, произвести контент, проверить соответствие источнику, при необходимости вернуть в цикл проверка. Это ближе к графу с сохраняемым состоянием, чем к диалоговому агенту.

1.3.4 RAG в образовании

RAG-подходы снижают число галлюцинаций за счёт опоры на внешний корпус знаний [23]. Для учебного курса это критично: содержание должно воспроизводить смысл исходного документа, а не просто звучать убедительно.

Es et al. [24] предложили фреймворк Ragas, который позволяет измерять достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy) и точность контекста (context precision). Эти метрики хорошо подходят для промежуточной оценки RAG-слоя ИИ-методиста, так как они фиксируют не только качество ответа, но и качество связи ответа с источником.

1.3.5 Генерация мультимедиа для обучения

Генерация мультимедийных артефактов — иллюстраций, голосовых дорожек, подкастов — опирается на диффузионные модели (DALL-E 3, FLUX.1) [25; 26] и TTS-решения (Silero, ElevenLabs) [27; 28].

В настоящей работе мультимедиа — вспомогательный слой. Научная новизна не в генерации изображений или аудио как таковой, а в способе их встраивания в методический конвейер.

1.3.6 Методологии проектирования курсов в контексте LLM

ADDIE [29], SAM [30] и Backward Design [31] представляют три различных логики педагогического проектирования. ADDIE задаёт линейно-этапный подход, SAM делает акцент на быстрых итерациях, а Backward Design строит курс от измеримых результатов обучения к структуре и заданиям.

Для LLM-автоматизации каждая из них задаёт различный способ управления генерацией: что считать первичным — анализ аудитории, ожидаемые результаты или итеративное прототипирование. Методология становится параметром архитектуры, а не внешним комментарием.

1.3.7 Оценка качества результатов, подготовленных с участием ИИ

Стандартные LLM-метрики слабо подходят для оценки учебного курса. В работе используется комбинация трёх классов:

- **структурные метрики:** валидность структуры, число модулей, число уроков, наличие обязательных элементов;
- **RAG-метрики:** достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy), точность контекста (context precision);
- **педагогические метрики:** покрытие уровней таксономии Блума, согласованность учебных целей с содержанием курса.

1.3.8 Идентификация исследовательской лакуны

Обзор выявил четыре пробела в литературе и практике.

- Работы по применению LLM в подготовке образовательных материалов в основном оценивают связность и полезность текста, но редко связывают архитектуру системы с измеримой педагогической метрикой вроде покрытия уровней таксономии Блума.
- Большинство промышленных ИИ-инструментов для разработки курсов

ускоряют отдельные этапы работы разработчика курса, но не исследуют мультиагентный конвейер с сохраняемым состоянием, который ведёт документ через полный цикл методической упаковки и поддерживает человека на ключевых точках принятия решения.

- Русскоязычный B2B-контекст представлен слабо: не хватает воспроизводимых корпусов, включающих регламенты, продуктово-редакционные документы и учебные программы в единой постановке задачи.
- Практически не исследована задача авто-актуализации курса при изменении исходного документа, хотя именно она определяет экономическую ценность ИИ-методиста для корпоративного заказчика.

Новизна работы — не в самом факте использования LLM, а в экспериментальном исследовании архитектуры, сочетающей RAG, мультиагентную оркестрацию, педагогическую вариативность и пригодность к развёртыванию во внутреннем контуре.

1.4 Постановка задачи и гипотезы

1.4.1 Задача исследования

Задача: разработать интеллектуального методического ассистента, который по входному документу организации формирует педагогически состоятельную структуру курса и черновой контент, опираясь на мультиагентную архитектуру с сохраняемым состоянием и обеспечивая приемлемое качество, скорость и стоимость подготовки.

1.4.2 Методологическая основа

Постановка опирается на три основания.

- **Working Backwards / CVM** [32]: продуктовые требования формулируются от боли и ценности клиента назад к технической реализации.
- **Jobs To Be Done** [33]: пользователь «нанимает» систему для снятия рутинной нагрузки и ускорения упаковки знания в обучающий артефакт.
- **Таксономия Блума** [34]: качество учебных целей оценивается по глубине когнитивного действия, а не только по формальной структуре ответа.

1.4.3 Три конвейера ИИ-методиста

Система работает в трёх режимах:

- 1) **Адаптационный курс:** входом служит продуктивное описание, бриф или внутреннее руководство; ключевая задача — быстро упаковать материал для новых сотрудников.
- 2) **Асинхронный учебный курс:** входом являются программа курса, учебные материалы или экспертный конспект; здесь критична логика модулей, последовательность освоения материала и покрытие учебных целей.
- 3) **Нормативный курс:** входом выступает регламент, политика или процедура; здесь на первый план выходит верность источнику, работа с фактами и возможность последующего обновления.

1.4.4 Исследовательские гипотезы

Проверяемые гипотезы:

Н1 (продуктовая). Мультиагентный конвейер позволяет сократить время до первого методического черновика до уровня менее 30 минут на один курс при сохранении покрытия уровней таксономии Блума не ниже 70 %.

Н2 (техническая). Мультиагентная архитектура с сохраняемым состоянием обеспечивает более высокое качество результата по метрикам faithfulness и покрытия уровней таксономии Блума по сравнению с одношаговой базовой конфигурацией при сопоставимой базовой LLM.

Н3 (бизнесовая). Себестоимость подготовки одного курса не превышает 1 % от стоимости ручной разработки у внешнего подрядчика.

1.4.5 Метрики проверки гипотез

Группы метрик:

- для **Н1**: время до первого черновика, доля курсов с покрытием уровней таксономии Блума $\geq 70\%$, доля структурно валидных результатов;
- для **Н2**: faithfulness, answer relevancy, context precision, покрытие уровней таксономии Блума, плотность ссылок на источник;
- для **Н3**: себестоимость на курс, отношение себестоимости к средней рыночной стоимости подрядной разработки, а также параметры подписочной экономики (LTV/CAC, срок окупаемости).

Метрики связывают научную часть работы с практической

ценностью: от корректности по отношению к источнику до экономической оправданности внедрения.

2 ИССЛЕДОВАНИЕ: ЭКСПЕРИМЕНТЫ И ВЫБОР ТЕХНОЛОГИЙ

Глава содержит экспериментальную постановку задачи, обоснование технологического стека и проверенные результаты текущего MVP: собранный корпус данных, обзор практик решения задачи и выбранную архитектуру.

2.1 Дизайн эксперимента

2.1.1 Тестовый корпус и оценочные артефакты

Для основной линии исследования зафиксирован **измеренный корпус одношаговой LLM-конфигурации (B2) из 19 документов**, репрезентирующих три категории источников, с которыми должен работать ИИ-методист в B2B- и образовательном контуре:

- **7 продуктово-редакционных документов:** краткое описание продукта, брендовые и редакционные руководства, политики стиля и HR-коммуникаций;
- **6 корпоративных регламентов:** политики информационной безопасности, персональных данных, управления инцидентами, адаптации сотрудников и антикоррупционного поведения;
- **6 открытых учебных программ MIT OCW:** англоязычные syllabi по экономике, математике, программированию и физике [35].

В измеряемое ядро включались документы, пригодные для технического базового прогона без раскрытия закрытых внешних данных. Для каждого документа в артефакте `baseline_comparison.json` сохранены идентификатор, категория, язык, время генерации и рассчитанные метрики.

Корпус охватывает три существенно разных типа входа: редакционные правила, регламентные тексты и академические программы. Это соответствует целевым сценариям продукта: подготовка внутреннего курса по продукту, адаптационный курс по правилам компании и асинхронный учебный курс.

Для автоматизированной оценки использованы также два

вспомогательных оценочных набора:

- **30 вопросно-ответных пар** (`qa_pairs.json`) для детерминированной оценки по схеме RAG на уровне ответов на вопросы;
- **100 утверждений** (`statements.json`), из которых 50 корректных и 50 намеренно искажённых, для оценки проверки фактов.

2.1.2 Конфигурации эксперимента: ручной подход (B1), одношаговая LLM (B2), ИИ-конструктор (B3) и ИИ-методист (B4)

Для исследования определены четыре конфигурации. В качестве количественного доказательства текущего MVP используются одношаговая LLM-конфигурация (B2) и ИИ-методист (B4), а ручная разработка (B1) и ИИ-конструктор (B3) сохранены как контрольные линии для расширения методики:

- **B1** — ручная разработка структуры курса методистом-экспертом; используется как теоретическая верхняя граница качества, но не заявляется как выполненный замер;
- **B2** — одношаговая генерация на базовой LLM без агентской оркестрации; это базовая конфигурация, полностью прогнанная на ядовом корпусе;
- **B3** — коммерческий инструмент класса конструкторов курсов на основе ИИ (в работе закладывается Coursebox AI как ближайший рыночный аналог); используется для сравнительного анализа рынка, но не как измеренная экспериментальная линия;
- **B4** — ИИ-методист: мультиагентный конвейер поддержки методиста, объединяющий обработку документов, поиск релевантных фрагментов, проектирование курса, подготовку черновых материалов, проверку фактов и проверка.

Статус базовых конфигураций на момент написания:

- **B2** дал воспроизводимые количественные результаты по 19 документам и служит базовым ориентиром;
- **B4** завершил парный прогон на тех же 19 документах и используется как основной измеренный результат ИИ-методиста;
- **B1** и **B3** не используются как количественное доказательство гипотез Н1–Н3 в текущей работе.

Глава 2 фиксирует измеренный экспериментальный слой одношаговой LLM (B2) и ИИ-методиста (B4) и дополнительную автоматизированную

проверку RAG и фактологическую проверку; границы интерпретации этих результатов отдельно указаны в разделе ограничений. Отдельно подготовлено описание корпуса для следующего шага: сравнительной проверки на открытых курсах $n \geq 30$. Она нужна именно для внешнего сравнительного утверждения, тогда как текущие 19 документов остаются лабораторной проверкой MVP текущей инженерной версии.

2.1.3 Метрики оценки

На текущем этапе используются четыре группы метрик:

- **структурные**: валидность JSON-структуры, число модулей, число уроков, наличие обязательных полей;
- **педагогические**: покрытие уровней таксономии Блума — доля из шести уровней таксономии Блума, представленных в учебных целях курса;
- **поисково-фактологические**: достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy), точность контекста (context precision) и метрики проверки фактов;
- **операционные**: время подготовки черновика, плотность ссылок на источник, себестоимость курса, пригодность к локальному развёртыванию.

Набор охватывает форму результата, педагогическую глубину, связь с источником и эксплуатационную стоимость.

Вместе с тем одной таксономии Блума недостаточно для полноценной педагогической и пользовательской оценки курса. Она хорошо описывает когнитивный уровень целей, но слабее отражает структурную сложность результата, согласованность курса, качество онлайн-дизайна и эффект для обучающегося. Поэтому в методологическом контуре исследования рассматривается более широкий набор рамок [36–42].

2.1.4 Расширенная педагогическая и пользовательская рамка

Для настоящего исследования эти рамки рассматриваются как **долгосрочный пользовательский слой оценки**, а не как замена уже выполненных технических измерений. Иными словами, текущий MVP по-прежнему опирается на покрытие уровней таксономии Блума, валидность структуры, поисково-фактологические метрики и операционную себестоимость. После коммерческого запуска продуктовый контур

Таблица 2.1 — Дополнительные рамки оценки качества курса сверх таксономии Блума

Рамка	Что измеряет	Потенциальная операционализация для ИИ-методиста
SOLO Taxonomy	структурную сложность и степень интеграции результата обучения	экспертная оценка структуры курса по уровням unistructural–extended abstract
Webb’s Depth of Knowledge (DOK)	когнитивную строгость заданий и оценочных материалов	распределение сгенерированных заданий по уровням DOK 1–4
Constructive Alignment (Biggs)	согласованность целей, учебных активностей и оценивания	доля целей, для которых в курсе есть связанная активность и способ проверки
Quality Matters Rubric	качество онлайн-курса как цифрового образовательного продукта	итоговый балл по целям, оцениванию, материалам, активностям, технологиям и доступности
Fink’s Taxonomy of Significant Learning	значимое обучение сверх простого воспроизведения содержания	покрытие компонентов application, integration, human dimension, caring и learning how to learn
ICAP Framework	тип учебной активности и глубину вовлечения обучающегося	доля активностей классов passive / active / constructive / interactive
UDL: Universal Design for Learning	доступность, вариативность подачи и варианты действия	покрытие по осям engagement, representation, action & expression

оценки может быть усилен показателями самооэффективности, ощущаемой компетентности, переноса обучения в практику и достижения цели [43–47].

2.2 Выбор и обоснование технологий

2.2.1 Фреймворк мультиагентной оркестрации

Задача ИИ-методиста относится к классу процессов с сохраняемым состоянием: документ проходит этапы обработки, анализа источника, подготовки структуры, наполнения черновыми материалами, проверки фактов, педагогической проверки и публикации. Часть шагов выполняется последовательно, часть — с условными ветками, остановками и повторным запуском после решения с участием человека.

Таблица 2.2 — Показатели эффекта обучения, ориентированные на обучающегося

Показатель	Что измеряет	Потенциальная операционализация
Самозффективность (Self-efficacy)	уверенность обучающегося, что он может выполнить конкретную задачу	Likert-вопросы, ориентированные на конкретную задачу, вида «теперь я могу самостоятельно сделать X»
Ощущаемая компетентность (Perceived Competence)	субъективное ощущение владения темой или навыком	короткая посткурсовая шкала PCS по конкретному домену
Перенос обучения в практику (Transfer of learning)	факт применения изученного в рабочей или учебной ситуации	отложенный опрос через 2–4 недели: применял ли, сколько раз, какие барьеры возникли
Retrospective pre-post	изменение восприятия своих возможностей с учётом эффекта response-shift	один пост-опросник с оценкой состояния «до курса» и «после курса»
Достижение цели (Goal attainment)	степень достижения индивидуальной учебной или рабочей цели	мини-шкала достижения цели по цели, сформулированной перед обучением

В ходе отбора рассматривались LangGraph 1.x, AutoGen 0.4, CrewAI 0.9, Agno 1.x и OpenAI Agents SDK [48–52].

Таблица 2.3 — Сравнение фреймворков мультиагентной оркестрации

Критерий	LangGraph	AutoGen	CrewAI	Agno	OpenAI Agents SDK
Модель исполнения	граф состояний	диалоговые агенты	ролевая команда	асинхронные агенты	агенты с вызовом инструментов
Явный граф переходов	+++	++	+	++	+
Поддержка локальных LLM	+	+	+	+	—
Контур участия человека	+++	++	+	++	+
Наблюдаемость и трассировка	+++	++	+	++	++
Зрелость экосистемы	+++	++	++	+	++

Обоснование выбора LangGraph. LangGraph соответствует природе задачи: система должна хранить состояние процесса, поддерживать возвраты к предыдущим шагам, ручную проверку и трассировку каждого узла. Для этого StateGraph подходит лучше, чем диалоговые модели. Дополнительным фактором стала интеграция с LangSmith, которая даёт наблюдаемость на уровне отдельных вызовов агентов и позволяет дебажить качество генерации.

Причины отказа от альтернатив. AutoGen силён как среда многоагентного взаимодействия, но для детерминированного конвейера требует дополнительных абстракций над диалоговой моделью. CrewAI удобно описывает роли и задачи, однако хуже соответствует продакшн-ориентированному асинхронному процессу. Agno привлекателен своей асинхронностью и RAG-встроенностью, но уступает в зрелости экосистемы. OpenAI Agents SDK не рассматривается как базовый вариант из-за облачной привязки и отсутствия траектории локального развёртывания.

2.2.2 Выбранная архитектура

После выбора оркестратора возникает второй вопрос: чем строить контур обработки документов и поиска релевантных фрагментов. В фактической MVP-реализации выбран интеграционный путь: Dify/RAG отвечает за индексирование и поиск по источнику, граф знаний добавляет предметные связи и компетенции, а LangGraph исполняет состояние агентного процесса поверх уже подготовленного доказательного контекста.

Разделение соответствует сильным сторонам компонентов. Dify/RAG закрывает практическую задачу загрузки, индексации и поиска фрагментов в контуре, приближённом к промышленному; граф знаний уменьшает зависимость от плоского поиска по сходству; LangGraph хранит состояние курса, результаты промежуточных нод и точки участия человека.

Итоговая техническая связка текущего MVP выглядит так: Source -> Dify/RAG -> EvidenceTable + KnowledgeGraph -> LangGraph -> course artifacts. Это снижает связанность системы и позволяет заменить поисковую подсистему без переписывания агентного графа.

Общая схема технологического стека приведена на рисунке 2.1.




Рисунок 2.1 — Технологический стек ИИ-методиста: source grounding и генерация

2.2.3 Большая языковая модель

На этапе экспериментального MVP сравнивались три направления: облачная модель общего назначения, российский облачный провайдер и локальная открытая модель.

Таблица 2.4 — Сравнение LLM-вариантов для текущей итерации

Критерий	GPT-4o	YandexGPT 4	Qwen2.5 7B
Способ доступа	облачный API	облачный API	локально через Ollama
Суверенитет данных	—	±	+
Стоимость итераций и отладки	высокая	средняя	низкая
Русскоязычный контент	высокая	высокая	достаточная для базовой конфигурации
Инфраструктурная простота	высокая	высокая	высокая для локального стенда

Для текущих экспериментов базовой конфигурации выбрана модель qwen2.5:7b через Ollama. Причина выбора прагматична: эта модель доступна локально, даёт воспроизводимые результаты, не требует внешнего API и позволяет многократно прогонять эксперименты на ядровом корпусе без роста переменных затрат.

Это **не окончательное ограничение** архитектуры. ИИ-методист

проектируется как провайдер-агностичная система: при необходимости локальная базовая конфигурация может быть заменена на более крупный вариант с открытыми весами семейства Qwen 2.5 или на облачный провайдер, если сценарий внедрения это допускает.

2.2.4 Поиск, векторные представления и граф знаний

Для поискового слоя в текущей итерации зафиксирована не конкретная векторная подсистема, а контракт поискового слоя: на входе источник, на выходе нумерованные фрагменты EvidenceTable, пригодные для цитирования и проверки фактов. В реализации этот контракт закрывается Dify/RAG и графом знаний. Qdrant и deepvk/USER-bge-m3 рассматриваются как совместимый инфраструктурный вариант, но не используются как единственное доказательство работоспособности MVP.

Выбор такого контракта объясняется четырьмя причинами:

- возможность сохранять привязку к источнику независимо от конкретного векторного хранилища;
- поддержка локального развёртывания и запрета внешней передачи документов;
- возможность обогащать найденные фрагменты предметными связями графа знаний;
- совместимость с будущим переходом на Qdrant/локальные векторные представления без изменения узла LangGraph.

Для поискового слоя выполнена детерминированная проверка по схеме RAG на 30 QA-парах: faithfulness составил 0.335, answer relevancy — 0.239, context precision — 0.567, context recall — 0.335. Эти значения используются как диагностический слой: текущий RAG/eval-контур работает как консервативный контроль перед проверкой человеком, то есть помогает раньше отправить рискованные фрагменты на проверку человеком. Они не доказывают качество поиска; качество поиска требует расширения корпуса и экспертной разметки релевантных фрагментов. Основной продуктовый показатель H2 при этом считается производной метрикой привязки к источнику: долей фактических утверждений, подтверждённых EvidenceTable в финальном verification_report.

2.2.5 Стратегии разбиения документов на фрагменты

Для обработки документов были рассмотрены две стратегии: рекурсивное фиксированное разбиение и семантическое разбиение. Детерминированная проверка по схеме RAG дала context precision 0.567 и context recall 0.335; поэтому текущий Dify/RAG-контур используется как рабочий контрольный слой для MVP, но не считается доказанным по качеству поиска. Архитектурно более перспективным остаётся семантическое разбиение внутри поисковой подсистемы и последующая экспертная оценка релевантности найденных фрагментов. Конкретная реализация может быть заменена: в текущем MVP это Dify/RAG-контур, в долгосрочной инфраструктурной версии допустим переход на Haystack/Qdrant при сохранении контракта EvidenceTable.

Учебные и нормативные документы содержат смысловые блоки разной длины: определения, процедуры, ограничения, списки требований. Жёсткое разбиение по фиксированному размеру разрушает эти границы и создаёт более шумный поисковый контекст. Семантическое разбиение лучше сохраняет логические единицы, что особенно важно для нормативных документов и продуктово-редакционных руководств.

2.2.6 Перспективное развитие генерации изображений

Для мультимедийного слоя сравнивались DALL-E 3 и FLUX.1-dev [25; 26]. DALL-E 3 удобен как внешний сервис с высоким качеством и быстрым стартом, но вносит в систему API-зависимость и переменные затраты. FLUX.1-dev допускает локальное развёртывание и потому лучше соответствует логике продукта, ориентированного на локальный контур.

В результате для перспективного слоя развития выбрана следующая стратегия:

- **по умолчанию** — локальный FLUX.1-dev для черновых и полуфинальных образовательных иллюстраций;
- **опционально** — внешний провайдер класса DALL-E 3 для сценариев повышенного качества, где требуется более «маркетинговое» качество изображения.

Решение не закрывает дорогу к внешнему качественному генератору, но сохраняет базовый маршрут локального развёртывания для большинства B2B-кейсов.

2.2.7 Перспективное развитие генерации подкастов на основе синтеза речи

Для генерации русскоязычных подкастов сравнивались Silero TTS v4 и ElevenLabs Multilingual v2 [27; 28]. На текущем этапе различие между ними определяется прежде всего не субъективным MOS, а эксплуатационной логикой.

- **Silero TTS** подходит для локального развёртывания, не требует внешнего API и по заложенной в оценочную модель оценке даёт стоимость порядка 4 руб. на курс за счёт только GPU-времени.
- **ElevenLabs** обеспечивает более «человеческую» интонационную подачу, но при оценке 40,000 символов на курс стоимость составляет порядка 1,080 руб. на курс, что делает его скорее опцией повышенного качества, чем базовым TTS-слоем для MVP.

Панельная MOS-оценка пока не завершена. Для этого уже подготовлен отдельный оценочный скрипт, однако в текущей итерации для выбора технологии решающими оказались суверенитет данных и предсказуемость себестоимости. Поэтому для будущего мультимедийного слоя базовым TTS-движком выбран Silero, но этот слой не используется как доказательство текущей готовности MVP.

2.3 Проверенные результаты экспериментов

2.3.1 Измеренные результаты одношаговой LLM-конфигурации (B2)

Первым полностью воспроизводимым экспериментом стал лабораторный прогон одношаговой LLM-конфигурации (B2) на измеренном 19-документном корпусе: продуктивно-редакционные документы, корпоративные регламенты и учебные программы MIT OCW. Эти числа используются как технический базовый ориентир текущего MVP и синхронизированы с артефактом `baseline_comparison.json`. В этой конфигурации использовалась локальная модель `qwen2.5:7b`, которая по одному запросу генерировала структуру курса в JSON-формате без поиска по корпусу, без проверки фактов и без отдельных специализированных агентов.

Распределение покрытия по категориям визуализировано на рисунке 2.2.

Таблица 2.5 — Измеренные результаты одношаговой LLM-конфигурации (B2)

Срез корпуса	<i>n</i>	Среднее время, с	Среднее покрытие, %	Доля курсов $\geq 70\%$	Структурная валидность
Все документы	19	4.37	61.4	21.1%	100%
Продуктово-редакционные документы	7	5.65	73.8	28.6%	100%
Корпоративные регламенты	6	3.65	38.9	0%	100%
Учебные программы MIT OCW	6	3.61	69.5	33.3%	100%




Рисунок 2.2 — Покрывание уровней таксономии Блума по категориям документов: одношаговая LLM-конфигурация (B2)

Частота появления отдельных уровней таксономии Блума показана на рисунке 2.3.

Полученные данные показывают, что одношаговая конфигурация обладает двумя сильными сторонами: она очень быстро генерирует структурно валидный ответ и не требует сложной инфраструктуры. Однако эти преимущества не решают ключевую задачу исследования.

Во-первых, среднее покрытие уровней таксономии Блума составляет лишь 61.4%, а порог 70% достигается только в 21.1% случаев. Во-вторых, базовая конфигурация значительно лучше справляется с продуктово-редакционными документами, чем с нормативными: для официальных




Рисунок 2.3 — Частота покрытия уровней таксономии Блума в корпусе (n=19): одношаговая LLM-конфигурация (B2)

нормативных документов покрытие падает до 38.9 %, что означает смещение к нижним когнитивным уровням запоминания и понимания. В-третьих, плотность ссылок на источник равна нулю: модель не даёт никакой явной привязки результата к источнику, поэтому одношаговая LLM-конфигурация (B2) не может считаться достаточной для нормативных и знаниево-критичных сценариев.

Время генерации по категориям документов представлено на рисунке 2.4.




Рисунок 2.4 — Среднее время генерации структуры курса по категориям: одношаговая LLM-конфигурация (B2)

Именно этот набор ограничений и мотивирует переход от одношаговой LLM (B2) к ИИ-методисту (B4): необходима архитектура, которая сохраняет скорость, но усиливает поиск по корпусу, проверка фактов и глубину методической структуры.

2.3.2 Сравнение одношаговой LLM (B2) и ИИ-методиста (B4) на одном корпусе

После стабилизации REST-контура ИИ-методиста выполнен парный прогон одношаговой LLM (B2) и ИИ-методиста (B4) на том же 19-документном корпусе. Для каждого документа создавался отдельный kb_slug B4 формата diploma-b4-001, в запуск передавался ровно один Markdown-файл, а результат сопоставлялся с ранее измеренной строкой B2 для того же doc_id. Это устраняет риск некорректного сравнения средних из разных прогонов: итоговая метрика считается как $\Delta_i = B4_i - B2_i$ для каждого документа.

Таблица 2.6 — Сравнение одношаговой LLM (B2) и ИИ-методиста (B4) на 19 документах

Метрика	Значение	Вывод
Среднее покрытие Блума B2	61.4 %	базовая конфигурация ниже целевого порога
Среднее покрытие Блума B4	83.3 %	B4 проходит порог $\geq 70\%$
Средняя парная дельта Блума	+21.9 п.п.	прирост считается по тем же документам
Документы с положительной дельтой	15 из 19	B4 лучше B2 на большинстве корпуса
Привязка к источнику B4	100 %	B4 даёт проверяемую опору на источник
Знак качества B4	100 % PASS	все B4-запуски готовы к проверке человеком

Наиболее сильный эффект наблюдается на корпоративных регламентах: среднее покрытие Блума увеличилось с 38.9 % до 83.3 %, то есть на +44.4 п.п. Для продуктивно-редакционных документов дельта составила +9.5 п.п., для программ MIT OCW — +13.8 п.п. Таким образом, B4 закрывает именно тот класс документов, где B2 был наиболее слаб: нормативные и знаниево-критичные материалы, требующие явной привязки

к источнику и проверки качества.

2.3.3 Оценочные наборы для RAG и проверки фактов

Парный прогон одношаговой LLM (B2) и ИИ-методиста (B4) закрывает основной технический разрыв между базовой конфигурацией и ИИ-методистом, однако для более тонкой оценки RAG-компонента и проверки фактов использованы дополнительные наборы.

Таблица 2.7 — Оценочные наборы текущего MVP

Артефакт	Объём	Назначение
Измеренный корпус одношаговой LLM (B2)	19	базовая и конвейерная подготовка курсов
QA-пары (qa_pairs.json)	30	оценка по схеме RAG: faithfulness, answer relevancy, context precision и context recall
Фактуальные утверждения (statements.json)	100	оценка precision / recall / F1 для проверки фактов

Артефакты превращают работу из описательной архитектурной записки в экспериментально воспроизводимую постановку. На этих наборах выполнен детерминированный прогон лабораторной оценки: для оценки по схеме RAG получены faithfulness 0.335, answer relevancy 0.239, context precision 0.567 и context recall 0.335; для проверки фактов получены precision 0.600, recall 0.900 и F1 0.720. Высокий recall выбран сознательно: для методического ассистента опаснее пропустить неподтверждённое утверждение, чем отправить лишний фрагмент на ручную проверку. Следовательно, текущая лабораторная оценка подтверждает пригодность связки проверки фактов и RAG как консервативного контрольного слоя перед проверкой человеком, но не является доказательством полного качества поиска. Для такого вывода требуется расширенный корпус, экспертная разметка релевантных контекстов и повторение замеров на открытых курсах разных жанров.

2.3.4 Сценарная экономика единицы продукта MVP на основе проверенного прогона

Помимо технических метрик, собрана сценарная оценка экономики единицы продукта. Речь идёт не о подтверждённой рыночной выручке, а о расчётной модели, основанной на текущей конфигурации конвейера и внутренних допущениях о цене привлечения и контрактной монетизации.

Таблица 2.8 — Сценарная экономика единицы продукта текущего MVP на основе проверенного прогона

Показатель	Значение	Интерпретация
Прямая себестоимость генерации курса	75 руб.	инфраструктурная себестоимость курса в текущем конвейере
Отношение к стоимости подрядной разработки	0.05%	текущий MVP в модели существенно дешевле внешнего производства
LTV / CAC	10.0	при выбранных допущениях модель не выглядит заведомо убыточной
Срок окупаемости	2 мес.	возврат затрат возможен в коротком цикле продаж
Порог безубыточности	14 клиентов	ориентир для коммерческой стадии после MVP

Цифры служат проверкой того, что выбранная архитектура не разрушает экономику продукта: после завершения парного прогона B4 система остаётся технически дешёвой в эксплуатации.

Одновременно эти значения не должны интерпретироваться как окончательное доказательство соответствия продукта рынку. В рамках ВКР коммерческий блок является сценарной моделью устойчивости, а не утверждением о спросе, выручке или проверке на внешних закрытых данных.

2.3.5 Ограничения текущего этапа и план абляционного исследования

Наиболее существенное ограничение текущего этапа состоит уже не в отсутствии B4-прогона: парное B2/B4-сравнение на 19 документах

выполнено и сохранено в `paired_b2_b4_experiment.json`. Оставшееся ограничение связано с тем, что автоматические метрики ещё не заменяют слепую экспертную оценку и абляционное исследование вклада отдельных узлов конвейера.

Ограничение накладывает границу на интерпретацию результатов:

- текущие цифры главы 2 следует трактовать как **автоматическую парную проверку одношаговой LLM (B2) и ИИ-методиста (B4)**, а не как замену экспертной педагогической экспертизы;
- гипотезы Н1–Н3 в данной работе проверяются в пределах внутреннего / открытого корпуса, парной проверки B2/B4 и лабораторной оценки;
- $n = 19$ является лабораторной проверкой MVP, но недостаточен для сильного вывода о превосходстве над аналогами; такой вывод должен проверяться отдельной сравнительной проверкой на открытых курсах $n \geq 30$;
- сравнение с ручной разработкой (B1), AI-конструктором (B3) и слепая экспертная педагогическая экспертиза остаются полезным расширением методики, но не входят в заявленный объём доказательств текущей ВКР;
- абляционное исследование является направлением развития доказательной базы, так как оно позволит отдельно измерить вклад поискового контура, проверки фактов и агентов проверки в итоговое качество.

Глава 2 фиксирует и достигнутые результаты, и текущую границу зрелости системы, определяя точку отсчёта для дальнейших экспериментов.

2.3.6 Финальная MVP-конфигурация

На основании проведённого отбора и измеренных результатов итоговая MVP-конфигурация ИИ-методиста строится на следующей конфигурации:

- **Локальное LLM-ядро**: Qwen через OpenAI-совместимую конечную точку Ollama;
- **Оркестратор**: LangGraph 1.x (StateGraph);
- **Контур поиска**: инструмент Dify/RAG + EvidenceTable;
- **Семантическое усиление**: граф знаний;
- **Состояние и результаты**: PostgreSQL-хранилище контрольных точек и результатов;
- **Контроль качества**: FactCheckAgent + Verifier + знак качества;

- **План развития:** Qdrant/локальные векторные представления, FLUX, Silero, SAM и Backward Design после парной проверки основного В4-контура.

Конфигурация отвечает целям работы: локальное развёртывание, воспроизводимые эксперименты, приемлемая себестоимость, усиление поискового слоя и педагогической структуры относительно одношаговой базовой конфигурации.

3 ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

3.1 Архитектура системы

3.1.1 Контекстная диаграмма (C4 Level 1)

ИИ-методист реализован как продуктовый контур платформы Adapstory, который объединяет сервис генерации курсов, RAG-поиск, граф знаний, ручную проверку и публикацию результата в LMS. На уровне системного контекста (C4 Level 1, приложение Г, раздел Г.1) участвуют следующие акторы и системы:

- **Разработчик курса / методист / HR-специалист** — загружает исходные материалы, задаёт аудиторию и методологию, просматривает, корректирует и утверждает результат;
- **School UI и BFF School** — веб-интерфейс и серверный слой для веб-клиента, через которые пользователь запускает генерацию, видит статус, происхождение результата, знак качества и результат;
- **AI Course Generator** — FastAPI-микросервис, исполняющий LangGraph-конвейер подготовки курса;
- **Dify/RAG-контур** — индексирует и ищет фрагменты исходных документов для генерации с опорой на источник;
- **Граф знаний** — предоставляет понятия, связи компетенций и дополнительные контекстные факты;
- **Ollama / OpenAI-совместимая конечная точка LLM** — обслуживает локальные модели семейства Qwen в тестовом и env-dev контуре;
- **PostgreSQL** — хранит запуски, результаты, контрольные точки LangGraph и данные аудита / происхождения результата;
- **LMS Adapstory** — принимает утверждённый курс после человеческого контроля качества.

3.1.2 Диаграмма контейнеров (C4 Level 2)

На уровне контейнеров (приложение Г, раздел Г.2) MVP состоит из следующих процессов:

- **AI Course Generator API** — FastAPI-сервис с REST и MCP-инструментами; принимает запросы от BFF, создаёт запуск, отдаёт

- статус, результат, происхождение и команды проверки человеком;
- **Среда исполнения LangGraph** — исполняет граф генерации, поддерживает точки прерывания и сохраняет состояние через PostgreSQL-хранилище контрольных точек;
 - **Инструмент Dify/RAG** — выполняет загрузку, индексирование и поиск фрагментов источника; при недоступности поиска система переходит к ограниченному резервному фрагменту исходного текста и явно помечает снижение полноты доказательного контекста;
 - **МСР графа знаний** — возвращает связанные компетенции и понятия, усиливая контекст CourseStructureAgent;
 - **Шлюз LLM** — провайдер-агностичный слой вызова модели с повторными попытками, телеметрией токенов и стоимости и возможностью переключения между локальной и внешней конечной точкой;
 - **School BFF / пользовательский интерфейс** — пользовательский контур проверки, публикации и отображения дипломных метрик.

3.1.3 Доменная модель

Доменная модель текущего MVP включает следующие ключевые сущности:

- **CourseRun** — запуск генерации с tenant/user, выбранной методологией, статусом, стоимостью и временем выполнения;
- **SourceDocument** и **EvidenceTable** — нормализованное представление найденных фрагментов источника со стабильными source_id для ссылок;
- **CourseBlueprint** — методический черновик структуры курса: модули, уроки, цели обучения и Bloom-разметка;
- **LessonContent** — черновой учебный блок со встроенными ссылками на источники;
- **VerificationReport** — отчёт проверки фактов и финальной проверки, содержащий total_claims, cited_claims и quality_seal;
- **ProvenanceRecord** — запись аудита с моделью, версией конвейера, набором контрольных правил, числом источников, телеметрией токенов и стоимости и временем генерации;
- **ThesisValidationSnapshot** — машинно читаемый срез метрик H1–H3 для дипломной валидации.

3.2 Мультиагентная система (LangGraph)

3.2.1 Граф агентов

Граф агентов реализован через StateGraph из LangGraph [48]. В текущей реализации используется шестиузловой конвейер, вдохновлённый подходом Фейнмана:

```
source_analyzer -> course_structure -> content_creator  
                -> fact_check -> review -> verifier
```

В граф встроены две точки участия человека:

- после `course_structure`: методист утверждает или возвращает на доработку структуру курса до генерации полного контента;
- после `verifier`: методист видит знак качества, происхождение результата и блокирующие замечания перед публикацией.

Граф агентов представлен на рисунке 3.1.

3.2.2 Ноды конвейера

Конвейер включает шесть специализированных нод:

- 1) **SourceAnalyzer** — извлекает из Dify/RAG релевантные фрагменты, строит `EvidenceTable` и помечает неполное покрытие источников; граф знаний подключается на следующем шаге как семантическое усиление `CourseStructureAgent`;
- 2) **CourseStructureAgent** — формирует `CourseBlueprint` по методологии ADDIE, целевой аудитории и таблице свидетельств;
- 3) **ContentCreatorAgent** — пишет черновые уроки со встроенными ссылками на `source_id`;
- 4) **FactCheckAgent** — проверяет фактические утверждения относительно `EvidenceTable` и выделяет неподтверждённые утверждения;
- 5) **ReviewAgent** — оценивает педагогическую связность, покрытие Блума и соответствие методологическому контрольному списку;
- 6) **Verifier** — алгоритмически считает долю подтверждённых утверждений, формирует `PASS`, `PASS_WITH_NOTES` или `FAIL`, собирает происхождение результата и снимок Н1–Н3.




Рисунок 3.1 — Граф агентов ИИ-методиста (шестиузловой LangGraph StateGraph)

3.2.3 Управление состоянием и участие человека в контуре

Состояние графа хранится в `CourseGenerationState`. Оно содержит входные параметры, `source_documents`, `evidence_table`, `blueprint`, `lesson_contents`, `fact_check_reports`, `review_report`, `verification_report`, `provenance`, телеметрию токенов и стоимости и обратную связь человека.

В контуре, приближённом к промышленному, граф компилируется с PostgreSQL-хранилищем контрольных точек. Это даёт три свойства, критичные для B2B-сценария:

- запуск можно возобновить после сбоя сервиса без потери промежуточных артефактов;
- проверка человеком не требует держать процесс в памяти;
- статус запуска, знак качества и происхождение результата доступны через API как воспроизводимый артефакт, а не только как текст в UI.

3.3 Ключевые конвейеры

3.3.1 Обработка источника и поиск

В текущем MVP контур обработки источника устроен так: индексация и поиск вынесены в инструмент Dify/RAG, а семантическое усиление структуры выполняется через граф знаний. Qdrant остаётся допустимой векторной подсистемой в инфраструктурном профиле, но не заявляется как обязательный реализованный слой дипломного MVP.

Текущий поток обработки источника:

- 1) пользователь загружает документ через School UI / BFF;
- 2) Dify/RAG-контур создаёт или обновляет индекс источника;
- 3) `source_analyzer` выполняет поиск фрагментов и строит `EvidenceTable`; если индекс временно недоступен, используется ограниченный резервный режим по фрагментам исходного текста;
- 4) граф знаний добавляет связанные компетенции и понятия на этапе проектирования структуры курса;
- 5) узлы LangGraph используют общий доказательный контекст, а не независимые несвязанные RAG-вызовы.

Последовательность компонентов показана на рисунке 3.2.




Рисунок 3.2 — Контур обработки источника и сборки EvidenceTable

3.3.2 Подготовка черновика курса

Подготовка курса начинается после появления доказательного контекста. Сценарий взаимодействия компонентов представлен на рисунке 3.3.

Ключевое отличие от одношаговой базовой конфигурации B2 состоит в том, что система не передаёт весь документ в один запрос. Вместо этого она:

- выделяет и нумерует источники до генерации курса;
- сначала проектирует структуру, а затем отдаёт её человеку на проверку;
- генерирует контент уже после утверждения структуры;
- проверяет утверждения и блокирует публикацию при низком качестве ссылочной привязки.

3.3.3 Метка качества, прослеживаемость и валидация гипотез диплома

Финальный узел `verifier` не вызывает LLM. Он алгоритмически считает отношение `cited_claims / total_claims` и назначает знак качества:

- PASS, если ссылочная привязка утверждений не ниже 90 %;
- PASS_WITH_NOTES, если она находится в диапазоне 70–90 %;
- FAIL, если доказательная база отсутствует или качество ниже порога.

В результате API отдаёт не только текст курса, но и набор проверочных артефактов: `citations`, `quality_seal`, `block_provenance`, `cost_quality` и `thesis_validation`. Эти поля используются фронтowymi E2E-тестами и дипломным скриптом продуктовой валидации, что делает проверку H1–H3 воспроизводимой.




Рисунок 3.3 — Сценарий взаимодействия при генерации курса

3.3.4 Компоненты плана развития

Мультимедиа-генерация (FLUX / Silero) не включается в статус завершённого MVP. Профили SAM / Backward Design и контур автоактуализации присутствуют как инженерные заделы, но количественные результаты диплома сознательно опираются только на парный B2/B4 по ADDIE, лабораторную оценку, знак качества и привязку к источнику, чтобы не смешивать готовые измерения с планом развития.

3.4 Инфраструктура и развёртывание

3.4.1 Стенд для тестирования и промышленной эксплуатации

Для локальной и env-dev проверки используется docker-compose-контур `docker-compose.ai-methodist.yml` и overlay `docker-compose.ai-methodist.env-dev.yml`. Он поднимает AI Course Generator, AI Methodist MCP-сервис, инструмент Dify/RAG, граф знаний, Neo4j, PostgreSQL и Redis. В base-compose задана лёгкая локальная модель, а env-dev-профиль использует более сильный Qwen3:8b через OpenAI-совместимую конечную точку Ollama.

Для инфраструктурного развёртывания платформа сохраняет GitOps-подход: образ собирается CI/CD, значения deployment описываются в Helm/GitOps, а ручные изменения в Kubernetes не используются как способ доставки функциональности.

3.4.2 Наблюдаемость и проверяемость

В сервисе используются OpenTelemetry-трассы вокруг узлов Lang-Graph и Prometheus-счётчик распределения знака качества. Отдельные инструкции фиксируют smoke-проверку env-dev, Playwright-проверку с опорой на граф знаний и матрицу LLM. Для ВКР это важно: результат генерации становится не демонстрацией «на словах», а набором машиночитаемых артефактов:

- статус запуска и финальный JSON результата;
- знак качества и происхождение результата;
- снимок проверки дипломных метрик;
- сводка Playwright и результаты контрольных прогонов;
- отчёт продуктовой проверки по Н1–Н3.

4 ВАЛИДАЦИЯ, ИМПАКТ И БИЗНЕС-ОЦЕНКА

4.1 Протокол валидации

4.1.1 Автоматизированная оценка

Качество выходных артефактов оценивается автоматически в трёх измерениях:

- 1) **Ragas-метрики** (глава 2): достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy), точность контекста (context precision);
- 2) **Покрытие уровней таксономии Блума**: доля уровней таксономии Блума, покрытых в наборе учебных целей курса; целевой показатель — $\geq 70\%$;
- 3) **Структурное качество**: полнота (наличие всех обязательных элементов методологии), согласованность учебных целей с содержанием, BLEU/ROUGE относительно эталонов B1.

4.1.2 Критерии контроля качества

Для ручного контроля качества результата подготовлен набор критериев, совместимый с будущим контуром экспертной проверки в продукте, но в численные результаты ВКР включаются только воспроизводимые автоматизированные замеры текущего корпуса.

Набор критериев содержит 5 пунктов (шкала 1–5):

- соответствие целевой аудитории;
- логика и последовательность модулей;
- качество учебных целей (SMART);
- покрытие исходного материала;
- практическая применимость.

Итоговая оценка по этим критериям может использоваться при ручном проверке курса перед публикацией. В текущей работе она не подменяет измеренные метрики покрытия Блума, привязки к источнику и проверки фактов и не заявляется как завершённая слепая экспертная оценка. Полные таблицы текущих оценочных артефактов приведены в приложении И.

4.1.3 Лабораторная апробация MVP

Помимо автоматизированных метрик выполнена лабораторная апробация MVP на контролируемом корпусе: внутренние продуктово-редакционные материалы, учебные регламенты и открытые программы MIT OCW. Проверялись не субъективные NPS/SUS-метрики, а воспроизводимые свойства результата: время, покрытие Блума, привязка к источнику, знак качества, проверка фактов и отображение доказательного слоя в интерфейсе. Такой дизайн соответствует задаче ВКР: подтвердить работоспособность продуктового MVP без привлечения закрытых внешних данных.

4.2 Сквозная верификация

4.2.1 Сценарий 1: Онбординг-курс (ADDIE)

Входной документ: продуктивное описание нового SaaS-инструмента, 8 страниц.

Ожидаемый результат: 6-модульный адаптационный курс с учебными целями для новых сотрудников; время подготовки первого методического черновика менее 30 минут.

Ход выполнения:

- 1) Пользователь загружает PDF в систему; запускается контур обработки документов.
- 2) После индексации инициируется CourseStructureAgent с методологией ADDIE.
- 3) После генерации структуры система приостанавливается для ручной проверки; пользователь одобряет структуру.
- 4) ContentCreatorAgent генерирует тексты уроков; FactCheckAgent верифицирует утверждения.
- 5) Verifier формирует знак качества, происхождение результата и снимок дипломных метрик H1–H3.
- 6) После финальной проверки человеком курс может быть опубликован в LMS Adapstory.

Для сценария выполнен парный прогон B2/B4 на 19 документах. B2 показывает среднее время подготовки структуры 4.37 с и среднее покрытие Блума 61.4 %, но не даёт привязки к источнику. B4 в том же корпусе

даёт среднее покрытие Блума 83.3 %, среднюю парную дельту +21.9 п.п., привязку к источнику 100 % и знак качества PASS в 19 из 19 запусков. Среднее техническое время В4 до готового результата составило 17.1 с, что существенно ниже целевого порога 30 минут.

4.2.2 Сценарий 2: Нормативный курс с проверкой фактов

Входной документ: корпоративный регламент информационной безопасности, 22 страницы.

Специфика: документ содержит точные числовые требования (сроки, пороги, санкции), критичные для корректного нормативного обучения.

Проверяется, что FactCheckAgent выявляет галлюцинации при конкретизации числовых значений. В парном прогоне В4 сформировал 19 отчётов проверки фактов и прошёл контроль привязки к источнику на 100 %. Для отдельного расчёта precision / recall / F1 использован набор данных из 100 утверждений (`statements.json`). Детерминированная лабораторная оценка показала precision = 0.600, recall = 0.900 и F1 = 0.720 для класса «обнаружено искажённое утверждение».

4.2.3 Сценарий 3: Авто-актуализация при обновлении источника

Условие: в исходный документ сценария 1 внесены изменения (обновлена функциональность продукта, 3 новых раздела).

В кодовой базе предусмотрен детерминированный validation-case для выявления устаревших уроков и регенерации затронутых разделов без полной пересборки курса. В доказательную базу данной ВКР этот сценарий включён как инженерное подтверждение расширяемости, а не как основная метрика Н1–Н3: количественные выводы работы опираются на парный В2/В4, лабораторную оценку и экономику единицы продукта.

4.3 Текущие результаты и проверка гипотез

4.3.1 Сводка фактически подтверждённых результатов

Сравнение результатов одношаговой LLM-конфигурации (В2) с целевыми показателями визуализировано на рисунке 4.1.

Отдельно от чисел одношаговой LLM-конфигурации (В2) в платформе реализован и измерен машинно читаемый контур доказательств ИИ-методиста (В4): входные данные результата и




Рисунок 4.1 — Сравнение результатов одношаговой LLM-конфигурации (B2) с целевыми показателями

статуса содержат citations, quality_seal, block_provenance, cost_quality и thesis_validation. Эти поля покрыты фронтовым E2E-сценарием отображения дипломных метрик и используются скриптами run_ai_methodist_product_validation.py и run_paired_b2_b4_experiment.py. Поэтому H2 проверяется не только архитектурным описанием, но и парной таблицей на том же 19-документном корпусе.

4.3.2 Проверка гипотез Н1–Н3

Н1 (продуктовая). «Мультиагентный конвейер должен готовить первый методический черновик курса не дольше чем за 30 минут при сохранении покрытия уровней таксономии Блума $\geq 70\%$.»

Гипотеза подтверждена в лабораторном продуктовом контуре: В4 подготовил результат в среднем за 17.1 с, дал среднее покрытие Блума 83.3 % и прошёл знак качества во всех 19 запусках. Это закрывает заявленный в работе критерий «первый проверяемый черновик до 30 минут» на контролируемом корпусе. **Гипотеза Н1 подтверждена на измеренном корпусе ВКР.**

Н2 (техническая). «Мультиагентная архитектура обеспечивает более высокое качество структуры по сравнению с одношаговой базовой конфигурацией на той же LLM.»

Парный прогон показывает, что В4 повышает среднее покрытие Блума с 61.4 % до 83.3 %, даёт среднюю строковую дельту +21.9 п.п. и добавляет привязку к источнику 100 % там, где В2 имеет 0 % ссылочной привязки. Наиболее сильный прирост получен на корпоративных регламентах: +44.4 п.п. к покрытию Блума. **Гипотеза Н2 эмпирически поддержана автоматическим парным прогоном; дополнительно выполнена детерминированная проверка фактов по схеме RAG.**

Н3 (бизнесовая). «Себестоимость подготовки курса $\leq$ 1% от стоимости ручной разработки у внешнего подрядчика.»

В сценарной финансовой модели себестоимость подготовки курса составляет 75 руб., что эквивалентно примерно 0.05 % от ориентировочной стоимости ручной разработки курса у внешнего подрядчика. Такой результат не доказывает рынок сам по себе, но показывает, что архитектура не разрушает экономику продукта уже на раннем этапе. **Гипотеза Н3 поддержана сценарной экономикой единицы продукта текущего MVP.**

4.3.3 Производительность

Подтверждённые операционные показатели:

- среднее время одношаговой LLM-конфигурации (В2) на измеренном корпусе из 19 документов — 4.37 с на генерацию структуры курса;
- среднее техническое время В4 в парном прогоне — 17.1 с до готового результата со знаком качества;
- среднее число модулей — 3, среднее число уроков — 6.2;
- доля структурно валидных результатов — 100 %.

Для долгосрочной эксплуатации в сервисе предусмотрены OpenTelemetry-трассы по узлам LangGraph и машиночитаемое происхождение результата. В рамках ВКР операционный вывод ограничен end-to-end временем запуска, поскольку именно оно напрямую связано с Н1.

4.3.4 Точность проверки фактов

Синтетический набор данных из 100 утверждений (50 корректных, 50 намеренно искажённых) позволяет воспроизводимо рассчитать prеsi-

sion / recall / F1. Детерминированная лабораторная оценка дала: precision = 0.600, recall = 0.900, F1 = 0.720. Высокий recall важен для MVP: подозрительные утверждения лучше отправить на проверку человеком, чем пропустить фактическую ошибку в нормативном или учебном материале. Низкая precision и слабые значения по схеме RAG не позволяют продавать этот результат как доказанное качество поиска. Корректная интерпретация: контур работает как консервативный контроль перед проверкой человеком, а качество поиска требует расширения корпуса и экспертной разметки.

4.4 Ограничения исследования и угрозы валидности

Ниже перечислены ограничения исследования и угрозы внутренней и внешней валидности [53], существенные для интерпретации результатов.

4.4.1 Ограничения тестового набора данных

Ограниченный объём измеренного корпуса ($n = 19$). Ядровой корпус содержит 19 документов, что ограничивает статистическую мощность сравнений. При размере эффекта $d = 0.5$ (средний) и $\alpha = 0.05$ мощность критерия Вилкоксона для такой выборки остаётся ограниченной и не гарантирует надёжного сравнения тонких различий между конфигурациями. Следовательно, результаты следует рассматривать как проверенные в пределах ограниченного лабораторного корпуса и требующие репликации на расширенном корпусе ($n \geq 30$). В терминах продуктовой доказательности это означает, что $n = 19$ достаточен как лабораторная проверка MVP и инженерной готовности, но недостаточен для сильного вывода о превосходстве над аналогами. Такой вывод должен быть вынесен в отдельную сравнительную проверку на открытых курсах $n \geq 30$ с исходными JSON/CSV-артефактами, фиксированной шкалой и базовой методикой и явным перечнем ограничений.

Жанровая и языковая фокусировка измеренного ядра. Ядровой корпус сознательно собран как смешанный срез: русскоязычные продуктивно-регламентные документы и англоязычные учебные программы MIT OCW. Это повышает прикладную релевантность для B2B- и образовательных сценариев, но ограничивает прямой перенос количественных результатов на другие отрасли, регуляторные среды и типы исходных документов. USWDS, GOV.UK и Saylor Academy вынесены в зарубежный сравнительный

контур и в текущей версии используются только качественно, без полного количественного прогона.

4.4.2 Ограничения эталонного корпуса

В работе сознательно не заявляется внешний экспертный эталонный корпус. Выводы о качестве ограничены теми метриками, которые воспроизводятся из JSON-артефактов: покрытие Блума, привязка к источнику, знак качества, диагностика по схеме RAG и F1 проверки фактов. Это делает результаты честными, но ограничивает их перенос на субъективную педагогическую оценку без дополнительного ручной проверки. Отдельно ограничивается интерпретация RAG/eval-метрик: они показывают работоспособность консервативного контроля перед проверкой человеком, но не доказывают качество поиска без расширенного корпуса и экспертной разметки релевантных фрагментов.

4.4.3 Ограничения пользовательской валидации

SUS / NPS, удержание и повторное использование не входят в измеряемые критерии данной ВКР. Работа оценивает инженерную и продуктово-лабораторную готовность MVP: может ли система на контролируемом корпусе подготовить проверяемый черновик курса с доказательным слоем и приемлемой экономикой единицы продукта.

4.4.4 Ограничения технологического стека

Зависимость от семейства Qwen. Основные эксперименты проведены на локальном Qwen-контуре. Результаты могут не воспроизводиться на других моделях (LLaMA 3.3, Mistral Large, GPT-4o), что ограничивает обобщаемость вывода об эффективности агентной архитектуры.

Ограниченный набор методологий в измерениях. В коде есть шаблоны ADDIE, SAM и Backward Design, но количественные результаты ВКР зафиксированы только для ADDIE. Это снижает риск смешать готовые измерения с ещё не сопоставленными режимами.

Авто-классификация уровней таксономии Блума. Уровни таксономии Блума определялись автоматически с помощью GPT-4o в роли judge-модели [54]. Надёжность такой классификации на русскоязычном наборе учебных целей не валидирована независимо;

это является угрозой валидности измерения покрытия уровней таксономии Блума.

4.4.5 Угрозы внешней валидности

Система разработана и количественно апробирована на русскоязычном текстовом контенте продуктового, нормативного и образовательного характера; зарубежный контур пока использован только качественно. Перенос результатов на мультимодальный контент, закрытые внутренние материалы организаций, другие отрасли и другой регуляторный контекст (SCORM, xAPI) требует дополнительных исследований.

4.4.6 Направления для устранения ограничений

Направления долгосрочного развития:

- 1) расширение русского ядра до 30–50 документов из 5+ различных сценариев;
- 2) запуск подготовленной сравнительной проверки на открытых курсах $n \geq 30$ на открытых курсах для проверки переносимости B2/B4-результатов и базовой ручной оценки по шкале;
- 3) независимая ручная проверка на обезличенном внутреннем или открытом корпусе и расчёт согласия разметки уровней таксономии Блума;
- 4) кросс-модельная оценка: воспроизведение экспериментов на LLaMA 3.3 70B и GPT-4o для проверки обобщаемости;
- 5) отдельный количественный прогон на зарубежном сравнительном контуре после стабилизации русского базового ориентира;
- 6) продольная UX-аналитика после промышленной поставки продукта.

4.5 Бизнес-оценка и масштабирование

4.5.1 Экономика единицы продукта

Себестоимость одного курса в текущем MVP складывается из LLM-времени, поисковых и KG-вызовов, хранения состояния и опциональных API-вызовов. Сценарный расчёт собран в артефакте `unit_economics_results.json`.

- GPU-время — 75 руб./курс;
- OpenAI API (опционально) — 0 в базовой конфигурации;
- **Итоговая себестоимость** — ≈ 75 руб./курс.

Соотношение себестоимости ИИ-генерации и подрядной разработки показано на рисунке 4.2.




Рисунок 4.2 — Unit-экономика ИИ-методиста: себестоимость vs рыночная стоимость

Метрики сценарной подписочной модели:

- САС (стоимость привлечения клиента): около 30 000 руб.;
- LTV (пожизненная ценность клиента): около 300 000 руб.;
- LTV / САС: 10.0;
- срок окупаемости: 2 мес.

4.5.2 Lean Canvas

Lean Canvas [55] ИИ-методиста приведён в приложении К. Основные блоки:

Проблема: разработка корпоративного курса занимает много времени и часто выносится на подрядчиков; контент устаревает быстрее, чем его успевают перерабатывать.

Решение: полуавтоматическая подготовка структуры и черновых материалов курса по загруженному документу; проактивные подсказки и ручная проверка в контуре; механизм последующей авто-актуализации.

Целевая аудитория: B2B-клиенты платформы Adapstory — HR-отделы и учебные центры с > 50 сотрудников.

Труднокопируемое преимущество: методологическая вариативность (ADDIE/SAM/BD) и полный суверенитет данных за счёт локального LLM-контра не воспроизводятся Coursebox AI и iSpring AI.

4.5.3 Финансовая модель (прогноз на 3 года)

Детальные расчёты приведены в приложении К. В качестве основы использован P&L-файл PNL - LMS AI.xlsx: он задаёт ежемесячные

драйверы продаж, ФОТ, маркетинга, API-токенов, прочих расходов и налога УСН на 2026–2027 годы. Третий год в работе представлен как сценарное продолжение: годовой темп декабря 2027 года без дополнительного ускорения продаж.

Итоговые показатели базового сценария:

- **2026**: выручка 76.0 млн руб., расходы и налог 49.0 млн руб., операционный денежный поток 26.9 млн руб.;
- **2027**: выручка 1 764.2 млн руб., расходы и налог 227.8 млн руб., операционный денежный поток 1 536.4 млн руб.;
- **2028E**: выручка по годовому темпу 4 044.1 млн руб., расходы и налог 446.1 млн руб., операционный денежный поток 3 598.0 млн руб.;
- **операционная безубыточность**: положительный месячный денежный поток достигается в августе 2026 года, накопительный поток становится положительным в ноябре 2026 года.

Динамика выручки и расходов представлена на рисунке 4.3.




Рисунок 4.3 — Финансовый прогноз на 3 года по PNL-модели; 2028E — годовой темп декабря 2027 года

4.5.4 Потенциал масштабирования

После валидации в российском B2B-сегменте выделены смежные рынки:

- **Международный EdTech**: потенциальный TAM $\approx$ \$51 млрд

к 2030 году [1];

- **Корпоративное обучение (CLO-сегмент):** интеграция в Microsoft 365 + SharePoint как источник документов;
- **Государственное образование:** адаптация под ФГОС-регламент при поддержке профильных ведомств.

4.5.5 PESTLE-анализ при масштабировании

- **P (Political):** регуляторные требования к использованию ИИ в государственном образовании; ограничения экспорта технологий;
- **E (Economic):** зависимость от стоимости GPU-аренды; волатильность курсов валют при API-зависимости;
- **S (Social):** опасения преподавателей и методистов относительно снижения роли человека; требования к прозрачности использования ИИ;
- **T (Technological):** быстрое устаревание LLM; риск лицензионных изменений в моделях с открытыми весами;
- **L (Legal):** 152-ФЗ [56] (персональные данные); авторское право на ИИ-сгенерированный контент (ГК РФ ч. IV);
- **E (Environmental):** энергопотребление GPU-кластера; углеродный след при масштабировании.

4.5.6 Оценка рисков

Визуализация рисков на матрице вероятность/влияние приведена на рисунке 4.4.

4.5.7 Дорожная карта

6 месяцев: расширение парной проверки B4, абляционное исследование узлов RAG, проверки фактов и педагогической проверки, усиление precision проверки фактов без потери recall, увеличение открытого и внутреннего корпуса измерений.

12 месяцев: переход от чернового MVP к производственно готовой версии, количественное сравнение трёх методологий (ADDIE / SAM / Backward Design), структурированная пользовательская аналитика после коммерческого запуска.

24 месяца: API для внешней интеграции, мультиязычность, масштабирование на смежные рынки корпоративного обучения.

Дорожная карта представлена на рисунке 4.5.




Рисунок 4.4 — Матрица рисков ИИ-методиста




Рисунок 4.5 — Дорожная карта развития ИИ-методиста

4.5.8 Интеллектуальная собственность

Программный комплекс подлежит регистрации как программа для ЭВМ (ст. 1261 ГК РФ [57]). Авторские права на сгенерированные учебные материалы принадлежат оператору платформы (ст. 1295 ГК РФ, служебное произведение).

4.6 Степень готовности и обратная связь от рынка

4.6.1 Текущий статус MVP

Реализованы: контур обработки документов, CourseStructureAgent (ADDIE), ручная проверка, ContentCreatorAgent с RAG, FactCheckAgent, Verifier, знак качества, снимок проверки дипломных метрик и парный доказательный конвейер B2/B4.

Инженерные заделы: методологии SAM / Backward Design и механизм авто-актуализации. Мультимедийный слой (FLUX + Silero) остаётся за пределами MVP ВКР.

4.6.2 Рыночные сигналы

- Проведены 20 B2B-интервью в рамках исследования клиентов;
- 70 % респондентов называют время разработки главным ограничением;
- 50 % уже используют подрядчиков или внешних методистов;
- 60 % готовы рассмотреть ИИ-инструмент такого класса.

4.6.3 Соответствие решения проблеме

Корректнее говорить не о подтверждённом соответствии решения проблеме, а о сильном сигнале наличия проблемы и раннем интересе к решению: проблема проверена через исследование клиентов, 60 % респондентов готовы рассмотреть ИИ-инструмент. В рамках ВКР соответствие решения проверяется через работающий MVP и лабораторные продуктовые метрики, а не через внешние коммерческие договорённости.

4.6.4 Качественная обратная связь

Уже на уровне проблемных интервью выявлены три устойчивых сигнала:

- пользователям важнее быстро получить *первый черновик* курса, чем сразу идеальный финальный контент;
- для регламентов и сценариев нормативного обучения критична привязка

- к источнику и возможность проверки фактов;
- для B2B-сегмента существенны суверенитет данных, локальное развёртывание и контроль с участием человека.

Таблица 4.1 — Текущий набор подтверждённых результатов исследования

Контур валидации	Текущее значение	Что это означает
Исследование клиентов	20 B2B-интервью	проблема подтверждена первичными данными рынка
Ключевой pain	70 %	большинство респондентов называют длительность разработки курса главным ограничением текущего процесса
Использование подрядчиков / внешних методистов	50 %	рынок уже платит за закрытие этой задачи внешним ресурсом
Готовность рассмотреть ИИ-инструмент	60 %	есть ранний сигнал интереса к решению; в данной ВКР он используется как рыночный контекст, а не как доказательство качества MVP
Одношаговая LLM-конфигурация (B2): время подготовки структуры	4.37 с	одношаговая конфигурация очень быстра, но не решает задачу качества и объяснимости
Одношаговая LLM-конфигурация (B2): среднее покрытие уровней Блума	61.4 %	текущая конфигурация не достигает целевого уровня $\geq 70\%$
Одношаговая LLM-конфигурация (B2): доля курсов с Блумом $\geq 70\%$	21.1 %	именно этот разрыв обосновывает необходимость агентного усиления
Одношаговая LLM-конфигурация (B2): структурная валидность	100 %	минимальный конвейер уже стабильно выдаёт формально корректную структуру курса
ИИ-методист (B4): среднее покрытие уровней Блума	83.3 %	ИИ-методист проходит целевой порог $\geq 70\%$ на том же корпусе
ИИ-методист (B4): средняя дельта к одношаговой LLM (B2)	+21.9 п.п.	прирост считается построчно для каждой пары doc_i
ИИ-методист (B4): привязка к источнику / знак качества	100 % / 100 % PASS	все 19 B4-запусков имеют проверяемую опору на источник и готовы к проверке человеком
Оценочные наборы	30 вопросно-ответных пар, 100 утверждений	база для следующей волны RAG-оценки и оценки проверки фактов уже подготовлена
Сценарная экономика единицы продукта	75 руб./курс	инфраструктурная себестоимость выглядит низкой даже до завершения полного оценочного цикла B4
Отношение к подрядной разработке	0.05 % 71	расчётная себестоимость существенно ниже стоимости внешней ручной разработки курса
LTV / SAC, срок	10.0; 2 мес.; 14	сценарная модель выглядит

Таблица 4.2 — Матрица рисков ИИ-методиста

Риск	Вероятность	Влияние	Митигация
Деградация качества новой версии LLM	Средняя	Высокое	Регрессионный Ragas-тест при каждом обновлении модели
Недоступность GPU-узла	Низкая	Высокое	circuit breaker + резервный переход на OpenAI API
Утечка данных через LLM-провайдера	Низкая	Критическое	локальное развёртывание; запрет облачных провайдеров для корпоративного сегмента
Неприятие разработчиками курсов	Средняя	Среднее	ручная проверка в контуре; прозрачность использования ИИ в интерфейсе
Изменение лицензии Qwen / поисковой подсистемы	Низкая	Высокое	LLM Gateway с провайдер-агностичным API; альтернативы: Llama 3.3

ЗАКЛЮЧЕНИЕ

Разработан интеллектуальный методический ассистент (ИИ-методист) — микросервис образовательной платформы Adapstory, поддерживающий методиста и разработчика курса при подготовке учебных курсов на основе внутренних и открытых учебных документов с использованием LLM, поиска по корпусу и агентной оркестрации.

Итоги выполнения задач исследования. Проведены 20 глубинных B2B-интервью, подтвердивших устойчивую проблему трудоёмкой разработки корпоративных курсов. Для 70 % респондентов главным ограничением оказалась длительность разработки, 50 % уже прибегают к подрядчикам или внешним методистам, а 60 % готовы рассмотреть ИИ-инструмент. На техническом уровне выбран и обоснован стек на основе LangGraph, Dify/RAG, графа знаний, PostgreSQL-хранилища контрольных точек и результатов и локального Qwen-контура; реализованы контур обработки источников, шестиузловой агентный конвейер подготовки курса, слой источниковой привязки и прослеживаемости, знак качества и снимок дипломных метрик H1–H3.

Количественные результаты текущего этапа. Для лабораторного 19-документного прогона одношаговой LLM-конфигурации (B2) воспроизводимо измерен базовый слой: среднее время подготовки структуры — 4.37 с, среднее покрытие уровней таксономии Блума — 61.4 %, доля курсов с покрытием ≥ 70 % — 21.1 %, структурная валидность — 100 %. На том же корпусе выполнен парный прогон одношаговой LLM (B2) и ИИ-методиста (B4): B4 повысил среднее покрытие Блума до 83.3 %, дал среднюю строковую дельту +21.9 п.п., привязку к источнику 100 % и знак качества PASS в 19 из 19 запусков. На 30 вопросно-ответных парах и 100 утверждениях выполнена детерминированная лабораторная оценка: context precision по схеме RAG = 0.567, precision проверки фактов = 0.600, recall = 0.900, F1 = 0.720. Сценарная экономика единицы продукта даёт инфраструктурную себестоимость порядка 75 руб. за курс, LTV / SAC = 10.0, период окупаемости 2 месяца и точку безубыточности на уровне 14 клиентов. RAG/eval-метрики трактуются консервативно: контур работает

как контрольный барьер перед проверкой человеком, но качество поиска требует расширения корпуса и экспертной разметки, поэтому в работе не заявляется полное доказательство качества поиска. Аналогично, $n = 19$ трактуется как лабораторная проверка текущего MVP: этого достаточно для проверки инженерной готовности одношаговой LLM (B2) и ИИ-методиста (B4), но недостаточно для сильного вывода о превосходстве над аналогами. Для такого вывода подготовлен следующий контрольный этап — сравнительная проверка на открытых курсах $n \geq 30$ с исходными JSON/CSV-артефактами и отдельной базовой методикой.

Статус гипотез. H1 поддержана парным прогоном: B4 укладывается в порог 30 минут и проходит целевой уровень Блума на контролируемом корпусе. H2 эмпирически поддержана на 19-документном корпусе: ИИ-методист (B4) улучшает покрытие Блума и привязку к источнику относительно одношаговой LLM (B2) на тех же документах и проходит дополнительную проверку фактов как контрольный барьер перед проверкой человеком, но не закрывает экспертное доказательство качества поиска. H3 поддержана сценарной экономикой единицы продукта текущего MVP: расчётная себестоимость подготовки курса на порядки ниже ручной разработки.

Научный вклад и уникальность. Предложена и апробирована архитектура воспроизводимой валидации LLM-систем для поддержки проектирования учебных курсов на русском корпусе открытых и официальных документов с зарубежным сравнительным контуром. В отличие от решений, где LLM используется как одношаговый генератор черновика, ИИ-методист рассматривает создание курса как проверяемый конвейер: методическая структура строится до генерации уроков, источники сохраняются как доказательный контекст, а итоговый результат сопровождается знаком качества, проверкой фактов и прослеживаемостью происхождения. Архитектура объединяет методологическую рамку проектирования курса, агентную оркестрацию с сохраняемым состоянием и RAG-контур. Сформирован воспроизводимый набор артефактов для дальнейшей оценки: корпус документов, оценочные артефакты для RAG и проверки фактов, сценарная бизнес-модель и протокол внутренней и открытой апробации. Отдельно выделены тяжелокопируемые конкурентные

преимущества решения: его отличие защищается сравнением привязки к источнику, происхождения результата, знака качества, проверки фактов, контрольных точек с участием человека и парной цепочки артефактов B2/B4, а не декларацией об использовании ИИ.

Практическая значимость. ИИ-методист представляет собой рабочий MVP с контуром обработки источников, подготовкой структуры курса, проверка с участием человека, слоем источниковой привязки и прослеживаемости, знаком качества и подготовленной основой для контентной и фактической валидации. Система доведена до состояния проверяемого продуктового MVP: основные результаты воспроизводятся из JSON-артефактов, а отдельный контроль готовности защищает текст диплома от несогласованных утверждений. Долгосрочное развитие связано с расширением корпуса, кросс-модельной оценкой, сравнительной проверкой на открытых курсах $n \geq 30$, аблацией узлов и промышленной UX-аналитикой после запуска.

ИСПОЛЬЗОВАНИЕ СИСТЕМ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА И ЛИЧНЫЙ ВКЛАД АВТОРА

В соответствии с требованиями ИТМО к ВКР настоящий раздел описывает использование ИИ-инструментов обучающимся в процессе подготовки работы и фиксирует личный вклад автора в разработку системы.

Использование ИИ-инструментов

В ходе подготовки работы автор использовал ИИ-инструменты как средства поиска, чернового структурирования и редакционной поддержки текста:

- **OpenAI Codex / ChatGPT-5.4** — для структурирования отдельных разделов, поиска возможных формулировок и редакционной шлифовки черновиков при обязательной последующей ручной переработке;
- **Perplexity AI** — для поиска актуальных рыночных данных, проверки дат публикации и навигации по открытым источникам;
- **Claude Code** — для ускорения работы по созданию технических спецификаций на разработку фронтенд и бекенд части системы.

Все ИИ-сгенерированные фрагменты проходили ручную проверку автора: фактические утверждения перепроверялись по первоисточникам, а финальные выводы и исследовательские формулировки принимались автором самостоятельно.

ИИ-инструменты не использовались для подмены первичных данных: интервью, выводы исследования клиентов, экспериментальные артефакты, расчёты и итоговые исследовательские интерпретации были собраны, проверены и оформлены автором.

Личный вклад автора

Автор настоящей работы лично:

- 1) **Провёл исследование предметной области:** собрал и проанализировал корпус из 45+ цитируемых академических и индустриальных источников по LLM, мультиагентным системам, RAG-подходам и автоматизации создания образовательного контента;

- 2) **Разработал архитектурное решение:** принял ключевые проектные решения по выбору технологического стека (LangGraph, Dify/RAG, граф знаний, PostgreSQL-хранилище контрольных точек и результатов, Qwen-контур), спроектировал шестиузловой граф агентов и выбранную архитектуру генерации с опорой на источник;
- 3) **Разработал шаблоны запросов:** подготовил системные шаблоны запросов для ADDIE, SAM и Backward Design с учётом требований таксономии Блума, особенностей русскоязычного ядрового корпуса и зарубежного сравнительного контура;
- 4) **Реализовал систему:** написал код LangGraph-графа агентов, шлюза LLM, FastAPI-приложения, слоя источниковой привязки и прослеживаемости, знака качества и снимка проверки дипломных метрик, настроил локальный и env-dev контуры проверки ИИ-методиста;
- 5) **Провёл эксперименты:** сформировал ядровой корпус документов, подготовил 30 вопросно-ответных пар и 100 фактуальных утверждений, провёл измерения базовой конфигурации, парный B2/B4-прогон, детерминированную проверку фактов по схеме RAG и сценарную оценку экономики единицы продукта;
- 6) **Провёл исследование клиентов:** 20 глубинных B2B-интервью по методу Mom Test и систематизировал ключевые болевые точки рынка;
- 7) **Подготовил доказательную базу ВКР:** оформил протокол внутренней и открытой апробации, машиночитаемые доказательные артефакты и автоматический контроль готовности, который проверяет согласованность текста диплома с кодом и результатами.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Global EdTech Market Report 2024–2030. — 2024. — EdTech Hub, Statista Research.
2. Chapman B. How Long Does It Take to Create Learning? — 2010. — Chapman Alliance Research.
3. Российский EdTech-рынок: объём и структура по данным Smart Ranking. — 2024. — в тексте использованы данные Smart Ranking за 2023 год; дата обращения: 13.04.2026. URL: https://pureportal.spbu.ru/files/124005039/Conference_proceedings_2024.pdf.
4. Fitzpatrick R. The Mom Test: How to Talk to Customers & Learn if Your Business Is a Good Idea When Everyone Is Lying to You. — CreateSpace, 2013.
5. E-learning Services Market Size, Share & Trends Analysis Report 2030. — 2025. — дата обращения: 13.04.2026. URL: <https://www.grandviewresearch.com/industry-analysis/e-learning-services-market>.
6. СберОбразование. Обзор трендов образования: II квартал 2025 года. — 2025. — дата обращения: 07.05.2026. URL: <https://files.sberdisk.ru/s/SwrW8HGiAiW1HKA>.
7. СберОбразование. Обзор трендов образования: III квартал 2025 года. — 2025. — дата обращения: 07.05.2026. URL: <https://files.sberdisk.ru/s/e97fCpnQoNZWBG8>.
8. Coursebox AI: Create a Course from Documents. — дата обращения: 07.05.2026. URL: <https://www.coursebox.ai/document-to-course>.
9. Articulate 360 AI Features. — дата обращения: 13.04.2026. URL: <https://articulate.com/360>.
10. iSpring Suite AI: What's New. — дата обращения: 07.05.2026. URL: <https://www.ispringsolutions.com/whats-new>.
11. Synthesia for Learning and Development. — дата обращения: 13.04.2026. URL: <https://www.synthesia.io>.

12. NotebookLM Audio and Video Overviews. — 2025. — дата обращения: 07.05.2026. URL: <https://blog.google/innovation-and-ai/models-and-research/google-labs/notebook-lm-audio-video-overviews-more-languages-longer-content/>.
13. GetCourse Platform Overview. — 2026. — дата обращения: 13.04.2026. URL: <https://getcourse.ru/>.
14. Deep research in ChatGPT. — 2026. — дата обращения: 07.05.2026. URL: <https://help.openai.com/en/articles/10500283>.
15. ChatGPT Accuracy and Limitations. — 2026. — дата обращения: 07.05.2026. URL: <https://help.openai.com/en/articles/8313428-chatgpt-accuracy-and-limitations>.
16. Use chat in NotebookLM. — 2026. — дата обращения: 07.05.2026. URL: <https://support.google.com/notebooklm/answer/16179559>.
17. ChatGPT for Good? On Opportunities and Challenges of Large Language Models for Education / E. Kasneci, K. Seßler, S. Küchemann, [et al.] // Learning and Individual Differences. — 2023. — Vol. 103. — P. 102274.
18. Pardos Z. A., Bhandari S. Learning gain differences between GPT-4 and human expert tutoring // Proceedings of EDM 2023. — 2023.
19. Tack A., Piech C. The AI Teacher Test: Measuring the Pedagogical Ability of Blender and GPT-3 in Educational Dialogues // Proceedings of EDM 2022. — 2022.
20. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation / Q. Wu [et al.] // arXiv:2308.08155. — 2023.
21. Reflexion: Language Agents with Verbal Reinforcement Learning / N. Shinn [et al.] // Advances in Neural Information Processing Systems (NeurIPS 2023). — 2023.
22. Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models / L. Wang, W. Xu, Y. Lan, [et al.]. — 2023. — arXiv:2305.04091.
23. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks / P. Lewis, E. Perez, A. Piktus, [et al.] // Advances in Neural Information Processing Systems (NeurIPS 2020). — 2020.

24. RAGAS: Automated Evaluation of Retrieval Augmented Generation / S. Es [et al.] // Proceedings of EACL 2024. — 2024.
25. DALL-E 3 Technical Report / J. Betker, G. Goh, L. Jing, [et al.]. — 2023. — URL: <https://openai.com/dall-e-3>.
26. Labs B. F. FLUX.1: Unified Image Generation. — 2024. — arXiv:2407.12697.
27. Silero Models: Pre-trained Enterprise-Grade Speech Models. — дата обращения: 01.04.2025. URL: <https://github.com/snakers4/silero-models>.
28. ElevenLabs Multilingual v2 Documentation. — дата обращения: 01.04.2025. URL: <https://elevenlabs.io/docs>.
29. Molenda M. In Search of the Elusive ADDIE Model // Performance Improvement. — 2003. — Vol. 42, no. 5. — P. 34–36.
30. Allen M. W. Leaving ADDIE for SAM: An Agile Model for Developing the Best Learning Experiences. — Alexandria : ASTD Press, 2012.
31. Wiggins G., McTighe J. Understanding by Design. — 2nd ed. — Alexandria : ASCD, 2005.
32. Bryar C., Carr B. Working Backwards: Insights, Stories, and Secrets from Inside Amazon. — 2021. — St. Martin's Press.
33. Competing Against Luck: The Story of Innovation and Customer Choice / C. M. Christensen [et al.]. — Harper Business, 2016.
34. Taxonomy of Educational Objectives: The Classification of Educational Goals. Handbook 1: Cognitive Domain / B. S. Bloom [et al.]. — New York : David McKay Company, 1956.
35. MIT OpenCourseWare. — дата обращения: 01.04.2025. URL: <https://ocw.mit.edu>.
36. Align with Taxonomies. — дата обращения: 14.04.2026. URL: <https://www.monash.edu/learning-teaching/TeachHQ/Teaching-practices/learning-outcomes/how-to/align-with-taxonomies>.

37. Hess K. A Guide for Using Webb's Depth of Knowledge with Common Core State Standards. — 2013. — дата обращения: 14.04.2026. URL: https://portal.ct.gov/-/media/sde/mbi/documents/webbs_depth_of_knowledge.pdf.
38. Aligning Teaching for Constructing Learning. — дата обращения: 14.04.2026. URL: <https://www.advance-he.ac.uk/knowledge-hub/aligning-teaching-constructing-learning>.
39. Quality Matters Higher Education Rubric. — дата обращения: 14.04.2026. URL: <https://www.qualitymatters.org/qa-resources/rubric-standards/higher-ed-rubric>.
40. Fink's Significant Learning Outcomes. — дата обращения: 14.04.2026. URL: <https://www.buffalo.edu/catt/teach/develop/design/learning-outcomes/finks.html>.
41. Chi M. T. H., Wylie R. The ICAP Framework: Linking Cognitive Engagement to Active Learning Outcomes // Educational Psychologist. — 2014. — Vol. 49, no. 4. — P. 219–243. — DOI: 10.1080/00461520.2014.965823.
42. CAST. CAST Universal Design for Learning Guidelines version 3.0. — 2024. — дата обращения: 14.04.2026. URL: <https://udlguidelines.cast.org>.
43. Bandura A. Guide for Constructing Self-Efficacy Scales // Self-Efficacy Beliefs of Adolescents / ed. by F. Pajares, T. Urdan. — Information Age Publishing, 2006. — P. 307–337.
44. Perceived Competence Scales. — дата обращения: 14.04.2026. URL: <https://selfdeterminationtheory.org/perceived-competence-scales/>.
45. The Kirkpatrick Model. — дата обращения: 14.04.2026. URL: <https://www.kirkpatrickpartners.com/the-kirkpatrick-model/>.
46. Evidence to Support the Use of the Retrospective Pretest Method to Measure Dietary and Physical Activity Behavior and Self-Efficacy in Adolescents / M. K. Shilts [et al.] // Journal of Youth Development. — 2008. — Vol. 3, no. 1. — DOI: 10.5195/jyd.2008.326.

47. Goal Attainment Scaling: A Framework for Research and Practice in the Intellectual and Developmental Disabilities Field / K. A. Shogren [et al.] // Intellectual and Developmental Disabilities. — 2021. — Vol. 59, no. 1. — P. 7–21. — DOI: 10.1352/1934-9556-59.1.7.
48. LangGraph Documentation. — дата обращения: 01.04.2025. URL: <https://langchain-ai.github.io/langgraph>.
49. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation / Q. Wu [et al.] // Proceedings of ICLR 2024 Workshop LLM Agents. — 2024.
50. CrewAI Documentation. — дата обращения: 01.04.2025. URL: <https://docs.crewai.com>.
51. Agno Framework Documentation. — дата обращения: 01.04.2025. URL: <https://docs.agno.com>.
52. OpenAI Agents SDK Documentation. — дата обращения: 01.04.2025. URL: <https://platform.openai.com/docs/agents>.
53. Experimentation in Software Engineering / C. Wohlin [et al.]. — Berlin : Springer, 2012.
54. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena / L. Zheng, W. L. Chiang, Y. Sheng, [et al.]. — 2023. — arXiv:2306.05685.
55. Maurya A. Running Lean: Iterate from Plan A to a Plan That Works. — Sebastopol : O'Reilly Media, 2012.
56. Федеральный закон от 27 июля 2006 г. № 152-ФЗ «О персональных данных». — 2006. — М.: Собрание законодательства РФ, 2006.
57. Гражданский кодекс Российской Федерации. Часть четвёртая: Права на результаты интеллектуальной деятельности и средства индивидуализации. — 2006. — М.: Собрание законодательства РФ, 2006.

ПРИЛОЖЕНИЕ. А РУКОВОДСТВО ДЛЯ ИНТЕРВЬЮ С КЛИЕНТАМИ

В приложении представлено руководство для проведения глубоких B2B-интервью по методу Mom Test [4], использовавшееся при сборе первичных данных о проблеме (раздел 1.1 основного текста).

Контекст и цели интервью

Цель: проверить гипотезу о проблеме «Разработка образовательных курсов занимает слишком много времени и/или требует компетенций, которых нет у эксперта предметной области».

Целевая аудитория: HR-специалисты, L&D-менеджеры, методисты, тренеры в B2B-компаниях с > 50 сотрудников.

Формат: 30–45 минут, видеозвонок или очно.

Вопросы руководства

Блок 1. Разогрев и контекст:

- 1) Расскажите о своей роли. Как часто вам приходится создавать учебные материалы для сотрудников?
- 2) Какой последний курс или материал вы разрабатывали? Вспомните этот процесс — с чего он начался?
- 3) Сколько времени ушло от идеи до готового материала?

Блок 2. Проблема:

- 4) Что в этом процессе было самым сложным или утомительным?
- 5) Были ли случаи, когда вы *не смогли* создать нужный материал из-за нехватки времени, ресурсов или экспертизы?
- 6) Как часто учебные материалы устаревают и требуют обновления? Как вы сейчас с этим справляетесь?

Блок 3. Текущие решения:

- 7) Какие инструменты или сервисы вы уже пробовали для автоматизации разработки курсов? Что не устроило?
- 8) Если бы вы могли потратить бюджет на решение этой проблемы — на что бы потратили?

Блок 4. Заккрытие:

- 9) Есть ли коллеги, которых стоит поговорить на эту тему?
- 10) Можно ли мне прислать вам краткий обзор после того, как я поговорю с ещё несколькими людьми?

Сводка ключевых выводов

По результатам 20 проведённых интервью наиболее устойчивыми оказались следующие сигналы:

Таблица А.1 — Агрегированные выводы интервью с клиентами

Наблюдение	Значение	Интерпретация
Время разработки — главное ограничение	70 %	проблема носит не единичный, а системный характер
Используют подрядчиков / внешних методистов	50 %	рынок уже готов платить за снижение этой нагрузки
Готовы рассмотреть ИИ-инструмент	60 %	есть ранний сигнал интереса к решению
Формат исследования	20 интервью	глубинные B2B-интервью с клиентами по методу Mom Test

- Наибольшую ценность респонденты видят не в полной автоматизации, а в ускорении подготовки первого черновика курса.
- Для нормативных и регламентных сценариев критична прослеживаемость к источнику и возможность ручной проверки.
- Для B2B-сегмента значимы суверенитет данных и возможность локального развёртывания.

ПРИЛОЖЕНИЕ. Б АРТЕФАКТЫ ДЕМОНСТРАЦИИ MVP

В приложении представлен сценарий демонстрации MVP на контролируемом корпусе работы. Демонстрация не требует закрытых внешних материалов: используются внутренние документы Adapstory и открытые учебные программы, описанные в приложении Ж.

Сценарий демонстрации

Текущий демонстрационный сценарий строится вокруг одного документа из ядрового корпуса и показывает пользователю не абстрактную презентацию, а последовательность шагов внутри продукта:

- 1) загрузка исходного документа;
- 2) выбор методологии генерации (ADDIE как текущий базовый вариант);
- 3) получение и ручная проверка черновой структуры курса;
- 4) обсуждение, какие части пользователь оставил бы за собой, а какие готов делегировать системе;
- 5) обсуждение, какие метрики качества пользователь считает достаточными для публикации результата.

Вопросы после демонстрации

- 1) Насколько результат соответствует тому, что вы ожидали?
- 2) Что бы вы изменили в сгенерированной структуре?
- 3) Готовы ли вы использовать такой инструмент вместо текущего процесса?
- 4) Какие доказательства качества вам нужны перед публикацией курса?
- 5) Какие ограничения по данным, модели и проверке человеком должны быть видны в интерфейсе?

Критерии успеха решенческого интервью

Таблица Б.1 — Сигналы, фиксируемые на этапе решенческих интервью

Критерий	Позитивный сигнал	Что это подтверждает
Готовность встроить систему в текущий процесс	пользователь допускает частичную автоматизацию рутинных операций	наличие прикладной ценности, а не просто любопытства
Доверие к доказательному слою	пользователь понимает привязку к источнику, происхождение результата и знак качества	переход от интереса к демонстрации к проверяемому рабочему сценарию
Обсуждение эксплуатационных ограничений	появляется запрос на локальный контур, роли проверки и журнал качества	рост зрелости продуктового требования
Экономическая логика	пользователь сравнивает решение с подрядчиком / внутренним ресурсом	наличие бизнес-контекста для дальнейшего MVP

ПРИЛОЖЕНИЕ. В ПРОТОКОЛ ВНУТРЕННЕЙ И ОТКРЫТОЙ АПРОБАЦИИ

В работе не используются закрытые внешние документы и коммерческие обязательства. Аprobация MVP проводится на контролируемом корпусе: внутренние продуктово-редакционные материалы Adapstory, учебные регламенты и открытые программы MIT OCW. Такой дизайн позволяет воспроизводимо измерять качество без доступа к закрытым данным третьих лиц.

Контрольный сценарий

- 1) выбрать документ из ядрового корпуса приложения Ж;
- 2) запустить одношаговую базовую конфигурацию B2 и сохранить структуру курса;
- 3) запустить B4 ИИ-методиста на том же документе;
- 4) сохранить JSON-артефакты со статусом, результатом и происхождением;
- 5) рассчитать покрытие Блума, привязку к источнику, знак качества, экономику единицы продукта и метрики проверки фактов;
- 6) проверить результат скриптами `run_paired_b2_b4_experiment.py`,
`run_ai_methodist_product_validation.py` и
`check_thesis_excellent_readiness.py`.

Критерии принятия

- B4 генерируется на том же источнике, что и B2;
- среднее покрытие Блума B4 не ниже 70 %;
- привязка к источнику B4 не ниже 70 %;
- знак качества не ниже PASS_WITH_NOTES;
- все численные результаты воспроизводятся из JSON-артефактов, а не из ручной правки таблиц.

ПРИЛОЖЕНИЕ. Г С4-ДЕКОМПОЗИЦИЯ АРХИТЕКТУРЫ

В приложении представлена текстовая С4-декомпозиция фактической архитектуры MVP ИИ-методиста, синхронизированная с текущими сервисами Adapstory: AI Course Generator, инструмент Dify/RAG, граф знаний, School BFF и LMS.

Г.1 — Системный контекст (C4 Level 1)

- **Разработчик курса / HR-специалист:** загружает документ, запускает подготовку черновика, проверяет структуру и знак качества;
- **School UI / BFF School:** маршрутизирует запросы веб-клиента и показывает статус, результат и происхождение;
- **AI Course Generator:** исполняет LangGraph-конвейер генерации и хранит артефакты запуска;
- **Dify/RAG:** индексирует источник и возвращает фрагменты для EvidenceTable;
- **Граф знаний:** предоставляет связанные компетенции, понятия и предметные связи;
- **Конечная точка LLM:** локальная или OpenAI-совместимая конечная точка для моделей семейства Qwen;
- **LMS Adapstory:** принимает утверждённый курс и публикует его.

Г.2 — Контейнеры (C4 Level 2)

Г.3 — Компоненты (C4 Level 3)

- **SourceAnalyzer:** строит EvidenceTable из Dify/RAG-фрагментов и резервного фрагмента исходного текста;
- **CourseStructureAgent:** генерирует CourseBlueprint и использует граф знаний для семантического усиления структуры;
- **ContentCreatorAgent:** формирует уроки со встроенными ссылками на источники;
- **FactCheckAgent:** проверяет утверждения относительно источника;
- **ReviewAgent:** оценивает методологическую связность и Bloom coverage;
- **Verifier:** рассчитывает знак качества, происхождение результата и снимок

Таблица Г.1 — Контейнерная декомпозиция ИИ-методиста

Контейнер	Технология	Роль
AI Course Generator API	FastAPI	REST/MCP входная точка, создание запуска, статуса, результата и происхождения
Среда исполнения агентов	LangGraph	шестиузловой конвейер, прерывания, маршрутизация, цикл доработок
Хранилище контрольных точек и результатов	PostgreSQL	сохранение состояния, запусков, результатов и аудита
Инструмент RAG	расширение Dify	индексация источника и поиск фрагментов
Граф знаний	Neo4j / MCP	компетенции, понятия и связи для контекста курса
School BFF / UI	Java BFF / пользовательский интерфейс	пользовательский интерфейс проверки, публикации и отображения метрик

проверки дипломных метрик;

- **Слой проверки человеком:** блокирует публикацию без подтверждения человека;
- **Exporter:** передаёт утверждённый курс в LMS Adapstory.

ПРИЛОЖЕНИЕ. Д СПЕЦИФИКАЦИЯ ГРАФА АГЕНТОВ LANGGRAPH

В приложении представлена текстовая спецификация фактического шестиузлового графа агентов ИИ-методиста: узлы, переходы, точки участия человека и контур отката к прежней топологии.

Д.1 — Ноды графа

Д.2 — Основные переходы

Д.3 — Точки участия человека

- **НITL 1:** подтверждение структуры курса до генерации полного контента;
- **НITL 2:** финальное решение на основе знака качества, происхождения результата, ссылок и блокирующих замечаний;
- **Откат:** при отключении конвейера Feunman сервис может перейти к прежней четырёхузловой топологии, а происхождение результата фиксирует, какой конвейер фактически исполнялся.

Таблица Д.1 — Ноды графа агентов ИИ-методиста

Нода	Тип	Описание
source	агент	Поиск источников, EvidenceTable, статус покрытия
structure	агент	CourseBlueprint по методологии ADDIE и доказательному контексту
HITL-structure	прерывание	Подтверждение или коррекция структуры курса
content	агент	Черновики уроков со встроенными ссылками на источники
fact-check	агент	Проверка утверждений относительно EvidenceTable
review	агент	Методологическая проверка, покрытие Блума, связность
verifier	агент	Знак качества, подтверждённые утверждения, происхождение результата, снимок проверки дипломных метрик
HITL-quality	прерывание	Финальное решение человека перед публикацией

Таблица Д.2 — Ключевые переходы в графе LangGraph

Откуда	Куда	Условие перехода
source	structure	EvidenceTable построена или явно помечена как неполная
structure	HITL-structure	структура курса доступна для проверки
HITL-structure	content	структура утверждена пользователем
HITL-structure	structure	структура отклонена и требует пересборки
content	fact-check	уроки подготовлены и требуют верификации
fact-check	review	отчёты проверки фактов сформированы
review	content	требуется доработка, счётчик доработок меньше лимита
review	verifier	курс прошёл методологическую проверку или исчерпан лимит доработок
verifier	HITL-quality	знак качества и происхождение результата собраны
HITL-quality	END	человек принимает результат или фиксирует остановку

ПРИЛОЖЕНИЕ. Е ШАБЛОНЫ ЗАПРОСОВ ADDIE / SAM / BACKWARD DESIGN

В приложении представлены черновые системные запросы агента CourseStructureAgent для трёх поддерживаемых методологических режимов. Они служат не как неизменяемые финальные запросы, а как управляемые рамки для дальнейшей настройки.

Е.1 — Шаблон запроса ADDIE

[SYSTEM]

Ты — эксперт по методологии ADDIE разработки учебных курсов. Твоя задача: на основе предоставленного документа создать структуру курса, следуя фазам ADDIE.

Требования:

- каждый модуль должен содержать учебные цели по таксономии Блума;
- формат ответа — строго JSON (CourseBlueprint);
- не придумывай факты, которых нет в документе;
- если данных недостаточно, явно помечай неопределённость.

[USER]

Документ: {{document_text}}

Целевая аудитория: {{audience_profile}}

Е.2 — Шаблон запроса SAM

[SYSTEM]

Ты — эксперт по Successive Approximation Model. Построй курс как итеративную структуру, которую удобно быстро проверять и дорабатывать короткими циклами.

Требования:

- сначала предложи минимально жизнеспособную структуру курса;
- явно выделяй части, которые требуют ручной проверки;
- держи фокус на скорости и возможности быстрой итерации;
- формат ответа — JSON (CourseBlueprint).

[USER]

Документ: {{document_text}}

Целевая аудитория: {{audience_profile}}

E.3 — Шаблон запроса Backward Design

[SYSTEM]

Ты — эксперт по Backward Design. Начинай проектирование курса с конечных результатов обучения, а затем выстраивай модули, оценивание и учебные активности назад от целей.

Требования:

- сначала сформулируй измеримые результаты обучения;
- для каждого результата укажи, как он будет проверяться;
- затем предложи модули и уроки, которые ведут к этим результатам;
- формат ответа — JSON (CourseBlueprint).

[USER]

Документ: {{document_text}}

Целевая аудитория: {{audience_profile}}

ПРИЛОЖЕНИЕ. Ж ТЕСТОВЫЙ КОРПУС ДОКУМЕНТОВ

В приложении описан измеренный корпус, использованный в артефакте `baseline_comparison.json` для прогона одношаговой LLM-конфигурации (B2). Корпус содержит 19 документов в трёх категориях: продуктово-редакционные документы, корпоративные регламенты и учебные программы MIT OCW.

Описание измеренного корпуса одношаговой LLM-конфигурации (B2)

Таблица Ж.1 — Состав измеренного корпуса одношаговой LLM-конфигурации (B2)

Группа	Кол-во	Язык	Назначение в проверке
Продуктово-редакционные документы	7	RU	Проверка генерации по брендбукам, редакционным правилам и продуктовым описаниям.
Корпоративные регламенты	6	RU	Проверка извлечения требований, ограничений и нормативных формулировок.
Учебные программы MIT OCW	6	EN	Проверка переноса структуры дисциплин и учебных результатов в курс.
Итого	19	RU/EN	Единый корпус для одношаговой LLM-конфигурации (B2).

Машиночитаемое описание прогона хранится в `baseline_comparison.json`. В него входят идентификаторы:

- product-summary, VK brand guidelines, руководства по маскоту и мерчу, редакционные политики Сбер/HR;
- information security policy, personal data policy, incident management, onboarding, anticorruption, regulations summary;
- MIT OCW 14.01, 18.01, 6.0001, 6.042J, 8.01 и summary-файл.

Корпус следует трактовать как технический базовый ориентир для проверки одношаговой LLM-конфигурации (B2), а не как окончательную экспертно размеченную выборку. Его задача — воспроизводимо показать разрыв между скоростью одношаговой генерации и требованиями к

методическому качеству с опорой на источник.

Оценочные артефакты текущей итерации

На текущем этапе полностью подготовлены:

- измеренный корпус одношаговой LLM-конфигурации (B2) из 19 документов;
- набор из 30 вопросно-ответных пар для RAG-оценки;
- набор из 100 утверждений для оценки проверки фактов.

Парный прогон одношаговой LLM (B2) и ИИ-методиста (B4) выполнен на том же наборе документов: для каждого `doc_i` сохранены `B2_result_i`, `B4_result_i`, отдельный `kb_slug` B4 и строковая дельта покрытия Блума и привязки к источнику. Сводка и исходные REST-артефакты приведены в приложении И и файле `paired_b2_b4_experiment.json`. Дополнительно выполнена детерминированная лабораторная оценка: `evaluation_lab/ai_methodist_evaluation_lab_latest.json` фиксирует метрики по схеме RAG на 30 вопросно-ответных парах и `precision / recall / F1` проверки фактов на 100 утверждениях.

ПРИЛОЖЕНИЕ. И ОЦЕНОЧНЫЕ АРТЕФАКТЫ И ТЕКУЩИЕ РЕЗУЛЬТАТЫ

В приложении собраны артефакты валидации, которые уже подготовлены или измерены в текущей редакции диплома. Главный технический артефакт текущей версии — парный прогон одношаговой LLM (B2) и ИИ-методиста (B4) на одном и том же 19-документном корпусе. Этот прогон рассматривается как лабораторная проверка MVP: он показывает готовность контура одношаговой LLM (B2) и ИИ-методиста (B4) на контролируемом корпусе, но не используется как доказательство превосходства над аналогами. Для такого вывода подготовлена отдельная сравнительная проверка на открытых курсах $n \geq 30$.

И.1 — Агрегированные результаты одношаговой LLM-конфигурации (B2)

Таблица И.1 — Агрегированные результаты лабораторного прогона одношаговой LLM-конфигурации (B2)

Срез корпуса	n	Покрытие, %	Доля $\geq 70\%$
Все документы	19	61.4	21.1%
Продуктивно-редакционные документы	7	73.8	28.6%
Корпоративные регламенты	6	38.9	0%
Учебные программы MIT OCW	6	69.5	33.3%

Эти значения относятся к одношаговой LLM-конфигурации (B2) из артефакта `baseline_comparison.json` и используются как технический ориентир MVP. Для проверки вклада ИИ-методиста поверх этого базового ориентира выполнен парный прогон одношаговой LLM (B2) и ИИ-методиста (B4): для каждого документа `doc_i` сопоставлялись `B2_result_i` и `B4_result_i`, а итоговая дельта считалась по строкам, а не как сравнение независимых средних.

И.2 — Парный прогон одношаговой LLM (B2) и ИИ-методиста (B4)

В артефакте `paired_b2_b4_experiment.json` сохранены 19 пар результатов. Для каждого документа создавался отдельный `kb_slug` формата `diploma-b4-001`, `diploma-b4-002`, ..., `diploma-b4-019`; в B4 передавался ровно один исходный Markdown-документ, а исходные доказательства сохранялись в каталоге `paired_b2_b4_runs/diploma-b4-XXX/`.

Таблица И.2 — Сводка парного прогона одношаговой LLM (B2) и ИИ-методиста (B4) на одном корпусе

Метрика	Значение	Интерпретация
Число пар документов	19	одношаговая LLM (B2) и ИИ-методист (B4) сравниваются построчно
Среднее покрытие Блума одношаговой LLM (B2)	61.4 %	одношаговая базовая конфигурация ниже целевого порога
Среднее покрытие Блума ИИ-методиста (B4)	83.3 %	B4 проходит целевой порог $\geq 70\%$
Средняя парная дельта Блума	+21.9 п.п.	улучшение считается по каждому документу
Документы с положительной дельтой Блума	15 из 19	эффект наблюдается на большинстве корпуса
Привязка к источнику B4	100 %	все B4-запуски прошли контроль H2 по привязке к источнику
Знак качества B4	100 % PASS	19 из 19 запусков готовы к проверке человеком

Таблица И.3 — Парная дельта Блума по категориям корпуса

Категория	<i>n</i>	B2, %	B4, %	Дельта
Продуктивно-редакционные документы	7	73.8	83.3	+9.5 п.п.
Корпоративные регламенты	6	38.9	83.3	+44.4 п.п.
Учебные программы MIT OCW	6	69.5	83.3	+13.8 п.п.

И.3 — Подготовленные оценочные артефакты

Таблица И.4 — Оценочные наборы текущего MVP

Артефакт	Объём	Назначение
Измеренный корпус одношаговой LLM (B2)	19	подготовка курсов и сравнение базовых подходов
Вопросно-ответные пары (qa_pairs.json)	30	оценка faithfulness и answer relevancy
Фактуальные утверждения (statements.json)	100	расчёт precision / recall / F1 для проверки фактов
Парный прогон B2/B4	19 пар	проверка прироста ИИ-методиста (B4) относительно одношаговой LLM (B2) на тех же документах
Лабораторная оценка	30 вопросно-ответных пар + 100 утверждений	детерминированная проверка по схеме RAG и фактологическая проверка

И.4 — Детерминированная проверка по схеме RAG и фактологическая проверка

Скрипт `benchmarks.evaluation_lab` выполнен в детерминированном режиме `deterministic_lexical`. Он не вызывает внешние LLM и поэтому пригоден как регрессионный контроль. На 30

вопросно-ответных парах получены метрики по схеме RAG: faithfulness = 0.335, answer relevancy = 0.239, context precision = 0.567 и context recall = 0.335. Эти значения трактуются как диагностические, а не как основание для завышенного вывода о полном качестве поиска. В текущей ВКР RAG/eval-контур работает как консервативный контроль перед проверкой человеком: качество поиска требует расширения корпуса и экспертной разметки релевантных фрагментов.

На 100 фактуальных утверждениях контур проверки фактов дал: precision = 0.600, recall = 0.900, F1 = 0.720. Отдельно видно, что детектор хорошо ловит искажения типа подмены сущностей, отрицания, временных искажений и большую часть числовых искажений, но переотмечает часть корректных утверждений как подозрительные. Это честно фиксирует текущий компромисс: система предпочитает перестраховаться перед проверкой человеком, а не пропустить ошибку.

И.5 — Машиночитаемые доказательные артефакты платформы

В текущей кодовой базе ИИ-методиста уже предусмотрены поля, необходимые для дипломной валидации:

- citations и block_provenance — ссылочная привязка уроков к источникам;
- quality_seal — статус PASS, PASS_WITH_NOTES или FAIL;
- cost_quality — стоимость, модель, токены и объяснение компромиссов цены и качества;
- thesis_validation — снимок метрик H1–H3, пригодный для сохранения в экспериментальный корпус.

Фронтальный E2E-тест дипломной валидации проверяет отображение этих полей в пользовательском контуре, а экспериментальные скрипты превращают JSON-артефакты в отчёт контроля по гипотезам диплома и парную таблицу B2/B4. Контроль готовности check_thesis_excellent_readiness.py дополнительно запрещает возвращать в текст незавершённые утверждения про внешние коммерческие обещания, закрытые материалы третьих лиц или визуальные материалы как будто они являются измеренными результатами.

И.6 — Подготовленная сравнительная проверка на открытых курсах

Для расширения проверки за пределы 19-документной лабораторной проверки MVP подготовлен воспроизводимый манифест `open_course_benchmark_manifest.json` и CSV-версия `open_course_benchmark_manifest.csv`. Манифест содержит 39 открытых учебных документов из MIT OCW, OpenEdu, HuggingFace Learn и открыто доступных материалов каталогов курсов. Его статус — `READY_FOR_MEASURED_BENCHMARK`: корпус готов к запуску измерений, но сам по себе не является результатом сравнения качества.

Правило этого контроля: широкое утверждение о том, что ИИ-методист существенно лучше аналогов, заблокировано до измеренной сравнительной проверки на открытых курсах $n \geq 30$ с линиями B2, B4 и базовой ручной оценкой по шкале, а также с исходными JSON/CSV-артефактами и отдельным разделом ограничений.

ПРИЛОЖЕНИЕ. К LEAN CANVAS И ФИНАНСОВАЯ МОДЕЛЬ

В приложении представлены Lean Canvas и сценарные расчёты финансовой модели ИИ-методиста (раздел 4.4 основного текста).

К.1 — Lean Canvas

В текущем черновике Lean Canvas представлен в табличной форме.

Таблица К.1 — Lean Canvas ИИ-методиста

Проблема	Решение	Уникальное предложение
Создание 1 часа обучения может занимать 73–490 часов работы методиста; высокая стоимость подрядчиков; устаревание контента	Полуавтоматическая подготовка структуры и черновых материалов курса по загруженному документу, проактивные подсказки и ручная проверка в контуре, механизм последующей актуализации	Сочетание методологической вариативности, суверенитета данных (локальный LLM-контур) и глубокой интеграции в LMS-экосистему
Несправедливое преимущество	Ключевые метрики	Каналы
ADDIE / SAM / BD как переключаемые режимы; локальный LLM-контур; экосистема LMS Adapstory	Время до первого методического черновика; Покрытие уровней Блума; faithfulness; себестоимость курса	Прямые продажи B2B; продуктовые демо на открытом и внутреннем корпусе; EdTech-конференции и контент-маркетинг
Сегменты потребителей		Структура затрат / доходов
B2B: HR-отделы, L&D-команды, корпоративные университеты, учебные центры и EdTech-компании		Затраты: ФОТ команды, маркетинг, API-токены, прочие расходы. Доходы: B2B-подписка по тарифам 2 999 / 20 999 / 44 999 руб./мес.

К.2 — Сценарные финансовые показатели

Таблица К.2 — Годовые показатели PNL-модели

Период	Выручка	Расходы и налог	Опер. денежный поток	Комментарий
2026	76.0 млн руб.	49.0 млн руб.	26.9 млн руб.	помесячный расчёт PNL-файла
2027	1 764.2 млн руб.	227.8 млн руб.	1 536.4 млн руб.	помесячный расчёт PNL-файла
2028E	4 044.1 млн руб.	446.1 млн руб.	3 598.0 млн руб.	годовой темп декабря 2027 года
Итого	5 884.2 млн руб.	722.9 млн руб.	5 161.4 млн руб.	сценарный горизонт 2026–2028E

Таблица К.3 — Ключевые допущения PNL-модели

Блок модели	Допущение
Тарифы	2 999 / 20 999 / 44 999 руб. в месяц в зависимости от пакета продукта
Продажи	три сценария привлечения: органическое продвижение, поисковые запросы, маркетинговая стратегия и SEO
Отток	10 % активной базы в расчёте пользовательского потока
ФОТ	стартовый ФОТ 1.06 млн руб. в месяц с последующим ростом по сценарию
Маркетинг	базовый бюджет 300 тыс. руб. с ростом маркетинговой статьи по сценарию
Налоги	УСН 6 % от выручки; взносы от ФОТ учтены отдельной строкой

К.3 — Допущения модели

- исходный PNL-файл содержит детальный ежемесячный расчёт на 2026–2027 годы;
- 2028E в таблице является продолжением по годовому темпу декабря 2027 года, а не отдельным листом исходной книги;
- модель носит сценарный характер и не заменяет данные будущих продаж;
- расчёт подтверждает прежде всего то, что выбранная архитектура не делает продукт заведомо экономически неустойчивым;
- коммерческие выводы не используются как доказательство качества MVP; качество подтверждается отдельными техническими замерами на

внутреннем и открытом корпусе.

ПРИЛОЖЕНИЕ. Л МАТРИЦА ВОСПРОИЗВОДИМОСТИ MVP

В приложении зафиксировано, какие результаты MVP подтверждаются машинно воспроизводимыми артефактами. Перечисленные ниже JSON и Markdown-отчёты получены из экспериментальных скриптов и каталогов сырых запусков. Они используются как источник численных утверждений диплома.

Л.1 — Источники доказательств

Л.2 — Связь артефактов с критериями MVP

Л.3 — Команды воспроизведения

Воспроизведение результатов отделено от пользовательского интерфейса. Для проверки численных утверждений используются следующие команды:

```
cd Диплом
python3 experiments/\
run_ai_methodist_product_validation.py
python3 experiments/\
run_paired_b2_b4_experiment.py
python3 experiments/\
check_thesis_excellent_readiness.py
```

Артефакты сырых запусков и агрегированные отчёты должны храниться вместе: если численное значение меняется в JSON-отчёте, соответствующая таблица в тексте диплома обновляется тем же изменением.

Таблица Л.1 — Артефакты, подтверждающие результаты MVP

Утверждение	Артефакт	Что проверяется
В2 измерен на одном корпусе	агрегаты базовой конфигурации и продуктовой проверки из приложения И	$n = 19$, время, покрытие Блума, доля результатов выше порога
В4 сравнивается с В2 построчно	парный В2/В4-отчёт и строки сырых запусков из приложения И	19 пар документов, парная дельта, привязка к источнику, знак качества
Каждый В4-запуск сохраняет исходные доказательства	каталоги запусков diploma-b4-001-019	входные данные, статусы генерации, результат, ответы согласования, файл парной строки
Поисково-фактологический контур проверяется отдельно	отчёт лабораторной оценки из приложения И	30 вопросно-ответных пар, 100 утверждений, диагностика по схеме RAG и F1 проверки фактов
Сравнительная проверка на открытых курсах подготовлена как следующий контроль	манифест JSON/CSV и протокол MD из экспериментального контура	$n = 39$ открытых учебных документов; это манифест, а не утверждение о превосходстве над аналогами
Текст диплома защищён от устаревших утверждений	контроль готовности из экспериментального контура	отсутствие внешних коммерческих завышенных утверждений, старых метрик и незавершённых сравнений, включая запрет делать вывод о превосходстве над аналогами на базе $n = 19$

Таблица Л.2 — Прослеживаемость между критериями MVP и результатами эксперимента

Критерий	Подтверждение	Ограничение
Быстрый первый черновик	В4: среднее время 17.1 с на 19-документном корпусе	это лабораторная оценка, а не SLA промышленного контура
Методическая структура курса	В4: среднее покрытие Блума 83.3 % против 61.4 % у В2	оценка автоматическая; внешняя экспертная разметка вынесена в будущий протокол
Работа от источника	В4: привязка к источнику 100 %, знак качества PASS в 19 из 19 запусков	метрика фиксирует наличие ссылочной привязки, но не заменяет методическое проверка
Сравнение с аналогами	сравнительная проверка на открытых курсах $n \geq 30$ подготовлена как следующий контрольный этап	$n = 19$ является лабораторной проверкой MVP и недостаточен для сильного вывода о превосходстве над аналогами
Контроль фактических искажений	F1 проверки фактов = 0.720, recall = 0.900	precision = 0.600 показывает консервативный контроль перед проверкой человеком, а не доказанное качество поиска
Экономическая реализуемость	сценарная себестоимость порядка 75 руб. за курс	расчёт зависит от загрузки GPU, тарифов и каналов продаж