

СОДЕРЖАНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ	9
ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ	11
ВВЕДЕНИЕ	12
1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И ПОСТАНОВКА ЗАДАЧИ ..	16
1.1 Проблема и её масштаб	16
1.1.1 Болевые точки авторов курсов	16
1.1.2 Разрыв между экспертизой и образовательной упаковкой	17
1.1.3 Подтверждение проблемы: результаты Customer De- velopment	17
1.1.4 Решенческие интервью и критерии решения	17
1.1.5 Рыночный контекст: TAM / SAM / SOM	18
1.2 Анализ существующих продуктов	19
1.2.1 Прямые конкуренты	19
1.2.2 Смежные решения	20
1.2.3 Сравнительная матрица	20
1.2.4 Пробел между проблемой и существующими решениями	20
1.2.5 Тяжелокопируемые конкурентные преимущества	22
1.3 Обзор научных методов и подходов	25
1.3.1 Формулировка исследовательского вопроса	25
1.3.2 LLM для поддержки проектирования образовательных материалов	26
1.3.3 Мультиагентные системы для поддержки проектирования курса	26
1.3.4 RAG в образовании	26
1.3.5 Генерация мультимедиа для обучения	27
1.3.6 Методологии проектирования курсов в контексте LLM	27
1.3.7 Оценка качества результатов, подготовленных с участием ИИ	27
1.3.8 Идентификация исследовательской лакуны	27

1.4	Постановка задачи и гипотезы	28
1.4.1	Задача исследования	28
1.4.2	Методологическая основа	28
1.4.3	Три конвейера ИИ-методиста	29
1.4.4	Исследовательские гипотезы	29
1.4.5	Метрики проверки гипотез	29
2	ИССЛЕДОВАНИЕ: ЭКСПЕРИМЕНТЫ И ВЫБОР ТЕХНОЛОГИЙ .	31
2.1	Дизайн эксперимента	31
2.1.1	Тестовый корпус и оценочные артефакты	31
2.1.2	Конфигурации эксперимента и расшифровка B1–B4....	32
2.1.3	Метрики оценки	33
2.1.4	Расширенная педагогическая и пользовательская рамка	33
2.2	Выбор и обоснование технологий	34
2.2.1	Фреймворк мультиагентной оркестрации.....	34
2.2.2	Выбранная архитектура	36
2.2.3	Большая языковая модель.....	37
2.2.4	Поиск, векторные представления и граф знаний.....	38
2.2.5	Стратегии чанкинга.....	39
2.2.6	Перспективное развитие генерации изображений	39
2.2.7	Перспективное развитие генерации подкастов.....	40
2.3	Проверенные результаты экспериментов	40
2.3.1	Результаты одношаговой LLM-конфигурации (B2).....	40
2.3.2	Сравнение LLM-конфигурации (B2) и ИИ-методиста (B4)	43
2.3.3	Оценочные наборы для RAG и факт-чекинга	44
2.3.4	Сценарная unit-экономика MVP.....	45
2.3.5	Ограничения этапа и план исследования	46
2.3.6	Финальная MVP-конфигурация	46
3	ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ	48
3.1	Архитектура системы	48
3.1.1	Контекстная диаграмма (C4 Level 1)	48
3.1.2	Диаграмма контейнеров (C4 Level 2).....	48
3.1.3	Доменная модель	49

3.2	Мультиагентная система (LangGraph).....	50
3.2.1	Граф агентов.....	50
3.2.2	Ноды конвейера	50
3.2.3	Управление состоянием и human-in-the-loop	50
3.3	Ключевые конвейеры.....	52
3.3.1	Обработка источника и поиск	52
3.3.2	Подготовка черновика курса	52
3.3.3	Метка качества, прослеживаемость и валидация ВКР ..	54
3.3.4	Roadmap-компоненты	54
3.4	Инфраструктура и развёртывание	54
3.4.1	Dev/env-dev контур	54
3.4.2	Наблюдаемость и проверяемость	55
4	ВАЛИДАЦИЯ, ИМПАКТ И БИЗНЕС-ОЦЕНКА	56
4.1	Протокол валидации.....	56
4.1.1	Автоматизированная оценка.....	56
4.1.2	Рубрика контроля качества	56
4.1.3	Лабораторная апробация MVP	57
4.2	Сквозная верификация	57
4.2.1	Сценарий 1: Онбординг-курс (ADDIE)	57
4.2.2	Сценарий 2: Нормативный курс с факт-чекингом	58
4.2.3	Сценарий 3: Автоактуализация	58
4.3	Текущие результаты и проверка гипотез.....	58
4.3.1	Сводка фактически подтверждённых результатов	58
4.3.2	Проверка гипотез Н1–Н3	59
4.3.3	Производительность.....	60
4.3.4	Точность факт-чекинга	60
4.4	Ограничения исследования и угрозы валидности	61
4.4.1	Ограничения тестового датасета.....	61
4.4.2	Ограничения эталонного корпуса.....	62
4.4.3	Ограничения пользовательской валидации	62
4.4.4	Ограничения технологического стека	62
4.4.5	Угрозы внешней валидности	63
4.4.6	Направления для устранения ограничений	63
4.5	Бизнес-оценка и масштабирование	63

4.5.1	Unit-экономика	63
4.5.2	Lean Canvas	64
4.5.3	Финансовая модель (прогноз на 3 года)	64
4.5.4	Потенциал масштабирования	65
4.5.5	PESTLE-анализ при масштабировании	65
4.5.6	Оценка рисков	66
4.5.7	Дорожная карта	66
4.5.8	Интеллектуальная собственность	67
4.6	Степень готовности и обратная связь от рынка	67
4.6.1	Текущий статус MVP	67
4.6.2	Рыночные сигналы	67
4.6.3	Соответствие решения проблеме	68
4.6.4	Качественная обратная связь	68
ЗАКЛЮЧЕНИЕ		71
Использование ИИ и личный вклад автора		74
Использование ИИ-инструментов		74
Личный вклад автора		74
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ		75
А ГАЙД ДЛЯ CUSTOMER DEVELOPMENT ИНТЕРВЬЮ		81
Б АРТЕФАКТЫ ДЕМОНСТРАЦИИ MVP		83
В ПРОТОКОЛ ВНУТРЕННЕЙ И ОТКРЫТОЙ АПРОБАЦИИ		85
Г С4-ДЕКОМПОЗИЦИЯ АРХИТЕКТУРЫ		86
Д СПЕЦИФИКАЦИЯ ГРАФА АГЕНТОВ LANGGRAPH		88
Е ПРОМПТ-ШАБЛОНЫ ADDIE / SAM / BACKWARD DESIGN		90
Ж ТЕСТОВЫЙ КОРПУС ДОКУМЕНТОВ		92
И ОЦЕНОЧНЫЕ АРТЕФАКТЫ И ТЕКУЩИЕ РЕЗУЛЬТАТЫ		94

К	LEAN CANVAS И ФИНАНСОВАЯ МОДЕЛЬ	99
Л	МАТРИЦА ВОСПРОИЗВОДИМОСТИ MVP	101

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

ADDIE	— Analyze, Design, Develop, Implement, Evaluate (методология проектирования курсов)
API	— Application Programming Interface (интерфейс программирования приложений)
B2B	— Business-to-Business (бизнес-модель)
BD	— Backward Design (методология «обратного проектирования» курса)
BFF	— Backend-for-Frontend (паттерн архитектуры)
CAC	— Customer Acquisition Cost (стоимость привлечения клиента)
CI/CD	— Continuous Integration / Continuous Delivery (непрерывная интеграция и доставка)
CVM	— Customer Value Management (управление ценностью клиента)
DAG	— Directed Acyclic Graph (ориентированный ациклический граф)
GPU	— Graphics Processing Unit (графический процессор)
IRR	— Internal Rate of Return (внутренняя норма доходности)
JTBD	— Jobs To Be Done (методология исследования потребностей)
KPI	— Key Performance Indicator (ключевой показатель эффективности)
LLM	— Large Language Model (большая языковая модель)
LMS	— Learning Management System (система управления обучением)
LTV	— Lifetime Value (пожизненная ценность клиента)

MVP	— Minimum Viable Product (минимально жизнеспособный продукт)
NPS	— Net Promoter Score (индекс потребительской лояльности)
NPV	— Net Present Value (чистая приведённая стоимость)
RAG	— Retrieval-Augmented Generation (генерация с дополнением поиском)
REST	— Representational State Transfer (архитектурный стиль API)
ROI	— Return on Investment (рентабельность инвестиций)
SAM	— Successive Approximation Model (итеративная методология проектирования курсов)
SAM	— Serviceable Addressable Market (доступный рынок) [в контексте рыночного анализа]
SOM	— Serviceable Obtainable Market (реально достижимый рынок)
SUS	— System Usability Scale (шкала удобства использования системы)
TAM	— Total Addressable Market (общий доступный рынок)
TTS	— Text-to-Speech (синтез речи)
ВКР	— выпускная квалификационная работа
ИИ	— искусственный интеллект
ИС	— интеллектуальная собственность
ЛМС	— система управления обучением (эквивалент LMS)
ЛПР	— лицо, принимающее решения

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

Классификация	— процесс распределения объектов по категориям на основе их признаков
Нейронная сеть	— математическая модель, имитирующая работу мозга, используемая для решения задач распознавания и классификации
Обучающая выборка	— совокупность данных, используемых для настройки параметров модели машинного обучения

ВВЕДЕНИЕ

Большие языковые модели (LLM) всё активнее применяются для автоматизации рутинных операций при проектировании образовательных материалов. Мировой рынок корпоративного обучения, по оценкам аналитических агентств, превысит \$51 млрд к 2030 году [1]. Главный сдерживающий фактор роста — высокая стоимость и длительность создания качественного учебного контента. Средний цикл разработки одного корпоративного курса силами методиста-эксперта составляет от нескольких дней до нескольких недель и требует педагогических компетенций, которыми не всегда обладают эксперты предметной области.

Существующие ИИ-инструменты для ускоренной подготовки курсов (Coursebox AI, iSpring AI) сильны как authoring-ускорители: они помогают получить структуру, квиз, визуальные материалы, перевод или SCORM/LMS-экспорт, однако в открытых продуктовых материалах для них не заявлен воспроизводимый artifact trail уровня source-grounding, block provenance, fact-check, quality seal и paired-сравнения с одношаговым baseline. Мультиагентные LLM-конвейеры для решения этой задачи остаются малоизученными: отсутствуют систематические сравнения архитектур на воспроизводимом российском корпусе документов и внешнем зарубежном сравнительном контуре, а также воспроизводимые бенчмарки с привязкой не только к таксономии Блума, но и к согласованности курса, качеству онлайн-курса и переносу обучения в практику.

Объект исследования — образовательная платформа Adapstory (AI LMS), предоставляющая инструменты создания и управления учебными курсами для B2B-клиентов.

Предмет исследования — микросервис ИИ-методист: интеллектуальный проактивный методический ассистент, поддерживающий методиста, эксперта и разработчика курса при создании, упаковке и актуализации образовательных продуктов на основе LLM с применением мультиагентной оркестрации.

Цель работы — разработать MVP интеллектуального методического ассистента платформы Adapstory и воспроизводимый контур его технической

и продуктовой валидации, показывающий, насколько мультиагентная обработка внутренних и открытых учебных документов способна снизить рутинную нагрузку при подготовке структуры и черновых материалов курса при сохранении за человеком методического решения и контроля качества.

Для достижения цели поставлены следующие задачи:

- 1) провести анализ предметной области: Customer Development с B2B-аудиторией, продуктовый обзор конкурентов и систематический обзор научных подходов;
- 2) оценить рыночный потенциал решения (TAM/SAM/SOM) и сформулировать исследовательские гипотезы;
- 3) спроектировать мультиагентную архитектуру конвейера поддержки проектирования курсов и обосновать выбор технологического стека через воспроизводимые эксперименты;
- 4) реализовать систему: FastAPI-микросервис AI Course Generator, граф агентов LangGraph, интеграцию с Dify/RAG-контуром, Knowledge Graph и сохранением состояния в PostgreSQL;
- 5) провести валидацию системы: автоматизированную оценку времени генерации, покрытия уровней таксономии Блума, source-grounding, факт-чекинга и unit-экономики на внутреннем и открытом корпусе;
- 6) оценить бизнес-потенциал: unit-экономику, финансовую модель и провести Customer Development для подтверждения соответствия решения выявленной проблеме.

Научная новизна работы состоит в следующем: предложена и инженерно реализована воспроизводимая схема проверки мультиагентного ИИ-методиста для проектирования учебных курсов, сочетающая (1) исполняемую методологическую модель проектирования курса в первой реализации ADDIE, (2) графовую оркестрацию LangGraph с двумя точками участия человека, (3) source-grounded RAG/KG-контур, таблицу свидетельств, факт-чекинг, quality seal и provenance-запись каждого запуска. Уникальность решения не сводится к применению LLM: в отличие от Coursebox AI, iSpring AI, NotebookLM и одношаговой LLM-конфигурации (B2), система проектирует курс как проверяемый методический pipeline, где каждый блок результата связан с исходным документом, проходит автоматический quality gate и сохраняется как

воспроизводимый evidence-артефакт для последующего human review. Тяжелокопируемые конкурентные преимущества решения раскрыты через таблицу 1.2: сравнение построено не по лозунгам, а по проверяемым механизмам доверия, ревью и повторяемости результата.

Положения, выносимые на защиту:

- 1) Одношаговая LLM-конфигурация (B2) на измеренном корпусе из 19 документов генерирует структуру курса в среднем за 4.37 с, но достигает только 61.4 % среднего покрытия уровней таксономии Блума и не создаёт ссылок на источник; это обосновывает переход к мультиагентной архитектуре.
- 2) Мультиагентная 6-node архитектура LangGraph (source_analyzer -> course_structure -> content_creator -> fact_check -> review -> verifier) вводит таблицу свидетельств, факт-чекинг, quality seal, provenance и две human-review точки, необходимые для source-grounded корпоративного курса. В paired-прогоне на том же корпусе ИИ-методист (B4) повысил среднее покрытие Блума до 83.3 % и дал source-grounding 100 % при quality seal PASS в 19 из 19 запусков.
- 3) Customer Development подтвердил наличие проблемы: проведены 20 B2B-интервью, 70 % респондентов называют длительность разработки главным ограничением, 50 % используют подрядчиков или внешних методистов, 60 % готовы рассмотреть ИИ-инструмент такого класса.

Текущее состояние проекта: разработан MVP, включающий контур обработки источников, агентный конвейер поддержки проектирования курса с методологией ADDIE, source/provenance-слой, quality seal и ручное ревью. Проведены проблемные B2B-интервью, paired-прогон одношаговой LLM (B2) и ИИ-методиста (B4) на 19 документах, детерминированная RAG-style/fact-check проверка и сценарная unit-экономическая оценка. Партнёрские материалы и закрытые внешние документы в валидации работы не используются. Важно зафиксировать границу доказательств: $n = 19$ является MVP/lab validation и лабораторной валидацией инженерной готовности текущего MVP, но этого недостаточно для сильного вывода о превосходстве над аналогами. Следующий validation gate — open-course benchmark $n \geq 30$ на открытых курсах с raw JSON/CSV-артефактами, competitor-style/manual rubric baseline и отдельной фиксацией ограничений.

Работа состоит из введения, четырёх глав, заключения, раздела об использовании ИИ, списка использованных источников и десяти приложений. Глава 1 содержит анализ предметной области и постановку задачи. Глава 2 описывает дизайн эксперимента и обоснование выбора технологий. Глава 3 посвящена технической реализации системы. Глава 4 содержит результаты валидации, анализ ограничений и бизнес-оценку.

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И ПОСТАНОВКА ЗАДАЧИ

1.1 Проблема и её масштаб

1.1.1 Болевые точки авторов курсов

Разработка корпоративного учебного курса остаётся трудоёмким и слабо масштабируемым процессом. Даже при наличии готового экспертного материала необходимо определить целевую аудиторию, сформулировать учебные цели, разбить содержание на модули и уроки, подобрать формат подачи, подготовить оценочные материалы и синхронизировать всё это с требованиями LMS. По оценке Charman Alliance, производство одного часа eLearning-контента требует от 42 до 490 часов работы в зависимости от сложности сценария, мультимедийности и глубины методической проработки; для большинства практических проектов реалистичный коридор составляет 40–200 часов на один час готового обучения [2].

Для российского B2B-сегмента проблема усугубляется дополнительно.

- **Дефицит методических компетенций.** Эксперт предметной области знает материал, но не всегда умеет переводить знание в педагогически корректную структуру курса. Другой проблемой становится нехватка или перегрузка специалистов в области методики преподавания. У компаний зачастую нет финансовой возможности иметь собственный методический отдел.
- **Высокая стоимость внешней разработки.** На рынке корпоративного обучения разработка одного курса силами подрядчика обычно оценивается в диапазоне 100–300 тыс. руб. за проект, что делает частое обновление контента экономически невыгодным для малого и среднего бизнеса [3].
- **Быстрое устаревание источников.** Регламенты, продуктовые описания и внутренние правила обновляются быстрее, чем команда успевает вручную пересобрать учебные материалы, из-за чего курс быстро расходится с актуальной версией исходного документа.

1.1.2 Разрыв между экспертизой и образовательной упаковкой

В корпоративной среде инициатором курса обычно выступает владелец продукта, руководитель функции, HR или L&D-менеджер. Первый хорошо знает предметную область, второй понимает бизнес-контекст, однако ни один из них не обязательно владеет инструментами педагогическим дизайном на уровне, достаточном для создания масштабируемого цифрового курса.

На практике это проявляется так: черновой материал остаётся на уровне «экспертного конспекта» без явных учебных результатов и уровней освоения. Структура курса строится от имеющихся документов, а не от целей обучения, что снижает практическую ценность. Сопровождение же требует подключения методиста, зачастую не входящего в команду.

1.1.3 Подтверждение проблемы: результаты Customer Development

Для первичной проверки гипотез о проблеме проведено 20 глубинных B2B-интервью с HR-специалистами, L&D-менеджерами, методистами и корпоративными тренерами по подходу Mom Test [4]. Гайд интервью, логика кодирования ответов и шаблон таблицы инсайтов вынесены в приложение А.

Количественные результаты:

- **70 %** респондентов называют время подготовки курса главным ограничением запуска нового обучения;
- **50 %** респондентов уже привлекают внешних подрядчиков или отдельных методистов для упаковки материала;
- **60 %** готовы рассмотреть ИИ-инструмент как часть текущего процесса разработки, если он не ухудшает качество структуры и позволяет сохранить контроль над итоговым результатом.

Распределение ответов респондентов представлено на рисунке 1.1.

Качественный вывод: обучающиеся находятся в профиците информации и дефиците времени. Отсюда запрос — быстро превратить регламент, брендбук или продуктовый бриф в обучение с понятной логикой, проверяемыми учебными целями и практическим результатом.

1.1.4 Решенческие интервью и критерии соответствия решения проблеме

Серия решенческих интервью проведена на базе функционального прототипа ИИ-методиста (сценарий демонстрации — приложение Б).



Рисунок 1.1 — Результаты Customer Development (n=20 B2B-интервью)

Проверяемые критерии соответствия решения проблеме:

- 1) готов ли руководитель L&D-отдела встроить систему в текущую ручную стадию подготовки черновой структуры курса как инструмент ускорения и снятия рутины;
- 2) готов ли методист использовать систему на реальном документе своей организации;
- 3) экономически эффективно ли решение по отношению к стоимости аутсорс-разработки или внутреннего методического ресурса.

1.1.5 Рыночный контекст: TAM / SAM / SOM

Глобальный рынок онлайн-обучения растёт: по оценке Grand View Research, его объём составил \$299.67 млрд в 2024 году и может достичь \$842.64 млрд к 2030 году при CAGR около 19 % [5]. Это задаёт широкий TAM для решений, ускоряющих подготовку цифровых образовательных материалов.

Для оценки сегмента в России в работе используется более консервативная логика. По данным Smart Ranking, объём российского EdTech-рынка в 2023 году достиг 119.33 млрд руб., а доля сегмента «разработчики и платформы» составляла 13 % от общей структуры рынка [3]. Этот слой ближе всего по природе к ИИ-методисту; рынок инструментов поддержки разработки курсов оценивается примерно в 15.5 млрд руб.

При целевой доле 0.1 % от SAM в горизонте трёх лет SOM составляет около 15.5 млн руб. в год. При базовой B2B-подписке порядка 15 тыс. руб. в месяц это соответствует примерно 85–90 активным корпоративным клиентам. Такой масштаб достижим для нишевого B2B-продукта.

Структура рыночной оценки показана на рисунке 1.2.




Рисунок 1.2 — Оценка рынка: TAM / SAM / SOM

1.2 Анализ существующих продуктов

1.2.1 Прямые конкуренты

Coursebox AI позиционируется как конструктор курсов на основе ИИ и позволяет преобразовывать документы, слайды, видео и URL в курс, автоматически генерировать тесты, видео, изображения и публиковать результат в собственную LMS либо экспортировать в SCORM/LTI форматах [6]. Это один из наиболее близких по ценностному предложению продукт на рынке. Однако его логика остаётся в первую очередь ориентированной на быструю упаковку содержимого: сильная сторона продукта — скорость, а не явная педагогическая методология или контроль корректности фактов по отношению к исходному документу.

Articulate 360 AI добавляет ИИ-функции в зрелую среду корпоративного контента: создание структуры курса, чернового текста, перевода, изображений и озвучки внутри экосистемы Articulate. Продукт хорошо встроен в привычный рабочий процесс методиста, но остаётся инструментом повышения производительности разработчика курса, а не самостоятельным методическим конвейером с RAG-слоем, факт-чекингом и локальным развёртыванием [7].

iSpring Suite AI развивает похожую траекторию: в 2025 году в продукт добавлены AI Course Creation Helper, AI Translator, AI Image Generator, а также функции синтеза речи и другие инструменты ускорения разработки курса [8]. Сильной стороной iSpring является зрелая экосистема для корпоративного обучения и русскоязычный рынок. Ограничение состоит в том, что ИИ остаётся надстройкой над средой разработки контента, а не автономным мультиагентным конвейером, принимающим на вход первичный документ и проводящим его через полную цепочку анализа,

проектирования и обновления курса.

Synthesia лидирует в классе ИИ-видеогенерации для обучения и корпоративных коммуникаций: её ценность сосредоточена в создании аватарных роликов, озвучки и мультязычного видео-контента для обучения и L&D-задач [9]. Но Synthesia не закрывает задачу проектирования учебной структуры.

1.2.2 Смежные решения

Google NotebookLM — сильный смежный продукт для работы с источниками, который умеет строить краткие выжимки, аудиообзоры и видеообзоры по загруженным материалам. В 2025 году Google расширил генерацию аудио и видео обзоров до 80+ языков, сделав их заметно реалистичнее и полезнее для изучения сложных источников [10]. Однако NotebookLM не предназначен для создания LMS-совместимой структуры курса, педагогического дизайна и контроля соответствия учебных целей.

GetCourse является одним из крупнейших российских игроков рынка LMS/онлайн-школ: платформа сообщает о 50,000+ клиентах, 16 млн учеников и совокупном обороте школ на платформе в 158 млрд руб. за 2025 год [11]. Для настоящей работы GetCourse важен как ориентир класса систем, в которые ИИ-методист потенциально может встраиваться как сервис генерации и обновления курса.

1.2.3 Сравнительная матрица

В таблице 1.1 приведено сравнение решений по критериям, которые оказались значимыми в Customer Development: способность работать от исходного документа, наличие встроенной педагогической логики, поддержка русскоязычного контента, суверенитет данных, автоматическое обновление содержания и интеграция с LMS-средой.

Визуализация сравнения в форме радарной диаграммы приведена на рисунке 1.3.

1.2.4 Пробел между проблемой и существующими решениями

Рынок предлагает и стартапы, и зрелые продукты для ускорения создания обучения. Однако сохраняется разрыв между генерацией учебных материалов и адаптацией к контексту каждого обучающегося.

Ни одно из рассмотренных решений не закрывает одновременно




Рисунок 1.3 — Радарная диаграмма сравнения решений

Таблица 1.1 — Сравнительный анализ конкурентных решений

Критерий	Coursebox	Articulate AI	iSpring AI	Synthesia	ИИ-методист
Генерация курса из документа	+	±	±	—	+
Явная методология (ADDIE / SAM / BD)	—	—	—	—	+
Русскоязычный контент	±	±	+	±	+
On-premise / суверенитет данных	—	—	—	—	+
ИИ-аудио / видео	+	+	+	+	+
Факт-чекинг по источнику	—	—	—	—	+
Авто-актуализация курса	±	—	—	—	+
Ревью с участием человека	+	+	+	+	+
Интеграция с LMS-потокотом разработки	+	+	+	—	+

четыре требования корпоративного B2B-заказчика:

- 1) работу от внутреннего документа организации как от первичного источника;
- 2) поддерживать методическую логику проектирования курса для достижения целей обучения;
- 3) возможность локального развёртывания и контроля данных;
- 4) механизм повторной генерации и обновления курса при изменении исходного источника.

Позиционирование решений на карте приведено на рисунке 1.4.

1.2.5 Тяжелокопируемые конкурентные преимущества

Уникальность предлагаемого решения состоит не в том, что оно использует LLM для генерации текста, а в соединении методического проектирования, источниковой доказательности и воспроизводимой проверки в одном производственном контуре. В отличие от одношагового промптинга, authoring-ускорителей и source-grounded notebook-инструментов, ИИ-методист не ограничивается созданием черновика:




Рисунок 1.4 — Карта позиционирования конкурентных решений

он сохраняет evidence-контекст, строит course structure до генерации уроков, вводит human-review точки, рассчитывает quality seal и позволяет повторить paired-валидацию на том же корпусе.

Ключевое возражение к новизне решения состоит в том, что современный ChatGPT уже умеет работать с файлами, искать в вебе и в режиме deep research формировать отчёты с источниками [12; 13]. Это действительно снижает ценность простого промптинга как самостоятельной разработки. Поэтому в настоящей работе уникальность защищается не самим фактом использования LLM, а тем, что ИИ-методист превращает генерацию курса в контролируемый производственный процесс: источник становится первым объектом системы, provenance сохраняется на уровне блоков результата, quality seal рассчитывается машинно, а публикация проходит через human-review gates.

В таблице 1.2 сравниваются не маркетинговые заявления, а свойства, которые можно проверить в артефактах MVP. Для ChatGPT учитывается текущий класс возможностей OpenAI: поиск и deep research дают source links,

но сам по себе prompt не создаёт постоянный course-production trail и не гарантирует доменный quality gate [13; 14]. Для NotebookLM признаётся сильная source-grounded работа с цитатами, однако продукт остаётся исследовательским notebook, а не конвейером подготовки корпоративного курса [15]. Для Coursebox и iSpring фиксируются сильные authoring-функции из открытых материалов [6; 8]; отсутствие отметки означает только то, что в открытом описании продукта не заявлен такой же проверяемый механизм.

Таблица 1.2 — Защита уникальности ИИ-методиста через сравнение механизмов доверия

Критерий	ChatGPT + prompt / B2	Coursebox / iSpring	NotebookLM	ИИ-методист B4
Source grounding	Зависит от режима и дисциплины промпта; B2 в эксперименте имеет 0 % grounding.	Генерируют курс или структуру из материалов, но artifact-level source map не заявлен.	Ответы опираются на выбранные источники и цитаты.	100 % B4-запусков имеют citations и связь блока с источником.
Provenance результата	История чата не является воспроизводимым журналом курса.	В открытом описании не заявлен block provenance для каждого фрагмента курса.	Сохраняет notebook-источники и заметки, но не course-production trace.	Сохраняются status/result/provenance JSON, block provenance и raw-run evidence.
Методический pipeline	Методология остаётся текстом в промпте и легко теряется при повторе.	Сильный authoring-слой: outline, quiz, visuals, translation, LMS/SCORM.	Сильный research/study assistant, но не LMS-конструктор курса.	ADDIE реализован как граф: анализ источника, структура, контент, fact-check, review, verifier.
Fact-check и quality seal	OpenAI рекомендует проверять важные данные; встроенного доменного seal для курса нет.	В открытых материалах не заявлен воспроизводимый quality seal по источнику.	Цитаты помогают проверять ответ, но не дают педагогический quality gate.	19 из 19 B4-runs получили quality seal PASS; fact-check F1 = 0.720.
Human-review gates	Возможны вручную, но не являются частью исполняемого процесса.	Редактирование автором есть, но gate как состояние конвейера не заявлен.	Совместное редактирование заметок, без LMS approval flow.	Две обязательные точки human review до публикации и после верификации.
Воспроизводимый artifact trail	Нельзя честно повторить paired-сравнение без внешней дисциплины логирования.	Продуктовые материалы описывают ускорение authoring, не экспериментальный trail.	Есть notebook-артефакты, но нет paired B2/B4 evaluation loop.	Paired B2/B4 на 19 документах, readiness-gate, raw evidence и приложения Ж-К.

Из сравнения следует, что преимущество ИИ-методиста защищается не доступом к LLM, а воспроизводимым контуром доверия. ChatGPT может быть сильным генератором черновика и исследовательским помощником, но ИИ-методист делает проверяемым весь жизненный цикл учебного артефакта. В системе явно заданы источник, методическая рамка, цепочка provenance, автоматический fact-check, quality seal, human-review gates и paired B2/B4 trail. Именно эта совокупность даёт долгосрочно развиваемое преимущество: каждый новый агент, модель или методология могут

подключаться к тем же контрактам доверия, а качество версии проверяется не впечатлением от ответа, а повторяемым набором артефактов. При этом paired B2/B4 на 19 документах доказывает не рыночное превосходство над аналогами, а работоспособность механизма доверия в пределах MVP/lab validation. Для сильного сравнительного claim требуется отдельный open-course benchmark $n \geq 30$ с теми же raw-артефактами и явно описанной baseline-методикой.

Тяжелокопируемое преимущество формируется на основе четырёх элементов:

- **методологического подхода** — вариативные педагогические рамки ADDIE, SAM и Backward Design становятся параметрами агентного конвейера, а не внешним текстовым комментарием;
- **evidence-first подхода** — каждый результат связан с источником через citations, block provenance, fact-check и quality seal, что снижает риск неподтверждённой генерации;
- **инфраструктурного подхода** — быстрый старт в формате самостоятельного запуска с возможностью перехода к локальному развёртыванию на собственной ИИ/LMS-инфраструктуре без вывода данных клиента в облако Adapstory;
- **платформного подхода** — масштабируемой работы человека с ИИ для автоматизации актуализации, факт-чекинга, сопровождения и других рутинных операций на базе общей истории запусков и машинно читаемых evidence-артефактов.

1.3 Обзор научных методов и подходов

1.3.1 Формулировка исследовательского вопроса

Исследовательский вопрос:

«В какой мере мультиагентная архитектура с сохраняемым состоянием и вариативной методологической моделью превосходит одношаговый подход при поддержке методического проектирования корпоративных и учебных материалов по показателям точности, покрытия уровней таксономии Блума и времени подготовки первого черновика?»

Работа находится на стыке трёх линий: применения LLM в проектировании образовательных материалов, мультиагентной оркестрации

и метрик педагогического качества.

1.3.2 LLM для поддержки проектирования образовательных материалов

Применение LLM в образовании стало особенно заметным после 2022 года. Kasneci et al. [16] показывают, что большие языковые модели способны существенно ускорять создание объяснений, учебных заданий и материалов для самостоятельной работы. Pardos [17] и Tack et al. [18] указывают, что наибольший потенциал LLM возникает в задачах, где требуется быстро построить первую версию обучающего материала и затем доработать её с участием человека.

Однако у большинства существующих работ есть повторяющееся ограничение: генерация строится как одношаговый сценарий или короткая цепочка промптов. В результате модель выдаёт связный текст, но не обязательно поддерживает дисциплину педагогического проектирования: учебные цели оказываются слабо связаны с содержанием, а уровни когнитивной сложности не распределяются осмысленно.

1.3.3 Мультиагентные системы для поддержки проектирования курса

Мультиагентные LLM-системы декомпозируют сложную задачу на специализированные роли и состояния. Wu et al. [19] показали, что распределение ролей между агентами повышает управляемость и качество LLM-приложений. Shinn et al. [20] предложили паттерн Reflexion, а Wang et al. [21] описали Plan-and-Execute как схему разделения планирования и исполнения.

Проектирование курса — *многошаговая* задача: разобрать источник, сформулировать структуру, произвести контент, проверить соответствие источнику, при необходимости вернуть в цикл ревью. Это ближе к графу с сохраняемым состоянием, чем к диалоговому агенту.

1.3.4 RAG в образовании

RAG-подходы снижают число галлюцинаций за счёт опоры на внешний корпус знаний [22]. Для учебного курса это критично: содержание должно воспроизводить смысл исходного документа, а не просто звучать убедительно.

Es et al. [23] предложили фреймворк Ragas, который позволяет измерять

достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy) и точность контекста (context precision). Эти метрики хорошо подходят для промежуточной оценки RAG-слоя ИИ-методиста, так как они фиксируют не только качество ответа, но и качество связи ответа с источником.

1.3.5 Генерация мультимедиа для обучения

Генерация мультимедийных артефактов — иллюстраций, голосовых дорожек, подкастов — опирается на диффузионные модели (DALL-E 3, FLUX.1) [24; 25] и TTS-решения (Silero, ElevenLabs) [26; 27].

В настоящей работе мультимедиа — вспомогательный слой. Научная новизна не в генерации изображений или аудио как таковой, а в способе их встраивания в методический конвейер.

1.3.6 Методологии проектирования курсов в контексте LLM

ADDIE [28], SAM [29] и Backward Design [30] представляют три различных логики педагогического проектирования. ADDIE задаёт линейно-этапный подход, SAM делает акцент на быстрых итерациях, а Backward Design строит курс от измеримых результатов обучения к структуре и заданиям.

Для LLM-автоматизации каждая из них задаёт различный способ управления генерацией: что считать первичным — анализ аудитории, ожидаемые результаты или итеративное прототипирование. Методология становится параметром архитектуры, а не внешним комментарием.

1.3.7 Оценка качества результатов, подготовленных с участием ИИ

Стандартные LLM-метрики слабо подходят для оценки учебного курса. В работе используется комбинация трёх классов:

- **структурные метрики:** валидность структуры, число модулей, число уроков, наличие обязательных элементов;
- **RAG-метрики:** достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy), точность контекста (context precision);
- **педагогические метрики:** покрытие уровней таксономии Блума, согласованность учебных целей с содержанием курса.

1.3.8 Идентификация исследовательской лакуны

Обзор выявил четыре пробела в литературе и практике.

- Работы по применению LLM в подготовке образовательных материалов в основном оценивают связность и полезность текста, но редко связывают архитектуру системы с измеримой педагогической метрикой вроде покрытия уровней таксономии Блума.
- Большинство промышленных ИИ-инструментов для разработки курсов ускоряют отдельные этапы работы разработчика курса, но не исследуют мультиагентный конвейер с сохраняемым состоянием, который ведёт документ через полный цикл методической упаковки и поддерживает человека на ключевых точках принятия решения.
- Русскоязычный B2B-контекст представлен слабо: не хватает воспроизводимых корпусов, включающих регламенты, продуктово-редакционные документы и учебные программы в единой постановке задачи.
- Практически не исследована задача авто-актуализации курса при изменении исходного документа, хотя именно она определяет экономическую ценность ИИ-методиста для корпоративного заказчика.

Новизна работы — не в самом факте использования LLM, а в экспериментальном исследовании архитектуры, сочетающей RAG, мультиагентную оркестрацию, педагогическую вариативность и пригодность к развёртыванию во внутреннем контуре.

1.4 Постановка задачи и гипотезы

1.4.1 Задача исследования

Задача: разработать интеллектуального методического ассистента, который по входному документу организации формирует педагогически состоятельную структуру курса и черновой контент, опираясь на мультиагентную архитектуру с сохраняемым состоянием и обеспечивая приемлемое качество, скорость и стоимость подготовки.

1.4.2 Методологическая основа

Постановка опирается на три основания.

- **Working Backwards / CVM** [31]: продуктовые требования формулируются от боли и ценности клиента назад к технической реализации.
- **Jobs To Be Done** [32]: пользователь «нанимает» систему для снятия

- рутинной нагрузки и ускорения упаковки знания в обучающий артефакт.
- **Таксономия Блума** [33]: качество учебных целей оценивается по глубине когнитивного действия, а не только по формальной структуре ответа.

1.4.3 Три конвейера ИИ-методиста

Система работает в трёх режимах:

- 1) **Онбординг-курс**: входом служит продуктовое описание, бриф или внутренний гайд; ключевая задача — быстро упаковать материал для новых сотрудников.
- 2) **Асинхронный учебный курс**: входом являются программа курса, учебные материалы или экспертный конспект; здесь критична логика модулей, последовательность освоения материала и покрытие учебных целей.
- 3) **Нормативный курс**: входом выступает регламент, политика или процедура; здесь на первый план выходит верность источнику, работа с фактами и возможность последующего обновления.

1.4.4 Исследовательские гипотезы

Проверяемые гипотезы:

Н1 (продуктовая). Мультиагентный конвейер позволяет сократить время до первого методического черновика до уровня менее 30 минут на один курс при сохранении покрытия уровней таксономии Блума не ниже 70 %.

Н2 (техническая). Мультиагентная архитектура с сохраняемым состоянием обеспечивает более высокое качество результата по метрикам faithfulness и покрытия уровней таксономии Блума по сравнению с одношаговой базовой конфигурацией при сопоставимой базовой LLM.

Н3 (бизнесовая). Себестоимость подготовки одного курса не превышает 1 % от стоимости ручной разработки у внешнего подрядчика.

1.4.5 Метрики проверки гипотез

Группы метрик:

- для **Н1**: время до первого черновика, доля курсов с покрытием уровней таксономии Блума $\geq 70\%$, доля структурно валидных результатов;
- для **Н2**: faithfulness, answer relevancy, context precision, покрытие уровней таксономии Блума, плотность ссылок на источник;
- для **Н3**: себестоимость на курс, отношение себестоимости к средней

рыночной стоимости подрядной разработки, а также параметры подписочной экономики (LTV/CAC, срок окупаемости).

Метрики связывают научную часть работы с практической ценностью: от корректности по отношению к источнику до экономической оправданности внедрения.

2 ИССЛЕДОВАНИЕ: ЭКСПЕРИМЕНТЫ И ВЫБОР ТЕХНОЛОГИЙ

Глава содержит экспериментальную постановку задачи, обоснование технологического стека и проверенные результаты текущего MVP: собранный корпус данных, обзор практик решения задачи и выбранную архитектуру.

2.1 Дизайн эксперимента

2.1.1 Тестовый корпус и оценочные артефакты

Для основной линии исследования зафиксирован **измеренный корпус одношаговой LLM-конфигурации (B2) из 19 документов**, репрезентирующих три категории источников, с которыми должен работать ИИ-методист в B2B- и образовательном контуре:

- **7 продуктово-редакционных документов:** краткое описание продукта, брендовые и редакционные гайды, политики стиля и HR-коммуникаций;
- **6 корпоративных регламентов:** политики информационной безопасности, персональных данных, управления инцидентами, онбординга и антикоррупционного поведения;
- **6 открытых учебных программ MIT OCW:** англоязычные syllabi по экономике, математике, программированию и физике [34].

В измеряемое ядро включались документы, пригодные для технического baseline-прогона без раскрытия закрытых внешних данных. Для каждого документа в артефакте `baseline_comparison.json` сохранены идентификатор, категория, язык, время генерации и рассчитанные метрики.

Корпус охватывает три существенно разных типа входа: редакционные правила, регламентные тексты и академические программы. Это соответствует целевым сценариям продукта: подготовка внутреннего курса по продукту, онбординг по правилам компании и асинхронный учебный курс.

Для автоматизированной оценки использованы также два вспомогательных оценочных набора:

- **30 QA-пар** (`qa_pairs.json`) для детерминированной RAG-style оценки на уровне ответов на вопросы;
- **100 утверждений** (`statements.json`), из которых 50 корректных и 50 намеренно искажённых, для оценки факт-чекинга.

2.1.2 Конфигурации эксперимента: ручной подход (B1), одношаговая LLM (B2), AI-конструктор (B3) и ИИ-методист (B4)

Для исследования определены четыре конфигурации. В качестве количественного доказательства текущего MVP используются одношаговая LLM-конфигурация (B2) и ИИ-методист (B4), а ручная разработка (B1) и AI-конструктор (B3) сохранены как референсные линии для расширения методики:

- **B1** — ручная разработка структуры курса методистом-экспертом; используется как теоретическая верхняя граница качества, но не заявляется как выполненный замер;
- **B2** — одношаговая генерация на базовой LLM без агентской оркестрации; это baseline, полностью прогнанный на ядровом корпусе;
- **B3** — коммерческий инструмент класса конструкторов курсов на основе ИИ (в работе закладывается Coursebox AI как ближайший рыночный аналог); используется для сравнительного анализа рынка, но не как измеренная экспериментальная линия;
- **B4** — ИИ-методист: мультиагентный конвейер поддержки методиста, объединяющий обработку документов, поиск релевантных фрагментов, проектирование курса, подготовку черновых материалов, проверку фактов и ревью.

Статус базовых конфигураций на момент написания:

- **B2** дал воспроизводимые количественные результаты по 19 документам и служит baseline;
- **B4** завершил paired-прогон на тех же 19 документах и используется как основной измеренный результат ИИ-методиста;
- **B1** и **B3** не используются как количественное доказательство гипотез H1–H3 в текущей работе.

Глава 2 фиксирует измеренный экспериментальный слой одношаговой LLM (B2) и ИИ-методиста (B4) и дополнительную автоматизированную проверку RAG/fact-check; границы интерпретации этих результатов отдельно

указаны в разделе ограничений. Отдельно подготовлен корпусный manifest для следующего шага: open-course benchmark $n \geq 30$ на открытых курсах. Он нужен именно для внешнего сравнительного claim, тогда как текущие 19 документов остаются MVP/lab validation текущей инженерной версии.

2.1.3 Метрики оценки

На текущем этапе используются четыре группы метрик:

- **структурные**: валидность JSON-структуры, число модулей, число уроков, наличие обязательных полей;
- **педагогические**: покрытие уровней таксономии Блума — доля из шести уровней таксономии Блума, представленных в учебных целях курса;
- **поисково-фактологические**: достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy), точность контекста (context precision) и метрики факт-чекинга;
- **операционные**: время подготовки черновика, плотность ссылок на источник, себестоимость курса, пригодность к локальному развёртыванию.

Набор охватывает форму результата, педагогическую глубину, связь с источником и эксплуатационную стоимость.

Вместе с тем одной таксономии Блума недостаточно для полноценной педагогической и пользовательской оценки курса. Она хорошо описывает когнитивный уровень целей, но слабее отражает структурную сложность результата, согласованность курса, качество онлайн-дизайна и эффект для обучающегося. Поэтому в методологическом контуре исследования рассматривается более широкий набор рамок [35–41].

2.1.4 Расширенная педагогическая и пользовательская рамка

Для настоящего исследования эти рамки рассматриваются как **долгосрочный пользовательский слой оценки**, а не как замена уже выполненных технических измерений. Иными словами, текущий MVP по-прежнему опирается на покрытие уровней таксономии Блума, валидность структуры, поисково-фактологические метрики и операционную себестоимость. После коммерческого запуска продуктовый контур оценки может быть усилен показателями самоэффективности, ощущаемой компетентности, переноса обучения в практику и достижения цели [42–46].

Таблица 2.1 — Дополнительные рамки оценки качества курса сверх таксономии Блума

Рамка	Что измеряет	Потенциальная операционализация для ИИ-методиста
SOLO Taxonomy	структурную сложность и степень интеграции результата обучения	экспертная оценка структуры курса по уровням unistructural–extended abstract
Webb’s Depth of Knowledge (DOK)	когнитивную строгость заданий и оценочных материалов	распределение сгенерированных заданий по уровням DOK 1–4
Constructive Alignment (Biggs)	согласованность целей, учебных активностей и оценивания	доля целей, для которых в курсе есть связанная активность и способ проверки
Quality Matters Rubric	качество онлайн-курса как цифрового образовательного продукта	итоговый балл по целям, оцениванию, материалам, активностям, технологиям и доступности
Fink’s Taxonomy of Significant Learning	значимое обучение сверх простого воспроизведения содержания	покрытие компонентов application, integration, human dimension, caring и learning how to learn
ICAP Framework	тип учебной активности и глубину вовлечения обучающегося	доля активностей классов passive / active / constructive / interactive
UDL: Universal Design for Learning	доступность, вариативность подачи и варианты действия	покрытие по осям engagement, representation, action & expression

2.2 Выбор и обоснование технологий

2.2.1 Фреймворк мультиагентной оркестрации

Задача ИИ-методиста относится к классу процессов с сохраняемым состоянием: документ проходит этапы обработки, анализа источника, подготовки структуры, наполнения черновыми материалами, проверки фактов, ревью и публикации. Часть шагов выполняется последовательно, часть — с условными ветками, остановками и повторным запуском после решения с участием человека.

В ходе отбора рассматривались LangGraph 1.x, AutoGen 0.4, CrewAI 0.9, Agno 1.x и OpenAI Agents SDK [47–51].

Обоснование выбора LangGraph. LangGraph соответствует природе

Таблица 2.2 — Показатели эффекта обучения, ориентированные на обучающегося

Показатель	Что измеряет	Потенциальная операционализация
Самозффективность (Self-efficacy)	уверенность обучающегося, что он может выполнить конкретную задачу	Likert-вопросы, ориентированные на конкретную задачу, вида «теперь я могу самостоятельно сделать X»
Ощущаемая компетентность (Perceived Competence)	субъективное ощущение владения темой или навыком	короткая посткурсовая шкала PCS по конкретному домену
Перенос обучения в практику (Transfer of learning)	факт применения изученного в рабочей или учебной ситуации	отложенный опрос через 2–4 недели: применял ли, сколько раз, какие барьеры возникли
Retrospective pre-post	изменение восприятия своих возможностей с учётом эффекта response-shift	один пост-опросник с оценкой состояния «до курса» и «после курса»
Достижение цели (Goal attainment)	степень достижения индивидуальной учебной или рабочей цели	мини-шкала достижения цели по цели, сформулированной перед обучением

Таблица 2.3 — Сравнение фреймворков мультиагентной оркестрации

Критерий	LangGraph	AutoGen	CrewAI	Agno	OpenAI Agents SDK
Модель исполнения	граф состояний	диалоговые агенты	ролевая команда	асинхронные агенты	агенты с вызовом инструментов
Явный граф переходов	+++	++	+	++	+
Поддержка локальных LLM	+	+	+	+	—
Контур участия человека	+++	++	+	++	+
Наблюдаемость и трассировка	+++	++	+	++	++
Зрелость экосистемы	+++	++	++	+	++

задачи: система должна хранить состояние процесса, поддерживать возвраты к предыдущим шагам, ручное ревью и трассировку каждого узла. Для этого

StateGraph подходит лучше, чем диалоговые модели. Дополнительным фактором стала интеграция с LangSmith, которая даёт наблюдаемость на уровне отдельных вызовов агентов и позволяет дебажить качество генерации.

Причины отказа от альтернатив. AutoGen силён как среда многоагентного взаимодействия, но для детерминированного конвейера требует дополнительных абстракций над диалоговой моделью. CrewAI удобно описывает роли и задачи, однако хуже соответствует продакшн-ориентированному асинхронному процессу. Agno привлекателен своей асинхронностью и RAG-встроенностью, но уступает в зрелости экосистемы. OpenAI Agents SDK не рассматривается как базовый вариант из-за облачной привязки и отсутствия траектории локального развёртывания.

2.2.2 Выбранная архитектура

После выбора оркестратора возникает второй вопрос: чем строить контур обработки документов и поиска релевантных фрагментов. Ранняя архитектурная гипотеза предполагала Haystack 2.x + Qdrant, однако фактическая MVP-реализация пошла по более интеграционному пути: Dify/RAG tool отвечает за индексирование и retrieval источника, Knowledge Graph добавляет предметные связи и компетенции, а LangGraph исполняет состояние агентного процесса поверх уже подготовленного evidence-контекста.

Разделение соответствует сильным сторонам компонентов. Dify/RAG закрывает практическую задачу загрузки, индексации и поиска фрагментов в production-like контуре; Knowledge Graph уменьшает зависимость от плоского similarity-search; LangGraph хранит состояние курса, результаты промежуточных нод и точки участия человека.

Итоговая техническая связка текущего MVP выглядит так: Document source -> Dify/RAG -> EvidenceTable + KnowledgeGraph -> LangGraph process -> course artifacts. Это снижает связанность системы и позволяет заменить retrieval backend без переписывания агентного графа.

Общая схема технологического стека приведена на рисунке 2.1.




Рисунок 2.1 — Технологический стек ИИ-методиста: source grounding и генерация

2.2.3 Большая языковая модель

На этапе экспериментального MVP сравнивались три направления: облачная модель общего назначения, российский облачный провайдер и локальная открытая модель.

Таблица 2.4 — Сравнение LLM-вариантов для текущей итерации

Критерий	GPT-4o	YandexGPT 4	Qwen2.5 7B
Способ доступа	облачный API	облачный API	локально через Ollama
Суверенитет данных	—	±	+
Стоимость итераций и отладки	высокая	средняя	низкая
Русскоязычный контент	высокая	высокая	достаточная для базовой конфигурации
Инфраструктурная простота	высокая	высокая	высокая для локального стенда

Для текущих экспериментов базовой конфигурации выбрана модель qwen2.5:7b через Ollama. Причина выбора прагматична: эта модель доступна локально, даёт воспроизводимые результаты, не требует внешнего API и позволяет многократно прогонять эксперименты на ядровом корпусе без роста переменных затрат.

Это **не окончательное ограничение** архитектуры. ИИ-методист

проектируется как провайдер-агностичная система: при необходимости локальная базовая конфигурация может быть заменена на более крупный вариант с открытыми весами семейства Qwen 2.5 или на облачный провайдер, если сценарий внедрения это допускает.

2.2.4 Поиск, векторные представления и граф знаний

Для поискового слоя в текущей итерации зафиксирован не конкретный векторный backend, а контракт retrieval-слоя: на входе источник, на выходе нумерованные фрагменты EvidenceTable, пригодные для цитирования и факт-чекинга. В реализации этот контракт закрывается Dify/RAG tool и Knowledge Graph. Qdrant и deepvk/USER-bge-m3 рассматриваются как совместимый infrastructure/backend вариант, но не используются как единственное доказательство работоспособности MVP.

Выбор такого контракта объясняется четырьмя причинами:

- возможность сохранять source-grounding независимо от конкретного векторного хранилища;
- поддержка локального развёртывания и запрета внешней передачи документов;
- возможность обогащать retrieval результат предметными связями Knowledge Graph;
- совместимость с будущим переходом на Qdrant/локальные embeddings без изменения LangGraph-нода.

Для retrieval-слоя выполнена детерминированная RAG-style проверка на 30 QA-парах: faithfulness составил 0.335, answer relevancy — 0.239, context precision — 0.567, context recall — 0.335. Эти значения используются как диагностический слой: текущий RAG/eval-контур работает как conservative guardrail перед human-review, то есть помогает раньше отправить рискованные фрагменты на проверку человеком. Они не доказывают качество retrieval; качество retrieval требует расширения корпуса и экспертной разметки релевантных фрагментов. Основной продуктовый показатель H2 при этом считается downstream-метрикой source-grounding: долей фактических утверждений, подтверждённых EvidenceTable в финальном verification_report.

2.2.5 Стратегии чанкинга

Для обработки документов были рассмотрены две стратегии: рекурсивный фиксированный чанкинг и семантический чанкинг. Детерминированная RAG-style проверка дала context precision 0.567 и context recall 0.335; поэтому текущий Dify/RAG-контур используется как рабочий guardrail для MVP, но не считается доказанным по качеству retrieval. Архитектурно более перспективным остаётся семантический чанкинг внутри retrieval backend и последующая экспертная оценка релевантности найденных фрагментов. Конкретная реализация может быть заменена: в текущем MVP это Dify/RAG-контур, в долгосрочной инфраструктурной версии допустим переход на Haystack/Qdrant при сохранении контракта EvidenceTable.

Учебные и нормативные документы содержат смысловые блоки разной длины: определения, процедуры, ограничения, списки требований. Жёсткое разбиение по фиксированному размеру разрушает эти границы и создаёт более шумный поисковый контекст. Семантический чанкинг лучше сохраняет логические единицы, что особенно важно для нормативных документов и продуктово-редакционных руководств.

2.2.6 Перспективное развитие генерации изображений

Для мультимедийного слоя сравнивались DALL-E 3 и FLUX.1-dev [24; 25]. DALL-E 3 удобен как внешний сервис с высоким качеством и быстрым стартом, но вносит в систему API-зависимость и переменные затраты. FLUX.1-dev допускает локальное развёртывание и потому лучше соответствует логике продукта, ориентированного на локальный контур.

В результате для перспективного слоя развития выбрана следующая стратегия:

- **по умолчанию** — локальный FLUX.1-dev для черновых и полуфинальных образовательных иллюстраций;
- **опционально** — внешний провайдер класса DALL-E 3 для сценариев повышенного качества, где требуется более «маркетинговое» качество изображения.

Решение не закрывает дорогу к внешнему качественному генератору, но сохраняет базовый маршрут локального развёртывания для большинства B2B-кейсов.

2.2.7 Перспективное развитие генерации подкастов на основе синтеза речи

Для генерации русскоязычных подкастов сравнивались Silero TTS v4 и ElevenLabs Multilingual v2 [26; 27]. На текущем этапе различие между ними определяется прежде всего не субъективным MOS, а эксплуатационной логикой.

- **Silero TTS** подходит для локального развёртывания, не требует внешнего API и по заложенной в оценочную модель оценке даёт стоимость порядка 4 руб. на курс за счёт только GPU-времени.
- **ElevenLabs** обеспечивает более «человеческую» интонационную подачу, но при оценке 40,000 символов на курс стоимость составляет порядка 1,080 руб. на курс, что делает его скорее опцией повышенного качества, чем базовым TTS-слоем для MVP.

Панельная MOS-оценка пока не завершена. Для этого уже подготовлен отдельный оценочный скрипт, однако в текущей итерации для выбора технологии решающими оказались суверенитет данных и предсказуемость себестоимости. Поэтому для будущего мультимедийного слоя базовым TTS-движком выбран Silero, но этот слой не используется как доказательство текущей готовности MVP.

2.3 Проверенные результаты экспериментов

2.3.1 Измеренные результаты одношаговой LLM-конфигурации (B2)

Первым полностью воспроизводимым экспериментом стал лабораторный прогон одношаговой LLM-конфигурации (B2) на измеренном 19-документном корпусе: продуктивно-редакционные документы, корпоративные регламенты и учебные программы MIT OCW. Эти числа используются как технический baseline текущего MVP и синхронизированы с артефактом `baseline_comparison.json`. В этой конфигурации использовалась локальная модель `qwen2.5:7b`, которая по одному промпту генерировала структуру курса в JSON-формате без поиска по корпусу, без факт-чекинга и без отдельных специализированных агентов.

Распределение покрытия по категориям визуализировано на рисунке 2.2.

Частота появления отдельных уровней таксономии Блума показана на

Таблица 2.5 — Измеренные результаты одношаговой LLM-конфигурации (B2)

Срез корпуса	n	Среднее время, с	Среднее покрытие, %	Доля курсов $\geq 70\%$	Структурная валидность
Все документы	19	4.37	61.4	21.1%	100%
Продуктивно-редакционные документы	7	5.65	73.8	28.6%	100%
Корпоративные регламенты	6	3.65	38.9	0%	100%
Учебные программы MIT OCW	6	3.61	69.5	33.3%	100%

рисунке 2.3.

Полученные данные показывают, что одношаговая конфигурация обладает двумя сильными сторонами: он очень быстро генерирует структурно валидный ответ и не требует сложной инфраструктуры. Однако эти преимущества не решают ключевую задачу исследования.

Во-первых, среднее покрытие уровней таксономии Блума составляет лишь 61.4 %, а порог 70 % достигается только в 21.1 % случаев. Во-вторых, базовая конфигурация значительно лучше справляется с продуктивно-редакционными документами, чем с нормативными: для официальных нормативных документов покрытие падает до 38.9 %, что означает смещение к нижним когнитивным уровням запоминания и понимания. В-третьих, плотность ссылок на источник равна нулю: модель не даёт никакой явной привязки результата к источнику, поэтому одношаговая LLM-конфигурация (B2) не может считаться достаточной для нормативных и знаниево-критичных сценариев.

Время генерации по категориям документов представлено на рисунке 2.4.

Именно этот набор ограничений и мотивирует переход от одношаговой LLM (B2) к ИИ-методисту (B4): необходима архитектура, которая сохраняет скорость, но усиливает поиск по корпусу, факт-чекинг и глубину методической структуры.




Рисунок 2.2 — Покрытие уровней таксономии Блума по категориям документов: одношаговая LLM-конфигурация (B2)




Рисунок 2.3 — Частота покрытия уровней таксономии Блума в корпусе (n=19): одношаговая LLM-конфигурация (B2)




Рисунок 2.4 — Среднее время генерации структуры курса по категориям: одношаговая LLM-конфигурация (B2)

2.3.2 Сравнение одношаговой LLM (B2) и ИИ-методиста (B4) на одном корпусе

После стабилизации REST-контура ИИ-методиста выполнен paired-прогон одношаговой LLM (B2) и ИИ-методиста (B4) на том же 19-документном корпусе. Для каждого документа создавался отдельный kb_slug B4 формата diploma-b4-001, в запуск передавался ровно один Markdown-файл, а результат сопоставлялся с ранее измеренной строкой B2 для того же doc_id. Это устраняет риск некорректного сравнения средних из разных прогонов: итоговая метрика считается как $\Delta_i = B4_i - B2_i$ для каждого документа.

Наиболее сильный эффект наблюдается на корпоративных регламентах: среднее покрытие Блума увеличилось с 38.9% до 83.3%, то есть на +44.4 п.п. Для продуктово-редакционных документов дельта составила +9.5 п.п., для программ MIT OCW — +13.8 п.п. Таким образом, B4 закрывает именно тот класс документов, где B2 был наиболее слаб: нормативные и знаниево-критичные материалы, требующие явного source-grounding и проверки качества.

Таблица 2.6 — Сравнение одношаговой LLM (B2) и ИИ-методиста (B4) на 19 документах

Метрика	Значение	Вывод
Среднее покрытие Блума B2	61.4 %	baseline ниже целевого порога
Среднее покрытие Блума B4	83.3 %	B4 проходит порог $\geq 70\%$
Средняя paired-дельта Блума	+21.9 п.п.	прирост считается по тем же документам
Документы с положительной дельтой	15 из 19	B4 лучше B2 на большинстве корпуса
Source grounding B4	100 %	B4 даёт проверяемую опору на источник
Quality seal B4	100 % PASS	все B4-runs готовы к human review

2.3.3 Оценочные наборы для RAG и факт-чекинга

Paired-прогон одношаговой LLM (B2) и ИИ-методиста (B4) закрывает основной технический разрыв между baseline и ИИ-методистом, однако для более тонкой оценки RAG-компонента и факт-чекинга использованы дополнительные наборы.

Таблица 2.7 — Оценочные наборы текущего MVP

Артефакт	Объём	Назначение
Измеренный корпус одношаговой LLM (B2)	19	базовая и конвейерная подготовка курсов
QA-пары (qa_pairs.json)	30	RAG-style оценка faithfulness, answer relevancy, context precision и context recall
Фактуальные утверждения (statements.json)	100	оценка precision / recall / F1 для факт-чекинга

Артефакты превращают работу из описательной архитектурной записки в экспериментально воспроизводимую постановку. На этих наборах выполнен детерминированный прогон evaluation lab: для RAG-style оценки получены faithfulness 0.335, answer relevancy 0.239, context precision 0.567 и context recall 0.335; для факт-чекинга получены precision 0.600, recall 0.900 и F1 0.720. Высокий recall выбран сознательно: для методического ассистента

опаснее пропустить неподтверждённое утверждение, чем отправить лишний фрагмент на ручное ревью. Следовательно, текущий evaluation lab подтверждает пригодность fact-check/RAG связки как консервативного контрольного слоя перед human-review, но не является доказательством полного качества retrieval. Для такого вывода требуется расширенный корпус, экспертная разметка релевантных контекстов и повторение замеров на открытых курсах разных жанров.

2.3.4 Сценарная unit-экономика MVP на основе проверенного прогона

Помимо технических метрик, собрана сценарная оценка unit-экономики. Речь идёт не о подтверждённой рыночной выручке, а о расчётной модели, основанной на текущей конфигурации пайплайна и внутренних допущениях о цене привлечения и контрактной монетизации.

Таблица 2.8 — Сценарная unit-экономика текущего MVP на основе проверенного прогона

Показатель	Значение	Интерпретация
Прямая себестоимость генерации курса	75 руб.	инфраструктурная себестоимость курса в текущем конвейере
Отношение к стоимости подрядной разработки	0.05%	текущий MVP в модели существенно дешевле внешнего производства
LTV / CAC	10.0	при выбранных допущениях модель не выглядит заведомо убыточной
Payback period	2 мес.	возврат затрат возможен в коротком цикле продаж
Порог безубыточности	14 клиентов	ориентир для коммерческой стадии после MVP

Цифры служат проверкой того, что выбранная архитектура не разрушает экономику продукта: после завершения raised-прогона B4 система остаётся технически дешёвой в эксплуатации.

Одновременно эти значения не должны интерпретироваться как окончательное доказательство product-market fit. В рамках ВКР коммерческий блок является сценарной моделью устойчивости, а не утверждением о спросе, выручке или проверке на внешних закрытых данных.

2.3.5 Ограничения текущего этапа и план абляционного исследования

Наиболее существенное ограничение текущего этапа состоит уже не в отсутствии B4-прогона: paired B2/B4-сравнение на 19 документах выполнено и сохранено в `paired_b2_b4_experiment.json`. Оставшееся ограничение связано с тем, что автоматические метрики ещё не заменяют слепую экспертную оценку и абляционное исследование вклада отдельных узлов конвейера.

Ограничение накладывает границу на интерпретацию результатов:

- текущие цифры главы 2 следует трактовать как **автоматическую paired-валидацию одношаговой LLM (B2) и ИИ-методиста (B4)**, а не как замену экспертной педагогической экспертизы;
- гипотезы H1–H3 в данной работе проверяются в пределах внутреннего / открытого корпуса, paired-валидации B2/B4 и evaluation lab;
- $n = 19$ является MVP/lab validation, но недостаточен для сильного вывода о превосходстве над аналогами; такой вывод должен проверяться отдельным open-course benchmark $n \geq 30$;
- сравнение с ручной разработкой (B1), AI-конструктором (B3) и слепая экспертная педагогическая экспертиза остаются полезным расширением методики, но не входят в заявленный объём доказательств текущей ВКР;
- абляционное исследование является направлением развития доказательной базы, так как оно позволит отдельно измерить вклад поискового контура, факт-чекинга и ревью-агентов в итоговое качество.

Глава 2 фиксирует и достигнутые результаты, и текущую границу зрелости системы, определяя точку отсчёта для дальнейших экспериментов.

2.3.6 Финальная MVP-конфигурация

На основании проведённого отбора и измеренных результатов итоговая MVP-конфигурация ИИ-методиста строится на следующей конфигурации:

- **Локальное LLM-ядро**: Qwen через OpenAI-compatible Ollama endpoint;

- **Оркестратор:** LangGraph 1.x (StateGraph);
- **Контур поиска:** Dify/RAG tool + EvidenceTable;
- **Семантическое усиление:** Knowledge Graph;
- **Состояние и результаты:** PostgreSQL checkpointer/result store;
- **Quality gate:** FactCheckAgent + Verifier + quality seal;
- **Roadmap:** Qdrant/локальные embeddings, FLUX, Silero, SAM и Backward Design после paired-валидации основного B4-контура.

Конфигурация отвечает целям работы: локальное развёртывание, воспроизводимые эксперименты, приемлемая себестоимость, усиление поискового слоя и педагогической структуры относительно одношаговой базовой конфигурации.

3 ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

3.1 Архитектура системы

3.1.1 Контекстная диаграмма (C4 Level 1)

ИИ-методист реализован как продуктовый контур платформы Adapstory, который объединяет сервис генерации курсов, RAG-поиск, граф знаний, ручное ревью и публикацию результата в LMS. На уровне системного контекста (C4 Level 1, приложение Г, раздел Г.1) участвуют следующие акторы и системы:

- **Разработчик курса / методист / HR-специалист** — загружает исходные материалы, задаёт аудиторию и методологию, просматривает, корректирует и утверждает результат;
- **School UI и BFF School** — веб-интерфейс и Backend-for-Frontend, через которые пользователь запускает генерацию, видит статус, provenance, quality seal и результат;
- **AI Course Generator** — FastAPI-микросервис, исполняющий LangGraph-конвейер подготовки курса;
- **Dify/RAG-контур** — индексирует и ищет фрагменты исходных документов для source-grounded генерации;
- **Knowledge Graph** — предоставляет понятия, связи компетенций и дополнительные контекстные факты;
- **Ollama / OpenAI-compatible LLM endpoint** — обслуживает локальные модели семейства Qwen в dev/env-dev контуре;
- **PostgreSQL** — хранит запуски, результаты, LangGraph-checkpoints и audit/provenance-данные;
- **LMS Adapstory** — принимает утверждённый курс после человеческого контроля качества.

3.1.2 Диаграмма контейнеров (C4 Level 2)

На уровне контейнеров (приложение Г, раздел Г.2) MVP состоит из следующих процессов:

- **AI Course Generator API** — FastAPI-сервис с REST и MCP-инструментами; принимает запросы от BFF, создаёт run, отдаёт sta-

- tus/result/provenance и команды human-review;
- **LangGraph Runtime** — исполняет граф генерации, поддерживает interrupt-точки и сохраняет состояние через PostgreSQL checkpoint;
 - **Dify course tool / RAG plugin** — выполняет загрузку, индексирование и поиск фрагментов источника; при недоступности retrieval система переходит к ограниченному source-excerpt fallback и явно помечает снижение полноты evidence;
 - **Knowledge Graph MCP** — возвращает связанные компетенции и понятия, усиливая контекст CourseStructureAgent;
 - **LLM Gateway** — провайдер-агностичный слой вызова модели с retry, token/cost telemetry и возможностью переключения между локальным и внешним endpoint;
 - **School BFF / Frontend** — пользовательский контур ревью, публикации и отображения thesis-validation метрик.

3.1.3 Доменная модель

Доменная модель текущего MVP включает следующие ключевые сущности:

- **CourseRun** — запуск генерации с tenant/user, выбранной методологией, статусом, стоимостью и временем выполнения;
- **SourceDocument** и **EvidenceTable** — нормализованное представление найденных фрагментов источника со стабильными source_id для ссылок;
- **CourseBlueprint** — методический черновик структуры курса: модули, уроки, цели обучения и Bloom-разметка;
- **LessonContent** — черновой учебный блок с inline citations/source references;
- **VerificationReport** — отчёт факт-чекинга и финальной проверки, содержащий total_claims, cited_claims и quality_seal;
- **ProvenanceRecord** — audit-запись с моделью, версией pipeline, guardrail bundle, числом источников, token/cost telemetry и временем генерации;
- **ThesisValidationSnapshot** — машинно читаемый срез метрик H1–H3 для дипломной валидации.

3.2 Мультиагентная система (LangGraph)

3.2.1 Граф агентов

Граф агентов реализован через StateGraph из LangGraph [47]. В текущей реализации используется 6-node Feynman-inspired pipeline:

```
source_analyzer -> course_structure -> content_creator  
-> fact_check -> review -> verifier
```

В граф встроены две точки участия человека:

- после `course_structure`: методист утверждает или возвращает на доработку структуру курса до генерации полного контента;
- после `verifier`: методист видит `quality seal`, `provenance` и блокирующие замечания перед публикацией.

Граф агентов представлен на рисунке 3.1.

3.2.2 Ноды конвейера

Конвейер включает шесть специализированных нод:

- 1) **SourceAnalyzer** — извлекает из Dify/RAG релевантные фрагменты, строит `EvidenceTable` и помечает неполное покрытие источников; Knowledge Graph подключается на следующем шаге как семантическое усиление `CourseStructureAgent`;
- 2) **CourseStructureAgent** — формирует `CourseBlueprint` по методологии ADDIE, целевой аудитории и таблице свидетельств;
- 3) **ContentCreatorAgent** — пишет черновые уроки с `inline`-ссылками на `source_id`;
- 4) **FactCheckAgent** — проверяет фактические утверждения относительно `EvidenceTable` и выделяет неподтверждённые `claims`;
- 5) **ReviewAgent** — оценивает педагогическую связность, Bloom coverage и соответствие методологическому чек-листу;
- 6) **Verifier** — алгоритмически считает долю подтверждённых `claims`, формирует `PASS`, `PASS_WITH_NOTES` или `FAIL`, собирает `provenance` и `snapshot H1–H3`.

3.2.3 Управление состоянием и human-in-the-loop

Состояние графа хранится в `CourseGenerationState`. Оно содержит входные параметры, `source_documents`, `evidence_table`,




Рисунок 3.1 — Граф агентов ИИ-методиста (6-node LangGraph StateGraph)

`blueprint`, `lesson_contents`, `fact_check_reports`, `review_report`, `verification_report`, `provenance`, `token/cost` `telemetry` и обратную связь человека.

В production-like контуре граф компилируется с PostgreSQL checkpoint. Это даёт три свойства, критичные для B2B-сценария:

- запуск можно возобновить после сбоя сервиса без потери промежуточных артефактов;
- human-review не требует держать процесс в памяти;
- статус запуска, `quality seal` и `provenance` доступны через API как воспроизводимый артефакт, а не только как текст в UI.

3.3 Ключевые конвейеры

3.3.1 Обработка источника и поиск

В ранней архитектурной гипотезе рассматривалась связка Haystack 2.x + Qdrant. В текущем MVP фактический контур другой: индексация и retrieval вынесены в Dify course tool / RAG plugin, а семантическое усиление структуры выполняется через Knowledge Graph. Qdrant остаётся допустимым векторным backend в инфраструктурном профиле, но не заявляется как обязательный реализованный слой дипломного MVP.

Текущий поток обработки источника:

- 1) пользователь загружает документ через School UI / BFF;
- 2) Dify/RAG-контур создаёт или обновляет индекс источника;
- 3) `source_analyzer` выполняет поиск фрагментов и строит `EvidenceTable`; если индекс временно недоступен, используется ограниченный fallback по фрагментам исходного текста;
- 4) Knowledge Graph добавляет связанные компетенции и понятия на этапе проектирования структуры курса;
- 5) LangGraph-ноды используют общий evidence-контекст, а не независимые несвязанные RAG-вызовы.

Последовательность компонентов показана на рисунке 3.2.

3.3.2 Подготовка черновика курса

Подготовка курса начинается после появления evidence-контекста. Сценарий взаимодействия компонентов представлен на рисунке 3.3.

Ключевое отличие от одношагового baseline B2 состоит в том, что




Рисунок 3.2 — Контур обработки источника и сборки EvidenceTable




Рисунок 3.3 — Сценарий взаимодействия при генерации курса

система не передаёт весь документ в один prompt. Вместо этого она:

- выделяет и нумерует источники до генерации курса;
- сначала проектирует структуру, а затем отдаёт её человеку на ревью;
- генерирует контент уже после утверждения структуры;
- проверяет claims и блокирует публикацию при низком качестве ссылочной привязки.

3.3.3 Метка качества, прослеживаемость и валидация гипотез диплома

Финальная нода verifier не вызывает LLM. Она алгоритмически считает отношение `cited_claims / total_claims` и назначает quality seal:

- PASS, если ссылочная привязка claims не ниже 90 %;
- PASS_WITH_NOTES, если она находится в диапазоне 70–90 %;
- FAIL, если evidence отсутствует или качество ниже порога.

В результате API отдаёт не только текст курса, но и набор проверочных артефактов: `citations`, `quality_seal`, `block_provenance`, `cost_quality` и `thesis_validation`. Эти поля используются фронтowymi E2E-тестами и дипломным скриптом продуктовой валидации, что делает проверку H1–H3 воспроизводимой.

3.3.4 Roadmap-компоненты

Мультимедиа-генерация (FLUX / Silero) не включается в статус завершённого MVP. Профили SAM / Backward Design и контур автоактуализации присутствуют как инженерные заделы, но количественные результаты диплома сознательно опираются только на ADDIE paired B2/B4, evaluation lab, quality seal и source-grounding, чтобы не смешивать готовые измерения с roadmap-слоями.

3.4 Инфраструктура и развёртывание

3.4.1 Dev/env-dev контур

Для локальной и env-dev проверки используется docker-compose контур `docker-compose.ai-methodist.yml` и overlay `docker-compose.ai-methodist.env-dev.yml`. Он поднимает AI Course Generator, AI Methodist MCP-сервис, Dify course tool, Knowl-

edge Graph, Neo4j, PostgreSQL и Redis. В base-compose задана лёгкая локальная модель, а env-dev профиль использует более сильный Qwen3:8b через OpenAI-compatible Ollama endpoint.

Для инфраструктурного развёртывания платформа сохраняет GitOps-подход: образ собирается CI/CD, значения deployment описываются в Helm/GitOps, а ручные изменения в Kubernetes не используются как способ доставки функциональности.

3.4.2 Наблюдаемость и проверяемость

В сервисе используются OpenTelemetry spans вокруг нод LangGraph и Prometheus-счётчик распределения quality seal. Отдельные runbook-и фиксируют env-dev smoke, KG-backed Playwright benchmark и LLM matrix. Для ВКР это важно: результат генерации становится не демонстрацией «на словах», а набором machine-readable артефактов:

- статус запуска и финальный result JSON;
- quality seal и provenance;
- thesis-validation snapshot;
- Playwright summary и benchmark results;
- product validation report по H1–H3.

4 ВАЛИДАЦИЯ, ИМПАКТ И БИЗНЕС-ОЦЕНКА

4.1 Протокол валидации

4.1.1 Автоматизированная оценка

Качество выходных артефактов оценивается автоматически в трёх измерениях:

- 1) **Ragas-метрики** (глава 2): достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy), точность контекста (context precision);
- 2) **Покрытие уровней таксономии Блума**: доля уровней таксономии Блума, покрытых в наборе учебных целей курса; целевой показатель — $\geq 70\%$;
- 3) **Структурное качество**: полнота (наличие всех обязательных элементов методологии), согласованность учебных целей с содержанием, BLEU/ROUGE относительно эталонов B1.

4.1.2 Рубрика контроля качества

Для ручного контроля качества результата подготовлена рубрика, совместимая с future expert-review workflow в продукте, но в численные результаты ВКР включаются только воспроизводимые автоматизированные замеры текущего корпуса.

Рубрика содержит 5 критериев (шкала 1–5):

- соответствие целевой аудитории;
- логика и последовательность модулей;
- качество учебных целей (SMART);
- покрытие исходного материала;
- практическая применимость.

Итоговая оценка по этой рубрике может использоваться при ручном ревью курса перед публикацией. В текущей работе она не подменяет измеренные метрики Bloom/source-grounding/fact-check и не заявляется как завершённая слепая экспертная оценка. Полные таблицы текущих оценочных артефактов приведены в приложении И.

4.1.3 Лабораторная апробация MVP

Помимо автоматизированных метрик выполнена лабораторная апробация MVP на контролируемом корпусе: внутренние продуктово-редакционные материалы, учебные регламенты и открытые программы MIT OCW. Проверялись не субъективные NPS/SUS-метрики, а воспроизводимые свойства результата: время, Bloom coverage, source-grounding, quality seal, факт-чек и отображение evidence-слоя в интерфейсе. Такой дизайн соответствует задаче ВКР: подтвердить работоспособность продуктового MVP без привлечения закрытых внешних данных.

4.2 Сквозная верификация

4.2.1 Сценарий 1: Онбординг-курс (ADDIE)

Входной документ: продуктивное описание нового SaaS-инструмента, 8 страниц.

Ожидаемый результат: 6-модульный онбординг-курс с учебными целями для новых сотрудников; время подготовки первого методического черновика менее 30 минут.

Ход выполнения:

- 1) Пользователь загружает PDF в систему; запускается контур обработки документов.
- 2) После индексации инициируется CourseStructureAgent с методологией ADDIE.
- 3) После генерации структуры система приостанавливается для ручного ревью; пользователь одобряет структуру.
- 4) ContentCreatorAgent генерирует тексты уроков; FactCheckAgent верифицирует утверждения.
- 5) Verifier формирует quality seal, provenance и snapshot дипломных метрик H1–H3.
- 6) После финального human-review курс может быть опубликован в LMS Adapstory.

Для сценария выполнен paired-прогон B2/B4 на 19 документах. B2 показывает среднее время подготовки структуры 4.37 с и среднее покрытие Блума 61.4 %, но не даёт source-grounding. B4 в том же корпусе даёт среднее покрытие Блума 83.3 %, среднюю paired-дельту +21.9 п.п., source-grounding

100 % и quality seal PASS в 19 из 19 запусков. Среднее техническое время В4 до готового результата составило 17.1 с, что существенно ниже целевого порога 30 минут.

4.2.2 Сценарий 2: Нормативный курс с факт-чекингом

Входной документ: корпоративный регламент информационной безопасности, 22 страницы.

Специфика: документ содержит точные числовые требования (сроки, пороги, санкции), критичные для корректного нормативного обучения.

Проверяется, что FactCheckAgent выявляет галлюцинации при конкретизации числовых значений. В paired-прогоне В4 сформировал 19 fact-check reports и прошёл source-grounding gate на 100 %. Для отдельного расчёта precision / recall / F1 использован датасет из 100 утверждений (statements.json). Детерминированный evaluation lab показал precision = 0.600, recall = 0.900 и F1 = 0.720 для класса «обнаружено искажённое утверждение».

4.2.3 Сценарий 3: Авто-актуализация при обновлении источника

Условие: в исходный документ сценария 1 внесены изменения (обновлена функциональность продукта, 3 новых раздела).

В кодовой базе предусмотрен детерминированный validation-case для выявления устаревших уроков и регенерации затронутых разделов без полной пересборки курса. В доказательную базу данной ВКР этот сценарий включён как инженерное подтверждение расширяемости, а не как основная метрика Н1–Н3: количественные выводы работы опираются на paired В2/В4, evaluation lab и unit-экономику.

4.3 Текущие результаты и проверка гипотез

4.3.1 Сводка фактически подтверждённых результатов

Сравнение результатов одношаговой LLM-конфигурации (В2) с целевыми показателями визуализировано на рисунке 4.1.

Отдельно от чисел одношаговой LLM-конфигурации (В2) в платформе реализован и измерен машинно читаемый контур доказательств ИИ-методиста (В4): result/status payload содержит citations, quality_seal, block_provenance, cost_quality




Рисунок 4.1 — Сравнение результатов одношаговой LLM-конфигурации (B2) с целевыми показателями

и `thesis_validation`. Эти поля покрыты фронтным E2E-сценарием отображения дипломных метрик и используются скриптами `run_ai_methodist_product_validation.py` и `run_paired_b2_b4_experiment.py`. Поэтому Н2 проверяется не только архитектурным описанием, но и paired-таблицей на том же 19-документном корпусе.

4.3.2 Проверка гипотез Н1–Н3

Н1 (продуктовая). «Мультиагентный конвейер должен готовить первый методический черновик курса не дольше чем за 30 минут при сохранении покрытия уровней таксономии Блума $\geq 70\%$.»

Гипотеза подтверждена в лабораторном продуктовом контуре: В4 подготовил результат в среднем за 17.1 с, дал среднее покрытие Блума 83.3 % и прошёл quality seal во всех 19 запусках. Это закрывает заявленный в работе критерий «первый проверяемый черновик до 30 минут» на контролируемом корпусе. **Гипотеза Н1 подтверждена на измеренном корпусе ВКР.**

Н2 (техническая). «Мультиагентная архитектура обеспечивает более высокое качество структуры по сравнению с одношаговой базовой

конфигурацией на той же LLM.»

Paired-прогон показывает, что B4 повышает среднее покрытие Блума с 61.4 % до 83.3 %, даёт среднюю строковую дельту +21.9 п.п. и добавляет source-grounding 100 % там, где B2 имеет 0 % ссылочной привязки. Наиболее сильный прирост получен на корпоративных регламентах: +44.4 п.п. к покрытию Блума. **Гипотеза Н2 эмпирически поддержана автоматическим paired-прогоном; дополнительно выполнена детерминированная fact-check/RAG-style проверка.**

Н3 (бизнесовая). «Себестоимость подготовки курса $\leq$ 1% от стоимости ручной разработки у внешнего подрядчика.»

В сценарной финансовой модели себестоимость подготовки курса составляет 75 руб., что эквивалентно примерно 0.05 % от ориентировочной стоимости ручной разработки курса у внешнего подрядчика. Такой результат не доказывает рынок сам по себе, но показывает, что архитектура не разрушает экономику продукта уже на раннем этапе. **Гипотеза Н3 поддержана сценарной unit-экономикой текущего MVP.**

4.3.3 Производительность

Подтверждённые операционные показатели:

- среднее время одношаговой LLM-конфигурации (B2) на измеренном корпусе из 19 документов — 4.37 с на генерацию структуры курса;
- среднее техническое время B4 в paired-прогоне — 17.1 с до готового результата с quality seal;
- среднее число модулей — 3, среднее число уроков — 6.2;
- доля структурно валидных результатов — 100 %.

Для долгосрочной эксплуатации в сервисе предусмотрены Open-Telemetry spans по нодам LangGraph и machine-readable provenance. В рамках ВКР операционный вывод ограничен end-to-end временем запуска, поскольку именно оно напрямую связано с Н1.

4.3.4 Точность факт-чекинга

Синтетический датасет из 100 утверждений (50 корректных, 50 намеренно искажённых) позволяет воспроизводимо рассчитать precision / recall / F1. Детерминированный evaluation lab дал: precision = 0.600, recall = 0.900, F1 = 0.720. Высокий recall важен для MVP:

подозрительные утверждения лучше отправить на human-review, чем пропустить фактическую ошибку в нормативном или учебном материале. Низкая precision и слабые RAG-style scores не позволяют продавать этот результат как доказанное качество retrieval. Корректная интерпретация: контур работает как conservative guardrail перед human-review, а качество retrieval требует расширения корпуса и экспертной разметки.

4.4 Ограничения исследования и угрозы валидности

Ниже перечислены ограничения исследования и угрозы внутренней и внешней валидности [52], существенные для интерпретации результатов.

4.4.1 Ограничения тестового датасета

Ограниченный объём измеренного корпуса ($n = 19$). Ядровой корпус содержит 19 документов, что ограничивает статистическую мощность сравнений. При размере эффекта $d = 0.5$ (средний) и $\alpha = 0.05$ мощность критерия Вилкоксона для такой выборки остаётся ограниченной и не гарантирует надёжного сравнения тонких различий между конфигурациями. Следовательно, результаты следует рассматривать как проверенные в пределах ограниченного лабораторного корпуса и требующие репликации на расширенном корпусе ($n \geq 30$). В терминах продуктовой доказательности это означает, что $n = 19$ достаточен как MVP/lab validation и лабораторная проверка инженерной готовности, но недостаточен для сильного вывода о превосходстве над аналогами. Такой вывод должен быть вынесен в отдельный open-course benchmark $n \geq 30$ на открытых курсах с raw JSON/CSV-артефактами, фиксированной rubric/baseline-методикой и явным перечнем ограничений.

Жанровая и языковая фокусировка измеренного ядра. Ядровой корпус сознательно собран как смешанный срез: русскоязычные продуктивно-регламентные документы и англоязычные учебные программы MIT OCW. Это повышает прикладную релевантность для B2B- и образовательных сценариев, но ограничивает прямой перенос количественных результатов на другие отрасли, регуляторные среды и типы исходных документов. USWDS, GOV.UK и Saylor Academy вынесены в зарубежный сравнительный контур и в текущей версии используются только качественно, без полного количественного прогона.

4.4.2 Ограничения эталонного корпуса

В работе сознательно не заявляется внешний экспертный эталонный корпус. Выводы о качестве ограничены теми метриками, которые воспроизводятся из JSON-артефактов: Bloom coverage, source-grounding, quality seal, RAG-style диагностика и fact-check F1. Это делает результаты честными, но ограничивает их перенос на субъективную педагогическую оценку без дополнительного ручного ревью. Отдельно ограничивается интерпретация RAG/eval-метрик: они показывают работоспособность консервативного guardrail перед human-review, но не доказывают качество retrieval без расширенного корпуса и экспертной разметки релевантных фрагментов.

4.4.3 Ограничения пользовательской валидации

SUS / NPS, удержание и повторное использование не входят в измеряемые критерии данной ВКР. Работа оценивает инженерную и продуктово-лабораторную готовность MVP: может ли система на контролируемом корпусе подготовить проверяемый черновик курса с evidence-слоем и приемлемой unit-экономикой.

4.4.4 Ограничения технологического стека

Зависимость от семейства Qwen. Основные эксперименты проведены на локальном Qwen-контуре. Результаты могут не воспроизводиться на других моделях (LLaMA 3.3, Mistral Large, GPT-4o), что ограничивает обобщаемость вывода об эффективности агентной архитектуры.

Ограниченный набор методологий в измерениях. В коде есть шаблоны ADDIE, SAM и Backward Design, но количественные результаты ВКР зафиксированы только для ADDIE. Это снижает риск смешать готовые измерения с ещё не сопоставленными режимами.

Авто-классификация уровней таксономии Блума. Уровни таксономии Блума определялись автоматически с помощью GPT-4o в роли judge-модели [53]. Надёжность такой классификации на русскоязычном наборе учебных целей не валидирована независимо; это является угрозой валидности измерения покрытия уровней таксономии Блума.

4.4.5 Угрозы внешней валидности

Система разработана и количественно апробирована на русскоязычном текстовом контенте продуктового, нормативного и образовательного характера; зарубежный контур пока использован только качественно. Перенос результатов на мультимодальный контент, закрытые внутренние материалы организаций, другие отрасли и другой регуляторный контекст (SCORM, xAPI) требует дополнительных исследований.

4.4.6 Направления для устранения ограничений

Направления долгосрочного развития:

- 1) расширение русского ядра до 30–50 документов из 5+ различных сценариев;
- 2) запуск подготовленного open-course benchmark $n \geq 30$ на открытых курсах для проверки переносимости B2/B4-результатов и competitor-style/manual rubric baseline;
- 3) независимое ручное ревью на обезличенном внутреннем или открытом корпусе и расчёт согласия разметки уровней таксономии Блума;
- 4) кросс-модельная оценка: воспроизведение экспериментов на LLaMA 3.3 70B и GPT-4o для проверки обобщаемости;
- 5) отдельный количественный прогон на зарубежном сравнительном контуре после стабилизации русского baseline;
- 6) продольная UX-аналитика после промышленной поставки продукта.

4.5 Бизнес-оценка и масштабирование

4.5.1 Unit-экономика

Себестоимость одного курса в текущем MVP складывается из LLM-времени, retrieval/KG-вызовов, хранения состояния и опциональных API-вызовов. Сценарный расчёт собран в артефакте `unit_economics_results.json`.

- GPU-время — 75 руб./курс;
- OpenAI API (опционально) — 0 в базовой конфигурации;
- **Итоговая себестоимость** — ≈ 75 руб./курс.

Соотношение себестоимости ИИ-генерации и подрядной разработки показано на рисунке 4.2.

Метрики сценарной подписочной модели:




Рисунок 4.2 — Unit-экономика ИИ-методиста: себестоимость vs рыночная стоимость

- САС (стоимость привлечения клиента): около 30 000 руб.;
- LTV (пожизненная ценность клиента): около 300 000 руб.;
- LTV / САС: 10.0;
- срок окупаемости: 2 мес.

4.5.2 Lean Canvas

Lean Canvas [54] ИИ-методиста приведён в приложении К. Основные блоки:

Проблема: разработка корпоративного курса занимает много времени и часто выносится на подрядчиков; контент устаревает быстрее, чем его успевают перерабатывать.

Решение: полуавтоматическая подготовка структуры и черновых материалов курса по загруженному документу; проактивные подсказки и ручное ревью в контуре; механизм последующей авто-актуализации.

Целевая аудитория: B2B-клиенты платформы Adapstory — HR-отделы и учебные центры с > 50 сотрудников.

Труднокопируемое преимущество: методологическая вариативность (ADDIE/SAM/BD) и полный суверенитет данных за счёт локального LLM-контура не воспроизводятся Coursebox AI и iSpring AI.

4.5.3 Финансовая модель (прогноз на 3 года)

Детальные расчёты приведены в приложении К. Итоговые показатели:

- NPV: 1 807 тыс. руб.;
- IRR: 32.2 %;
- ROI за 3 года: 42.2 %;
- Точка безубыточности: 14 клиентов / 32 мес. с момента коммерческого

запуска

Динамика выручки и расходов представлена на рисунке 4.3.




Рисунок 4.3 — Финансовый прогноз на 3 года (сценарная модель)

4.5.4 Потенциал масштабирования

После валидации в российском B2B-сегменте выделены смежные рынки:

- **Международный EdTech:** потенциальный TAM $\approx$ \$51 млрд к 2030 году [1];
- **Корпоративное обучение (CLO-сегмент):** интеграция в Microsoft 365 + SharePoint как источник документов;
- **Государственное образование:** адаптация под ФГОС-регламент при поддержке профильных ведомств.

4.5.5 PESTLE-анализ при масштабировании

- **P (Political):** регуляторные требования к использованию ИИ в государственном образовании; ограничения экспорта технологий;
- **E (Economic):** зависимость от стоимости GPU-аренды; волатильность курсов валют при API-зависимости;
- **S (Social):** опасения преподавателей и методистов относительно снижения роли человека; требования к прозрачности использования ИИ;
- **T (Technological):** быстрое устаревание LLM; риск лицензионных

изменений в моделях с открытыми весами;

- **L (Legal)**: 152-ФЗ [55] (персональные данные); авторское право на ИИ-сгенерированный контент (ГК РФ ч. IV);
- **E (Environmental)**: энергопотребление GPU-кластера; углеродный след при масштабировании.

4.5.6 Оценка рисков

Визуализация рисков на матрице вероятность/влияние приведена на рисунке 4.4.




Рисунок 4.4 — Матрица рисков ИИ-методиста

4.5.7 Дорожная карта

6 месяцев: расширение paired-валидации B4, абляционное исследование RAG/fact-check/review узлов, усиление fact-check precision без потери recall, увеличение открытого и внутреннего корпуса измерений.

12 месяцев: переход от чернового MVP к производственно готовой версии, количественное сравнение трёх методологий (ADDIE / SAM / Backward Design), структурированная пользовательская аналитика после коммерческого запуска.

24 месяца: API для внешней интеграции, мультиязычность, масштабирование на смежные рынки корпоративного обучения.

Дорожная карта представлена на рисунке 4.5.




Рисунок 4.5 — Дорожная карта развития ИИ-методиста

4.5.8 Интеллектуальная собственность

Программный комплекс подлежит регистрации как программа для ЭВМ (ст. 1261 ГК РФ [56]). Авторские права на сгенерированные учебные материалы принадлежат оператору платформы (ст. 1295 ГК РФ, служебное произведение).

4.6 Степень готовности и обратная связь от рынка

4.6.1 Текущий статус MVP

Реализованы: контур обработки документов, CourseStructureAgent (ADDIE), ручное ревью, ContentCreatorAgent с RAG, FactCheckAgent, Verifier, quality seal, thesis-validation snapshot и paired B2/B4 evidence pipeline.

Инженерные заделы: методологии SAM / Backward Design и механизм авто-актуализации. Мультимедийный слой (FLUX + Silero) остаётся за пределами MVP ВКР.

4.6.2 Рыночные сигналы

- Проведены 20 B2B-интервью (Customer Development);
- 70 % респондентов называют время разработки главным ограничением;
- 50 % уже используют подрядчиков или внешних методистов;
- 60 % готовы рассмотреть ИИ-инструмент такого класса.

4.6.3 Соответствие решения проблеме

Корректнее говорить не о подтверждённом соответствии решения проблеме, а о сильном сигнале наличия проблемы и раннем интересе к решению: проблема валидирована через CustDev, 60 % респондентов готовы рассмотреть ИИ-инструмент. В рамках ВКР соответствие решения проверяется через работающий MVP и лабораторные продуктовые метрики, а не через внешние коммерческие договорённости.

4.6.4 Качественная обратная связь

Уже на уровне проблемных интервью выявлены три устойчивых сигнала:

- пользователям важнее быстро получить *первый черновик* курса, чем сразу идеальный финальный контент;
- для регламентов и сценариев нормативного обучения критична привязка к источнику и возможность проверки фактов;
- для B2B-сегмента существенны суверенитет данных, локальное развёртывание и контроль с участием человека.

Таблица 4.1 — Текущий набор подтверждённых результатов исследования

Контур валидации	Текущее значение	Что это означает
Customer Development	20 B2B-интервью	проблема подтверждена первичными данными рынка
Ключевой pain	70 %	большинство респондентов называют длительность разработки курса главным ограничением текущего процесса
Использование подрядчиков / внешних методистов	50 %	рынок уже платит за закрытие этой задачи внешним ресурсом
Готовность рассмотреть ИИ-инструмент	60 %	есть ранний сигнал интереса к решению; в данной ВКР он используется как рыночный контекст, а не как доказательство качества MVP
Одношаговая LLM-конфигурация (B2): время подготовки структуры	4.37 с	одношаговая конфигурация очень быстра, но не решает задачу качества и объяснимости
Одношаговая LLM-конфигурация (B2): среднее покрытие уровней Блума	61.4 %	текущая конфигурация не достигает целевого уровня $\geq 70\%$
Одношаговая LLM-конфигурация (B2): доля курсов с Блумом $\geq 70\%$	21.1 %	именно этот разрыв обосновывает необходимость агентного усиления
Одношаговая LLM-конфигурация (B2): структурная валидность	100 %	минимальный конвейер уже стабильно выдаёт формально корректную структуру курса
ИИ-методист (B4): среднее покрытие уровней Блума	83.3 %	ИИ-методист проходит целевой порог $\geq 70\%$ на том же корпусе
ИИ-методист (B4): средняя дельта к одношаговой LLM (B2)	+21.9 п.п.	прирост считается построчно для каждой пары doc_i
ИИ-методист (B4): source grounding / quality seal	100 % / 100 % PASS	все 19 B4-runs имеют проверяемую опору на источник и готовы к human review
Оценочные наборы	30 вопросно-ответных пар, 100 утверждений	база для следующей волны RAG-оценки и оценки факт-чекинга уже подготовлена
Сценарная экономика unit-	75 руб./курс	инфраструктурная себестоимость выглядит низкой даже до завершения полного оценочного цикла B4
Отношение к подрядной разработке	0.05 % 69	расчётная себестоимость существенно ниже стоимости внешней ручной разработки курса
LTV / SAC, срок	10.0; 2 мес.; 14	сценарная модель выглядит

Таблица 4.2 — Матрица рисков ИИ-методиста

Риск	Вероятность	Влияние	Митигация
Деградация качества новой версии LLM	Средняя	Высокое	Регрессионный Ragas-тест при каждом обновлении модели
Недоступность GPU-узла	Низкая	Высокое	circuit breaker + резервный переход на OpenAI API
Утечка данных через LLM-провайдера	Низкая	Критическое	локальное развёртывание; запрет облачных провайдеров для корпоративного сегмента
Неприятие разработчиками курсов	Средняя	Среднее	ручное ревью в контуре; прозрачность использования ИИ в интерфейсе
Изменение лицензии Qwen / retrieval back-end	Низкая	Высокое	LLM Gateway с провайдер-агностичным API; альтернативы: Llama 3.3

ЗАКЛЮЧЕНИЕ

Разработан интеллектуальный методический ассистент (ИИ-методист) — микросервис образовательной платформы Adapstory, поддерживающий методиста и разработчика курса при подготовке учебных курсов на основе внутренних и открытых учебных документов с использованием LLM, поиска по корпусу и агентной оркестрации.

Итоги выполнения задач исследования. Проведены 20 глубинных B2B-интервью, подтвердивших устойчивую проблему трудоёмкой разработки корпоративных курсов. Для 70 % респондентов главным ограничением оказалась длительность разработки, 50 % уже прибегают к подрядчикам или внешним методистам, а 60 % готовы рассмотреть ИИ-инструмент. На техническом уровне выбран и обоснован стек на основе LangGraph, Dify/RAG, Knowledge Graph, PostgreSQL checkpoint/result store и локального Qwen-контура; реализованы контур обработки источников, 6-node агентный конвейер подготовки курса, source/provenance-слой, quality seal и snapshot дипломных метрик H1–H3.

Количественные результаты текущего этапа. Для лабораторного 19-документного прогона одношаговой LLM-конфигурации (B2) воспроизводимо измерен базовый слой: среднее время подготовки структуры — 4.37 с, среднее покрытие уровней таксономии Блума — 61.4 %, доля курсов с покрытием ≥ 70 % — 21.1 %, структурная валидность — 100 %. На том же корпусе выполнен paired-прогон одношаговой LLM (B2) и ИИ-методиста (B4): B4 повысил среднее покрытие Блума до 83.3 %, дал среднюю строковую дельту +21.9 п.п., source-grounding 100 % и quality seal PASS в 19 из 19 запусков. На 30 вопросно-ответных парах и 100 утверждениях выполнена детерминированная evaluation lab: RAG-style context precision = 0.567, fact-check precision = 0.600, recall = 0.900, F1 = 0.720. Сценарная unit-экономика даёт инфраструктурную себестоимость порядка 75 руб. за курс, LTV / CAC = 10.0, период окупаемости 2 месяца и точку безубыточности на уровне 14 клиентов. RAG/eval-метрики трактуются консервативно: контур работает как conservative guardrail перед human-review, но качество retrieval требует расширения корпуса и экспертной

разметки, поэтому в работе не заявляется полное доказательство retrieval-качества. Аналогично, $n = 19$ трактуется как MVP/lab validation текущего MVP: этого достаточно для проверки инженерной готовности одношаговой LLM (B2) и ИИ-методиста (B4), но недостаточно для сильного вывода о превосходстве над аналогами. Для такого вывода подготовлен следующий validation gate — open-course benchmark $n \geq 30$ на открытых курсах с raw JSON/CSV-артефактами и отдельной baseline-методикой.

Статус гипотез. H1 поддержана paired-прогоном: B4 укладывается в порог 30 минут и проходит целевой уровень Блума на контролируемом корпусе. H2 эмпирически поддержана на 19-документном корпусе: ИИ-методист (B4) улучшает Bloom/source-grounding относительно одношаговой LLM (B2) на тех же документах и проходит дополнительную fact-check проверку как guardrail перед human-review, но не закрывает экспертное доказательство качества retrieval. H3 поддержана сценарной unit-экономикой текущего MVP: расчётная себестоимость подготовки курса на порядки ниже ручной разработки.

Научный вклад и уникальность. Предложена и апробирована архитектура воспроизводимой валидации LLM-систем для поддержки проектирования учебных курсов на русском корпусе открытых и официальных документов с зарубежным сравнительным контуром. В отличие от решений, где LLM используется как одношаговый генератор черновика, ИИ-методист рассматривает создание курса как проверяемый pipeline: методическая структура строится до генерации уроков, источники сохраняются как evidence-контекст, а итоговый результат сопровождается quality seal, fact-check и provenance. Архитектура объединяет методологическую рамку проектирования курса, агентную оркестрацию с сохраняемым состоянием и RAG-контур. Сформирован воспроизводимый набор артефактов для дальнейшей оценки: корпус документов, оценочные артефакты для RAG и факт-чекинга, сценарная бизнес-модель и протокол внутренней и открытой апробации. Отдельно выделены тяжелокопируемые конкурентные преимущества решения: его отличие защищается сравнением source grounding, provenance, quality seal, fact-check, human-review gates и paired B2/B4 artifact trail, а не декларацией об использовании ИИ.

Практическая значимость. ИИ-методист представляет собой рабочий MVP с контуром обработки источников, подготовкой структуры курса, ревью с участием человека, source/provenance-слоем, quality seal и подготовленной основой для контентной и фактической валидации. Система доведена до состояния проверяемого продуктового MVP: основные результаты воспроизводятся из JSON-артефактов, а отдельный readiness-gate защищает текст диплома от несогласованных claims. Долгосрочное развитие связано с расширением корпуса, кросс-модельной оценкой, open-course benchmark $n \geq 30$, абляцией узлов и промышленной UX-аналитикой после запуска.

ИСПОЛЬЗОВАНИЕ СИСТЕМ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА И ЛИЧНЫЙ ВКЛАД АВТОРА

В соответствии с требованиями ИТМО к ВКР настоящий раздел описывает использование ИИ-инструментов обучающимся в процессе подготовки работы и фиксирует личный вклад автора в разработку системы.

Использование ИИ-инструментов

В ходе подготовки работы автор использовал ИИ-инструменты как средства поиска, чернового структурирования и редакционной поддержки текста:

- **OpenAI Codex / ChatGPT-5.4** — для структурирования отдельных разделов, поиска возможных формулировок и редакционной шлифовки черновиков при обязательной последующей ручной переработке;
- **Perplexity AI** — для поиска актуальных рыночных данных, проверки дат публикации и навигации по открытым источникам;
- **Claude Code** — для ускорения работы по созданию технических спецификаций на разработку фронтенд и бекенд части системы.

Все ИИ-сгенерированные фрагменты проходили ручную проверку автора: фактические утверждения перепроверялись по первоисточникам, а финальные выводы и исследовательские формулировки принимались автором самостоятельно.

ИИ-инструменты не использовались для подмены первичных данных: интервью, CustDev-выводы, экспериментальные артефакты, расчёты и итоговые исследовательские интерпретации были собраны, проверены и оформлены автором.

Личный вклад автора

Автор настоящей работы лично:

- 1) **Провёл исследование предметной области:** собрал и проанализировал корпус из 45+ цитируемых академических и индустриальных источников по LLM, мультиагентным системам, RAG-подходам и автоматизации создания образовательного контента;

- 2) **Разработал архитектурное решение:** принял ключевые проектные решения по выбору технологического стека (LangGraph, Dify/RAG, Knowledge Graph, PostgreSQL checkpointer/result store, Qwen-контур), спроектировал 6-node граф агентов и выбранную архитектуру source-grounded генерации;
- 3) **Разработал промпт-шаблоны:** подготовил системные промпт-шаблоны для ADDIE, SAM и Backward Design с учётом требований таксономии Блума, особенностей русскоязычного ядрового корпуса и зарубежного сравнительного контура;
- 4) **Реализовал систему:** написал код LangGraph-графа агентов, LLM Gateway, FastAPI-приложения, source/provenance-слоя, quality seal и thesis-validation snapshot, настроил локальный и env-dev контуры проверки ИИ-методиста;
- 5) **Провёл эксперименты:** сформировал ядровой корпус документов, подготовил 30 вопросно-ответных пар и 100 фактуальных утверждений, провёл измерения базовой конфигурации, paired B2/B4-прогон, детерминированную fact-check/RAG-style проверку и сценарную unit-экономическую оценку;
- 6) **Провёл Customer Development:** 20 глубинных B2B-интервью по методу Mom Test и систематизировал ключевые болевые точки рынка;
- 7) **Подготовил доказательную базу ВКР:** оформил протокол внутренней и открытой апробации, machine-readable evidence-артефакты и автоматический readiness-gate, который проверяет согласованность текста диплома с кодом и результатами.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Global EdTech Market Report 2024–2030. — 2024. — EdTech Hub, Statista Research.
2. Chapman B. How Long Does It Take to Create Learning? — 2010. — Chapman Alliance Research.
3. Российский EdTech-рынок: объём и структура по данным Smart Ranking. — 2024. — в тексте использованы данные Smart Ranking за 2023 год; дата обращения: 13.04.2026. URL: https://pureportal.spbu.ru/files/124005039/Conference_proceedings_2024.pdf.
4. Fitzpatrick R. The Mom Test: How to Talk to Customers & Learn if Your Business Is a Good Idea When Everyone Is Lying to You. — CreateSpace, 2013.
5. E-learning Services Market Size, Share & Trends Analysis Report 2030. — 2025. — дата обращения: 13.04.2026. URL: <https://www.grandviewresearch.com/industry-analysis/e-learning-services-market>.
6. Coursebox AI: Create a Course from Documents. — дата обращения: 07.05.2026. URL: <https://www.coursebox.ai/document-to-course>.
7. Articulate 360 AI Features. — дата обращения: 13.04.2026. URL: <https://articulate.com/360>.
8. iSpring Suite AI: What's New. — дата обращения: 07.05.2026. URL: <https://www.ispringsolutions.com/whats-new>.
9. Synthesia for Learning and Development. — дата обращения: 13.04.2026. URL: <https://www.synthesia.io>.
10. NotebookLM Audio and Video Overviews. — 2025. — дата обращения: 07.05.2026. URL: <https://blog.google/innovation-and-ai/models-and-research/google-labs/notebook-lm-audio-video-overviews-more-languages-longer-content/>.
11. GetCourse Platform Overview. — 2026. — дата обращения: 13.04.2026. URL: <https://getcourse.ru/>.

12. What is ChatGPT: FAQ. — 2026. — дата обращения: 07.05.2026. URL: <https://help.openai.com/en/articles/12677804-what-is-chatgpt-faq>.
13. Deep research in ChatGPT. — 2026. — дата обращения: 07.05.2026. URL: <https://help.openai.com/en/articles/10500283>.
14. ChatGPT Accuracy and Limitations. — 2026. — дата обращения: 07.05.2026. URL: <https://help.openai.com/en/articles/8313428-chatgpt-accuracy-and-limitations>.
15. Use chat in NotebookLM. — 2026. — дата обращения: 07.05.2026. URL: <https://support.google.com/notebooklm/answer/16179559>.
16. ChatGPT for Good? On Opportunities and Challenges of Large Language Models for Education / E. Kasneci, K. Seßler, S. Küchemann, [et al.] // Learning and Individual Differences. — 2023. — Vol. 103. — P. 102274.
17. Pardos Z. A., Bhandari S. Learning gain differences between GPT-4 and human expert tutoring // Proceedings of EDM 2023. — 2023.
18. Tack A., Piech C. The AI Teacher Test: Measuring the Pedagogical Ability of Blender and GPT-3 in Educational Dialogues // Proceedings of EDM 2022. — 2022.
19. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation / Q. Wu [et al.] // arXiv:2308.08155. — 2023.
20. Reflexion: Language Agents with Verbal Reinforcement Learning / N. Shinn [et al.] // Advances in Neural Information Processing Systems (NeurIPS 2023). — 2023.
21. Plan-and-Solve Prompting: Improving Zero-Shot Chain-of-Thought Reasoning by Large Language Models / L. Wang, W. Xu, Y. Lan, [et al.]. — 2023. — arXiv:2305.04091.
22. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks / P. Lewis, E. Perez, A. Piktus, [et al.] // Advances in Neural Information Processing Systems (NeurIPS 2020). — 2020.
23. RAGAS: Automated Evaluation of Retrieval Augmented Generation / S. Es [et al.] // Proceedings of EACL 2024. — 2024.

24. DALL-E 3 Technical Report / J. Betker, G. Goh, L. Jing, [et al.]. — 2023. — URL: <https://openai.com/dall-e-3>.
25. Labs B. F. FLUX.1: Unified Image Generation. — 2024. — arXiv:2407.12697.
26. Silero Models: Pre-trained Enterprise-Grade Speech Models. — дата обращения: 01.04.2025. URL: <https://github.com/snakers4/silero-models>.
27. ElevenLabs Multilingual v2 Documentation. — дата обращения: 01.04.2025. URL: <https://elevenlabs.io/docs>.
28. Molenda M. In Search of the Elusive ADDIE Model // Performance Improvement. — 2003. — Vol. 42, no. 5. — P. 34–36.
29. Allen M. W. Leaving ADDIE for SAM: An Agile Model for Developing the Best Learning Experiences. — Alexandria : ASTD Press, 2012.
30. Wiggins G., McTighe J. Understanding by Design. — 2nd ed. — Alexandria : ASCD, 2005.
31. Bryar C., Carr B. Working Backwards: Insights, Stories, and Secrets from Inside Amazon. — 2021. — St. Martin's Press.
32. Competing Against Luck: The Story of Innovation and Customer Choice / C. M. Christensen [et al.]. — Harper Business, 2016.
33. Taxonomy of Educational Objectives: The Classification of Educational Goals. Handbook 1: Cognitive Domain / B. S. Bloom [et al.]. — New York : David McKay Company, 1956.
34. MIT OpenCourseWare. — дата обращения: 01.04.2025. URL: <https://ocw.mit.edu>.
35. Align with Taxonomies. — дата обращения: 14.04.2026. URL: <https://www.monash.edu/learning-teaching/TeachHQ/Teaching-practices/learning-outcomes/how-to/align-with-taxonomies>.
36. Hess K. A Guide for Using Webb's Depth of Knowledge with Common Core State Standards. — 2013. — дата обращения: 14.04.2026. URL: https://portal.ct.gov/-/media/sde/mbf/documents/webbs_depth_of_knowledge.pdf.

37. Aligning Teaching for Constructing Learning. — дата обращения: 14.04.2026. URL: <https://www.advance-he.ac.uk/knowledge-hub/aligning-teaching-constructing-learning>.
38. Quality Matters Higher Education Rubric. — дата обращения: 14.04.2026. URL: <https://www.qualitymatters.org/qa-resources/rubric-standards/higher-ed-rubric>.
39. Fink's Significant Learning Outcomes. — дата обращения: 14.04.2026. URL: <https://www.buffalo.edu/catt/teach/develop/design/learning-outcomes/finks.html>.
40. Chi M. T. H., Wylie R. The ICAP Framework: Linking Cognitive Engagement to Active Learning Outcomes // Educational Psychologist. — 2014. — Vol. 49, no. 4. — P. 219–243. — DOI: 10.1080/00461520.2014.965823.
41. CAST. CAST Universal Design for Learning Guidelines version 3.0. — 2024. — дата обращения: 14.04.2026. URL: <https://udlguidelines.cast.org>.
42. Bandura A. Guide for Constructing Self-Efficacy Scales // Self-Efficacy Beliefs of Adolescents / ed. by F. Pajares, T. Urdan. — Information Age Publishing, 2006. — P. 307–337.
43. Perceived Competence Scales. — дата обращения: 14.04.2026. URL: <https://selfdeterminationtheory.org/perceived-competence-scales/>.
44. The Kirkpatrick Model. — дата обращения: 14.04.2026. URL: <https://www.kirkpatrickpartners.com/the-kirkpatrick-model/>.
45. Evidence to Support the Use of the Retrospective Pretest Method to Measure Dietary and Physical Activity Behavior and Self-Efficacy in Adolescents / M. K. Shilts [et al.] // Journal of Youth Development. — 2008. — Vol. 3, no. 1. — DOI: 10.5195/jyd.2008.326.
46. Goal Attainment Scaling: A Framework for Research and Practice in the Intellectual and Developmental Disabilities Field / K. A. Shogren [et al.] // Intellectual and Developmental Disabilities. — 2021. — Vol. 59, no. 1. — P. 7–21. — DOI: 10.1352/1934-9556-59.1.7.
47. LangGraph Documentation. — дата обращения: 01.04.2025. URL: <https://langchain-ai.github.io/langgraph>.

48. AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation / Q. Wu [et al.] // Proceedings of ICLR 2024 Workshop LLM Agents. — 2024.
49. CrewAI Documentation. — дата обращения: 01.04.2025. URL: <https://docs.crewai.com>.
50. Agno Framework Documentation. — дата обращения: 01.04.2025. URL: <https://docs.agno.com>.
51. OpenAI Agents SDK Documentation. — дата обращения: 01.04.2025. URL: <https://platform.openai.com/docs/agents>.
52. Experimentation in Software Engineering / C. Wohlin [et al.]. — Berlin : Springer, 2012.
53. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena / L. Zheng, W. L. Chiang, Y. Sheng, [et al.]. — 2023. — arXiv:2306.05685.
54. Maurya A. Running Lean: Iterate from Plan A to a Plan That Works. — Sebastopol : O'Reilly Media, 2012.
55. Федеральный закон от 27 июля 2006 г. № 152-ФЗ «О персональных данных». — 2006. — М.: Собрание законодательства РФ, 2006.
56. Гражданский кодекс Российской Федерации. Часть четвёртая: Права на результаты интеллектуальной деятельности и средства индивидуализации. — 2006. — М.: Собрание законодательства РФ, 2006.

ПРИЛОЖЕНИЕ. А ГАЙД ДЛЯ CUSTOMER DEVELOPMENT ИНТЕРВЬЮ

В приложении представлен гайд для проведения глубинных B2B-интервью по методу Mom Test [4], использовавшийся при сборе первичных данных о проблеме (раздел 1.1 основного текста).

Контекст и цели интервью

Цель: валидировать гипотезу о проблеме «Разработка образовательных курсов занимает слишком много времени и/или требует компетенций, которых нет у эксперта предметной области».

Целевая аудитория: HR-специалисты, L&D-менеджеры, методисты, тренеры в B2B-компаниях с > 50 сотрудников.

Формат: 30–45 минут, видеозвонок или очно.

Вопросы гайда

Блок 1. Разогрев и контекст:

- 1) Расскажите о своей роли. Как часто вам приходится создавать учебные материалы для сотрудников?
- 2) Какой последний курс или материал вы разрабатывали? Вспомните этот процесс — с чего он начался?
- 3) Сколько времени ушло от идеи до готового материала?

Блок 2. Проблема:

- 4) Что в этом процессе было самым сложным или утомительным?
- 5) Были ли случаи, когда вы *не смогли* создать нужный материал из-за нехватки времени, ресурсов или экспертизы?
- 6) Как часто учебные материалы устаревают и требуют обновления? Как вы сейчас с этим справляетесь?

Блок 3. Текущие решения:

- 7) Какие инструменты или сервисы вы уже пробовали для автоматизации разработки курсов? Что не устроило?
- 8) Если бы вы могли потратить бюджет на решение этой проблемы — на что бы потратили?

Блок 4. Закрытие:

- 9) Есть ли коллеги, которых стоит поговорить на эту тему?
- 10) Можно ли мне прислать вам краткий обзор после того, как я поговорю с ещё несколькими людьми?

Сводка ключевых инсайтов

По результатам 20 проведённых интервью наиболее устойчивыми оказались следующие сигналы:

Таблица А.1 — Агрегированные выводы Customer Development интервью

Наблюдение	Значение	Интерпретация
Время разработки — главное ограничение	70 %	проблема носит не единичный, а системный характер
Используют подрядчиков / внешних методистов	50 %	рынок уже готов платить за снижение этой нагрузки
Готовы рассмотреть ИИ-инструмент	60 %	есть ранний сигнал интереса к решению
Формат исследования	20 интервью	глубинные B2B CustDev-интервью по методу Mom Test

- Наибольшую ценность респонденты видят не в полной автоматизации, а в ускорении подготовки первого черновика курса.
- Для нормативных и регламентных сценариев критична прослеживаемость к источнику и возможность ручного ревью.
- Для B2B-сегмента значимы суверенитет данных и возможность локального развёртывания.

ПРИЛОЖЕНИЕ. Б АРТЕФАКТЫ ДЕМОНСТРАЦИИ MVP

В приложении представлен сценарий демонстрации MVP на контролируемом корпусе работы. Демонстрация не требует закрытых внешних материалов: используются внутренние документы Adapstory и открытые учебные программы, описанные в приложении Ж.

Сценарий демонстрации

Текущий демонстрационный сценарий строится вокруг одного документа из ядрового корпуса и показывает пользователю не абстрактную презентацию, а последовательность шагов внутри продукта:

- 1) загрузка исходного документа;
- 2) выбор методологии генерации (ADDIE как текущий базовый вариант);
- 3) получение и ревью черновой структуры курса;
- 4) обсуждение, какие части пользователь оставил бы за собой, а какие готов делегировать системе;
- 5) обсуждение, какие метрики качества пользователь считает достаточными для публикации результата.

Вопросы после демонстрации

- 1) Насколько результат соответствует тому, что вы ожидали?
- 2) Что бы вы изменили в сгенерированной структуре?
- 3) Готовы ли вы использовать такой инструмент вместо текущего процесса?
- 4) Какие доказательства качества вам нужны перед публикацией курса?
- 5) Какие ограничения по данным, модели и human-review должны быть видны в интерфейсе?

Критерии успеха решенческого интервью

Таблица Б.1 — Сигналы, фиксируемые на этапе решенческих интервью

Критерий	Позитивный сигнал	Что это подтверждает
Готовность встроить систему в текущий процесс	пользователь допускает частичную автоматизацию рутинных операций	наличие прикладной ценности, а не просто любопытства
Доверие к evidence-слою	пользователь понимает source-grounding, provenance и quality seal	переход от интереса к демонстрации к проверяемому рабочему сценарию
Обсуждение эксплуатационных ограничений	появляется запрос на локальный контур, роли ревью и журнал качества	рост зрелости продуктового требования
Экономическая логика	пользователь сравнивает решение с подрядчиком / внутренним ресурсом	наличие бизнес-контекста для дальнейшего MVP

ПРИЛОЖЕНИЕ. В ПРОТОКОЛ ВНУТРЕННЕЙ И ОТКРЫТОЙ АПРОБАЦИИ

В работе не используются закрытые внешние документы и коммерческие обязательства. Аprobация MVP проводится на контролируемом корпусе: внутренние продуктово-редакционные материалы Adapstory, учебные регламенты и открытые программы MIT OCW. Такой дизайн позволяет воспроизводимо измерять качество без доступа к закрытым данным третьих лиц.

Контрольный сценарий

- 1) выбрать документ из ядрового корпуса приложения Ж;
- 2) запустить одношаговый baseline B2 и сохранить структуру курса;
- 3) запустить B4 ИИ-методиста на том же документе;
- 4) сохранить status/result/provenance JSON-артефакты;
- 5) рассчитать Bloom coverage, source-grounding, quality seal, unit-экономику и факт-чек метрики;
- 6) проверить результат скриптами `run_paired_b2_b4_experiment.py`,
`run_ai_methodist_product_validation.py` и
`check_thesis_excellent_readiness.py`.

Критерии принятия

- B4 генерируется на том же источнике, что и B2;
- среднее Bloom coverage B4 не ниже 70 %;
- source-grounding B4 не ниже 70 %;
- quality seal не ниже PASS_WITH_NOTES;
- все численные результаты воспроизводятся из JSON-артефактов, а не из ручной правки таблиц.

ПРИЛОЖЕНИЕ. Г С4-ДЕКОМПОЗИЦИЯ АРХИТЕКТУРЫ

В приложении представлена текстовая С4-декомпозиция фактической архитектуры MVP ИИ-методиста, синхронизированная с текущими сервисами Adapstory: AI Course Generator, Dify/RAG tool, Knowledge Graph, School BFF и LMS.

Г.1 — Системный контекст (C4 Level 1)

- **Разработчик курса / HR-специалист:** загружает документ, запускает подготовку черновика, ревьюит структуру и quality seal;
- **School UI / BFF School:** маршрутизирует запросы веб-клиента и показывает status/result/provenance;
- **AI Course Generator:** исполняет LangGraph-конвейер генерации и хранит артефакты запуска;
- **Dify/RAG tool:** индексирует источник и возвращает фрагменты для EvidenceTable;
- **Knowledge Graph:** предоставляет связанные компетенции, понятия и предметные связи;
- **LLM endpoint:** локальный или OpenAI-compatible endpoint для моделей семейства Qwen;
- **LMS Adapstory:** принимает утверждённый курс и публикует его.

Г.2 — Контейнеры (C4 Level 2)

Г.3 — Компоненты (C4 Level 3)

- **SourceAnalyzer:** строит EvidenceTable из Dify/RAG-фрагментов и source-excerpt fallback;
- **CourseStructureAgent:** генерирует CourseBlueprint и использует Knowledge Graph для семантического усиления структуры;
- **ContentCreatorAgent:** формирует уроки с inline citations;
- **FactCheckAgent:** проверяет claims относительно источника;
- **ReviewAgent:** оценивает методологическую связность и Bloom coverage;
- **Verifier:** рассчитывает quality seal, provenance и thesis-validation snapshot;
- **Human review layer:** блокирует публикацию без подтверждения человека;

Таблица Г.1 — Контейнерная декомпозиция ИИ-методиста

Контейнер	Технология	Роль
AI Course Generator API	FastAPI	REST/MCP входная точка, создание run, status/result/provenance
Agent runtime	LangGraph	6-node pipeline, interrupts, routing, revision loop
Checkpoint/result store	PostgreSQL	сохранение состояния, запусков, результатов и audit-данных
RAG tool	Dify plugin	индексация источника и retrieval фрагментов
Knowledge Graph	Neo4j / MCP	компетенции, понятия и связи для контекста курса
School BFF / UI	Java BFF / Frontend	пользовательский контур ревью, публикации и отображения метрик

– **Exporter**: передаёт утверждённый курс в LMS Adapstory.

ПРИЛОЖЕНИЕ. Д СПЕЦИФИКАЦИЯ ГРАФА АГЕНТОВ LANGGRAPH

В приложении представлена текстовая спецификация фактического 6-node графа агентов ИИ-методиста: ноды, переходы, точки участия человека и rollback-контур к legacy-топологии.

Д.1 — Ноды графа

Таблица Д.1 — Ноды графа агентов ИИ-методиста

Нода	Тип	Описание
source	agent	Поиск источников, EvidenceTable, coverage status
structure	agent	CourseBlueprint по методологии ADDIE и evidence-контексту
HITL-structure	interrupt	Подтверждение или коррекция структуры курса
content	agent	Черновики уроков с inline-ссылками на источники
fact-check	agent	Проверка утверждений относительно EvidenceTable
review	agent	Методологическая проверка, Bloom coverage, coherence
verifier	agent	Quality seal, cited claims, provenance, thesis-validation snapshot
HITL-quality	interrupt	Финальное решение человека перед публикацией

Таблица Д.2 — Ключевые переходы в графе LangGraph

Откуда	Куда	Условие перехода
source	structure	EvidenceTable построена или явно помечена как неполная
structure	HITL-structure	структура курса доступна для проверки
HITL-structure	content	структура утверждена пользователем
HITL-structure	structure	структура отклонена и требует пересборки
content	fact-check	уроки подготовлены и требуют верификации
fact-check	review	отчёты факт-чекинга сформированы
review	content	требуется доработка, revision count меньше лимита
review	verifier	курс прошёл методологическое ревью или исчерпан лимит доработок
verifier	HITL-quality	quality seal и provenance собраны
HITL-quality	END	человек принимает результат или фиксирует остановку

Д.2 — Основные переходы

Д.3 — Точки участия человека

- **HITL 1**: подтверждение структуры курса до генерации полного контента;
- **HITL 2**: финальное решение на основе quality seal, provenance, citations и блокирующих замечаний;
- **Rollback**: при отключении Feynman pipeline сервис может перейти к legacy 4-node топологии, а provenance фиксирует, какой pipeline фактически исполнялся.

ПРИЛОЖЕНИЕ. Е ПРОМПТ-ШАБЛОНЫ ADDIE / SAM / BACKWARD DESIGN

В приложении представлены черновые системные промпты агента CourseStructureAgent для трёх поддерживаемых методологических режимов. Они служат не как неизменяемые финальные промпты, а как управляемые рамки для дальнейшей настройки.

Е.1 — Промпт-шаблон ADDIE

[SYSTEM]

Ты — эксперт по методологии ADDIE разработки учебных курсов. Твоя задача: на основе предоставленного документа создать структуру курса, следуя фазам ADDIE.

Требования:

- каждый модуль должен содержать учебные цели по таксономии Блума;
- формат ответа — строго JSON (CourseBlueprint);
- не придумывай факты, которых нет в документе;
- если данных недостаточно, явно помечай неопределённость.

[USER]

Документ: {{document_text}}

Целевая аудитория: {{audience_profile}}

Е.2 — Промпт-шаблон SAM

[SYSTEM]

Ты — эксперт по Successive Approximation Model. Построй курс как итеративную структуру, которую удобно быстро проверять и дорабатывать короткими циклами.

Требования:

- сначала предложи минимально жизнеспособную структуру курса;
- явно выделяй части, которые требуют ручного ревью;
- держи фокус на скорости и возможности быстрой итерации;
- формат ответа — JSON (CourseBlueprint).

[USER]

Документ: {{document_text}}

Целевая аудитория: {{audience_profile}}

Е.3 — Промпт-шаблон Backward Design

[SYSTEM]

Ты — эксперт по Backward Design. Начинай проектирование курса с конечных результатов обучения, а затем выстраивай модули, оценивание и учебные активности назад от целей.

Требования:

- сначала сформулируй измеримые learning outcomes;
- для каждого outcome укажи, как он будет проверяться;
- затем предложи модули и уроки, которые ведут к этим outcome;
- формат ответа — JSON (CourseBlueprint).

[USER]

Документ: {{document_text}}

Целевая аудитория: {{audience_profile}}

ПРИЛОЖЕНИЕ. Ж ТЕСТОВЫЙ КОРПУС ДОКУМЕНТОВ

В приложении описан измеренный корпус, использованный в артефакте `baseline_comparison.json` для прогона одношаговой LLM-конфигурации (B2). Корпус содержит 19 документов в трёх категориях: продуктово-редакционные документы, корпоративные регламенты и учебные программы MIT OCW.

Описание измеренного корпуса одношаговой LLM-конфигурации (B2)

Таблица Ж.1 — Состав измеренного корпуса одношаговой LLM-конфигурации (B2)

Группа	Кол-во	Язык	Назначение в проверке
Продуктово-редакционные документы	7	RU	Проверка генерации по брендбукам, редакционным правилам и продуктовым описаниям.
Корпоративные регламенты	6	RU	Проверка извлечения требований, ограничений и нормативных формулировок.
Учебные программы MIT OCW	6	EN	Проверка переноса структуры дисциплин и учебных результатов в курс.
Итого	19	RU/EN	Единый корпус для одношаговой LLM-конфигурации (B2).

Machine-readable manifest прогона хранится в `baseline_comparison.json`. В него входят идентификаторы:

- product-summary, VK brand guidelines, гайды по маскоту и мерчу, редакционные политики Сбер/HR;
- information security policy, personal data policy, incident management, onboarding, anticorruption, regulations summary;
- MIT OCW 14.01, 18.01, 6.0001, 6.042J, 8.01 и summary-файл.

Корпус следует трактовать как технический baseline для проверки одношаговой LLM-конфигурации (B2), а не как окончательную экспертно размеченную выборку. Его задача — воспроизводимо показать разрыв между скоростью одношаговой генерации и требованиями к source-grounded

методическому качеству.

Оценочные артефакты текущей итерации

На текущем этапе полностью подготовлены:

- измеренный корпус одношаговой LLM-конфигурации (B2) из 19 документов;
- набор из 30 вопросно-ответных пар для RAG-оценки;
- набор из 100 утверждений для оценки факт-чекинга.

Paired-прогон одношаговой LLM (B2) и ИИ-методиста (B4) выполнен на том же наборе документов: для каждого `doc_i` сохранены `B2_result_i`, `B4_result_i`, отдельный `kb_slug B4` и строковая дельта Bloom/source-grounding. Сводка и сырые REST-артефакты приведены в приложении И и файле `paired_b2_b4_experiment.json`. Дополнительно выполнен детерминированный `evaluation lab: evaluation_lab/ai_methodist_evaluation_lab_latest.json` фиксирует RAG-style метрики на 30 QA-парах и fact-check precision / recall / F1 на 100 утверждениях.

ПРИЛОЖЕНИЕ. И ОЦЕНОЧНЫЕ АРТЕФАКТЫ И ТЕКУЩИЕ РЕЗУЛЬТАТЫ

В приложении собраны артефакты валидации, которые уже подготовлены или измерены в текущей редакции диплома. Главный технический артефакт текущей версии — `paired`-прогон одношаговой LLM (B2) и ИИ-методиста (B4) на одном и том же 19-документном корпусе. Этот прогон рассматривается как MVP/lab validation: он показывает готовность контура одношаговой LLM (B2) и ИИ-методиста (B4) на контролируемом корпусе, но не используется как доказательство превосходства над аналогами. Для такого вывода подготовлен отдельный open-course benchmark $n \geq 30$.

И.1 — Агрегированные результаты одношаговой LLM-конфигурации (B2)

Таблица И.1 — Агрегированные результаты лабораторного прогона одношаговой LLM-конфигурации (B2)

Срез корпуса	n	Покрытие, %	Доля $\geq 70\%$
Все документы	19	61.4	21.1%
Продуктивно-редакционные документы	7	73.8	28.6%
Корпоративные регламенты	6	38.9	0%
Учебные программы MIT OCW	6	69.5	33.3%

Эти значения относятся к одношаговой LLM-конфигурации (B2) из артефакта `baseline_comparison.json` и используются как технический ориентир MVP. Для проверки вклада ИИ-методиста поверх этого baseline выполнен `paired`-прогон одношаговой LLM (B2) и ИИ-методиста (B4): для каждого документа `doc_i` сопоставлялись `B2_result_i` и `B4_result_i`, а итоговая дельта считалась по строкам, а не как сравнение независимых средних.

И.2 — Paired-прогон одношаговой LLM (B2) и ИИ-методиста (B4)

В артефакте `paired_b2_b4_experiment.json` сохранены 19 пар результатов. Для каждого документа создавался отдельный `kb_slug` формата `diploma-b4-001`, `diploma-b4-002`, ..., `diploma-b4-019`; в B4 передавался ровно один исходный Markdown-документ, а `raw evidence` сохранялся в каталоге `paired_b2_b4_runs/diploma-b4-XXX/`.

Таблица И.2 — Сводка `paired`-прогона одношаговой LLM (B2) и ИИ-методиста (B4) на одном корпусе

Метрика	Значение	Интерпретация
Число пар документов	19	одношаговая LLM (B2) и ИИ-методист (B4) сравниваются построчно
Среднее покрытие Блума одношаговой LLM (B2)	61.4 %	одношаговый baseline ниже целевого порога
Среднее покрытие Блума ИИ-методиста (B4)	83.3 %	B4 проходит целевой порог $\geq 70\%$
Средняя <code>paired</code> -дельта Блума	+21.9 п.п.	улучшение считается по каждому документу
Документы с положительной дельтой Блума	15 из 19	эффект наблюдается на большинстве корпуса
Source grounding B4	100 %	все B4-runs прошли H2-gate source-grounding
Quality seal B4	100 % PASS	19 из 19 запусков готовы к human review

Таблица И.3 — Paired-дельта Блума по категориям корпуса

Категория	<i>n</i>	B2, %	B4, %	Дельта
Продуктивно-редакционные документы	7	73.8	83.3	+9.5 п.п.
Корпоративные регламенты	6	38.9	83.3	+44.4 п.п.
Учебные программы MIT OCW	6	69.5	83.3	+13.8 п.п.

Таблица И.4 — Оценочные наборы текущего MVP

Артефакт	Объём	Назначение
Измеренный корпус одношаговой LLM (B2)	19	подготовка курсов и сравнение базовых подходов
Вопросно-ответные пары (qa_pairs.json)	30	оценка faithfulness и answer relevancy
Фактуальные утверждения (statements.json)	100	расчёт precision / recall / F1 для факт-чекинга
Paired-прогон B2/B4	19 пар	проверка прироста ИИ-методиста (B4) относительно одношаговой LLM (B2) на тех же документах
Evaluation lab	30 QA + 100 утверждений	детерминированная RAG-style и fact-check проверка

И.3 — Подготовленные оценочные артефакты

И.4 — Детерминированная RAG-style и fact-check проверка

Скрипт `benchmarks.evaluation_lab` выполнен в детерминированном режиме `deterministic_lexical`. Он не вызывает внешние LLM и поэтому пригоден как регрессионный gate. На 30 вопросно-ответных парах получены RAG-style метрики: `faithfulness` = 0.335, `answer relevancy` = 0.239, `context precision` = 0.567 и `context recall` = 0.335. Эти значения трактуются как диагностические, а не как основание для

завышенного вывода о полном качестве retrieval. В текущей ВКР RAG/eval-контур работает как conservative guardrail перед human-review: качество retrieval требует расширения корпуса и экспертной разметки релевантных фрагментов.

На 100 фактуальных утверждениях fact-check контур дал: precision = 0.600, recall = 0.900, F1 = 0.720. Отдельно видно, что детектор хорошо ловит искажения типа entity swap, negation, temporal и большую часть numeric distortions, но переотмечает часть корректных утверждений как подозрительные. Это честно фиксирует текущий trade-off: система предпочитает перестраховаться перед human-review, а не пропустить ошибку.

И.5 — Машинно читаемые evidence-артефакты платформы

В текущей кодовой базе ИИ-методиста уже предусмотрены поля, необходимые для дипломной валидации:

- citations и block_provenance — ссылочная привязка уроков к источникам;
- quality_seal — статус PASS, PASS_WITH_NOTES или FAIL;
- cost_quality — стоимость, модель, токены и объяснение quality trade-offs;
- thesis_validation — snapshot метрик H1–H3, пригодный для сохранения в экспериментальный корпус.

Фронтальный E2E-тест дипломной валидации проверяет отображение этих полей в пользовательском контуре, а экспериментальные скрипты превращают JSON-артефакты в gate-report по гипотезам диплома и paired-таблицу B2/B4. Readiness-gate check_thesis_excellent_readiness.py дополнительно запрещает возвращать в текст незавершённые claims про внешние коммерческие обещания, закрытые материалы третьих лиц или визуальные материалы как будто они являются измеренными результатами.

И.6 — Подготовленный open-course benchmark gate

Для расширения проверки за пределы 19-документной MVP/lab validation подготовлен воспроизводимый manifest open_course_benchmark_manifest.json и CSV-версия

`open_course_benchmark_manifest.csv`. Manifest содержит 39 открытых учебных документов из MIT OCW, OpenEdu, HuggingFace Learn и открыто доступных course-catalog материалов. Его статус — `READY_FOR_MEASURED_BENCHMARK`: корпус готов к запуску измерений, но сам по себе не является результатом сравнения качества.

Policy этого gate: broad claim о том, что ИИ-методист существенно лучше аналогов, заблокирован до измеренного open-course benchmark $n \geq 30$ с lanes B2, B4 и competitor-style/manual rubric baseline, а также с raw JSON/CSV-артефактами и отдельным разделом ограничений.

ПРИЛОЖЕНИЕ. К LEAN CANVAS И ФИНАНСОВАЯ МОДЕЛЬ

В приложении представлены Lean Canvas и сценарные расчёты финансовой модели ИИ-методиста (раздел 4.4 основного текста).

К.1 — Lean Canvas

В текущем черновике Lean Canvas представлен в табличной форме.

Таблица К.1 — Lean Canvas ИИ-методиста

Проблема	Решение	Уникальное предложение
Создание 1 часа обучения может занимать 73–490 часов работы методиста; высокая стоимость подрядчиков; устаревание контента	Полуавтоматическая подготовка структуры и черновых материалов курса по загруженному документу, проактивные подсказки и ручное ревью в контуре, механизм последующей актуализации	Сочетание методологической вариативности, суверенитета данных (локальный LLM-контур) и глубокой интеграции в LMS-экосистему
Несправедливое преимущество	Ключевые метрики	Каналы
ADDIE / SAM / BD как переключаемые режимы; локальный LLM-контур; экосистема LMS Adapstory	Время до первого методического черновика; Покрытие уровней Блума; faithfulness; себестоимость курса	Прямые продажи B2B; продуктовые демо на открытом и внутреннем корпусе; EdTech-конференции и контент-маркетинг
Сегменты потребителей		Структура затрат / доходов
B2B: HR-отделы, L&D-команды, корпоративные университеты, учебные центры и EdTech-компании		Затраты: GPU-инфраструктура, разработка, поддержка. Доходы: B2B-подписка после коммерческого запуска, себестоимость ≈ 75 руб./курс

К.2 — Сценарные финансовые показатели

Таблица К.2 — Ключевые показатели финансовой модели

Показатель	Значение	Комментарий
Себестоимость подготовки курса	75 руб.	прямая инфраструктурная себестоимость курса
Отношение к подрядной разработке	0.05 %	при ориентире ручной разработки около 150 000 руб.
CAC	30 000 руб.	вычисляется из $LTV / CAC = 10$
LTV	300 000 руб.	сценарная модель пожизненной ценности клиента
Срок окупаемости	2 мес.	быстрый возврат затрат в модели
NPV	1 806 514 руб.	сценарный прогноз на 3 года
IRR	32.19 %	внутренняя норма доходности
ROI (3 года)	42.15 %	возврат инвестиций в горизонте модели
Точка безубыточности	14 клиентов / 32 мес.	ориентир коммерческой устойчивости

К.3 — Допущения модели

- модель носит сценарный характер и не заменяет данные будущих продаж;
- расчёт подтверждает прежде всего то, что выбранная архитектура не делает продукт заведомо экономически неустойчивым;
- коммерческие выводы не используются как доказательство качества MVP; качество подтверждается отдельными техническими замерами на внутреннем и открытом корпусе.

ПРИЛОЖЕНИЕ. Л МАТРИЦА ВОСПРОИЗВОДИМОСТИ MVP

В приложении зафиксировано, какие результаты MVP подтверждаются машинно воспроизводимыми артефактами. Перечисленные ниже JSON и Markdown-отчёты получены из экспериментальных скриптов и raw-run каталогов. Они используются как источник численных утверждений диплома.

Л.1 — Источники доказательств

Л.2 — Связь артефактов с критериями MVP

Л.3 — Команды воспроизведения

Воспроизведение результатов отделено от пользовательского интерфейса. Для проверки численных claims используются следующие команды:

```
cd Диплом
python3 experiments/\
run_ai_methodist_product_validation.py
python3 experiments/\
run_paired_b2_b4_experiment.py
python3 experiments/\
check_thesis_excellent_readiness.py
```

Raw-run артефакты и агрегированные отчёты должны храниться вместе: если численное значение меняется в JSON-отчёте, соответствующая таблица в тексте диплома обновляется тем же изменением.

Таблица Л.1 — Артефакты, подтверждающие результаты MVP

Утверждение	Артефакт	Что проверяется
B2 baseline измерен на одном корпусе	агрегаты baseline и product validation из приложения И	$n = 19$, время, Bloom coverage, доля результатов выше порога
B4 сравнивается с B2 построчно	paired B2/B4-отчёт и raw-run строки из приложения И	19 пар документов, paired-дельта, source grounding, quality seal
Каждый B4-запуск сохраняет raw evidence	каталоги запусков diploma-b4-001-019	payload, статусы генерации, результат, approval responses, paired-row файл
Retrieval/fact-check контур проверяется отдельно	evaluation lab-отчёт из приложения И	30 QA-пар, 100 утверждений, RAG-style диагностика и F1 факт-чека
Open-course benchmark подготовлен как следующий gate	manifest JSON/CSV и protocol MD из экспериментального контура	$n = 39$ открытых учебных документов; это manifest, а не claim о превосходстве над аналогами
Текст диплома защищён от устаревших claims	readiness-gate из экспериментального контура	отсутствие внешних коммерческих overclaim, старых метрик и незавершённых сравнений, включая запрет делать вывод о превосходстве над аналогами на базе $n = 19$

Таблица Л.2 — Traceability между критериями MVP и результатами эксперимента

Критерий	Подтверждение	Ограничение
Быстрый первый черновик	B4: среднее время 17.1 с на 19-документном корпусе	это лабораторная оценка, а не SLA промышленного контура
Методическая структура курса	B4: среднее Bloom coverage 83.3 % против 61.4 % у B2	оценка автоматическая; внешняя экспертная разметка вынесена в будущий протокол
Работа от источника	B4: source grounding 100 %, quality seal PASS в 19 из 19 запусков	метрика фиксирует наличие ссылочной привязки, но не заменяет методическое ревью
Сравнение с аналогами	open-course benchmark $n \geq 30$ подготовлен как следующий validation gate	$n = 19$ является MVP/lab validation и недостаточен для сильного вывода о превосходстве над аналогами
Контроль фактических искажений	fact-check F1 = 0.720, recall = 0.900	precision = 0.600 показывает conservative guardrail перед human-review, а не доказанное качество retrieval
Экономическая реализуемость	сценарная себестоимость порядка 75 руб. за курс	расчёт зависит от загрузки GPU, тарифов и каналов продаж