

СОДЕРЖАНИЕ

СПИСОК СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

ADDIE	--- Analyze, Design, Develop, Implement, Evaluate (методология проектирования курсов)
API	--- Application Programming Interface (интерфейс программирования приложений)
B2B	--- Business-to-Business (бизнес-модель)
BD	--- Backward Design (методология «обратного проектирования» курса)
BFF	--- серверный слой для веб-клиента (Backend-for-Frontend)
CAC	--- Customer Acquisition Cost (стоимость привлечения клиента)
CI/CD	--- Continuous Integration / Continuous Delivery (непрерывная интеграция и доставка)
CVM	--- Customer Value Management (управление ценностью клиента)
DAG	--- Directed Acyclic Graph (ориентированный ациклический граф)
GPU	--- Graphics Processing Unit (графический процессор)
IRR	--- Internal Rate of Return (внутренняя норма доходности)
JTBD	--- Jobs To Be Done (методология исследования потребностей)
KPI	--- Key Performance Indicator (ключевой показатель эффективности)
LLM	--- Large Language Model (большая языковая модель)
LMS	--- Learning Management System (система управления обучением)
LTV	--- Lifetime Value (пожизненная ценность клиента)
MVP	--- Minimum Viable Product (минимально жизнеспособный продукт)
NPS	--- Net Promoter Score (индекс потребительской лояльности)

NPV	--- Net Present Value (чистая приведённая стоимость)
RAG	--- генерация с дополнением поиском
REST	--- Representational State Transfer (архитектурный стиль API)
ROI	--- Return on Investment (рентабельность инвестиций)
SAM	--- Successive Approximation Model (итеративная методология проектирования курсов)
SAM	--- Serviceable Addressable Market (доступный рынок) [в контексте рыночного анализа]
SOM	--- Serviceable Obtainable Market (реально достижимый рынок)
SUS	--- System Usability Scale (шкала удобства использования системы)
TAM	--- Total Addressable Market (общий доступный рынок)
TTS	--- Text-to-Speech (синтез речи)
ВКР	--- выпускная квалификационная работа
ИИ	--- искусственный интеллект
ИС	--- интеллектуальная собственность
ЛМС	--- система управления обучением (эквивалент LMS)
ЛПР	--- лицо, принимающее решения

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

Классификация	--- процесс распределения объектов по категориям на основе их признаков
Нейронная сеть	--- математическая модель, имитирующая работу мозга, используемая для решения задач распознавания и классификации
Обучающая выборка	--- совокупность данных, используемых для настройки параметров модели машинного обучения

ВВЕДЕНИЕ

Большие языковые модели (LLM) всё активнее применяются для автоматизации рутинных операций при проектировании образовательных материалов. Мировой рынок корпоративного обучения, по оценкам аналитических агентств, превысит \$51 млрд к 2030 году [[edtech_market_report_2024](#)]. Главный сдерживающий фактор роста --- высокая стоимость и длительность создания качественного учебного контента. Средний цикл разработки одного корпоративного курса силами методиста-эксперта составляет от нескольких дней до нескольких недель и требует педагогических компетенций, которыми не всегда обладают эксперты предметной области.

Существующие ИИ-инструменты для ускоренной подготовки курсов (Coursebox AI, iSpring AI) сильны в разработке курса: они помогают получить структуру, тестовые задания, визуальные материалы, перевод или SCORM/LMS-экспорт. Открытые продуктовые материалы этих решений не описывают воспроизводимую проверку результата по всей цепочке: от привязки к источнику и происхождения отдельных блоков до проверки фактов, знака качества и парного прогона одношаговой LLM и ИИ-методиста. Мультиагентные LLM-конвейеры для решения этой задачи остаются малоизученными: отсутствуют систематические проверки архитектур на воспроизводимом российском корпусе документов и внешнем зарубежном контрольном контуре. Также не хватает контрольных наборов с одновременной привязкой к таксономии Блума, согласованности курса, качеству онлайн-курса и переносу обучения в практику.

Объект исследования --- образовательная платформа Adapstory (AI LMS), предоставляющая инструменты создания и управления учебными курсами для B2B-клиентов.

Предмет исследования --- микросервис ИИ-методист: интеллектуальный проактивный методический ассистент, поддерживающий методиста, эксперта и разработчика курса при создании, упаковке и актуализации образовательных продуктов на основе LLM с применением мультиагентной оркестрации.

Цель работы --- разработать MVP интеллектуального методического

ассистента платформы Adapstory и воспроизводимый контур его технической и продуктовой валидации, показывающий, насколько мультиагентная обработка внутренних и открытых учебных документов способна снизить рутинную нагрузку при подготовке структуры и черновых материалов курса при сохранении за человеком методического решения и контроля качества.

Формат работы --- бизнес-тезис. Поэтому в фокусе инженерная реализуемость микросервиса и проверка продуктовой гипотезы: насколько подтверждена клиентская боль, сходится ли экономика единицы продукта, есть ли рыночный потенциал, описана ли канва бизнес-модели и готов ли MVP к следующему этапу коммерческой проверки.

Для достижения цели поставлены следующие задачи:

- 1) провести анализ предметной области: исследование клиентов с B2B-аудиторией, продуктовый обзор конкурентов и систематический обзор научных подходов;
- 2) оценить рыночный потенциал решения (TAM/SAM/SOM) и сформулировать исследовательские гипотезы;
- 3) спроектировать мультиагентную архитектуру конвейера поддержки проектирования курсов и обосновать выбор технологического стека через воспроизводимые эксперименты;
- 4) реализовать систему: FastAPI-микросервис AI Course Generator, граф агентов LangGraph, интеграцию с RAG-контуром, графом знаний и сохранением состояния в PostgreSQL;
- 5) провести валидацию системы: автоматизированную оценку времени генерации, покрытия уровней таксономии Блума, привязки к источнику, проверки фактов и экономики единицы продукта на внутреннем и открытом корпусе;
- 6) оценить бизнес-потенциал: экономику единицы продукта, финансовую модель и провести исследование клиентов для подтверждения соответствия решения выявленной проблеме.

Научная новизна работы состоит в следующем: предложена и инженерно реализована воспроизводимая схема проверки мультиагентного ИИ-методиста для проектирования учебных курсов, сочетающая (1) исполняемую методологическую модель проектирования курса в первой реализации ADDIE, (2) графовую оркестрацию LangGraph с двумя точками участия чело-

века, (3) RAG/KG-контур с опорой на источник, таблицу свидетельств, проверку фактов, знак качества и запись происхождения результата каждого запуска. Основание новизны связано с проверяемым методическим конвейером: каждый блок результата связан с исходным документом, проходит автоматический контроль качества и сохраняется в виде воспроизводимого доказательного артефакта для последующей проверки человеком. Таблица ?? раскрывает тяжелокопируемые конкурентные преимущества через проверяемые механизмы доверия, проверки и повторяемости результата.

Положения, выносимые на защиту:

- 1) Одношаговая LLM-конфигурация на измеренном корпусе из 19 документов генерирует структуру курса в среднем за 4.37 с, но достигает только 61.4 % среднего покрытия уровней таксономии Блума и не создаёт ссылок на источник; это обосновывает переход к мультиагентной архитектуре.
- 2) Мультиагентная шестиузловая архитектура LangGraph (анализ источника → структура курса → подготовка контента → проверка фактов → педагогическая проверка → верификация) вводит таблицу свидетельств, проверку фактов, знак качества, прослеживаемость результата и две точки проверки человеком, необходимые для корпоративного курса с опорой на источник. В парном прогоне на том же корпусе ИИ-методист повысил среднее покрытие Блума до 83.3 % и дал привязку к источнику 100 % при статусе «пройдено» по знаку качества в 19 из 19 запусков.
- 3) Исследование клиентов подтвердило наличие проблемы: проведены 20 B2B-интервью, 70 % респондентов называют длительность разработки главным ограничением, 50 % используют подрядчиков или внешних методистов, 60 % готовы рассмотреть ИИ-инструмент такого класса.

Текущее состояние проекта: разработан MVP, включающий контур обработки источников, агентный конвейер поддержки проектирования курса с методологией ADDIE, слой источниковой привязки и прослеживаемости результата, знак качества и ручная проверка. Проведены проблемные B2B-интервью, парный прогон одношаговой LLM и ИИ-методиста на 19 документах, детерминированная проверка RAG-показателей, фактологическая проверка и сценарная оценка экономики единицы продукта. Партнёрские материалы и закрытые внешние документы в валидации работы не используются. Оценка текущей версии выполнена на корпусе из 19 документов: этот объём

позволяет проверить работоспособность MVP и основные инженерные сценарии; следующий контрольный этап предусматривает расширение проверки до 30 и более предварительно собранных открытых учебных материалов с сохранением исходных JSON/CSV-артефактов, базовой ручной оценкой по шкале и отдельной фиксацией ограничений.

Работа состоит из введения, четырёх глав, заключения, раздела об использовании ИИ, списка использованных источников и десяти приложений. Глава 1 содержит анализ предметной области и постановку задачи. Глава 2 описывает дизайн эксперимента и обоснование выбора технологий. Глава 3 посвящена технической реализации системы. Глава 4 содержит результаты валидации, анализ ограничений и бизнес-оценку.

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И ПОСТАНОВКА ЗАДАЧИ

1.1 Проблема и её масштаб

1.1.1 Болевые точки авторов курсов

Разработка корпоративного учебного курса остаётся трудоёмким и слабо масштабируемым процессом. Даже при наличии готового экспертного материала необходимо определить целевую аудиторию, сформулировать учебные цели, разбить содержание на модули и уроки, подобрать формат подачи, подготовить оценочные материалы и синхронизировать всё это с требованиями LMS. По оценке Chapman Alliance, производство одного часа eLearning-контента требует от 42 до 490 часов работы в зависимости от сложности сценария, мультимедийности и глубины методической проработки; для большинства практических проектов реалистичный коридор составляет 40--200 часов на один час готового обучения [[chapman_elearning_hours_2010](#)].

Для российского B2B-сегмента проблема усугубляется дополнительно.

- **Дефицит методических компетенций.** Эксперт предметной области знает материал; перевод знания в педагогически корректную структуру курса требует отдельной методической компетенции. Другой проблемой становится нехватка или перегрузка специалистов в области методики преподавания. У компаний зачастую нет финансовой возможности иметь собственный методический отдел.
- **Высокая стоимость внешней разработки.** На рынке корпоративного обучения разработка одного курса силами подрядчика обычно оценивается в диапазоне 100--300 тыс. руб. за проект, что делает частое обновление контента экономически невыгодным для малого и среднего бизнеса [[smart_ranking_elearning_2024](#)].
- **Быстрое устаревание источников.** Регламенты, продуктовые описания и внутренние правила обновляются часто. Команда не всегда успевает вручную пересобрать учебные материалы, из-за чего курс быстро расходится с актуальной версией исходного документа.

1.1.2 Разрыв между экспертизой и образовательной упаковкой

В корпоративной среде инициатором курса обычно выступает владелец продукта, руководитель функции, HR или L&D-менеджер. Эти роли хорошо знают предметную область и бизнес-контекст; для создания масштабируемого цифрового курса им часто не хватает инструментов педагогического дизайна.

На практике это проявляется так: черновой материал остаётся на уровне «экспертного конспекта» без явных учебных результатов и уровней освоения. Ориентация структуры курса только на имеющиеся документы снижает практическую ценность. Сопровождение же требует подключения методиста, зачастую не входящего в команду.

1.1.3 Подтверждение проблемы: результаты исследования клиентов

Для первичной проверки гипотез о проблеме проведено 20 глубинных B2B-интервью с HR-специалистами, L&D-менеджерами, методистами и корпоративными тренерами по подходу Mom Test [[fitzpatrick_mom_test_2013](#)]. Руководство интервью, логика кодирования ответов и шаблон таблицы выводов вынесены в приложение А.

Количественные результаты:

- **70 %** респондентов называют время подготовки курса главным ограничением запуска нового обучения;
- **50 %** респондентов привлекают внешних подрядчиков или отдельных методистов для упаковки материала;
- **60 %** готовы включить ИИ-инструмент в текущий процесс разработки, если он не ухудшает качество структуры и позволяет сохранить контроль над итоговым результатом.

Распределение ответов респондентов представлено на рисунке ??.

Качественный вывод: обучающиеся находятся в профиците информации и дефиците времени. Отсюда запрос --- быстро превращать широкий класс образовательных материалов, включая учебные программы, методические описания, регламенты, брендбуки и продуктовые брифы, в обучение с понятной логикой, проверяемыми учебными целями и практическим результатом.



Рисунок 1.1 --- Результаты исследования клиентов (n=20 B2B-интервью)

1.1.4 Решенческие интервью и критерии соответствия решения проблеме

Серия решенческих интервью проведена на базе функционального прототипа ИИ-методиста (сценарий демонстрации --- приложение Б). Проверяемые критерии соответствия решения проблеме:

- 1) готов ли руководитель L&D-отдела встроить систему в текущую ручную стадию подготовки черновой структуры курса для ускорения и снятия рутины;
- 2) готов ли методист использовать систему на реальном документе своей организации;
- 3) экономически эффективно ли решение по отношению к стоимости аутсорс-разработки или внутреннего методического ресурса.

1.1.5 Рыночный контекст: TAM / SAM / SOM

Глобальный рынок онлайн-обучения растёт: по оценке Grand View Research, его объём составил \$299.67 млрд в 2024 году и может достичь \$842.64 млрд к 2030 году при CAGR около 19 % [**grandview_elearning_2025**]. Это задаёт широкий TAM для решений, ускоряющих подготовку цифровых образовательных материалов.

Для оценки сегмента в России в работе используется более консервативная логика. По данным Smart Ranking, объём российского EdTech-рынка в 2023 году достиг 119.33 млрд руб. Доля сегмента «разработчики и платформы» составляла 13 % от общей структуры рынка [**smart_ranking_elearning_2024**]. Актуальные обзоры СберОбразования за 2025 год также фиксируют рост внимания к ИИ-

инструментам, персонализации и автоматизации образовательных процессов [sber_education_trends_q2_2025; sber_education_trends_q3_2025]. Этот слой ближе всего по природе к ИИ-методисту; рынок инструментов поддержки разработки курсов оценивается примерно в 15.5 млрд руб.

При целевой доле 0.1 % от SAM в горизонте трёх лет SOM составляет около 15.5 млн руб. в год. При базовой B2B-подписке порядка 15 тыс. руб. в месяц это соответствует примерно 85--90 активным корпоративным клиентам. Такой масштаб достижим для нишевого B2B-продукта.

Структура рыночной оценки показана на рисунке ??.




Рисунок 1.2 --- Оценка рынка: TAM / SAM / SOM

1.2 Анализ существующих продуктов

1.2.1 Прямые конкуренты

Coursebox AI является конструктором курсов на основе ИИ и позволяет преобразовывать документы, слайды, видео и URL в курс, автоматически генерировать тесты, видео, изображения и публиковать результат в собственную LMS либо экспортировать в SCORM/LTI форматах [coursebox_ai_2024]. По ценностному предложению это близкий продуктовый ориентир на рынке. Однако его логика остаётся в первую очередь ориентированной на быструю упаковку содержимого: сильная сторона продукта --- скорость. Явная педагогическая методология и контроль корректности фактов по отношению к исходному документу выражены слабее.

Articulate 360 AI добавляет ИИ-функции в зрелую среду корпоративного контента: создание структуры курса, чернового текста, перевода, изображений и озвучки внутри экосистемы Articulate. Продукт хорошо встроен в привычный рабочий процесс методиста и остаётся инструментом повышения производительности разработчика курса без самостоятельного методи-

ческого конвейера с RAG-слоем, проверкой фактов и локальным развёртыванием [articulate_ai_2025].

iSpring Suite AI развивает похожую траекторию: в 2025 году в продукт добавлены AI Course Creation Helper, AI Translator, AI Image Generator, функции синтеза речи и другие инструменты ускорения разработки курса [ispring_suite_ai_2026]. Сильной стороной iSpring является зрелая экосистема для корпоративного обучения и русскоязычный рынок. Ограничение: ИИ остаётся надстройкой над средой разработки контента без автономного мультиагентного конвейера, принимающего на вход первичный документ и проводящего его через полную цепочку анализа, проектирования и обновления курса.

Synthesia лидирует в классе ИИ-видеогенерации для обучения и корпоративных коммуникаций: её ценность сосредоточена в создании аватарных роликов, озвучки и мультязычного видео-контента для обучения и L&D-задач [synthesia_ai_training_2025]. Но Synthesia не закрывает задачу проектирования учебной структуры.

1.2.2 Смежные решения

Google NotebookLM --- сильный смежный продукт для работы с источниками, который умеет строить краткие выжимки, аудиообзоры и видеообзоры по загруженным материалам. В 2025 году Google расширил генерацию аудио и видео обзоров до 80+ языков, сделав их заметно реалистичнее и полезнее для изучения сложных источников [notebooklm_audio_2025]. Однако NotebookLM не предназначен для создания LMS-совместимой структуры курса, педагогического дизайна и контроля соответствия учебных целей.

GetCourse является одним из крупнейших российских игроков рынка LMS/онлайн-школ: платформа сообщает о 50,000+ клиентах, 16 млн учеников и совокупном обороте школ на платформе в 158 млрд руб. за 2025 год [getcourse_platform_2026]. Для настоящей работы GetCourse служит ориентиром класса систем, куда ИИ-методист потенциально может встраиваться сервисом генерации и обновления курса.

1.2.3 Матрица свойств

Таблица ?? фиксирует свойства решений по критериям, которые оказались значимыми в исследовании клиентов: способность работать от исход-

ного документа, наличие встроенной педагогической логики, поддержка русскоязычного контента, суверенитет данных, автоматическое обновление содержания и интеграция с LMS-средой.

Таблица 1.1 --- Матрица свойств конкурентных решений

Критерий	Coursebox	Articulate AI	iSpring AI	Synthesia	ИИ-методист
Генерация курса из документа	+	±	±	---	+
Явная методология (ADDIE / SAM / BD)	---	---	---	---	+
Русскоязычный контент	±	±	+	±	+
Локальное развёртывание и суверенитет данных	---	---	---	---	+
ИИ-аудио / видео	+	+	+	+	+
Проверка фактов по источнику	---	---	---	---	+
Автоматическое обновление курса	±	---	---	---	+
Ревью с участием человека	+	+	+	+	+
Интеграция с LMS-потокотом разработки	+	+	+	---	+

Радарная визуализация свойств приведена на рисунке ??.

1.2.4 Пробел между проблемой и существующими решениями

Рынок предлагает стартапы и зрелые продукты для ускорения создания обучения. Сохраняется разрыв между генерацией учебных материалов и адаптацией к контексту каждого обучающегося.

В рассмотренных решениях четыре требования корпоративного B2B-заказчика не сходятся в одном продукте:

- 1) работа с внутренним документом организации, который задаёт первичный источник;
- 2) поддержка методической логики проектирования курса для достижения целей обучения;
- 3) возможность локального развёртывания и контроля данных;
- 4) механизм повторной генерации и обновления курса при изменении исходного источника.




Рисунок 1.3 --- Радарная карта свойств решений

Позиционирование решений на карте приведено на рисунке ??.




Рисунок 1.4 --- Карта позиционирования конкурентных решений

1.2.5 Тяжелокопируемые конкурентные преимущества

Предлагаемое решение автоматизирует рутинную работу методиста при проектировании курса и соединяет методическое проектирование, источниковую доказательность и воспроизводимую проверку в одном производственном контуре. В рабочем сценарии система сохраняет доказательный контекст и сначала формирует структуру курса, затем генерирует уроки. Также предусмотрены точки проверки человеком, расчёт знака качества и повторяемая парная проверка на том же корпусе.

Ключевое возражение к новизне решения: современный ChatGPT умеет работать с файлами, искать в вебе и в режиме глубокого исследования (deep research) формировать отчёты с источниками [chatgpt_deep_research_2026]. Это действительно снижает ценность простых одношаговых запросов в самостоятельной разработке. В настоящей работе новизна опирается на контролируемый производственный процесс подготовки курса: источник становится первым объектом системы, происхождение результата сохраняется на уровне

блоков, знак качества рассчитывается машинно, публикация проходит через контрольные точки с участием человека.

Таблица ?? сравнивает решения по проверяемым механизмам доверия, фактической проверки и повторяемости результата. Для ChatGPT учитывается текущий класс возможностей OpenAI: поиск и глубокое исследование дают ссылки на источники; постоянная цепочка подготовки курса и доменный контроль качества остаются вне такого запроса [**chatgpt_deep_research_2026**; **chatgpt_accuracy_2026**]. Для NotebookLM признаётся сильная работа с цитатами и опорой на источники; продукт при этом сохраняет формат исследовательского блокнота без полного конвейера подготовки корпоративного курса [**notebooklm_chat_2026**]. Открытые материалы Coursebox и iSpring подтверждают сильные функции разработки курса [**coursebox_ai_2024**; **ispring_suite_ai_2026**]. Заявленной воспроизводимой цепочки доверия в этих материалах нет: привязки к источнику, происхождения блоков, проверки фактов, знака качества и парного прогона.

Таблица 1.2 --- Защита уникальности ИИ-методиста через проверяемые механизмы доверия

Критерий	ChatGPT + запрос / B2	Coursebox / iSpring	NotebookLM	ИИ-методист B4
Привязка к источнику	Зависит от режима и дисциплины запроса; B2 в эксперименте имеет 0 % привязки к источнику.	Генерируют курс или структуру из материалов; карта источников на уровне артефактов не заявлена.	Ответы опираются на выбранные источники и цитаты.	100 % B4-запусков имеют ссылки и связь блока с источником.
Происхождение результата	История чата не является воспроизводимым журналом курса.	В открытом описании не заявлено происхождение каждого фрагмента курса.	Сохраняет источники и заметки блокнота; цепочка подготовки курса не описана.	Сохраняются JSON-файлы со статусом, результатом и происхождением, происхождение блоков и исходные доказательства запусков.
Методический конвейер	Методология остаётся текстом в запросе и легко теряется при повторе.	Сильный слой разработки курса: план, тестовые задания, визуальные материалы, перевод, LMS/SCORM.	Сильный исследовательский и учебный помощник; формат LMS-конструктора курса не заявлен.	ADDIE реализован в виде графа: анализ источника, структура, контент, проверка фактов, педагогическая проверка, верификатор.
Проверка фактов и знак качества	OpenAI рекомендует проверять критичные данные; встроенного доменного знака качества для курса нет.	В открытых материалах не заявлен воспроизводимый знак качества по источнику.	Цитаты помогают проверять ответ; педагогический контроль качества остаётся отдельной задачей.	19 из 19 B4-запусков получили значение знака качества «пройдено»; F1 проверки фактов = 0.720.
Контрольные точки с участием человека	Возможны вручную; исполняемый процесс их явно не фиксирует.	Редактирование автором есть; контрольная точка в состоянии конвейера не заявлена.	Совместное редактирование заметок, без процесса согласования в LMS.	Две обязательные точки проверки человеком до публикации и после верификации.
Воспроизводимая цепочка артефактов	Нельзя честно повторить парный прогон без внешней дисциплины логирования.	Продуктовые материалы описывают ускорение разработки курса; экспериментальная цепочка не заявлена.	Есть артефакты блокнота; цикл парной оценки B2/B4 не описан.	Парный B2/B4 на 19 документах, контроль готовности, исходные доказательства и приложения Ж--К.

Преимущество ИИ-методиста связано с воспроизводимым контуром доверия. ChatGPT может быть сильным генератором черновика и исследовательским помощником; ИИ-методист делает проверяемым весь жизненный цикл учебного артефакта. В системе явно заданы источник, методическая рамка, цепочка происхождения результата, автоматическая проверка фактов, знак качества, контрольные точки с участием человека и парная цепочка B2/B4. Именно эта совокупность даёт долгосрочно развиваемое преимущество: каждый новый агент, модель или методология могут подключаться к тем же контрактам доверия. Качество версии проверяется повторяемым набором артефактов, без опоры на впечатление от отдельного ответа. При этом парный B2/B4 на 19 документах подтверждает работоспособность механизма доверия в пределах лабораторной проверки MVP. Широкий рыночный вывод о качестве требует отдельной контрольной проверки на открытых курсах $n \geq 30$ с теми же исходными артефактами и явно описанной базовой методикой.

Тяжелокопируемое преимущество формируется на основе четырёх элементов:

- **методологического подхода** --- вариативные педагогические рамки ADDIE, SAM и Backward Design становятся параметрами агентного конвейера и фиксируются в исполняемом процессе;
- **подхода доказательности от источника** --- каждый результат связан с источником через ссылки, происхождение блоков, проверку фактов и знак качества, что снижает риск неподтверждённой генерации;
- **инфраструктурного подхода** --- быстрый старт в формате самостоятельного запуска с возможностью перехода к локальному развёртыванию на собственной ИИ/LMS-инфраструктуре без вывода данных клиента в облако Adapstory;
- **платформного подхода** --- масштабируемой работы человека с ИИ для автоматизации актуализации, проверки фактов, сопровождения и других рутинных операций на базе общей истории запусков и машиночитаемых доказательных артефактов.

1.3 Обзор научных методов и подходов

1.3.1 Формулировка исследовательского вопроса

Исследовательский вопрос:

«Какой эффект даёт мультиагентная архитектура с сохраняемым состоянием и вариативной методологической моделью при поддержке методического проектирования корпоративных и учебных материалов по показателям точности, покрытия уровней таксономии Блума и времени подготовки первого черновика?»

Работа находится на стыке трёх линий: применения LLM в проектировании образовательных материалов, мультиагентной оркестрации и метрик педагогического качества.

1.3.2 LLM для поддержки проектирования образовательных материалов

Применение LLM в образовании стало особенно заметным после 2022 года. Kasneci et al. [[kasneci_llm_education_2023](#)] отмечают способность больших языковых моделей существенно ускорять создание объяснений, учебных заданий и материалов для самостоятельной работы.

Pardos [pardos_llm_instructional_2023] и Tack et al. [tack_aied_2022] указывают, что наибольший потенциал LLM возникает в задачах, где требуется быстро построить первую версию обучающего материала и затем доработать её с участием человека.

У большинства существующих работ есть повторяющееся ограничение: генерация строится по одношаговому сценарию или короткой цепочке запросов. В результате модель выдаёт связный текст без устойчивой дисциплины педагогического проектирования: учебные цели оказываются слабо связаны с содержанием, уровни когнитивной сложности распределяются формально.

1.3.3 Мультиагентные системы для поддержки проектирования курса

Мультиагентные LLM-системы декомпозируют сложную задачу на специализированные роли и состояния. Wu et al. [wu_autogen_2023] показали, что распределение ролей между агентами повышает управляемость и качество LLM-приложений. Shinn et al. [shinn_reflexion_2023] предложили паттерн Reflexion. Wang et al. [wang_plan_and_execute_2023] описали Plan-and-Execute в виде схемы разделения планирования и исполнения.

Проектирование курса --- *многошаговая* задача: разобрать источник, сформулировать структуру, произвести контент, проверить соответствие источнику, при необходимости вернуть в цикл проверка. Такая задача относится к графу с сохраняемым состоянием и явными переходами между этапами.

1.3.4 RAG в образовании

RAG-подходы снижают число галлюцинаций за счёт опоры на внешний корпус знаний [lewis_rag_2020]. Для учебного курса это критично: содержание должно воспроизводить смысл исходного документа и сохранять доказательную проверяемость.

Es et al. [es_ragas_2023] предложили фреймворк Ragas, который позволяет измерять достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy) и точность контекста (context precision). Эти метрики хорошо подходят для промежуточной оценки RAG-слоя ИИ-методиста: они фиксируют качество ответа и качество связи ответа с источником.

1.3.5 Генерация мультимедиа для обучения

Генерация мультимедийных артефактов --- иллюстраций, голосовых дорожек, подкастов --- опирается на диффузионные модели (DALL-E 3, FLUX.1) [dalle3_2023; flux_2024] и TTS-решения (Silero, ElevenLabs) [silero_tts_2024; elevenlabs_2024].

В настоящей работе мультимедиа --- вспомогательный слой. Научная новизна связана со способом встраивания изображений и аудио в методический конвейер.

1.3.6 Методологии проектирования курсов в контексте LLM

ADDIE [addie_molenda_2003], SAM [allen_sam_2012] и Backward Design [wiggins_backward_design_2005] представляют три различных логики педагогического проектирования. ADDIE задаёт линейно-этапный подход, SAM делает акцент на быстрых итерациях. Backward Design строит курс от измеримых результатов обучения к структуре и заданиям.

Для LLM-автоматизации каждая из них задаёт различный способ управления генерацией: что считать первичным --- анализ аудитории, ожидаемые результаты или итеративное прототипирование. Методология становится параметром архитектуры и фиксируется в исполняемом процессе.

1.3.7 Оценка качества результатов, подготовленных с участием ИИ

Стандартные LLM-метрики слабо подходят для оценки учебного курса. В работе используется комбинация трёх классов:

- **структурные метрики:** валидность структуры, число модулей, число уроков, наличие обязательных элементов;
- **RAG-метрики:** достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy), точность контекста (context precision);
- **педагогические метрики:** покрытие уровней таксономии Блума, согласованность учебных целей с содержанием курса.

1.3.8 Идентификация исследовательской лакуны

Обзор выявил четыре пробела в литературе и практике.

- Работы по применению LLM в подготовке образовательных материалов в основном оценивают связность и полезность текста. Связь архитектуры системы с измеримой педагогической метрикой вроде покрытия уровней

таксономии Блума обычно остаётся слабой.

- Большинство промышленных ИИ-инструментов для разработки курсов ускоряют отдельные этапы работы разработчика курса. Мультиагентный конвейер с сохраняемым состоянием, который ведёт документ через полный цикл методической упаковки и поддерживает человека на ключевых точках принятия решения, остаётся вне их открытого описания.
- Русскоязычный B2B-контекст представлен слабо: не хватает воспроизводимых корпусов, включающих регламенты, продуктово-редакционные документы и учебные программы в единой постановке задачи.
- Практически не исследована задача автоматического обновления курса при изменении исходного документа, хотя именно она определяет экономическую ценность ИИ-методиста для корпоративного заказчика.

Новизна работы состоит в экспериментальном исследовании архитектуры, сочетающей RAG, мультиагентную оркестрацию, педагогическую вариативность и пригодность к развёртыванию во внутреннем контуре.

1.4 Постановка задачи и гипотезы

1.4.1 Задача исследования

Задача: разработать интеллектуального методического ассистента, который по входному документу организации формирует педагогически состоятельную структуру курса и черновой контент, опираясь на мультиагентную архитектуру с сохраняемым состоянием и обеспечивая приемлемое качество, скорость и стоимость подготовки.

1.4.2 Методологическая основа

Постановка опирается на три основания.

- **Working Backwards / CVM [amazon_cvm_2014]**: продуктовые требования формулируются от боли и ценности клиента назад к технической реализации.
- **Jobs To Be Done [christensen_jtbd_2016]**: пользователь «нанимает» систему для снятия рутинной нагрузки и ускорения упаковки знания в обучающий артефакт.
- **Таксономия Блума [bloom_taxonomy_1956]**: качество учебных целей оценивается по глубине когнитивного действия с учётом формальной структуры ответа.

1.4.3 Три конвейера ИИ-методиста

Система работает в трёх режимах:

- 1) **Адаптационный курс:** входом служит продуктивное описание, бриф или внутреннее руководство; ключевая задача --- быстро упаковать материал для новых сотрудников.
- 2) **Асинхронный учебный курс:** входом являются программа курса, учебные материалы или экспертный конспект; здесь критична логика модулей, последовательность освоения материала и покрытие учебных целей.
- 3) **Нормативный курс:** входом выступает регламент, политика или процедура; здесь на первый план выходит верность источнику, работа с фактами и возможность последующего обновления.

1.4.4 Исследовательские гипотезы

Проверяемые гипотезы:

Н1 (продуктовая). Мультиагентный конвейер позволяет сократить время до первого методического черновика до уровня менее 30 минут на один курс при сохранении покрытия уровней таксономии Блума не ниже 70 %.

Н2 (техническая). Мультиагентная архитектура с сохраняемым состоянием обеспечивает прирост качества результата по метрикам faithfulness и покрытия уровней таксономии Блума в парной проверке B2/B4 при сопоставимой базовой LLM.

Н3 (бизнесовая). Себестоимость подготовки одного курса не превышает 1 % от стоимости ручной разработки силами внешнего подрядчика.

1.4.5 Метрики проверки гипотез

Группы метрик:

- для **Н1:** время до первого черновика, доля курсов с покрытием уровней таксономии Блума $\geq 70\%$, доля структурно валидных результатов;
- для **Н2:** faithfulness, answer relevancy, context precision, покрытие уровней таксономии Блума, плотность ссылок на источник;
- для **Н3:** себестоимость на курс, отношение себестоимости к средней рыночной стоимости подрядной разработки и параметры подписочной экономики (LTV/CAC, срок окупаемости).

Метрики связывают научную часть работы с практической ценностью: от корректности по отношению к источнику до экономической оправданно-

сти внедрения.

2 ИССЛЕДОВАНИЕ: ЭКСПЕРИМЕНТЫ И ВЫБОР ТЕХНОЛОГИЙ

Глава содержит экспериментальную постановку задачи, обоснование технологического стека и проверенные результаты текущего MVP: собранный корпус данных, обзор практик решения задачи и выбранную архитектуру.

2.1 Дизайн эксперимента

2.1.1 Тестовый корпус и оценочные артефакты

Для основной линии исследования зафиксирован **измеренный корпус одношаговой LLM-конфигурации (B2) из 19 документов**, репрезентирующих три категории источников, с которыми должен работать ИИ-методист в B2B- и образовательном контуре:

- **7 продуктивно-редакционных документов:** краткое описание продукта, брендовые и редакционные руководства, политики стиля и HR-коммуникаций;
- **6 корпоративных регламентов:** политики информационной безопасности, персональных данных, управления инцидентами, адаптации сотрудников и антикоррупционного поведения;
- **6 открытых учебных программ Massachusetts Institute of Technology OpenCourseWare (MIT OCW):** англоязычные учебные планы по экономике, математике, программированию и физике [[mit_ocw_2024](#)].

MIT OCW выбран как открытый источник академических программ с устойчивыми публичными страницами, понятной дисциплинарной структурой и англоязычными учебными результатами. Эти материалы проверяют сценарий переноса университетской программы в структуру онлайн-курса без привлечения закрытых партнёрских данных. В качестве альтернатив для расширения корпуса рассматривались OpenEdu, Hugging Face Learn и Saylor Academy для открытых курсов, а также USWDS и GOV.UK для зарубежных нормативно-редакционных документов. Они вынесены в следующий контрольный контур, чтобы текущий 19-документный замер оставался небольшим, парным и полностью сопоставимым.

В измеряемое ядро включались документы, пригодные для технического базового прогона без раскрытия закрытых внешних данных. Для каждого документа в артефакте базового прогона сохранены идентификатор, категория, язык, время генерации и рассчитанные метрики.

Корпус охватывает три существенно разных типа входа: редакционные правила, регламентные тексты и академические программы. Это соответствует целевым сценариям продукта: подготовка внутреннего курса по продукту, адаптационный курс по правилам компании и асинхронный учебный курс.

Для автоматизированной оценки использованы также два вспомогательных оценочных набора:

- **30 вопросно-ответных пар** (`qa_pairs.json`) для детерминированной оценки по схеме RAG на уровне ответов на вопросы;
- **100 утверждений** (`statements.json`), из которых 50 корректных и 50 намеренно искажённых, для оценки проверки фактов.

2.1.2 Конфигурации эксперимента: ручной подход (B1), одношаговая LLM (B2), ИИ-конструктор (B3) и ИИ-методист (B4)

Для исследования определены четыре конфигурации. Количественное доказательство текущего MVP строится на одношаговой LLM-конфигурации (B2) и ИИ-методисте (B4). Ручная разработка (B1) и ИИ-конструктор (B3) служат контрольными линиями для расширения методики:

- **B1** --- ручная разработка структуры курса методистом-экспертом; служит теоретической верхней границей качества без статуса выполненного заказа;
- **B2** --- одношаговая генерация на базовой LLM без агентской оркестрации; это базовая конфигурация, полностью прогнанная на ядровом корпусе;
- **B3** --- коммерческий инструмент класса конструкторов курсов на основе ИИ (в работе закладывается Coursebox AI --- ближайший рыночный аналог); используется для анализа рынка без статуса измеренной экспериментальной линии;
- **B4** --- ИИ-методист: мультиагентный конвейер поддержки методиста, объединяющий обработку документов, поиск релевантных фрагментов, проектирование курса, подготовку черновых материалов, проверку фактов и верификацию результата.

Статус базовых конфигураций на момент написания:

- **B2** дал воспроизводимые количественные результаты по 19 документам и служит базовым ориентиром;
- **B4** завершил парный прогон на тех же 19 документах и служит основным измеренным результатом ИИ-методиста;
- **B1** и **B3** не служат количественным доказательством гипотез H1--H3 в текущей работе.

Глава 2 фиксирует измеренный экспериментальный слой одношаговой LLM (B2) и ИИ-методиста (B4) и дополнительную автоматизированную проверку RAG и фактологическую проверку; границы интерпретации этих результатов отдельно указаны в разделе ограничений. Отдельно подготовлено описание корпуса для следующего шага: проверки на открытых курсах $n \geq 30$. Этот этап нужен для внешней валидации выводов о качестве. Текущие 19 документов остаются лабораторной проверкой MVP текущей инженерной версии.

2.1.3 Метрики оценки

На текущем этапе используются четыре группы метрик:

- **структурные**: валидность JSON-структуры, число модулей, число уроков, наличие обязательных полей;
- **педагогические**: покрытие уровней таксономии Блума --- доля из шести уровней таксономии Блума, представленных в учебных целях курса;
- **поисково-фактологические**: достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy), точность контекста (context precision) и метрики проверки фактов;
- **операционные**: время подготовки черновика, плотность ссылок на источник, себестоимость курса, пригодность к локальному развёртыванию.

Набор охватывает форму результата, педагогическую глубину, связь с источником и эксплуатационную стоимость.

Одной таксономии Блума недостаточно для полноценной педагогической и пользовательской оценки курса. Она хорошо описывает когнитивный уровень целей и слабее отражает структурную сложность результата, согласованность курса, качество онлайн-дизайна и эффект для обучающегося. Поэтому в методологическом контуре исследования рассматривается более широкий набор рамок [monash_solo_2026; webb_dok_guide_2013;

advancehe_constructive_alignment_2026; quality_matters_he_rubric_2026; fink_significant_learning_2026; chi_wylie_2014; cast_udl_2024].

2.1.4 Расширенная педагогическая и пользовательская рамка

Таблица 2.1 --- Дополнительные рамки оценки качества курса сверх таксономии Блума

Рамка	Что измеряет	Потенциальная операционализация для ИИ-методиста
Таксономия SOLO	структурную сложность и степень интеграции результата обучения	экспертная оценка структуры курса по уровням от одноструктурного до расширенного абстрактного
Глубина знания по Webb (DOK)	когнитивную строгость заданий и оценочных материалов	распределение сгенерированных заданий по уровням DOK 1--4
Конструктивное согласование (Biggs)	согласованность целей, учебных активностей и оценивания	доля целей, для которых в курсе есть связанная активность и способ проверки
Методика Quality Matters	качество онлайн-курса --- цифрового образовательного продукта	итоговый балл по целям, оцениванию, материалам, активностям, технологиям и доступности
Таксономия значимого обучения Fink	значимое обучение сверх простого воспроизведения содержания	покрытие компонентов применения, интеграции, личностного измерения, ценностного отношения и умения учиться
Рамка ICAP	тип учебной активности и глубину вовлечения обучающегося	доля пассивных, активных, конструктивных и интерактивных учебных активностей
UDL: Universal Design for Learning	доступность, вариативность подачи и варианты действия	покрытие по осям engagement, representation, action & expression

Для настоящего исследования эти рамки относятся к долгосрочному **пользовательскому слою оценки**, дополняющему выполненные технические измерения. Иными словами, текущий MVP по-прежнему опирается на покрытие уровней таксономии Блума, валидность структуры, поисково-фактологические метрики и операционную себестоимость. После коммерческого запуска продуктовый контур оценки может быть усилен показателями самоэффективности, компетентности, переноса в практику и достижения цели [bandura_self_efficacy_2006; pcs_sdt_2026; kirkpatrick_model_2026; shilts_retrospective_2008; shogren_gas_2021].

Таблица 2.2 --- Показатели эффекта обучения, ориентированные на обучающегося

Показатель	Что измеряет	Потенциальная операционализация
Самоеффективность (Self-efficacy)	уверенность обучающегося, что он может выполнить конкретную задачу	Likert-вопросы, ориентированные на конкретную задачу, вида «теперь я могу самостоятельно сделать X»
Ощущаемая компетентность (Perceived Competence)	субъективное ощущение владения темой или навыком	короткая посткурсовая шкала PCS по конкретному домену
Перенос обучения в практику (Transfer of learning)	факт применения изученного в рабочей или учебной ситуации	отложенный опрос через 2--4 недели: применял ли, сколько раз, какие барьеры возникли
Retrospective pre-post	изменение восприятия своих возможностей с учётом эффекта response-shift	один пост-опросник с оценкой состояния «до курса» и «после курса»
Достижение цели (Goal attainment)	степень достижения индивидуальной учебной или рабочей цели	мини-шкала достижения цели по цели, сформулированной перед обучением

2.2 Выбор и обоснование технологий

2.2.1 Фреймворк мультиагентной оркестрации

Задача ИИ-методиста относится к классу процессов с сохраняемым состоянием: документ проходит этапы обработки, анализа источника, подготовки структуры, наполнения черновыми материалами, проверки фактов, педагогической проверки и публикации. Часть шагов выполняется последовательно, часть --- с условными ветками, остановками и повторным запуском после решения с участием человека.

В ходе отбора рассматривались LangGraph 1.x, AutoGen 0.4, CrewAI 0.9, Agno 1.x и OpenAI Agents SDK [langgraph_docs_2025; autogen_04_2024; crewai_docs_2025; agno_docs_2025; openai_agents_sdk_2025].

Обоснование выбора LangGraph. LangGraph соответствует природе задачи: система должна хранить состояние процесса, поддерживать возвраты к предыдущим шагам, ручную проверку и трассировку каждого узла. Для этого StateGraph даёт нужную модель исполнения: граф состояния с контрольными точками, возвратами и наблюдаемыми переходами. Дополнительным фактором стала интеграция с LangSmith, которая даёт наблюдае-

Таблица 2.3 --- Матрица фреймворков мультиагентной оркестрации

Критерий	LangGraph	AutoGen	CrewAI	Agno	OpenAI Agents SDK
Модель исполнения	граф состояний	диалоговые агенты	ролевая команда	асинхронные агенты	агенты с вызовом инструментов
Явный граф переходов	+++	++	+	++	+
Поддержка локальных LLM	+	+	+	+	---
Контур участия человека	+++	++	+	++	+
Наблюдаемость и трассировка	+++	++	+	++	++
Зрелость экосистемы	+++	++	++	+	++

мость на уровне отдельных вызовов агентов и позволяет дебажить качество генерации.

Причины отказа от альтернатив. AutoGen силён в роли среды многоагентного взаимодействия. Для детерминированного конвейера ему требуются дополнительные абстракции над диалоговой моделью. CrewAI удобно описывает роли и задачи; его применение в продакшн-ориентированном асинхронном процессе требует дополнительных соглашений. Agno привлекателен своей асинхронностью и RAG-встроенностью; зрелость экосистемы пока ограничивает его выбор в качестве базового фреймворка. OpenAI Agents SDK не выбран базовым вариантом из-за облачной привязки и отсутствия траектории локального развёртывания.

2.2.2 Выбранная архитектура

После выбора оркестратора возникает второй вопрос: с помощью чего строить контур обработки документов и поиска релевантных фрагментов. В фактической MVP-реализации выбран интеграционный путь: RAG-контур отвечает за индексирование и поиск по источнику, граф знаний добавляет предметные связи и компетенции. LangGraph исполняет состояние агентного процесса поверх подготовленного доказательного контекста.

Разделение соответствует сильным сторонам компонентов. RAG-контур закрывает практическую задачу загрузки, индексации и поиска фрагментов в контуре, приближённом к промышленному; граф знаний уменьшает зависимость от плоского поиска по сходству; LangGraph хранит состояние курса, результаты промежуточных нод и точки участия человека.

Итоговая техническая связка текущего MVP выглядит так: Источник → RAG-контур → таблица свидетельств + граф знаний → LangGraph → арте-

факты курса. Это снижает связанность системы и позволяет заменить поисковую подсистему без переписывания агентного графа.

На рисунке ?? эта связка представлена компонентной схемой. RAG-контур готовит доказательный контекст; LangGraph получает этот контекст в состояние генерации без смешения с реализацией поиска.




Рисунок 2.1 --- Компонентная схема текущего MVP ИИ-методиста

2.2.3 Большая языковая модель

На этапе экспериментального MVP рассматривались три направления: облачная модель общего назначения, российский облачный провайдер и локальная открытая модель.

Для текущих экспериментов базовой конфигурации выбрана модель `qwen2.5:7b` через Ollama. Причина выбора прагматична: эта модель доступна локально, даёт воспроизводимые результаты, не требует внешнего API и позволяет многократно прогонять эксперименты на ядровом корпусе без роста переменных затрат.

Это **не окончательное ограничение архитектуры**. ИИ-методист имеет провайдер-агностичную архитектуру: при необходимости локальная базовая

Таблица 2.4 --- Матрица выбора LLM-вариантов для текущей итерации

Критерий	GPT-4o	YandexGPT 4	Qwen2.5 7B
Способ доступа	облачный API	облачный API	локально через Ollama
Суверенитет данных	---	±	+
Стоимость итераций и отладки	высокая	средняя	низкая
Русскоязычный контент	высокая	высокая	достаточная для базовой конфигурации
Инфраструктурная простота	высокая	высокая	высокая для локального стенда

конфигурация может быть заменена на более крупный вариант с открытыми весами семейства Qwen 2.5 или на облачный провайдер, если сценарий внедрения это допускает.

2.2.4 Поиск, векторные представления и граф знаний

Для поискового слоя в текущей итерации зафиксирован контракт: на входе источник, на выходе нумерованные фрагменты таблицы свидетельств, пригодные для цитирования и проверки фактов. В реализации этот контракт закрывается RAG-контуром и графом знаний. В production-коде RAG подключён через порт `DifyRAGApi` и `retrieval-адаптер` к `Dify API`: ключ и датасет выбираются по `tenant`-контексту, базовый метод поиска --- `keyword_search`, `top_k=5`, порог релевантности `score_threshold=0.5`, `reranking` отключён. На выходе формируются ранжированные фрагменты `RAGChunk`: текст, оценка релевантности, имя документа, позиция в источнике и ключевые слова. Отдельный платформенный индекс методологических знаний в контуре `ai-orchestration` использует `Qdrant`-коллекцию `methodology_knowledge_v2`, `hash`-эмбединги, размерность вектора 64 и тайм-аут запроса 10 с; он считается совместимым инфраструктурным слоем, дополняющим доказательную базу MVP.

Выбор такого контракта объясняется четырьмя причинами:

- возможность сохранять привязку к источнику независимо от конкретного векторного хранилища;

- поддержка локального развёртывания и запрета внешней передачи документов;
- возможность обогащать найденные фрагменты предметными связями графа знаний;
- совместимость с заменой retrieval-адаптера или подключением Qdrant/локальных векторных представлений без изменения узла LangGraph.

Для поискового слоя выполнена детерминированная проверка по схеме RAG на 30 вопросно-ответных парах: достоверность ответа составила 0.335, релевантность ответа --- 0.239, точность контекста --- 0.567, полнота контекста --- 0.335. Эти значения дают диагностический слой: текущий контур оценки RAG --- консервативный контроль перед проверкой человеком, то есть помогает раньше отправить рискованные фрагменты на проверку человеком. Они не доказывают качество поиска; качество поиска требует расширения корпуса и экспертной разметки релевантных фрагментов. Основной продуктовый показатель H2 при этом считается производной метрикой привязки к источнику: долей фактических утверждений, подтверждённых таблицей свидетельств в финальном `verification_report`.

2.2.5 Стратегии разбиения документов на фрагменты

Для обработки документов были рассмотрены две стратегии: рекурсивное фиксированное разбиение и семантическое разбиение. Детерминированная проверка по схеме RAG дала точность контекста 0.567 и полноту контекста 0.335; поэтому текущий RAG-контур служит рабочим контрольным слоем для MVP. Доказательство качества поиска требует отдельной экспертной проверки. Архитектурно более перспективным остаётся семантическое разбиение внутри поисковой подсистемы и последующая экспертная оценка релевантности найденных фрагментов. Конкретная реализация может быть заменена: в текущем MVP это RAG-контур с Dify retrieval-адаптером, в долгосрочной инфраструктурной версии допустим переход на Haystack/Qdrant при сохранении контракта таблицы свидетельств.

Учебные и нормативные документы содержат смысловые блоки разной длины: определения, процедуры, ограничения, списки требований. Жёсткое разбиение по фиксированному размеру разрушает эти границы и создаёт более шумный поисковый контекст. Семантическое разбиение устойчиво со-

храняет логические единицы и лучше подходит для нормативных документов и продуктово-редакционных руководств.

2.2.6 Перспективное развитие генерации изображений

Для мультимедийного слоя рассматривались DALL-E 3 и FLUX.1-dev [dalle3_2023; flux_2024]. DALL-E 3 удобен для быстрого старта через внешний сервис с высоким качеством. Он вносит в систему API-зависимость и переменные затраты. FLUX.1-dev допускает локальное развёртывание и подходит логике продукта, ориентированного на локальный контур.

В результате для перспективного слоя развития выбрана следующая стратегия:

- **по умолчанию** --- локальный FLUX.1-dev для черновых и полуфинальных образовательных иллюстраций;
- **опционально** --- внешний провайдер класса DALL-E 3 для сценариев повышенного качества, где требуется «маркетинговое» качество изображения.

Решение не закрывает дорогу к внешнему качественному генератору, но сохраняет базовый маршрут локального развёртывания для большинства B2B-сценариев.

2.2.7 Перспективное развитие генерации подкастов на основе синтеза речи

Для генерации русскоязычных подкастов рассматривались Silero TTS v4 и ElevenLabs Multilingual v2 [silero_tts_2024; elevenlabs_2024]. На текущем этапе выбор между ними определяется эксплуатационной логикой.

- **Silero TTS** подходит для локального развёртывания, не требует внешнего API и по заложенной в оценочную модель оценке даёт стоимость порядка 4 руб. на курс за счёт только GPU-времени.
- **ElevenLabs** обеспечивает более «человеческую» интонационную подачу. При оценке 40,000 символов на курс стоимость составляет порядка 1,080 руб. на курс. В MVP его разумно оставить опцией повышенного качества для отдельных сценариев.

Панельная MOS-оценка пока не завершена. Для этого подготовлен отдельный оценочный скрипт. В текущей итерации для выбора технологии ре-

шающими оказались суверенитет данных и предсказуемость себестоимости. Поэтому для будущего мультимедийного слоя базовым движком синтеза речи выбран Silero. Этот слой не используется для доказательства текущей готовности MVP.

2.3 Проверенные результаты экспериментов

2.3.1 Измеренные результаты одношаговой LLM-конфигурации (B2)

Первым полностью воспроизводимым экспериментом стал лабораторный прогон одношаговой LLM-конфигурации (B2) на измеренном 19-документном корпусе: продуктово-редакционные документы, корпоративные регламенты и учебные программы MIT OCW. Эти числа служат техническим базовым ориентиром текущего MVP и синхронизированы с артефактом базового прогона. В этой конфигурации использовалась локальная модель qwen2.5:7b, которая по одному запросу генерировала структуру курса в JSON-формате без поиска по корпусу, без проверки фактов и без отдельных специализированных агентов.

Таблица 2.5 --- Измеренные результаты одношаговой LLM-конфигурации (B2)

Срез корпуса	n	Среднее время, с	Среднее покрытие, %	Доля курсов $\geq 70\%$	Структурная валидность
Все документы	19	4.37	61.4	21.1%	100%
Продуктово-редакционные документы	7	5.65	73.8	28.6%	100%
Корпоративные регламенты	6	3.65	38.9	0%	100%
Учебные программы MIT OCW	6	3.61	69.5	33.3%	100%

Распределение покрытия по категориям визуализировано на рисунке ??.

Частота появления отдельных уровней таксономии Блума показана на рисунке ??.

Полученные данные фиксируют две сильные стороны одношаговой конфигурации: она очень быстро генерирует структурно валидный ответ и не требует сложной инфраструктуры. Эти преимущества не закрывают клю-




Рисунок 2.2 --- Покрытие уровней таксономии Блума по категориям документов: одношаговая LLM-конфигурация (B2)




Рисунок 2.3 --- Частота покрытия уровней таксономии Блума в корпусе (n=19): одношаговая LLM-конфигурация (B2)

чевую задачу исследования.

Во-первых, среднее покрытие уровней таксономии Блума составляет лишь 61.4 %, порог 70 % достигается только в 21.1 % случаев. Во-вторых, по продуктивно-редакционным документам базовая конфигурация даёт устойчивый результат, для официальных нормативных документов покрытие падает до 38.9 %, что означает смещение к нижним когнитивным уровням запоминания и понимания. В-третьих, плотность ссылок на источник равна нулю: модель не даёт никакой явной привязки результата к источнику, поэтому одношаговая LLM-конфигурация (B2) не может считаться достаточной для нормативных и знаниево-критичных сценариев.

Время генерации по категориям документов представлено на рисунке ??.




Рисунок 2.4 --- Среднее время генерации структуры курса по категориям: одношаговая LLM-конфигурация (B2)

Именно этот набор ограничений и мотивирует переход от одношаговой LLM (B2) к ИИ-методисту (B4). Нужна архитектура со скоростью базовой линии, поиском по корпусу, проверкой фактов и более глубокой методической структурой.

2.3.2 Парная проверка одношаговой LLM (B2) и ИИ-методиста (B4) на одном корпусе

После стабилизации REST-контура ИИ-методиста выполнен парный прогон одношаговой LLM (B2) и ИИ-методиста (B4) на том же 19-документном корпусе. Для каждого документа создавался отдельный kb_slug B4 формата diploma-b4-001, в запуск передавался ровно один Markdown-файл, результат сопоставлялся с ранее измеренной строкой B2 для того же doc_id. Это устраняет риск некорректной агрегации средних из разных прогонов: итоговая метрика считается по формуле $\Delta_i = B4_i - B2_i$ для каждого документа.

Таблица 2.6 --- Парный прогон одношаговой LLM (B2) и ИИ-методиста (B4) на 19 документах

Метрика	Значение	Вывод
Среднее покрытие Блума B2	61.4 %	целевой порог не достигнут
Среднее покрытие Блума B4	83.3 %	B4 проходит порог $\geq 70\%$
Средняя парная дельта Блума	+21.9 п.п.	прирост считается по тем же документам
Документы с положительной дельтой	15 из 19	положительная дельта зафиксирована на большинстве корпуса
Привязка к источнику B4	100 %	B4 даёт проверяемую опору на источник
Знак качества B4	100 % «пройдено»	все B4-запуски готовы к проверке человеком

Самый заметный эффект получен на корпоративных регламентах: среднее покрытие Блума увеличилось с 38.9 % до 83.3 %, то есть на +44.4 п.п. Для продуктивно-редакционных документов дельта составила +9.5 п.п., для программ MIT OCW --- +13.8 п.п. Таким образом, B4 закрывает именно тот класс документов, где B2 давал самый слабый результат: нормативные и знаниево-критичные материалы, требующие явной привязки к источнику и проверки качества.

2.3.3 Оценочные наборы для RAG и проверки фактов

Парный прогон одношаговой LLM (B2) и ИИ-методиста (B4) закрывает основной технический разрыв между базовой конфигурацией и ИИ-методистом. Для более тонкой оценки RAG-компонента и проверки фактов использованы дополнительные наборы.

Таблица 2.7 --- Оценочные наборы текущего MVP

Артефакт	Объём	Назначение
Измеренный корпус одношаговой LLM (B2)	19	базовая и конвейерная подготовка курсов
Вопросно-ответные пары (qa_pairs.json)	30	оценка по схеме RAG: достоверность ответа, релевантность ответа, точность контекста и полнота контекста
Фактуальные утверждения (statements.json)	100	оценка точности, полноты и F1-меры для проверки фактов

Артефакты превращают работу из описательной архитектурной записки в экспериментально воспроизводимую постановку. На этих наборах выполнен детерминированный прогон лабораторной оценки: для оценки по схеме RAG получены достоверность ответа 0.335, релевантность ответа 0.239, точность контекста 0.567 и полнота контекста 0.335; для проверки фактов получены точность 0.600, полнота 0.900 и F1-мера 0.720. Высокая полнота выбрана сознательно: для методического ассистента опасен пропуск неподтверждённого утверждения. Лишний фрагмент можно отправить на ручную проверку. Следовательно, текущая лабораторная оценка подтверждает пригодность связки проверки фактов и RAG для консервативного контроля перед проверкой человеком. Доказательство полного качества поиска требует отдельного измерительного этапа. Для такого вывода требуется расширенный корпус, экспертная разметка релевантных контекстов и повторение замеров на открытых курсах разных жанров.

2.3.4 Сценарная экономика единицы продукта MVP на основе проверенного прогона

Помимо технических метрик, собрана сценарная оценка экономики единицы продукта. Это расчётная модель на основе текущей конфигурации

конвейера и внутренних допущений о цене привлечения и контрактной монетизации, без статуса подтверждённой рыночной выручки.

Таблица 2.8 --- Сценарная экономика единицы продукта текущего MVP на основе проверенного прогона

Показатель	Значение	Интерпретация
Прямая себестоимость генерации курса	75 руб.	инфраструктурная себестоимость курса в текущем конвейере
Отношение к стоимости подрядной разработки	0.05%	текущий MVP в модели существенно дешевле внешнего производства
LTV / CAC	10.0	при выбранных допущениях модель не выглядит заведомо убыточной
Срок окупаемости	2 мес.	возврат затрат возможен в коротком цикле продаж
Порог безубыточности	14 клиентов	ориентир для коммерческой стадии после MVP

Цифры подтверждают экономическую устойчивость выбранной архитектуры: после завершения парного прогона B4 система остаётся технически дешёвой в эксплуатации.

Одновременно эти значения не дают окончательного доказательства соответствия продукта рынку. В рамках ВКР коммерческий блок является сценарной моделью устойчивости без выводов о спросе, выручке или проверке на внешних закрытых данных.

2.3.5 Ограничения текущего этапа и план абляционного исследования

Проблема текущего этапа не в отсутствии B4-прогона: парный B2/B4-прогон на 19 документах выполнен, а результаты сохранены в `paired_b2_b4_experiment.json`. Далее нужно провести слепую экспертную оценку и абляционное исследование вклада отдельных узлов конвейера: автоматические метрики пока не заменяют эти проверки.

Эта граница задаёт интерпретацию результатов:

- текущие цифры главы 2 следует считать **автоматической парной проверкой одношаговой LLM (B2) и ИИ-методиста (B4)** с последующей экспертной педагогической экспертизой;
- гипотезы Н1--Н3 в данной работе проверяются в пределах внутреннего / открытого корпуса, парной проверки B2/B4 и лабораторной оценки;
- $n = 19$ является лабораторной проверкой MVP; сильный внешний вывод о качестве требует отдельной проверки на открытых курсах $n \geq 30$;
- линии ручной разработки (B1), AI-конструктора (B3) и слепой экспертной педагогической экспертизы остаются полезным расширением методики за пределами заявленного объёма доказательств текущей ВКР;
- абляционное исследование является направлением развития доказательной базы для отдельного измерения вклада поискового контура, проверки фактов и агентов проверки в итоговое качество.

Глава 2 фиксирует и достигнутые результаты, и текущую границу зрелости системы, определяя точку отсчёта для дальнейших экспериментов.

2.3.6 Финальная MVP-конфигурация

На основании проведённого отбора и измеренных результатов итоговая MVP-конфигурация ИИ-методиста строится на следующей конфигурации:

- **Локальное LLM-ядро:** Qwen через OpenAI-совместимую конечную точку Ollama;
- **Оркестратор:** LangGraph 1.x (StateGraph);
- **Контур поиска:** RAG-инструмент с параметрами `keyword_search`, `top_k=5`, `score_threshold=0.5` и таблица свидетельств;
- **Семантическое усиление:** граф знаний;
- **Состояние и результаты:** PostgreSQL-хранилище контрольных точек и результатов;
- **Контроль качества:** проверка фактов + верификация + знак качества;
- **План развития:** Qdrant/локальные векторные представления, FLUX, Silero, SAM и Backward Design после парной проверки основного B4-контура.

Конфигурация отвечает целям работы: локальное развёртывание, воспроизводимые эксперименты, приемлемая себестоимость, усиление поискового слоя и педагогической структуры относительно одношаговой базовой

конфигурации.

3 ТЕХНИЧЕСКАЯ РЕАЛИЗАЦИЯ

3.1 Архитектура системы

3.1.1 Контекстная диаграмма (C4 Level 1)

ИИ-методист реализован в продуктовом контуре платформы Adapstory, который объединяет сервис генерации курсов, RAG-поиск, граф знаний, ручную проверку и публикацию результата в LMS. На уровне системного контекста (C4 Level 1, приложение Г, раздел Г.1) участвуют следующие акторы и системы:

- **Разработчик курса / методист / HR-специалист** --- загружает исходные материалы, задаёт аудиторию и методологию, просматривает, корректирует и утверждает результат;
- **School UI и BFF School** --- веб-интерфейс и серверный слой для веб-клиента, через которые пользователь запускает генерацию, видит статус, происхождение результата, знак качества и результат;
- **AI Course Generator** --- FastAPI-микросервис, исполняющий LangGraph-конвейер подготовки курса;
- **RAG-контур** --- индексирует и ищет фрагменты исходных документов для генерации с опорой на источник;
- **Граф знаний** --- предоставляет понятия, связи компетенций и дополнительные контекстные факты;
- **Ollama / OpenAI-совместимая конечная точка LLM** --- обслуживает локальные модели семейства Qwen в тестовом контуре и контуре разработки env-dev;
- **PostgreSQL** --- хранит запуски, результаты, контрольные точки LangGraph и данные аудита / происхождения результата;
- **LMS Adapstory** --- принимает утверждённый курс после человеческого контроля качества.

3.1.2 Диаграмма контейнеров (C4 Level 2)

На уровне контейнеров (приложение Г, раздел Г.2) MVP состоит из следующих процессов:

- **AI Course Generator API** --- FastAPI-сервис с REST и MCP-

- инструментами; принимает запросы от BFF, создаёт запуск, отдаёт статус, результат, происхождение и команды проверки человеком;
- **Среда исполнения LangGraph** --- исполняет граф генерации, поддерживает точки прерывания и сохраняет состояние через PostgreSQL-хранилище контрольных точек;
 - **RAG-инструмент** --- выполняет загрузку, индексирование и поиск фрагментов источника; при недоступности поиска система переходит к ограниченному резервному фрагменту исходного текста и явно помечает снижение полноты доказательного контекста;
 - **MCP графа знаний** --- возвращает связанные компетенции и понятия, усиливая контекст структуры курса;
 - **Шлюз LLM** --- провайдер-агностичный слой вызова модели с повторными попытками, телеметрией токенов и стоимости и возможностью переключения между локальной и внешней конечной точкой;
 - **School BFF / пользовательский интерфейс** --- пользовательский контур проверки, публикации и отображения дипломных метрик.

3.1.3 Доменная модель

Доменная модель текущего MVP включает следующие ключевые сущности:

- **Запуск генерации курса** --- запуск генерации с арендатором и пользователем, выбранной методологией, статусом, стоимостью и временем выполнения;
- **Исходный документ и таблица свидетельств** --- нормализованное представление найденных фрагментов источника со стабильными `source_id` для ссылок;
- **Черновик структуры курса** --- методический черновик структуры курса: модули, уроки, цели обучения и Bloom-разметка;
- **Содержимое урока** --- черновой учебный блок со встроенными ссылками на источники;
- **Отчёт проверки** --- отчёт проверки фактов и финальной проверки, содержащий число утверждений, число подтверждённых утверждений и знак качества;
- **Запись происхождения результата** --- запись аудита с моделью, версией конвейера, набором контрольных правил, числом источников, телеметри-

ей токенов и стоимости и временем генерации;

- **Снимок дипломной проверки** --- машинно читаемый срез метрик H1--H3 для дипломной валидации.

3.2 Мультиагентная система (LangGraph)

3.2.1 Граф агентов

Граф агентов реализован через StateGraph из LangGraph [langgraph_docs_2025]. В текущей реализации используется шестиузловой конвейер, вдохновлённый подходом Фейнмана:

анализ источника → структура курса → подготовка контента → проверка фактов → педагогическая проверка → верификация

В граф встроены две точки участия человека:

- после узла структуры курса: методист утверждает или возвращает на доработку структуру курса до генерации полного контента;
- после узла верификации: методист видит знак качества, происхождение результата и блокирующие замечания перед публикацией.

Граф агентов представлен на рисунке ??.

3.2.2 Ноды конвейера

Конвейер включает шесть специализированных нод:

- 1) **Узел анализа источника** --- извлекает из RAG-контура релевантные фрагменты, строит таблицу свидетельств и помечает неполное покрытие источников; граф знаний подключается на следующем шаге для семантического усиления структуры курса;
- 2) **Узел структуры курса** --- формирует черновик структуры курса по методологии ADDIE, целевой аудитории и таблице свидетельств;
- 3) **Узел подготовки контента** --- пишет черновые уроки со встроенными ссылками на `source_id`;
- 4) **Узел проверки фактов** --- проверяет фактические утверждения относительно таблицы свидетельств и выделяет неподтверждённые утверждения;
- 5) **Узел педагогической проверки** --- оценивает педагогическую связность, покрытие Блума и соответствие методологическому контрольному списку;




Рисунок 3.1 --- C4-диаграмма графа агентов ИИ-методиста (шестиузловой LangGraph StateGraph)

- 6) **Узел верификации** --- алгоритмически считает долю подтверждённых утверждений и на её основе формирует значение знака качества: «пройдено» (PASS), «пройдено с замечаниями» (PASS_WITH_NOTES) или «не пройдено» (FAIL), собирает происхождение результата и снимок H1--H3.

3.2.3 Управление состоянием и участие человека в контуре

Состояние графа хранится в `CourseGenerationState`. Оно содержит входные параметры, исходные документы, таблицу свидетельств, черновик структуры, содержимое уроков, отчёты проверки фактов, педагогическую проверку, финальный отчёт, происхождение результата, телеметрию токенов и стоимости и обратную связь человека.

В контуре, приближённом к промышленному, граф компилируется с PostgreSQL-хранилищем контрольных точек. Это даёт три свойства, критичные для B2B-сценария:

- запуск можно возобновить после сбоя сервиса без потери промежуточных артефактов;
- проверка человеком не требует держать процесс в памяти;
- статус запуска, знак качества и происхождение результата доступны через API в виде воспроизводимого артефакта и текста в UI.

3.3 Ключевые конвейеры

3.3.1 Обработка источника и поиск

В текущем MVP контур обработки источника устроен так: индексация и поиск вынесены в RAG-инструмент, семантическое усиление структуры выполняется через граф знаний. Текущая production-реализация подключает этот контракт через Dify Retrieval API: используется `keyword_search`, возвращается до пяти фрагментов на запрос, минимальный порог релевантности равен 0.5, `reranking` отключён. Ключ и датасет выбираются из tenant-контекста через Vault. Qdrant остаётся допустимой векторной подсистемой в инфраструктурном профиле: для платформенного индекса методологических знаний задана коллекция `methodology_knowledge_v2`, hash-эмбединги, размерность 64 и тайм-аут 10 с.

Текущий поток обработки источника:

- 1) пользователь загружает документ через School UI / BFF;
- 2) RAG-контур создаёт или обновляет индекс источника;

- 3) узел анализа источника выполняет поиск фрагментов и строит таблицу свидетельств; если индекс временно недоступен, используется ограниченный резервный режим по фрагментам исходного текста;
- 4) граф знаний добавляет связанные компетенции и понятия на этапе проектирования структуры курса;
- 5) узлы LangGraph используют общий доказательный контекст с согласованными RAG-вызовами.

Последовательность компонентов показана на рисунке ??.




Рисунок 3.2 --- Контур обработки источника и сборки таблицы свидетельств

3.3.2 Подготовка черновика курса

Подготовка курса начинается после появления доказательного контекста. Сценарий взаимодействия компонентов представлен на рисунке ??.

В сценарии В4 система не передаёт весь документ в один запрос. Она работает поэтапно:

- выделяет и нумерует источники до генерации курса;
- проектирует структуру и передаёт её человеку на проверку;
- генерирует контент после утверждения структуры;
- проверяет утверждения и блокирует публикацию при низком качестве ссылочной привязки.

3.3.3 Знак качества, прослеживаемость и валидация гипотез диплома

Финальный узел верификации не вызывает LLM. В работе знак качества означает пороговый статус финальной верификации. Он рассчитывается по доле подтверждённых утверждений: отношению числа утверждений, подтверждённых таблицей свидетельств, к общему числу проверенных фактических утверждений:




Рисунок 3.3 --- Сценарий взаимодействия при генерации курса

$$= \frac{\text{доля подтверждённых утверждений}}{\text{число подтверждённых утверждений}} \cdot \frac{\text{общее число проверенных фактических утверждений}}{\text{общее число проверенных фактических утверждений}}.$$

По этой доле назначается значение знака качества:

- «пройдено» (PASS), если доля подтверждённых утверждений не ниже 90 %;
- «пройдено с замечаниями» (PASS_WITH_NOTES), если эта доля находится в диапазоне 70--90 %;
- «не пройдено» (FAIL), если доказательная база отсутствует или качество ниже порога.

В результате API отдаёт текст курса и набор проверочных артефактов: ссылки на источники, знак качества, происхождение блоков, стоимость и снимок дипломной проверки. Эти поля используются фронтowymi E2E-тестами и дипломным скриптом продуктовой валидации, что делает проверку Н1--Н3 воспроизводимой.

3.3.4 Компоненты плана развития

Мультимедиа-генерация (FLUX / Silero) не включается в статус завершённого MVP. Профили SAM / Backward Design и контур автоактуализации остаются инженерными заделами. Количественные результаты диплома сознательно опираются только на парный B2/B4 по ADDIE, лабораторную оценку, знак качества и привязку к источнику, чтобы не смешивать готовые измерения с планом развития.

3.4 Инфраструктура и развёртывание

3.4.1 Стенд для тестирования и промышленной эксплуатации

Для локальной проверки и проверки в контуре `env-dev` используется стенд на базе Docker Compose: `docker-compose.ai-methodist.yml` и файл переопределения `docker-compose.ai-methodist.env-dev.yml`. Он поднимает AI Course Generator, AI Methodist MCP-сервис, RAG-инструмент, граф знаний, Neo4j, PostgreSQL и Redis. В базовом compose-файле задана лёгкая локальная модель. Профиль `env-dev` исполь-

зует более сильный Qwen3:8b через OpenAI-совместимую конечную точку Ollama.

Для инфраструктурного развёртывания платформа сохраняет GitOps-подход: образ собирается CI/CD, значения deployment описываются в Helm/GitOps, ручные изменения в Kubernetes не используются для доставки функциональности.

3.4.2 Наблюдаемость и проверяемость

В сервисе используются OpenTelemetry-трассы вокруг узлов LangGraph и Prometheus-счётчик распределения знака качества. Отдельные инструкции фиксируют быструю проверку контура `env-dev`, Playwright-проверку с опорой на граф знаний и матрицу LLM. В рамках ВКР результат генерации подтверждается набором машиночитаемых артефактов:

- статус запуска и финальный JSON результата;
- знак качества и происхождение результата;
- снимок проверки дипломных метрик;
- сводка Playwright и результаты контрольных прогонов;
- отчёт продуктовой проверки по Н1--Н3.

4 ВАЛИДАЦИЯ, ИМПАКТ И БИЗНЕС-ОЦЕНКА

4.1 Протокол валидации

4.1.1 Автоматизированная оценка

Качество выходных артефактов оценивается автоматически в трёх измерениях:

- 1) **Ragas-метрики** (глава 2): достоверность относительно источника (faithfulness), релевантность ответа (answer relevancy), точность контекста (context precision);
- 2) **Покрытие уровней таксономии Блума**: доля уровней таксономии Блума, покрытых в наборе учебных целей курса; целевой показатель --- $\geq 70\%$;
- 3) **Структурное качество**: полнота (наличие всех обязательных элементов методологии), согласованность учебных целей с содержанием, BLEU/ROUGE относительно эталонов B1.

4.1.2 Критерии контроля качества

Для ручного контроля качества результата подготовлен набор критериев, совместимый с будущим контуром экспертной проверки в продукте, но в численные результаты ВКР включаются только воспроизводимые автоматизированные замеры текущего корпуса.

Набор критериев содержит 5 пунктов (шкала 1--5):

- соответствие целевой аудитории;
- логика и последовательность модулей;
- качество учебных целей (SMART);
- покрытие исходного материала;
- практическая применимость.

Итоговая оценка по этим критериям может использоваться при ручной проверке курса перед публикацией. В текущей работе она дополняет измеренные метрики покрытия Блума, привязки к источнику и проверки фактов. Статус завершённой слепой экспертной оценки ей не присваивается. Полные таблицы текущих оценочных артефактов приведены в приложении И.

4.1.3 Лабораторная апробация MVP

Помимо автоматизированных метрик выполнена лабораторная апробация MVP на контролируемом корпусе: внутренние продуктово-редакционные материалы, учебные регламенты и открытые программы MIT OCW. Проверялись воспроизводимые свойства результата: время, покрытие Блума, привязка к источнику, знак качества, проверка фактов и отображение доказательного слоя в интерфейсе. Такой дизайн соответствует задаче ВКР: подтвердить работоспособность продуктового MVP без привлечения закрытых внешних данных.

4.2 Сквозная верификация

4.2.1 Сценарий 1: Онбординг-курс (ADDIE)

Входной документ: продуктивное описание нового SaaS-инструмента, 8 страниц.

Ожидаемый результат: 6-модульный адаптационный курс с учебными целями для новых сотрудников; время подготовки первого методического черновика менее 30 минут.

Ход выполнения:

- 1) Пользователь загружает PDF в систему; запускается контур обработки документов.
- 2) После индексации иницируется узел структуры курса с методологией ADDIE.
- 3) После генерации структуры система приостанавливается для ручной проверки; пользователь одобряет структуру.
- 4) Узел подготовки контента генерирует тексты уроков; узел проверки фактов верифицирует утверждения.
- 5) Узел верификации формирует знак качества, происхождение результата и снимок дипломных метрик H1--H3.
- 6) После финальной проверки человеком курс может быть опубликован в LMS Adapstory.

Для сценария выполнен парный прогон B2/B4 на 19 документах. B2 показывает среднее время подготовки структуры 4.37 с и среднее покрытие Блума 61.4 %; привязка к источнику отсутствует. B4 в том же корпусе даёт среднее покрытие Блума 83.3 %, среднюю парную дельту +21.9 п.п., привязку

к источнику 100 % и значение знака качества «пройдено» в 19 из 19 запусков. Среднее техническое время В4 до готового результата составило 17.1 с при целевом пороге 30 минут.

4.2.2 Сценарий 2: Нормативный курс с проверкой фактов

Входной документ: корпоративный регламент информационной безопасности, 22 страницы.

Специфика: документ содержит точные числовые требования (сроки, пороги, санкции), критичные для корректного нормативного обучения.

Проверяется, что узел проверки фактов выявляет галлюцинации при конкретизации числовых значений. В парном прогоне В4 сформировал 19 отчётов проверки фактов и прошёл контроль привязки к источнику на 100 %. Для отдельного расчёта точности, полноты и F1-меры использован набор данных из 100 утверждений (`statements.json`). Детерминированная лабораторная оценка показала точность (precision) = 0.600, полноту (recall) = 0.900 и F1-меру = 0.720 для класса «обнаружено искажённое утверждение».

4.2.3 Сценарий 3: автоматическое обновление при изменении источника

Условие: в исходный документ сценария 1 внесены изменения (обновлена функциональность продукта, 3 новых раздела).

В кодовой базе предусмотрен детерминированный проверочный сценарий для выявления устаревших уроков и регенерации затронутых разделов без полной пересборки курса. В доказательной базе данной ВКР этот сценарий подтверждает инженерную расширяемость; количественные выводы по Н1--Н3 опираются на парный В2/В4, лабораторную оценку и экономику единицы продукта.

4.3 Текущие результаты и проверка гипотез

4.3.1 Сводка фактически подтверждённых результатов

Результаты одношаговой LLM-конфигурации (В2) относительно целевых показателей визуализированы на рисунке ??.

Отдельно от чисел одношаговой LLM-конфигурации (В2) в платформе реализован и измерен машинно читаемый контур доказательств

Таблица 4.1 --- Текущий набор подтверждённых результатов исследования

Контур валидации	Текущее значение	Что это означает
Исследование клиентов	20 B2B-интервью	проблема подтверждена первичными данными рынка
Ключевой pain	70 %	большинство респондентов называют длительность разработки курса главным ограничением текущего процесса
Использование подрядчиков / внешних методистов	50 %	рынок платит за закрытие этой задачи внешним ресурсом
Готовность рассмотреть ИИ-инструмент	60 %	есть ранний сигнал интереса к решению; в данной ВКР он даёт рыночный контекст без доказательства качества MVP
Одношаговая LLM-конфигурация (B2): время подготовки структуры	4.37 с	одношаговая конфигурация очень быстра; задача качества и объяснимости требует отдельного контура
Одношаговая LLM-конфигурация (B2): среднее покрытие уровней Блума	61.4 %	текущая конфигурация не достигает целевого уровня $\geq 70\%$
Одношаговая LLM-конфигурация (B2): доля курсов с Блумом $\geq 70\%$	21.1 %	именно этот разрыв обосновывает необходимость агентного усиления
Одношаговая LLM-конфигурация (B2): структурная валидность	100 %	минимальный конвейер стабильно выдаёт формально корректную структуру курса
ИИ-методист (B4): среднее покрытие уровней Блума	83.3 %	ИИ-методист проходит целевой порог $\geq 70\%$ на том же корпусе
ИИ-методист (B4): средняя дельта к одношаговой LLM (B2)	+21.9 п.п.	прирост считается построчно для каждой пары doc_i
ИИ-методист (B4): привязка к источнику / знак качества	100 % / 100 % «пройдено»	все 19 B4-запусков имеют проверяемую опору на источник и готовы к проверке человеком
Оценочные наборы	30 вопросно-ответных пар, 100 утверждений	база для следующей волны RAG-оценки и оценки проверки фактов подготовлена
Сценарная экономика единицы продукта	75 руб./курс	инфраструктурная себестоимость выглядит низкой даже до завершения полного оценочного цикла B4
Отношение к подрядной разработке	0.05 %	расчётная себестоимость сохраняет большой запас для unit-экономики курса
LTV / SAC, срок окупаемости, безубыточность	10.0; 2 мес.; 14 клиентов	сценарная модель выглядит экономически осмысленной; требуется подтверждения реальными продажами




Рисунок 4.1 --- Результаты одношаговой LLM-конфигурации (B2) и целевые показатели

ИИ-методиста (B4): входные данные результата и статуса содержат ссылки на источники, знак качества, происхождение блоков, стоимость и снимок дипломной проверки. Эти поля покрыты фронт-вым E2E-сценарием отображения дипломных метрик и используются скриптами `run_ai_methodist_product_validation.py` и `run_paired_b2_b4_experiment.py`. Поэтому H2 проверяется архитектурным описанием и парной таблицей на том же 19-документном корпусе.

4.3.2 Проверка гипотез H1--H3

H1 (продуктовая). «Мультиагентный конвейер должен готовить первый методический черновик курса за 30 минут или быстрее при сохранении покрытия уровней таксономии Блума $\geq 70\%$.»

Гипотеза подтверждена в лабораторном продуктовом контуре: B4 подготовил результат в среднем за 17.1 с, дал среднее покрытие Блума 83.3 % и получил значение знака качества «пройдено» во всех 19 запусках. Это закрывает заявленный в работе критерий «первый проверяемый черновик до 30 минут» на контролируемом корпусе. **Гипотеза H1 подтверждена на из-**

измеренном корпусе ВКР.

Н2 (техническая). «Мультиагентная архитектура обеспечивает прирост качества структуры в парной проверке с одношаговой базовой конфигурацией на той же LLM.»

В парном прогоне В4 повышает среднее покрытие Блума с 61.4 % до 83.3 %, даёт среднюю строковую дельту +21.9 п.п. и добавляет привязку к источнику 100 % там, где В2 имеет 0 % ссылочной привязки. Максимальный прирост получен на корпоративных регламентах: +44.4 п.п. к покрытию Блума. **Гипотеза Н2 эмпирически поддержана автоматическим парным прогоном; дополнительно выполнена детерминированная проверка фактов по схеме RAG.**

Н3 (бизнесовая). «Себестоимость подготовки курса $\leq 1\%$ от стоимости ручной разработки силами внешнего подрядчика.»

В сценарной финансовой модели себестоимость подготовки курса составляет 75 руб., что эквивалентно примерно 0.05 % от ориентировочной стоимости ручной разработки курса силами внешнего подрядчика. Сценарная модель подтверждает экономическую устойчивость архитектуры текущего MVP. Доказательство рынка требует коммерческих данных. **Гипотеза Н3 поддержана сценарной экономикой единицы продукта текущего MVP.**

4.3.3 Производительность

Подтверждённые операционные показатели:

- среднее время одношаговой LLM-конфигурации (В2) на измеренном корпусе из 19 документов --- 4.37 с на генерацию структуры курса;
- среднее техническое время В4 в парном прогоне --- 17.1 с до готового результата со знаком качества;
- среднее число модулей --- 3, среднее число уроков --- 6.2;
- доля структурно валидных результатов --- 100 %.

Для долгосрочной эксплуатации в сервисе предусмотрены OpenTelemetry-трассы по узлам LangGraph и машиночитаемое происхождение результата. В рамках ВКР операционный вывод ограничен end-to-end временем запуска, поскольку именно оно напрямую связано с Н1.

4.3.4 Точность проверки фактов

Синтетический набор данных из 100 утверждений (50 корректных, 50 намеренно искажённых) позволяет воспроизводимо рассчитать точность, полноту и F1-меру. Детерминированная лабораторная оценка дала: точность (precision) = 0.600, полноту (recall) = 0.900 и F1-меру = 0.720. В MVP приоритет отдан полноте: подозрительные утверждения нужно отправить на проверку человеком, не пропуская фактическую ошибку в нормативном или учебном материале. Недостаточная точность и слабые значения по схеме RAG не позволяют выдавать этот результат за доказанное качество поиска. Корректная интерпретация: RAG-контур --- консервативный контроль перед проверкой человеком. Качество поиска требует расширения корпуса и экспертной разметки.

4.4 Ограничения исследования и угрозы валидности

Ниже перечислены ограничения исследования и угрозы внутренней и внешней валидности [wohlin_experimentation_2012], существенные для интерпретации результатов.

4.4.1 Ограничения тестового набора данных

Ограниченный объём измеренного корпуса ($n = 19$). Ядровой корпус содержит 19 документов, что ограничивает статистическую мощность проверки. При размере эффекта $d = 0.5$ (средний) и $\alpha = 0.05$ мощность критерия Вилкоксона для такой выборки остаётся ограниченной и не гарантирует надёжной проверки тонких различий между конфигурациями. Следовательно, результаты следует считать проверенными в пределах ограниченного лабораторного корпуса и требующими репликации на расширенном корпусе ($n \geq 30$). В терминах продуктовой доказательности $n = 19$ достаточен для лабораторной проверки MVP и инженерной готовности. Сильный внешний вывод о качестве должен быть вынесен в отдельную контрольную проверку на открытых курсах $n \geq 30$ с исходными JSON/CSV-артефактами, фиксированной шкалой и базовой методикой и явным перечнем ограничений.

Жанровая и языковая фокусировка измеренного ядра. Ядровой корпус сознательно собран смешанным срезом: русскоязычные продуктивно-регламентные документы и англоязычные учебные программы MIT OCW. Это повышает прикладную релевантность для B2B- и образовательных

сценариев. Прямой перенос количественных результатов на другие отрасли, регуляторные среды и типы исходных документов ограничен. USWDS, GOV.UK и Saylor Academy вынесены в зарубежный контрольный контур и в текущей версии используются только качественно, без полного количественного прогона.

4.4.2 Ограничения эталонного корпуса

В работе сознательно не заявляется внешний экспертный эталонный корпус. Выводы о качестве ограничены теми метриками, которые воспроизводятся из JSON-артефактов: покрытие Блума, привязка к источнику, знак качества, диагностика по схеме RAG и F1 проверки фактов. Такая рамка делает результаты честными и требует дополнительной ручной проверки для субъективной педагогической оценки. Отдельно ограничивается интерпретация метрик оценки RAG: они показывают работоспособность консервативного контроля перед проверкой человеком. Качество поиска требует расширенного корпуса и экспертной разметки релевантных фрагментов.

4.4.3 Ограничения пользовательской валидации

SUS / NPS, удержание и повторное использование не входят в измеряемые критерии данной ВКР. Работа оценивает инженерную и продуктово-лабораторную готовность MVP: может ли система на контролируемом корпусе подготовить проверяемый черновик курса с доказательным слоем и приемлемой экономикой единицы продукта.

4.4.4 Ограничения технологического стека

Зависимость от семейства Qwen. Основные эксперименты проведены на локальном Qwen-контуре. Результаты могут не воспроизводиться на других моделях (LLaMA 3.3, Mistral Large, GPT-4o), что ограничивает обобщаемость вывода об эффективности агентной архитектуры.

Ограниченный набор методологий в измерениях. В коде есть шаблоны ADDIE, SAM и Backward Design. Количественные результаты ВКР зафиксированы только для ADDIE. Это снижает риск смешать готовые измерения с ещё не сопоставленными режимами.

Авто-классификация уровней таксономии Блума. Уровни таксономии Блума определялись автоматически с помощью GPT-4o в роли judge-модели [mt_bench_2023]. Надёжность такой классификации на русскоязыч-

ном наборе учебных целей не валидирована независимо; это является угрозой валидности измерения покрытия уровней таксономии Блума.

4.4.5 Угрозы внешней валидности

Система разработана и количественно апробирована на русскоязычном текстовом контенте продуктового, нормативного и образовательного характера; зарубежный контур пока использован только качественно. Перенос результатов на мультимодальный контент, закрытые внутренние материалы организаций, другие отрасли и другой регуляторный контекст (SCORM, xAPI) требует дополнительных исследований.

4.4.6 Направления для устранения ограничений

Направления долгосрочного развития:

- 1) расширение российского ядра до 30--50 документов из 5+ различных сценариев;
- 2) запуск подготовленной контрольной проверки на открытых курсах $n \geq 30$ для проверки переносимости B2/B4-результатов и базовой ручной оценки по шкале;
- 3) независимая ручная проверка на обезличенном внутреннем или открытом корпусе и расчёт согласия разметки уровней таксономии Блума;
- 4) кросс-модельная оценка: воспроизведение экспериментов на LLaMA 3.3 70B и GPT-4o для проверки обобщаемости;
- 5) отдельный количественный прогон на зарубежном контрольном контуре после стабилизации российского базового ориентира;
- 6) продольная UX-аналитика после промышленной поставки продукта.

4.5 Бизнес-оценка и масштабирование

Бизнес-оценка в данной работе фиксирует проверяемые продуктовые предпосылки: проблему клиента, сценарную экономику единицы продукта, канву бизнес-модели и финансовую модель. Эти материалы подтверждают готовность инженерного MVP к проверке продуктовой гипотезы. Рыночная выручка проверяется отдельным коммерческим этапом.

4.5.1 Экономика единицы продукта

Себестоимость одного курса в текущем MVP складывается из LLM-времени, поисковых и KG-вызовов, хранения состояния

и опциональных API-вызовов. Сценарный расчёт собран в артефакте `unit_economics_results.json`.

-- GPU-время --- 75 руб./курс;

-- OpenAI API (опционально) --- 0 в базовой конфигурации;

-- **Итоговая себестоимость** --- ≈ 75 руб./курс.

Соотношение себестоимости ИИ-генерации и подрядной разработки показано на рисунке ??.




Рисунок 4.2 --- Unit-экономика ИИ-методиста: себестоимость vs рыночная стоимость

Метрики сценарной подписочной модели:

-- САС (стоимость привлечения клиента): около 30 000 руб.;

-- LTV (пожизненная ценность клиента): около 300 000 руб.;

-- LTV / САС: 10.0;

-- срок окупаемости: 2 мес.

4.5.2 Канва бизнес-модели (Lean Canvas)

Канва бизнес-модели ИИ-методиста по методике Lean Canvas [maurya_lean_canvas_2012] приведена в приложении К. Основные блоки:

Проблема: разработка корпоративного курса занимает много времени и часто выносится на подрядчиков; контент устаревает быстро, команда не всегда успевает его перерабатывать.

Решение: полуавтоматическая подготовка структуры и черновых материалов курса по загруженному документу; проактивные подсказки и ручная проверка в контуре; механизм последующего автоматического обновления.

Целевая аудитория: B2B-клиенты платформы Adapstory --- HR-отделы и учебные центры с > 50 сотрудников.

Труднокопируемое преимущество: методологическая вариативность (ADDIE/SAM/BD) и полный суверенитет данных за счёт локального LLM-

контура не воспроизводятся Coursebox AI и iSpring AI.

4.5.3 Финансовая модель (прогноз на 3 года)

Детальные расчёты приведены в приложении К. В качестве основы использован P&L-файл PNL – LMS AI.xlsx: он задаёт помесячные драйверы продаж, ФОТ, маркетинга, API-токенов, прочих расходов и налога УСН на 2026--2027 годы. Третий год в работе представлен сценарным продолжением: годовой темп декабря 2027 года без дополнительного ускорения продаж.

Итоговые показатели базового сценария:

- **2026**: выручка 76.0 млн руб., расходы и налог 49.0 млн руб., операционный денежный поток 26.9 млн руб.;
- **2027**: выручка 1 764.2 млн руб., расходы и налог 227.8 млн руб., операционный денежный поток 1 536.4 млн руб.;
- **2028E**: выручка по годовому темпу 4 044.1 млн руб., расходы и налог 446.1 млн руб., операционный денежный поток 3 598.0 млн руб.;
- **операционная безубыточность**: положительный месячный денежный поток достигается в августе 2026 года, накопительный поток становится положительным в ноябре 2026 года.

Динамика выручки и расходов представлена на рисунке ??.




Рисунок 4.3 --- Финансовый прогноз на 3 года по PNL-модели; 2028E --- годовой темп декабря 2027 года

4.5.4 Потенциал масштабирования

После валидации в российском B2B-сегменте выделены смежные рынки:

- **Международный EdTech**: потенциальный TAM $\approx$ \$51 млрд к 2030 году [edtech_market_report_2024];
- **Корпоративное обучение (CLO-сегмент)**: интеграция с Microsoft 365 + SharePoint для получения документов;
- **Государственное образование**: адаптация под ФГОС-регламент при поддержке профильных ведомств.

4.5.5 PESTLE-анализ при масштабировании

- **P (Political)**: регуляторные требования к использованию ИИ в государственном образовании; ограничения экспорта технологий;
- **E (Economic)**: зависимость от стоимости GPU-аренды; волатильность курсов валют при API-зависимости;
- **S (Social)**: опасения преподавателей и методистов относительно снижения роли человека; требования к прозрачности использования ИИ;
- **T (Technological)**: быстрое устаревание LLM; риск лицензионных изменений в моделях с открытыми весами;
- **L (Legal)**: 152-ФЗ [fz_152_2006] (персональные данные); авторское право на ИИ-сгенерированный контент (ГК РФ ч. IV);
- **E (Environmental)**: энергопотребление GPU-кластера; углеродный след при масштабировании.

4.5.6 Оценка рисков

Визуализация рисков на матрице вероятность/влияние приведена на рисунке ??.

4.5.7 Дорожная карта

6 месяцев: расширение парной проверки B4, абляционное исследование узлов RAG, проверки фактов и педагогической проверки, усиление точности проверки фактов без потери полноты, увеличение открытого и внутреннего корпуса измерений.

12 месяцев: переход от чернового MVP к производственно готовой версии, количественная проверка трёх методологий (ADDIE / SAM / Backward Design), структурированная пользовательская аналитика после коммерческо-

Таблица 4.2 --- Матрица рисков ИИ-методиста

Риск	Вероятность	Влияние	Митигация
Деградация качества новой версии LLM	Средняя	Высокое	Регрессионный Ragas-тест при каждом обновлении модели
Недоступность GPU-узла	Низкая	Высокое	circuit breaker + резервный переход на OpenAI API
Утечка данных через LLM-провайдера	Низкая	Критическое	локальное развёртывание; запрет облачных провайдеров для корпоративного сегмента
Неприятие разработчиками курсов	Средняя	Среднее	ручная проверка в контуре; прозрачность использования ИИ в интерфейсе
Изменение лицензии Qwen / поисковой подсистемы	Низкая	Высокое	шлюз LLM с провайдер-агностичным API; альтернативы: Llama 3.3




Рисунок 4.4 --- Матрица рисков ИИ-методиста

го запуска.

24 месяца: API для внешней интеграции, мультиязычность, масштабирование на смежные рынки корпоративного обучения.

Дорожная карта представлена на рисунке ??.




Рисунок 4.5 --- Дорожная карта развития ИИ-методиста

4.5.8 Интеллектуальная собственность

Программный комплекс подлежит регистрации в реестре программ для ЭВМ (ст. 1261 ГК РФ [gk_rf_part4]). Авторские права на сгенерирован-

ные учебные материалы принадлежат оператору платформы (ст. 1295 ГК РФ, служебное произведение).

4.6 Степень готовности и обратная связь от рынка

4.6.1 Текущий статус MVP

Реализованы: контур обработки документов, узел структуры курса (ADDIE), ручная проверка, узел подготовки контента с RAG, узел проверки фактов, узел верификации, знак качества, снимок проверки дипломных метрик и парный доказательный конвейер B2/B4.

Инженерные заделы: методологии SAM / Backward Design и механизм автоматического обновления. Мультимедийный слой (FLUX + Silero) остаётся за пределами MVP ВКР.

4.6.2 Рыночные сигналы

- Проведены 20 B2B-интервью в рамках исследования клиентов;
- 70 % респондентов называют время разработки главным ограничением;
- 50 % используют подрядчиков или внешних методистов;
- 60 % готовы рассмотреть ИИ-инструмент такого класса.

4.6.3 Соответствие решения проблеме

Текущие данные дают сильный сигнал наличия проблемы и раннего интереса к решению: проблема проверена через исследование клиентов, 60 % респондентов готовы рассмотреть ИИ-инструмент. В рамках ВКР соответствие решения проверяется работающим MVP и лабораторными продуктовыми метриками; внешние коммерческие договорённости вынесены за рамки оценки.

4.6.4 Качественная обратная связь

По результатам проблемных интервью выявлены три устойчивых сигнала:

- пользователи сначала хотят быстро получить *первый черновик* курса; финальный контент появляется после проверки и доработки;
- для регламентов и сценариев нормативного обучения критична привязка к источнику и возможность проверки фактов;
- для B2B-сегмента существенны суверенитет данных, локальное развёртывание и контроль с участием человека.

ЗАКЛЮЧЕНИЕ

Разработан интеллектуальный методический ассистент (ИИ-методист) --- микросервис образовательной платформы Adapstory, поддерживающий методиста и разработчика курса при подготовке учебных курсов на основе внутренних и открытых учебных документов с использованием LLM, поиска по корпусу и агентной оркестрации. Итогом является инженерный прототип и проверяемый продуктовый MVP с клиентскими интервью, сценарной экономикой, финансовой моделью и канвой бизнес-модели.

Итоги выполнения задач исследования. Проведены 20 глубинных B2B-интервью, подтвердивших устойчивую проблему трудоёмкой разработки корпоративных курсов. Для 70 % респондентов главным ограничением оказалась длительность разработки, 50 % прибегают к подрядчикам или внешним методистам. 60 % готовы рассмотреть ИИ-инструмент. На техническом уровне выбран и обоснован стек на основе LangGraph, RAG-контура, графа знаний, PostgreSQL-хранилища контрольных точек и результатов и локального Qwen-контура; реализованы контур обработки источников, шестиузловой агентный конвейер подготовки курса, слой источниковой привязки и прослеживаемости, знак качества и снимок дипломных метрик H1--H3.

Количественные результаты текущего этапа. Для лабораторного 19-документного прогона одношаговой LLM-конфигурации (B2) воспроизводимо измерен базовый слой: среднее время подготовки структуры --- 4.37 с, среднее покрытие уровней таксономии Блума --- 61.4 %, доля курсов с покрытием $\geq 70\%$ --- 21.1 %, структурная валидность --- 100 %. На том же корпусе выполнен парный прогон одношаговой LLM (B2) и ИИ-методиста (B4): B4 повысил среднее покрытие Блума до 83.3 %, дал среднюю строковую дельту +21.9 п.п., привязку к источнику 100 % и статус «пройдено» по знаку качества в 19 из 19 запусков. На 30 вопросно-ответных парах и 100 утверждениях выполнена детерминированная лабораторная оценка: точность контекста по схеме RAG = 0.567, точность проверки фактов = 0.600, полнота = 0.900, F1-мера = 0.720. Сценарная экономика единицы продукта даёт инфраструк-

турную себестоимость порядка 75 руб. за курс, $LTV / CAC = 10.0$, период окупаемости 2 месяца и точку безубыточности на уровне 14 клиентов. Метрики оценки RAG трактуются консервативно: контур --- контрольный барьер перед проверкой человеком. Качество поиска требует расширения корпуса и экспертной разметки, поэтому в работе не заявляется полное доказательство качества поиска. Аналогично, $n = 19$ является лабораторной проверкой текущего MVP: этого достаточно для проверки инженерной готовности одношаговой LLM (B2) и ИИ-методиста (B4). Широкий рыночный вывод о качестве требует отдельного измерения. Для такого вывода подготовлен следующий контрольный этап --- контрольная проверка на открытых курсах $n \geq 30$ с исходными JSON/CSV-артефактами и отдельной базовой методикой.

Статус гипотез. H1 поддержана парным прогоном: B4 укладывается в порог 30 минут и проходит целевой уровень Блума на контролируемом корпусе. H2 эмпирически поддержана на 19-документном корпусе: ИИ-методист (B4) улучшает покрытие Блума и привязку к источнику на тех же документах линии B2/B4. Дополнительная проверка фактов создаёт контрольный барьер перед проверкой человеком. Экспертное доказательство качества поиска остаётся отдельным этапом. H3 поддержана сценарной экономикой единицы продукта текущего MVP: расчётная себестоимость подготовки курса составляет около 75 руб. за курс.

Научный вклад и уникальность. Предложена и апробирована архитектура воспроизводимой валидации LLM-систем для поддержки проектирования учебных курсов на русском корпусе открытых и официальных документов с зарубежным контрольным контуром. В ИИ-методисте создание курса оформлено проверяемым конвейером: методическая структура строится до генерации уроков, доказательный контекст источников сохраняется, итоговый результат сопровождается знаком качества, проверкой фактов и прослеживаемостью происхождения. Архитектура объединяет методологическую рамку проектирования курса, агентную оркестрацию с сохраняемым состоянием и RAG-контур. Сформирован воспроизводимый набор артефактов для дальнейшей оценки: корпус документов, оценочные артефакты для RAG и проверки фактов, сценарная бизнес-модель и протокол внутренней и открытой апробации. Отдельно выделены тяжелокопируемые конкурентные преимущества решения: привязка к источнику, происхождение ре-

зультата, знак качества, проверка фактов, контрольные точки с участием человека и парная цепочка артефактов B2/B4. Эти свойства подтверждают уникальность через проверяемые механизмы, без декларации об использовании ИИ.

Практическая значимость. ИИ-методист представляет собой рабочий MVP с контуром обработки источников, подготовкой структуры курса, проверкой с участием человека, слоем источниковой привязки и прослеживаемости, знаком качества и подготовленной основой для контентной и фактической валидации. Система доведена до состояния проверяемого продуктового MVP: основные результаты воспроизводятся из JSON-артефактов. Отдельный контроль готовности защищает текст диплома от несогласованных утверждений. Долгосрочное развитие связано с расширением корпуса, кросс-модельной оценкой, контрольной проверкой на открытых курсах $n \geq 30$, аблацией узлов и промышленной UX-аналитикой после запуска.

ИСПОЛЬЗОВАНИЕ СИСТЕМ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА И ЛИЧНЫЙ ВКЛАД АВТОРА

В соответствии с требованиями ИТМО к ВКР настоящий раздел описывает использование ИИ-инструментов обучающимся в процессе подготовки работы и фиксирует личный вклад автора в разработку системы.

Использование ИИ-инструментов

В ходе подготовки работы автор использовал ИИ-инструменты для поиска, чернового структурирования и редакционной поддержки текста:

- **OpenAI Codex / ChatGPT-5.4** --- для структурирования отдельных разделов, поиска возможных формулировок и редакционной шлифовки черновиков при обязательной последующей ручной переработке;
- **Perplexity AI** --- для поиска актуальных рыночных данных, проверки дат публикации и навигации по открытым источникам;
- **Claude Code** --- для ускорения работы по созданию технических спецификаций на разработку фронтенд и бекенд части системы.

Все ИИ-сгенерированные фрагменты проходили ручную проверку автора: фактические утверждения перепроверялись по первоисточникам, финальные выводы и исследовательские формулировки принимались автором самостоятельно.

ИИ-инструменты не использовались для подмены первичных данных: интервью, выводы исследования клиентов, экспериментальные артефакты, расчёты и итоговые исследовательские интерпретации были собраны, проверены и оформлены автором.

Личный вклад автора

Автор настоящей работы лично:

- 1) **Провёл исследование предметной области:** собрал и проанализировал корпус из 45+ цитируемых академических и индустриальных источников по LLM, мультиагентным системам, RAG-подходам и автоматизации создания образовательного контента;
- 2) **Разработал архитектурное решение:** принял ключевые проектные ре-

- шения по выбору технологического стека (LangGraph, RAG-контур, граф знаний, PostgreSQL-хранилище контрольных точек и результатов, Qwen-контур), спроектировал шестиузловой граф агентов и выбранную архитектуру генерации с опорой на источник;
- 3) **Разработал шаблоны запросов:** подготовил системные шаблоны запросов для ADDIE, SAM и Backward Design с учётом требований таксономии Блума, особенностей русскоязычного ядрового корпуса и зарубежного контрольного контура;
 - 4) **Реализовал систему:** написал код LangGraph-графа агентов, шлюза LLM, FastAPI-приложения, слоя источниковой привязки и прослеживаемости, знака качества и снимка проверки дипломных метрик, настроил локальный контур проверки и контур разработки `env-dev` для ИИ-методиста;
 - 5) **Провёл эксперименты:** сформировал ядровой корпус документов, подготовил 30 вопросно-ответных пар и 100 фактуальных утверждений, провёл измерения базовой конфигурации, парный B2/B4-прогон, детерминированную проверку фактов по схеме RAG и сценарную оценку экономики единицы продукта;
 - 6) **Провёл исследование клиентов:** 20 глубинных B2B-интервью по методу Mom Test и систематизировал ключевые болевые точки рынка;
 - 7) **Подготовил доказательную базу ВКР:** оформил протокол внутренней и открытой апробации, машиночитаемые доказательные артефакты и автоматический контроль готовности, который проверяет согласованность текста диплома с кодом и результатами.

ПРИЛОЖЕНИЕ. А РУКОВОДСТВО ДЛЯ ИНТЕРВЬЮ С КЛИЕНТАМИ

В приложении представлено руководство для проведения глубоких B2B-интервью по методу Mom Test [**fitzpatrick_mom_test_2013**], использовавшееся при сборе первичных данных о проблеме (раздел 1.1 основного текста).

Контекст и цели интервью

Цель: проверить гипотезу о проблеме «Разработка образовательных курсов занимает слишком много времени и/или требует компетенций, которых нет у эксперта предметной области».

Целевая аудитория: HR-специалисты, L&D-менеджеры, методисты, тренеры в B2B-компаниях с > 50 сотрудников.

Формат: 30--45 минут, видеозвонок или очно.

Вопросы руководства

Блок 1. Разогрев и контекст:

- 1) Расскажите о своей роли. С какой частотой вам приходится создавать учебные материалы для сотрудников?
- 2) Какой последний курс или материал вы разрабатывали? Вспомните этот процесс --- с чего он начался?
- 3) Сколько времени ушло от идеи до готового материала?

Блок 2. Проблема:

- 4) Что в этом процессе было самым сложным или утомительным?
- 5) Были ли случаи, когда вы *не смогли* создать нужный материал из-за нехватки времени, ресурсов или экспертизы?
- 6) С какой частотой учебные материалы устаревают и требуют обновления? Каким образом вы сейчас с этим справляетесь?

Блок 3. Текущие решения:

- 7) Какие инструменты или сервисы вы ранее пробовали для автоматизации разработки курсов? Что не устроило?
- 8) Если бы вы могли потратить бюджет на решение этой проблемы --- на что

бы потратили?

Блок 4. Закрытие:

- 9) Есть ли коллеги, которых стоит поговорить на эту тему?
- 10) Можно ли мне прислать вам краткий обзор после дополнительных разговоров с ещё несколькими людьми?

Сводка ключевых выводов

По результатам 20 проведённых интервью устойчивее всего повторялись следующие сигналы:

Таблица А.1 --- Агрегированные выводы интервью с клиентами

Наблюдение	Значение	Интерпретация
Время разработки --- главное ограничение	70 %	проблема носит систем- ный характер
Используют подрядчи- ков / внешних методи- стов	50 %	рынок готов платить за снижение этой на- грузки
Готовы рассмотреть ИИ-инструмент	60 %	есть ранний сигнал инте- реса к решению
Формат исследования	20 интер- вью	глубинные В2В- интервью с клиентами по методу Mom Test

- Наибольшую ценность респонденты видят в ускорении подготовки первого черновика курса.
- Для нормативных и регламентных сценариев критична прослеживаемость к источнику и возможность ручной проверки.
- Для В2В-сегмента значимы суверенитет данных и возможность локального развёртывания.

ПРИЛОЖЕНИЕ. Б АРТЕФАКТЫ ДЕМОНСТРАЦИИ MVP

В приложении представлен сценарий демонстрации MVP на контролируемом корпусе работы. Демонстрация не требует закрытых внешних материалов: используются внутренние документы Adapstory и открытые учебные программы, описанные в приложении Ж.

Сценарий демонстрации

Текущий демонстрационный сценарий строится вокруг одного документа из ядрового корпуса. Пользователь видит последовательность шагов внутри продукта:

- 1) загрузка исходного документа;
- 2) выбор методологии генерации (ADDIE --- текущий базовый вариант);
- 3) получение и ручная проверка черновой структуры курса;
- 4) обсуждение зон ответственности пользователя и системы;
- 5) обсуждение, какие метрики качества пользователь считает достаточными для публикации результата.

Вопросы после демонстрации

- 1) Насколько результат соответствует тому, что вы ожидали?
- 2) Что бы вы изменили в сгенерированной структуре?
- 3) Готовы ли вы встроить такой инструмент в текущий процесс?
- 4) Какие доказательства качества вам нужны перед публикацией курса?
- 5) Какие ограничения по данным, модели и проверке человеком должны быть видны в интерфейсе?

Критерии успеха решенческого интервью

Таблица Б.1 --- Сигналы, фиксируемые на этапе решенческих интервью

Критерий	Позитивный сигнал	Что это подтверждает
Готовность встроить систему в текущий процесс	пользователь допускает частичную автоматизацию рутинных операций	наличие прикладной ценности
Доверие к доказательному слою	пользователь понимает привязку к источнику, происхождение результата и знак качества	переход от интереса к демонстрации к проверяемому рабочему сценарию
Обсуждение эксплуатационных ограничений	появляется запрос на локальный контур, роли проверки и журнал качества	рост зрелости продуктового требования
Экономическая логика	пользователь оценивает решение через стоимость подрядчика / внутреннего ресурса	наличие бизнес-контекста для дальнейшего MVP

ПРИЛОЖЕНИЕ. В ПРОТОКОЛ ВНУТРЕННЕЙ И ОТКРЫТОЙ АПРОБАЦИИ

В работе не используются закрытые внешние документы и коммерческие обязательства. Аprobация MVP проводится на контролируемом корпусе: внутренние продуктово-редакционные материалы Adapstory, учебные регламенты и открытые программы MIT OCW. Такой дизайн позволяет воспроизводимо измерять качество без доступа к закрытым данным третьих лиц.

Контрольный сценарий

- 1) выбрать документ из ядрового корпуса приложения Ж;
- 2) запустить одношаговую базовую конфигурацию B2 и сохранить структуру курса;
- 3) запустить B4 ИИ-методиста на том же документе;
- 4) сохранить JSON-артефакты со статусом, результатом и происхождением;
- 5) рассчитать покрытие Блума, привязку к источнику, знак качества, экономику единицы продукта и метрики проверки фактов;
- 6) проверить результат скриптами: `run_paired_b2_b4_experiment.py`, `run_ai_methodist_product_validation.py` и `check_thesis_excellent_readiness.py`.

Критерии принятия

- B4 генерируется на том же источнике, что и B2;
- среднее покрытие Блума B4 не ниже 70 %;
- привязка к источнику B4 не ниже 70 %;
- значение знака качества не ниже «пройдено с замечаниями» (PASS_WITH_NOTES);
- все численные результаты воспроизводятся из JSON-артефактов, без ручной правки таблиц.

ПРИЛОЖЕНИЕ. Г С4-ДЕКОМПОЗИЦИЯ АРХИТЕКТУРЫ

В приложении представлена текстовая С4-декомпозиция фактической архитектуры MVP ИИ-методиста, синхронизированная с текущими сервисами Adapstory: AI Course Generator, RAG-инструмент, граф знаний, School BFF и LMS.

Г.1 --- Системный контекст (C4 Level 1)

- **Разработчик курса / HR-специалист:** загружает документ, запускает подготовку черновика, проверяет структуру и знак качества;
- **School UI / BFF School:** маршрутизирует запросы веб-клиента и показывает статус, результат и происхождение;
- **AI Course Generator:** исполняет LangGraph-конвейер генерации и хранит артефакты запуска;
- **RAG-контур:** индексирует источник и возвращает фрагменты для таблицы свидетельств;
- **Граф знаний:** предоставляет связанные компетенции, понятия и предметные связи;
- **Конечная точка LLM:** локальная или OpenAI-совместимая конечная точка для моделей семейства Qwen;
- **LMS Adapstory:** принимает утверждённый курс и публикует его.

Г.2 --- Контейнеры (C4 Level 2)

Г.3 --- Компоненты (C4 Level 3)

- **Узел анализа источника:** строит таблицу свидетельств из RAG-фрагментов и резервного фрагмента исходного текста;
- **Узел структуры курса:** генерирует черновик структуры курса и использует граф знаний для семантического усиления структуры;
- **Узел подготовки контента:** формирует уроки со встроенными ссылками на источники;
- **Узел проверки фактов:** проверяет утверждения относительно источника;
- **Узел педагогической проверки:** оценивает методологическую связность и покрытие Блума;

Таблица Г.1 --- Контейнерная декомпозиция ИИ-методиста

Контейнер	Технология	Роль
AI Course Generator API	FastAPI	REST/MCP входная точка, создание запуска, статуса, результата и происхождения
Среда исполнения агентов	LangGraph	шестиузловой конвейер, прерывания, маршрутизация, цикл доработок
Хранилище контрольных точек и результатов	PostgreSQL	сохранение состояния, запусков, результатов и аудита
Инструмент RAG	Dify Retrieval API	индексация источника и поиск фрагментов
Граф знаний	Neo4j / MCP	компетенции, понятия и связи для контекста курса
School BFF / UI	Java BFF / пользовательский интерфейс	пользовательский контур проверки, публикации и отображения метрик

- **Узел верификации:** рассчитывает знак качества, происхождение результата и снимок проверки дипломных метрик;
- **Слой проверки человеком:** блокирует публикацию без подтверждения человека;
- **Exporter:** передаёт утверждённый курс в LMS Adapstory.

ПРИЛОЖЕНИЕ. Д СПЕЦИФИКАЦИЯ ГРАФА АГЕНТОВ LANGGRAPH

В приложении представлена текстовая спецификация фактического шестиузлового графа агентов ИИ-методиста: узлы, переходы, точки участия человека и контур отката к прежней топологии.

Д.1 --- Ноды графа

Таблица Д.1 --- Ноды графа агентов ИИ-методиста

Нода	Тип	Описание
анализ источника	агент	Поиск источников, таблица свидетельств, статус покрытия
структура курса	агент	Черновик структуры курса по методологии ADDIE и доказательному контексту
проверка структуры человеком	прерывание	Подтверждение или коррекция структуры курса
подготовка контента	агент	Черновики уроков со встроенными ссылками на источники
проверка фактов	агент	Проверка утверждений относительно таблицы свидетельств
педагогическая проверка	агент	Методологическая проверка, покрытие Блума, связность
верификатор	агент	Знак качества, подтверждённые утверждения, происхождение результата, снимок проверки дипломных метрик
проверка качества человеком	прерывание	Финальное решение человека перед публикацией

Д.2 --- Основные переходы

Д.3 --- Точки участия человека

- **НITL 1:** подтверждение структуры курса до генерации полного контента;
- **НITL 2:** финальное решение на основе знака качества, происхождения результата, ссылок и блокирующих замечаний;
- **Откат:** при отключении конвейера Feunman сервис может перейти к прежней четырёхузловой топологии; происхождение результата фиксирует фактически исполненный конвейер.

Таблица Д.2 --- Ключевые переходы в графе LangGraph

Откуда	Куда	Условие перехода
анализ источника	структура курса	таблица свидетельств построена или помечена неполной
структура курса	проверка структуры человеком	структура курса доступна для проверки
проверка структуры человеком	подготовка контента	структура утверждена пользователем
проверка структуры человеком	структура курса	структура отклонена и требует пересборки
подготовка контента	проверка фактов	уроки подготовлены и требуют верификации
проверка фактов	педагогическая проверка	отчёты проверки фактов сформированы
педагогическая проверка	подготовка контента	требуется доработка, счётчик доработок меньше лимита
педагогическая проверка	верификатор	курс прошёл методологическую проверку или исчерпан лимит доработок
верификатор	проверка качества человеком	знак качества и происхождение результата собраны
проверка качества человеком	завершение	человек принимает результат или фиксирует остановку

ПРИЛОЖЕНИЕ. Е ШАБЛОНЫ ЗАПРОСОВ ADDIE / SAM / BACKWARD DESIGN

В приложении представлены черновые системные запросы агента CourseStructureAgent для трёх поддерживаемых методологических режимов. Эти запросы задают управляемые рамки для дальнейшей настройки.

Е.1 --- Шаблон запроса ADDIE

[SYSTEM]

Ты --- эксперт по методологии ADDIE разработки учебных курсов. Твоя задача: на основе предоставленного документа создать структуру курса, следуя фазам ADDIE.

Требования:

- каждый модуль должен содержать учебные цели по таксономии Блума;
- формат ответа --- строго JSON (CourseBlueprint);
- не придумывай факты, которых нет в документе;
- если данных недостаточно, явно помечай неопределённость.

[USER]

Документ: {{document_text}}

Целевая аудитория: {{audience_profile}}

Е.2 --- Шаблон запроса SAM

[SYSTEM]

Ты --- эксперт по Successive Approximation Model. Построй итеративную структуру курса, которую удобно быстро проверять и дорабатывать короткими циклами.

Требования:

- сначала предложи минимально жизнеспособную структуру курса;
- явно выделяй части, которые требуют ручной проверки;
- держи фокус на скорости и возможности быстрой итерации;
- формат ответа --- JSON (CourseBlueprint).

[USER]

Документ: {{document_text}}

Целевая аудитория: {{audience_profile}}

E.3 --- Шаблон запроса Backward Design

[SYSTEM]

Ты --- эксперт по Backward Design. Начинай проектирование курса с конечных результатов обучения. После этого выстраивай модули, оценивание и учебные активности назад от целей.

Требования:

- сначала сформулируй измеримые результаты обучения;
- для каждого результата укажи способ проверки;
- затем предложи модули и уроки, которые ведут к этим результатам;
- формат ответа --- JSON (CourseBlueprint).

[USER]

Документ: {{document_text}}

Целевая аудитория: {{audience_profile}}

ПРИЛОЖЕНИЕ. Ж ТЕСТОВЫЙ КОРПУС ДОКУМЕНТОВ

В приложении описан измеренный корпус, использованный в артефакте базового прогона одношаговой LLM-конфигурации (B2). Корпус содержит 19 документов в трёх категориях: продуктивно-редакционные документы, корпоративные регламенты и учебные программы Massachusetts Institute of Technology OpenCourseWare (MIT OCW).

Описание измеренного корпуса одношаговой LLM-конфигурации (B2)

Таблица Ж.1 --- Состав измеренного корпуса одношаговой LLM-конфигурации (B2)

Группа	Кол-во	Язык	Назначение в проверке
Продуктивно-редакционные документы	7	RU	Проверка генерации по брендбукам, редакционным правилам и продуктовым описаниям.
Корпоративные регламенты	6	RU	Проверка извлечения требований, ограничений и нормативных формулировок.
Учебные программы MIT OCW	6	EN	Проверка переноса структуры дисциплин и учебных результатов в курс.
Итого	19	RU/EN	Единый корпус для одношаговой LLM-конфигурации (B2).

Машиночитаемое описание прогона хранится в артефакте базового прогона. В него входят идентификаторы:

- описание продукта, брендовые правила VK, руководства по маскоту и мерчу, редакционные политики Сбер/HR;
- политика информационной безопасности, политика персональных данных, управление инцидентами, адаптация сотрудников, антикоррупционные правила и сводка регламентов;
- MIT OCW 14.01, 18.01, 6.0001, 6.042J, 8.01 и summary-файл.

MIT OCW включён в измеренное ядро как открытый англоязычный источник академических программ: он даёт проверяемые страницы курсов, дисциплинарную структуру и учебные результаты без закрытых договоров с

внешними партнёрами. Альтернативные открытые источники для расширения корпуса зафиксированы в контрольном манифесте приложения И; в текущем 19-документном замере они не смешивались с ядром, чтобы сохранить парное сравнение B2/B4 на одном и том же наборе документов.

Корпус является техническим базовым ориентиром для проверки одношаговой LLM-конфигурации (B2); окончательная экспертная разметка требует отдельного набора. Его задача --- воспроизводимо показать разрыв между скоростью одношаговой генерации и требованиями к методическому качеству с опорой на источник.

Оценочные артефакты текущей итерации

На текущем этапе полностью подготовлены:

- измеренный корпус одношаговой LLM-конфигурации (B2) из 19 документов;
- набор из 30 вопросно-ответных пар для RAG-оценки;
- набор из 100 утверждений для оценки проверки фактов.

Парный прогон одношаговой LLM (B2) и ИИ-методиста (B4) выполнен на том же наборе документов: для каждого `doc_i` сохранены `B2_result_i`, `B4_result_i`, отдельный `kb_slug` B4 и строковая дельта покрытия Блума и привязки к источнику. Сводка и исходные REST-артефакты приведены в приложении И и файле `paired_b2_b4_experiment.json`. Дополнительно выполнена детерминированная лабораторная оценка: `evaluation_lab/ai_methodist_evaluation_lab_latest.json` фиксирует метрики по схеме RAG на 30 вопросно-ответных парах и точность, полноту и F1-меру проверки фактов на 100 утверждениях.

ПРИЛОЖЕНИЕ. И ОЦЕНОЧНЫЕ АРТЕФАКТЫ И ТЕКУЩИЕ РЕЗУЛЬТАТЫ

В приложении собраны подготовленные и измеренные артефакты валидации текущей редакции диплома. Главный технический артефакт текущей версии --- парный прогон одношаговой LLM (B2) и ИИ-методиста (B4) на одном и том же 19-документном корпусе. Этот прогон является лабораторной проверкой MVP: он показывает готовность контура одношаговой LLM (B2) и ИИ-методиста (B4) на контролируемом корпусе. Широкий рыночный вывод о качестве требует отдельного контроля. Для такого вывода подготовлена отдельная контрольная проверка на открытых курсах $n \geq 30$.

И.1 --- Агрегированные результаты одношаговой LLM-конфигурации (B2)

Таблица И.1 --- Агрегированные результаты лабораторного прогона одношаговой LLM-конфигурации (B2)

Срез корпуса	n	Покры- тие, %	Доля $\geq$ 70%
Все документы	19	61.4	21.1%
Продуктивно- редакционные до- кументы	7	73.8	28.6%
Корпоративные ре- гламенты	6	38.9	0%
Учебные программы MIT OCW	6	69.5	33.3%

Эти значения относятся к одношаговой LLM-конфигурации (B2) из артефакта базового прогона и служат техническим ориентир MVP. Для проверки вклада ИИ-методиста поверх этого базового ориентира выполнен парный прогон одношаговой LLM (B2) и ИИ-методиста (B4): для каждого документа doc_i сопоставлялись $B2_result_i$ и $B4_result_i$, итоговая дельта считалась по строкам с сохранением парной природы измерения.

И.2 --- Парный прогон одношаговой LLM (B2) и ИИ-методиста (B4)

В артефакте `paired_b2_b4_experiment.json` сохранены 19 пар результатов. Для каждого документа создавался отдельный `kb_slug` формата `diploma-b4-001`, `diploma-b4-002`, ..., `diploma-b4-019`; в B4 передавался ровно один исходный Markdown-документ. Исходные доказательства сохранялись в каталоге `paired_b2_b4_runs/diploma-b4-XXX/`.

Таблица И.2 --- Сводка парного прогона одношаговой LLM (B2) и ИИ-методиста (B4) на одном корпусе

Метрика	Значение	Интерпретация
Число пар документов	19	каждая строка содержит один документ и две линии прогона: B2 и B4
Среднее покрытие Блума одношаговой LLM (B2)	61.4 %	целевой порог не достигнут
Среднее покрытие Блума ИИ-методиста (B4)	83.3 %	B4 проходит целевой порог $\geq 70\%$
Средняя парная дельта Блума	+21.9 п.п.	дельта считается по каждому документу
Документы с положительной дельтой Блума	15 из 19	эффект наблюдается на большинстве корпуса
Привязка к источнику B4	100 %	все B4-запуски прошли контроль H2 по привязке к источнику
Знак качества B4	100 % «пройденно»	19 из 19 запусков готовы к проверке человеком

И.3 --- Подготовленные оценочные артефакты

И.4 --- Детерминированная проверка по схеме RAG и фактологическая проверка

Скрипт `benchmarks.evaluation_lab` выполнен в детерминированном режиме `deterministic_lexical`. Он не вызывает внешние

Таблица И.3 --- Парная дельта Блума по категориям корпуса

Категория	<i>n</i>	B2, %	B4, %	Дельта
Продуктивно-редакционные документы	7	73.8	83.3	+9.5 п.п.
Корпоративные регламенты	6	38.9	83.3	+44.4 п.п.
Учебные программы MIT OCW	6	69.5	83.3	+13.8 п.п.

Таблица И.4 --- Оценочные наборы текущего MVP

Артефакт	Объём	Назначение
Измеренный корпус одношаговой LLM (B2)	19	подготовка курсов и базовая линия B2
Вопросно-ответные пары (qa_pairs.json)	30	оценка достоверности и релевантности ответа
Фактуальные утверждения (statements.json)	100	расчёт точности, полноты и F1-меры для проверки фактов
Парный прогон B2/B4	19 пар	проверка B4 на тех же документах с базовой линией B2
Лабораторная оценка	30 QA-пар + 100 утверждений	детерминированная проверка по схеме RAG и фактологическая проверка

LLM и поэтому пригоден для регрессионного контроля. На 30 вопросно-ответных парах получены метрики по схеме RAG: достоверность ответа (faithfulness) = 0.335, релевантность ответа (answer relevancy) = 0.239, точность контекста (context precision) = 0.567 и полнота контекста (context recall) = 0.335. Эти значения являются диагностическим сигналом и не обосновывают вывод о полном качестве поиска. В текущей ВКР контур оценки RAG --- консервативный контроль перед проверкой человеком: качество поиска требует расширения корпуса и экспертной разметки релевантных фрагментов.

На 100 фактуальных утверждениях контур проверки фактов дал: точность (precision) = 0.600, полноту (recall) = 0.900 и F1-меру = 0.720. Отдельный разбор ошибок выделяет сильную сторону модуля проверки: он хорошо выявляет подмену сущности, отрицание, временное искажение и большую часть числовых искажений. Часть корректных утверждений он ошибочно считает подозрительными. Это фиксирует текущий баланс рисков: система отдаёт приоритет дополнительной ручной проверке спорных случаев.

И.5 --- Машиночитаемые доказательные артефакты платформы

В текущей кодовой базе ИИ-методиста предусмотрены поля, необходимые для дипломной валидации:

- ссылки на источники и происхождение блоков --- ссылочная привязка уроков к источникам;
- знак качества --- пороговый статус финальной верификации: «пройдено» (PASS), «пройдено с замечаниями» (PASS_WITH_NOTES) или «не пройдено» (FAIL);
- стоимость и качество --- стоимость, модель, токены и объяснение компромиссов цены и качества;
- снимок дипломной проверки --- снимок метрик H1--H3, пригодный для сохранения в экспериментальный корпус.

Фронтальный E2E-тест дипломной валидации проверяет отображение этих полей в пользовательском контуре. Экспериментальные скрипты превращают JSON-артефакты в отчёт контроля по гипотезам диплома и парную таблицу B2/B4. Контроль готовности `check_thesis_excellent_readiness.py` дополнительно запрещает

возвращать в текст незавершённые утверждения про внешние коммерческие обещания, закрытые материалы третьих лиц или визуальные материалы в статусе измеренных результатов.

И.6 --- Подготовленная контрольная проверка на открытых курсах

Для расширения проверки за пределы 19-документной лабораторной проверки MVP подготовлен воспроизводимый манифест `open_course_benchmark_manifest.json` и CSV-версия `open_course_benchmark_manifest.csv`. Манифест содержит 39 открытых учебных документов из MIT OCW, OpenEdu, HuggingFace Learn и открыто доступных материалов каталогов курсов. Его статус --- `READY_FOR_MEASURED_BENCHMARK`: корпус готов к запуску измерений. Доказательным результатом по качеству он станет после отдельного измерительного прогона.

Правило этого контроля: широкий рыночный вывод о качестве ИИ-методиста заблокирован до измеренной проверки на открытых курсах $n \geq 30$ с линиями B2, B4, базовой ручной оценкой по шкале, исходными JSON/CSV-артефактами и отдельным разделом ограничений.

ПРИЛОЖЕНИЕ. К КАНВА БИЗНЕС-МОДЕЛИ И ФИНАНСОВАЯ МОДЕЛЬ

В приложении представлены канва бизнес-модели по методике Lean Canvas и сценарные расчёты финансовой модели ИИ-методиста (раздел 4.4 основного текста).

К.1 --- Канва бизнес-модели (Lean Canvas)

Канва бизнес-модели представлена в табличной форме.

Таблица К.1 --- Канва бизнес-модели ИИ-методиста

Проблема	Решение	Уникальное предложение
Создание 1 часа обучения может занимать 73--490 часов работы методиста; высокая стоимость подрядчиков; устаревание контента	Полуавтоматическая подготовка структуры и черновых материалов курса по загруженному документу, проактивные подсказки и ручная проверка в контуре, механизм последующей актуализации	Сочетание методологической вариативности, суверенитета данных (локальный LLM-контур) и глубокой интеграции в LMS-экосистему
Несправедливое преимущество	Ключевые метрики	Каналы
Переключаемые режимы ADDIE / SAM / BD; локальный LLM-контур; экосистема LMS Adapstory	Время до первого методического черновика; Покрывание уровней Блума; faithfulness; себестоимость курса	Прямые продажи B2B; продуктовые демо на открытом и внутреннем корпусе; EdTech-конференции и контент-маркетинг
Сегменты потребителей		Структура затрат / доходов
B2B: HR-отделы, L&D-команды, корпоративные университеты, учебные центры и EdTech-компании		Затраты: ФОТ команды, маркетинг, API-токены, прочие расходы. Доходы: B2B-подписка по тарифам 2 999 / 20 999 / 44 999 руб./мес.

Таблица К.2 --- Годовые показатели PNL-модели

Период	Выручка	Расходы и налог	Опер. денежный поток	Комментарий
2026	76.0 млн руб.	49.0 млн руб.	26.9 млн руб.	помесечный расчёт PNL-файла
2027	1 764.2 млн руб.	227.8 млн руб.	1 536.4 млн руб.	помесечный расчёт PNL-файла
2028E	4 044.1 млн руб.	446.1 млн руб.	3 598.0 млн руб.	годовой темп декабря 2027 года
Итого	5 884.2 млн руб.	722.9 млн руб.	5 161.4 млн руб.	сценарный горизонт 2026--2028E

Таблица К.3 --- Ключевые допущения PNL-модели

Блок модели	Допущение
Тарифы	2 999 / 20 999 / 44 999 руб. в месяц в зависимости от пакета продукта
Продажи	три сценария привлечения: органическое продвижение, поисковые запросы, маркетинговая стратегия и SEO
Отток	10 % активной базы в расчёте пользовательского потока
ФОТ	стартовый ФОТ 1.06 млн руб. в месяц с последующим ростом по сценарию
Маркетинг	базовый бюджет 300 тыс. руб. с ростом маркетинговой статьи по сценарию
Налоги	УСН 6 % от выручки; взносы от ФОТ учтены отдельной строкой

К.2 --- Сценарные финансовые показатели

К.3 --- Допущения модели

- исходный PNL-файл содержит детальный помесечный расчёт на 2026--2027 годы;
- 2028Е в таблице рассчитан по годовому темпу декабря 2027 года;
- модель носит сценарный характер и не заменяет данные будущих продаж;
- расчёт прежде всего подтверждает экономическую устойчивость выбранной архитектуры;
- коммерческие выводы не используются для доказательства качества MVP; качество подтверждается отдельными техническими замерами на внутреннем и открытом корпусе.

ПРИЛОЖЕНИЕ. Л МАТРИЦА ВОСПРОИЗВОДИМОСТИ MVP

В приложении зафиксировано, какие результаты MVP подтверждаются машинно воспроизводимыми артефактами. Перечисленные ниже JSON и Markdown-отчёты получены из экспериментальных скриптов и каталогов сырых запусков. На них опираются численные утверждения диплома.

Л.1 --- Источники доказательств

Л.2 --- Связь артефактов с критериями MVP

Л.3 --- Команды воспроизведения

Воспроизведение результатов отделено от пользовательского интерфейса. Для проверки численных утверждений используются следующие команды:

```
cd Диплом
python3 experiments/\
run_ai_methodist_product_validation.py
python3 experiments/\
run_paired_b2_b4_experiment.py
python3 experiments/\
check_thesis_excellent_readiness.py
```

Артефакты сырых запусков и агрегированные отчёты должны храниться вместе: если численное значение меняется в JSON-отчёте, соответствующая таблица в тексте диплома обновляется тем же изменением.

Таблица Л.1 --- Артефакты, подтверждающие результаты MVP

Утверждение	Артефакт	Что проверяется
В2 измерен на одном корпусе	агрегаты базовой конфигурации и продуктовой проверки из приложения И	$n = 19$, время, покрытие Блума, доля результатов, прошедших порог
В4 проверяется с В2 построчно	парный В2/В4-отчёт и строки сырых запусков из приложения И	19 пар документов, парная дельта, привязка к источнику, знак качества
Каждый В4-запуск сохраняет исходные доказательства	каталоги запусков diploma-b4-001--019	входные данные, статусы генерации, результат, ответы согласования, файл парной строки
Поисково-фактологический контур проверяется отдельно	отчёт лабораторной оценки из приложения И	30 вопросно-ответных пар, 100 утверждений, диагностика по схеме RAG и F1 проверки фактов
Контрольная проверка на открытых курсах запланирована следующим этапом	манифест JSON/CSV и протокол MD из экспериментального контура	$n = 39$ открытых учебных документов; манифест фиксирует следующий контроль без широкого рыночного вывода о качестве
Текст диплома защищён от устаревших утверждений	контроль готовности из экспериментального контура	отсутствие внешних коммерческих завышенных утверждений, старых метрик и незавершённых контрольных утверждений, включая запрет делать широкий рыночный вывод на базе $n = 19$

Таблица Л.2 --- Прослеживаемость между критериями MVP и результатами эксперимента

Критерий	Подтверждение	Ограничение
Быстрый первый черновик	В4: среднее время 17.1 с на 19-документном корпусе	лабораторная оценка без SLA промышленного контура
Методическая структура курса	В4: среднее покрытие Блума 83.3 %; В2: 61.4 %	оценка автоматическая; внешняя экспертная разметка вынесена в будущий протокол
Работа от источника	В4: привязка к источнику 100 %, значение знака качества «пройдено» в 19 из 19 запусков	метрика фиксирует наличие ссылочной привязки; методическая проверка остаётся отдельным этапом
Контроль по открытым курсам	следующий контрольный этап: проверка на открытых курсах $n \geq 30$	$n = 19$ является лабораторной проверкой MVP; сильный рыночный вывод требует отдельного измерения
Контроль фактических искажений	F1-мера проверки фактов = 0.720, полнота = 0.900	точность = 0.600 показывает консервативный контроль перед проверкой человеком, без доказательства полного качества поиска
Экономическая реализуемость	сценарная себестоимость порядка 75 руб. за курс	расчёт зависит от загрузки GPU, тарифов и каналов продаж